


Линейная регрессия

Как выбираются коэффициенты и что можно узнать из ошибок модели



На этой неделе разбираем, что происходит внутри `fit` у одной конкретной модели.

Задача регрессии

$$D = \{(x_i, y_i)\}_{i=1}^n, \quad x_i \in \mathcal{X}, \quad y_i \in \mathbb{R}$$

обучающая выборка

→

$$f : \mathcal{X} \rightarrow \mathbb{R}$$

$$\text{НОВЫЙ ОБЪЕКТ } x \longmapsto \hat{y} = f(x)$$

цена


спрос

время доставки

прочность

Целевая переменная числовая; модель выдаёт числовой прогноз для нового объекта.

Если признаков нет




Какое одно число **c** предсказывать всем объектам?

$$f_c(x) = c$$

$$RSS(c) = \sum_{i=1}^n (y_i - c)^2$$

Почему среднее — лучший постоянный прогноз



$$y_i - c = (y_i - \bar{y}) + (\bar{y} - c)$$

$$\sum_i (y_i - c)^2 = \sum_i (y_i - \bar{y})^2 + 2(\bar{y} - c) \sum_i (y_i - \bar{y}) + n(\bar{y} - c)^2$$

$$\sum_{i=1}^n (y_i - \bar{y}) = \sum_{i=1}^n y_i - n\bar{y} = 0$$


$$\sum_i (y_i - c)^2 = \sum_i (y_i - \bar{y})^2 + n(\bar{y} - c)^2$$

 $\implies$

$$\hat{c} = \bar{y}$$


Для квадратичной ошибки выборочное среднее — лучший постоянный прогноз.

Добавим один признак

 $x \in \mathbb{R}$ **какую прямую выбрать?**

Каждая прямая соответствует одному набору коэффициентов.

Семейство линейных моделей



$$f_{\beta}(x) = \beta_0 + \beta_1 x$$


β_0 — свободный член

β_1 — изменение прогноза при увеличении x на единицу

Единицы β_1 : «единицы y на единицу x ».

Пока β_0 и β_1 — произвольные параметры семейства.

После обучения: прогнозы и остатки




$$\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1)$$

$$\hat{y}_i = f_{\hat{\beta}}(x_i)$$

$$r_i = y_i - \hat{y}_i$$

- $r_i > 0$: прогноз ниже наблюдаемого значения
- $r_i < 0$: прогноз выше наблюдаемого значения

Критерий МНК



$$r_i(\beta_0, \beta_1) = y_i - \beta_0 - \beta_1 x_i$$

$$RSS(\beta_0, \beta_1) = \sum_{i=1}^n r_i(\beta_0, \beta_1)^2$$


$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} RSS(\beta_0, \beta_1)$$

МНК выбирает коэффициенты, для которых сумма квадратов остатков минимальна.


RSS как функция двух коэффициентов

$$RSS(\beta_0, \beta_1) = \sum_i (y_i - \beta_0 - \beta_1 x_i)^2$$

Поверхность RSS



Те же значения: линии уровня



Поверхность и линии уровня показывают одну выпуклую квадратичную функцию; отмеченная точка — решение МНК.

Условия первого порядка

$$\frac{\partial RSS}{\partial \beta_0} = -2 \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)$$

$$\frac{\partial RSS}{\partial \beta_1} = -2 \sum_{i=1}^n x_i (y_i - \beta_0 - \beta_1 x_i)$$

$$\begin{cases} \sum_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0, \\ \sum_i x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0. \end{cases}$$

В точке минимума обе частные производные равны нулю: получаем систему двух уравнений.

Сначала найдём свободный член

$$n\hat{\beta}_0 + \hat{\beta}_1 \sum_i x_i = \sum_i y_i$$

$$\hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$


$$\sum_i (x_i - \bar{x})^2 > 0$$

Если все $x_i = x_0$, данные определяют только число $\beta_0 + \beta_1 x_0$, но не разделяют свободный член и наклон.

Формула для наклона

$$\sum_i (x_i - \bar{x})(y_i - \bar{y}) = \hat{\beta}_1 \sum_i (x_i - \bar{x})^2$$

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}$$

числитель: совместное изменение x и y

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

знаменатель: вариация x

Численный пример: коэффициенты


$$x = (0, 1, 2)^\top, \quad y = (1, 2, 2)^\top$$

$$\bar{x} = 1 \qquad \bar{y} = \frac{5}{3}$$

$$\sum_i (x_i - \bar{x})^2 = 2 \qquad \sum_i (x_i - \bar{x})(y_i - \bar{y}) = 1$$

$$\hat{\beta}_1 = \frac{1}{2} \qquad \hat{\beta}_0 = \frac{7}{6}$$

$$\hat{f}(x) = \frac{7}{6} + \frac{1}{2}x$$




Численный пример: прогнозы и остатки

$$\hat{y} = \left(\frac{7}{6}, \frac{5}{3}, \frac{13}{6} \right)^T$$

$$r = y - \hat{y} = \left(-\frac{1}{6}, \frac{1}{3}, -\frac{1}{6} \right)^T$$

$$\sum_i r_i = 0$$



Формула дала коэффициенты, коэффициенты — прогнозы, прогнозы — остатки.

Следствия решения МНК

$$\hat{f}(\bar{x}) = \bar{y}$$

OLS-прямая проходит через точку $(\bar{x}, \bar{y})$.

$$\hat{\beta}_1 = \frac{s_{xy}}{s_x^2} = r_{xy} \frac{s_y}{s_x}$$

$$s_x^2 = \frac{1}{n-1} \sum_i (x_i - \bar{x})^2$$

$$s_y^2 = \frac{1}{n-1} \sum_i (y_i - \bar{y})^2$$

$$s_{xy} = \frac{1}{n-1} \sum_i (x_i - \bar{x})(y_i - \bar{y})$$

$$r_{xy} = \frac{s_{xy}}{s_x s_y}$$

- МНК минимизирует RSS.
- Наклон сравнивает совместное изменение x и y с вариацией x .
- При свободном члене сумма обучающих остатков равна нулю.

От таблицы к матрице X

объект	x_1	x_2
1	2.1	5.0
2	3.4	7.2
$\vdots$	$\vdots$	$\vdots$
n	4.8	9.1

 $\rightarrow$

$$X = \begin{pmatrix} 1 & x_{11} & x_{12} \\ 1 & x_{21} & x_{22} \\ \vdots & \vdots & \vdots \\ 1 & x_{n1} & x_{n2} \end{pmatrix}$$

строки — объекты

столбцы — признаки

единицы — свободный член

$X, \beta, X\beta, y$: что есть что

$$\underbrace{\begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix}}_{X \in \mathbb{R}^{n \times q}} \underbrace{\begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}}_{\beta \in \mathbb{R}^q} = \underbrace{\begin{pmatrix} (X\beta)_1 \\ \vdots \\ (X\beta)_n \end{pmatrix}}_{X\beta \in \mathbb{R}^n}$$

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$$

Произведение $X\beta$ содержит по одному прогнозу для каждого из n объектов.

МНК в матричной записи

$$r = y - X\beta$$


$$\|r\|_2^2 = \|y - X\beta\|_2^2 = \sum_i (y_i - X\beta_i)^2$$

$$\hat{\beta} \in \arg \min_{\beta} \|y - X\beta\|_2^2$$

Скалярная и матричная записи описывают один и тот же критерий МНК.

Как читать коэффициент β_j

$$\hat{y} = \beta_0 + \beta_1 x_1 + \dots + \beta_j x_j + \dots + \beta_p x_p$$



При фиксированных остальных признаках увеличение x_j на единицу меняет прогноз на β_j .

единицы у на единицу x_j

зависит от других признаков


не является автоматически причинным эффектом

Два факта линейной алгебры

$$\langle a, b \rangle = \sum_i a_i b_i$$

$$\|a\|_2^2 = \langle a, a \rangle$$

$$a \perp b \iff \langle a, b \rangle = 0$$



От n наблюдаемых значений к вектору y

$$y = \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} \in \mathbb{R}^n$$

координата i соответствует
объекту i

y — наблюдаемые значения
целевой переменной

$$\mathbf{1} = \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix} \in \mathbb{R}^n$$

n прогнозов модели тоже
образуют вектор в $\mathbb{R}^n$


Один набор координат можно рассматривать алгебраически как вектор и геометрически как точку.

Все постоянные прогнозы образуют прямую

$$c\mathbf{1} = \begin{pmatrix} c \\ \vdots \\ c \end{pmatrix}$$

$$L_0 = \{c\mathbf{1} : c \in \mathbb{R}\}$$

Меняя c , получаем все возможные прогнозы константной модели.
Геометрически это одна прямая в $\mathbb{R}^n$.



Средний прогноз как ортогональная проекция

$$RSS(c) = \|y - c\mathbf{1}\|_2^2$$


Поэтому минимизировать RSS — значит среди всех допустимых прогнозов вида $c\mathbf{1}$ найти ближайший к наблюдаемому вектору y .

$$r = y - \hat{y} = y - \hat{c}\mathbf{1}, \quad r \perp \mathbf{1}$$

Для ближайшей точки остаточный вектор перпендикулярен прямой допустимых прогнозов.

$$\langle y - \hat{c}\mathbf{1}, \mathbf{1} \rangle = 0 \implies \hat{c} = \frac{\langle y, \mathbf{1} \rangle}{\langle \mathbf{1}, \mathbf{1} \rangle} = \bar{y}$$

$$\hat{y} = \bar{y}\mathbf{1}$$



Добавляем один признак


$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$$

$$X\beta = \beta_0 \mathbf{1} + \beta_1 x$$

$$L_1 = \{\beta_0 \mathbf{1} + \beta_1 x : \beta_0, \beta_1 \in \mathbb{R}\}$$

Мы всё ещё находимся в $\mathbb{R}^n$: одна координата соответствует одному обучающему объекту.

Добавили направление x : если $\mathbf{1}$ и x линейно независимы, прямая допустимых прогнозов превращается в двумерную плоскость.



Коэффициенты и прогнозы живут в разных пространствах

$$\beta \in \mathbb{R}^q$$

пространство коэффициентов



$$X\beta \in \text{col}(X) \subseteq \mathbb{R}^n$$

пространство прогнозов

$\text{col}(X)$ — пространство всех линейных комбинаций столбцов X ; это множество всех допустимых векторов прогнозов $X\beta$.

Каждый столбец X задаёт одно направление изменения прогнозов.


МНК ищет ближайший допустимый прогноз

$$\hat{\beta} \in \arg \min_{\beta} \|y - X\beta\|_2^2$$

$$\hat{y} = X\hat{\beta} \in \text{col}(X)$$

$\hat{y}$ = ближайший к y допустимый прогноз

$$r = y - \hat{y}$$



Геометрически МНК — ортогональная проекция y на пространство столбцов X .

Численный пример: остаток ортогонален столбцам X

ПАРНЫЙ СЛУЧАЙ

$$X = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}$$

$$r = \begin{pmatrix} -1/6 \\ 1/3 \\ -1/6 \end{pmatrix}$$

$$\mathbf{1}^\top r = 0$$

$$-\frac{1}{6} + \frac{1}{3} - \frac{1}{6} = 0$$

$$x^\top r = 0$$

$$0 \cdot \left(-\frac{1}{6}\right) + 1 \cdot \frac{1}{3} + 2 \cdot \left(-\frac{1}{6}\right) = 0$$

Остаток ортогонален обоим столбцам X: вектору единиц и признаку x.

Обобщение на множественную регрессию

$$X = \begin{pmatrix} | & | & \cdots & | \\ X_{.1} & X_{.2} & \cdots & X_{.q} \\ | & | & \cdots & | \end{pmatrix}$$

$$X^{\top} r = \begin{pmatrix} \langle X_{.1}, r \rangle \\ \langle X_{.2}, r \rangle \\ \vdots \\ \langle X_{.q}, r \rangle \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$\boxed{X^{\top} r = 0}$$

Во множественной регрессии остаток ортогонален каждому столбцу X , следовательно, $r \perp \text{col}(X)$.

Нормальные уравнения

$$X^{\top} r = 0$$

$$X^{\top} (y - X\hat{\beta}) = 0$$

$$X^{\top} y - X^{\top} X\hat{\beta} = 0$$

$$X^{\top} X\hat{\beta} = X^{\top} y$$

Это те же условия оптимальности, что для β_0 и β_1 , записанные для произвольного числа признаков.

Геометрия МНК: итог

$$X\beta \in \text{col}(X)$$

$\hat{y}$ = ближайший к y допустимый прогноз

$$r = y - \hat{y} \perp \text{col}(X)$$

$$\boxed{X^\top r = 0}$$

Нормальные уравнения: $X^\top X \hat{\beta} = X^\top y$

Когда коэффициенты определены однозначно

$$\text{rank}(X) = q$$

столбцы X линейно независимы

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} y$$

При полном столбцовом ранге одному вектору прогнозов $X\beta$ соответствует один набор коэффициентов.

Формула полезна для теории; вычислительный способ обсудим отдельно.

Точная мультиколлинеарность: постановка

объект	x_1	x_2
1	1	2
2	3	6
3	5	10

$$x_2 = 2x_1$$

$$\beta_1 x_1 + \beta_2 x_2$$

$$\beta'_1 = \beta_1 - 2t, \quad \beta'_2 = \beta_2 + t$$

Изменится ли прогноз?


Разные коэффициенты — тот же прогноз

$$\begin{aligned}\beta'_1 x_1 + \beta'_2 x_2 &= (\beta_1 - 2t)x_1 + (\beta_2 + t)x_2 \\ &= (\beta_1 - 2t)x_1 + (\beta_2 + t)2x_1 \\ &= \beta_1 x_1 - 2tx_1 + 2\beta_2 x_1 + 2tx_1 \\ &= \beta_1 x_1 + \beta_2 x_2.\end{aligned}$$

Данные определяют прогнозы, но не позволяют однозначно разделить вклад зависимых столбцов.

$\text{rank}(X) < q \implies \hat{\beta}$ может быть неединственным

Приближённая мультиколлинеарность



	A	В после малого возмущения
$\hat{\beta}_1$	0.85	0.09
$\hat{\beta}_2$	0.98	1.36

RMSE между обучающими прогнозами

0.010

Коэффициенты меняются сильнее прогнозов

После малого возмущения данных коэффициенты изменились заметно, а прогнозы на обучающей выборке — намного меньше.

Стабильность прогнозов на наблюдавшихся комбинациях признаков не гарантирует такую же стабильность на новых комбинациях.

Точная и приближённая зависимость

	Точная зависимость	Почти зависимость
Столбцы X	линейно зависимы	почти линейно зависимы
Ранг	$\text{rank}(X) < q$	полный
Коэффициенты	могут быть неединственными	единственны, но чувствительны к небольшим изменениям данных
Прогнозы на наблюдавшихся данных	могут совпадать точно	часто меняются меньше коэффициентов

Мультиколлинеарность — точная или приближённая линейная зависимость столбцов матрицы признаков.

Формула и вычислительный алгоритм — разные вещи

$$\hat{\beta} = (X^{\top} X)^{-1} X^{\top} y$$

теоретическая формула при полном столбцовом ранге

В численном коде обычно не строят обратную матрицу $(X^{\top} X)^{-1}$ явно.

$$X = QR$$

QR-разложение сводит задачу к системе удобного вида.

$$X = U \Sigma V^{\top}$$

SVD помогает обнаружить потерю ранга и плохо определённые направления.

LinearRegression в scikit-learn

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)

model.intercept_
model.coef_

y_pred = model.predict(X_test)
```

`LinearRegression` — estimator scikit-learn.

`fit` оценивает параметры; `intercept_` и `coef_` хранят обученные коэффициенты.

`predict` применяет обученную модель к новым объектам.

При `fit_intercept=True` вручную добавлять столбец единиц в `X` не нужно.

Почему одного RSS мало

$$RSS = \sum_i (y_i - \hat{y}_i)^2$$

$$RSS = 12\,480$$

- зависит от количества объектов;
- измеряется в квадратах единиц целевой переменной;
- сам по себе не показывает, насколько модель лучше простой точки отсчёта.

MSE, RMSE и MAE

$$MSE = \frac{1}{m} \sum_i (y_i - \hat{y}_i)^2$$

квадраты единиц целевой
переменной

$$RMSE = \sqrt{\frac{1}{m} \sum_i (y_i - \hat{y}_i)^2}$$

единицы целевой переменной

$$MAE = \frac{1}{m} \sum_i |y_i - \hat{y}_i|$$

единицы целевой переменной

RMSE сильнее реагирует на отдельные крупные ошибки.

MAE учитывает абсолютный размер каждой ошибки линейно.

Одинаковый MAE, разный профиль ошибок

$$A = (2, 2, 2, 2)$$

$$B = (0, 0, 0, 8)$$

$$MAE_A = 2, \quad RMSE_A = 2$$

$$MAE_B = 2, \quad RMSE_B = 4$$

MAE и RMSE по-разному агрегируют один и тот же набор ошибок; выбор зависит от того, насколько существенны крупные отклонения.

R^2 на обучающей выборке OLS

$$TSS = \sum_i (y_i - \bar{y})^2$$

$$RSS = \sum_i (y_i - \hat{y}_i)^2$$

$$ESS = \sum_i (\hat{y}_i - \bar{y})^2$$

$$TSS = ESS + RSS$$

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

Для OLS со свободным членом на той же обучающей выборке R^2 можно интерпретировать как долю объяснённой выборочной вариации.

R^2 для готовых прогнозов

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

$\bar{y}$ — среднее `y_true` на оцениваемой выборке

```
from sklearn.metrics import r2_score  
r2_score(y_true, y_pred)
```

$R^2 = 1$: прогнозы идеальны.

$R^2 = 0$: тот же уровень квадратной ошибки, что у прогноза $\hat{y}_i = \bar{y}$ на этой выборке.

$R^2 < 0$: квадратная ошибка выше этой опорной вариации.

На тестовой выборке это метрика готовых прогнозов, а не геометрическое тождество OLS. Поэтому не говорим автоматически: «модель объяснила X% тестовой вариации».

Диагностический протокол

1. ДИАГНОСТИКА

метрика · остатки
· обнаружили структуру



2. ГИПОТЕЗА И ЭКСПЕРИМЕНТ

сформулировали гипотезу
· изменили X · переобучили




3. ПРОВЕРКА

повторили диагностику
· зафиксировали решение · test

$$r_i = y_i - \hat{y}_i$$

График остатков формулирует проверяемую гипотезу; сам по себе он её не доказывает.

Остатки против прогноза: есть ли систематическая структура?



Проблема вообще есть?


На краях остатки положительны: модель систематически занижает наблюдаемые значения целевой переменной.

В середине остатки отрицательны: модель систематически завышает наблюдаемые значения.

Одной линейной формы средней зависимости недостаточно.

Остатки против признака: с чем связана структура?

Обнаружили структуру → проверяем отдельные признаки.



С каким признаком связана проблема?

Остатки против x_j связывают обнаруженную структуру с конкретным признаком.

U-образный рисунок предлагает гипотезу о нелинейной форме средней зависимости по x_j .

Одна гипотеза: добавить x^2

до

$$f_1(x) = \beta_0 + \beta_1 x$$

$$X = \begin{pmatrix} 1 & x_1 & x_1^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix}$$




после

$$f_2(x) = \beta_0 + \beta_1 x + \beta_2 x^2$$

Модель нелинейна как функция исходного x , но остаётся линейной по коэффициентам β .

Переобучаем модель и повторяем ту же диагностику остатков.

Что изменилось после добавления x^2




Представление расширило семейство доступных функций.

Та же диагностика показывает, что U-структура уменьшилась.

Форму выбираем без использования тестовой выборки.


Экстраполяция: продолжения расходятся



Хорошее качество внутри наблюдаемого диапазона не обосновывает форму далёкой экстраполяции.

Представление признаков определяет и подгонку внутри данных, и способ продолжения модели за их пределами.

Непостоянный разброс остатков



При больших прогнозах вертикальный разброс остатков выше.

Такой рисунок может указывать на гетероскедастичность — неодинаковую условную дисперсию ошибки в разных областях данных.

Похожий рисунок может возникать и при неверно заданной форме средней зависимости; сначала проверяем спецификацию модели.

Диагностика: итог

- Метрика показывает общий размер ошибки, но не её структуру.
- Остатки против прогноза и отдельных признаков отвечают на разные диагностические вопросы.
- Повторяющийся рисунок в остатках формулирует гипотезу о представлении.
- Гипотезу проверяем на обучающей выборке, затем повторяем ту же диагностику.
- Новое представление может менять и качество внутри данных, и экстраполяцию.

Почему линейная регрессия остаётся полезной

Бейзлайн

Более сложная модель должна показать, чем она лучше.

Рабочая модель

Простая зависимость или удачное представление могут быть достаточны.

Инструмент исследования

Коэффициенты и остатки помогают предложить следующий эксперимент.

Качество прогнозов и интерпретация коэффициентов — связанные, но разные вопросы.

Единая схема недели

МОДЕЛЬ

$$X\beta$$

Признаки задают семейство допустимых прогнозов.

ОБУЧЕНИЕ

$$\hat{\beta} \in \arg \min_{\beta} \|y - X\beta\|_2^2$$

МНК выбирает прогноз с минимальной квадратной ошибкой.

ГЕОМЕТРИЯ И РАНГ

$$r = y - \hat{y}, \quad r \perp \text{col}(X)$$

Ранг определяет, насколько однозначно определены коэффициенты.

ПРОВЕРКА

метрики + остатки → гипотеза

Метрика отвечает, сколько мы ошибаемся; диагностика — как устроена ошибка и что проверить дальше.