


КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ · НЕДЕЛЯ 3

Функции потерь и градиентный спуск

Что минимизируем и как обучаем



Два вопроса после линейной регрессии

ПРОГНОЗЫ

$$\hat{y} = X\beta$$

Почему именно такой критерий ошибки?

ЗАДАЧА МНК

$$\hat{\beta} \in \arg \min_{\beta} \frac{1}{n} \|y - X\beta\|_2^2$$

Как искать параметры без специального способа решения?

Четыре компонента, которые важно различать

Модель

Какие прогнозы
можно представить.

Функция потерь

Как оценивается
ошибка одного
объекта.


Оптимизатор

Как ищутся
параметры.

Метрика качества

Как оценивается уже
обученная модель.

Остаток: ошибка со знаком



$$r_i = y_i - \hat{y}_i$$

$r_i > 0$ прогноз ниже наблюдаемого значения.

$r_i < 0$ прогноз выше наблюдаемого значения.

Остаток описывает ошибку со знаком, но ещё не определяет её цену.

Функция потерь: цена ошибки одного объекта

Функция потерь задаёт правило, по которому ошибка отдельного прогноза превращается в численную величину.

ОБЩАЯ ЗАПИСЬ

$$L_i(\theta) = L(y_i, \hat{y}_i)$$

$$r_i = y_i - \hat{y}_i$$

КВАДРАТИЧНАЯ ФУНКЦИЯ

$$L_{\text{sq}}(y_i, \hat{y}_i) = (y_i - \hat{y}_i)^2 = r_i^2$$

От функции потерь к эмпирическому риску

$$R_n(\theta) = \frac{1}{n} \sum_{i=1}^n L_i(\theta)$$

 L_i

функция потерь на объекте

 R_n

эмпирический риск

 R_n

целевая функция при обучении


$$\hat{\theta} \in \arg \min_{\theta} R_n(\theta)$$

$$RSS(\beta) = \sum_i (y_i - x_i^\top \beta)^2$$

$$MSE(\beta) = \frac{1}{n} RSS(\beta)$$

RSS и MSE достигают минимума при одних и тех же значениях параметров.

Путь от прогноза к цели обучения



Функция потерь оценивает один объект; эмпирический риск собирает цель обучения по всей выборке.

Целевая функция и метрика качества

ОБУЧЕНИЕ

$$R_{\text{train}}(\beta) = \frac{1}{n_{\text{train}}} \sum_{i \in \text{train}} L(y_i, f_{\beta}(x_i))$$

β — переменная оптимизации.

ОЦЕНИВАНИЕ

$$M_{\text{eval}} = M(y, \hat{y}(\hat{\beta}))$$

Оценённые параметры $\hat{\beta}$ уже зафиксированы.

Одна формула, например MSE, может быть целью обучения и метрикой: роль определяется местом в эксперименте.

Одна ошибка, разные правила оценки

$$r = y - \hat{y}$$

- 1 Ошибка 20 насколько хуже ошибки 10?
- 2 Как реагировать на редкие крупные остатки?
- 3 Нужна ли гладкость для выбранного метода оптимизации?

MSE: средняя квадратичная ошибка

MSE = Mean Squared Error


средняя квадратичная ошибка

$$L_{sq}(r) = r^2$$

$$MSE = \frac{1}{n} \sum_i r_i^2 = \frac{1}{n} RSS$$

$$10^2 = 100, \quad 20^2 = 400$$

Вдвое больший по модулю остаток даёт вчетверо больший вклад.



На графике квадратичная функция показана как $\frac{1}{2}r^2$ для сравнения формы; положительный множитель не меняет минимум.

MAE: средняя абсолютная ошибка


MAE = Mean Absolute Error

средняя абсолютная ошибка

$$L_{\text{abs}}(r) = |r|$$

$$MAE = \frac{1}{n} \sum_i |r_i|$$

Ошибка 20 ровно вдвое дороже ошибки 10.



На графике квадратичная функция показана как $\frac{1}{2}r^2$ для сравнения формы; положительный множитель не меняет минимум.

MAE среди постоянных прогнозов выбирает медиану

1, 2, 4, 5, 20

$$Q(c) = \sum_i |y_i - c|$$

$$Q(2) = 24, \quad Q(4) = 22, \quad Q(5) = 23$$

Минимум при $c=4$ — на медиане.

Пока справа от c точек больше, движение вправо уменьшает сумму расстояний. После медианы движение вправо уже увеличивает её.

MAE и излом в нуле

$$\frac{d|r|}{dr} = \begin{cases} -1, & r < 0, \\ 1, & r > 0. \end{cases}$$


В точке $r=0$ обычной производной нет.

Задача решается, но нужен метод, умеющий работать с негладкой целевой функцией.

Huber: зачем нужна третья форма

Хотим сохранить квадратичную форму для обычных ошибок, но ограничить влияние отдельных больших остатков.

- 1 около нуля — квадратичный режим;
- 2 в хвостах — линейный рост;
- 3 между режимами — гладкая склейка.



На графике квадратичная функция показана как $\frac{1}{2}r^2$ для сравнения формы; положительный множитель не меняет минимум.

Huber: формула и роль δ

$$L_{\delta}(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta, \\ \delta \left(|r| - \frac{1}{2}\delta \right), & |r| > \delta. \end{cases}$$

$$\delta = 2, r > 2 : \quad L_2(r) = 2(r - 1)$$

Меньшая δ : линейный режим начинается раньше.

Большая δ : квадратичный режим длится дольше.

δ измеряется в единицах остатка.

В $\pm\delta$ совпадают значение и наклон ветвей.

Одна модель, три целевые функции

$$\hat{y}_i = f_{\theta}(x_i)$$

Семейство прогнозов остаётся тем же.

MSE

$$R_{\text{MSE}}(\theta) = \frac{1}{n} \sum_i (y_i - f_{\theta}(x_i))^2$$

MAE

$$R_{\text{MAE}}(\theta) = \frac{1}{n} \sum_i |y_i - f_{\theta}(x_i)|$$


HUBER

$$R_{\text{Huber}}(\theta) = \frac{1}{n} \sum_i L_{\delta}(y_i - f_{\theta}(x_i))$$

Меняется цель обучения — обычно меняется и найденный набор параметров.

Производная показывает чувствительность к остатку

Производная показывает, как быстро меняется значение функции при небольшом изменении остатка



Квадратичная: $|L'(r)|$ растёт вместе с $|r|$.

MAE: вне нуля $|L'(r)|$ постоянно.



Huber: сначала $|L'(r)|$ растёт, после δ перестаёт расти.

Поэтому квадратичная функция всё сильнее реагирует на крупные остатки, а Huber ограничивает эту реакцию.

На первой панели: $L(r) = \frac{1}{2}r^2$, $L'(r) = r$.

Разные функции потерь по-разному реагируют на крупные остатки

Крупные остатки по-разному меняют обученную линейную модель



Разная целевая функция



разные коэффициенты.

Log-Cosh: ещё один гладкий робастный вариант



$$L(r) = \log \cosh r$$

около нуля: примерно $\frac{1}{2}r^2$;

в хвостах: примерно $|r| - \log 2$;

кривизна меняется плавно.

Log-Cosh и Huber: квадратичный центр и почти линейные хвосты



MAPE как метрика относительной ошибки

MAPE = Mean Absolute Percentage Error — средняя абсолютная процентная ошибка.

$$MAPE = \frac{1}{n} \sum_i \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Полезна, когда процентная ошибка содержательна, а положительные y не близки к нулю.

Ноль не допустим; малые $|y_i|$ получают огромный вес.

$$y = (200, 1000), \quad \hat{y} = (100, 900)$$

$$RMSE = 100$$

Относительные ошибки: 50% и 10%.

$$MAPE = 30\%$$

RMSE показывает абсолютный масштаб промаха; MAPE — его размер относительно фактического значения.

Зачем появился SMAPE

$$y = 100, \hat{y} = 50 \Rightarrow 50\%$$

$$y = 100, \hat{y} = 200 \Rightarrow 100\%$$

MAPE по-разному оценивает занижение и завышение в одинаковое число раз.

SMAPE = Symmetric Mean Absolute Percentage Error

$$SMAPE = \frac{1}{n} \sum_i \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

Симметрична при обмене факта и прогноза; для ненулевого знаменателя значения от 0 до 2.

Проблемы около нуля полностью не исчезают.

Три прикладных вопроса перед выбором функции потерь

Время доставки

Насколько критичны редкие крупные опоздания?

Если крупные промахи особенно дороги, важна скорость роста функции при больших $|r|$.

Спрос разного масштаба

Нужна абсолютная или относительная ошибка?

Если важна ошибка относительно уровня спроса, смотрим на относительные ошибки.

Складской запас

Одинакова ли цена недо- и перепрогноза?

Если недо- и перепрогноз имеют разную стоимость, нужна асимметричная функция потерь.

Кейс: дефицит дороже излишка

Сегодня выбираем запас $\hat{y}$, затем реализуется спрос y .

$$r = y - \hat{y}$$

$r > 0$: недопрогноз

Спрос выше запаса → часть спроса не обслужена → стоимость 4 за единицу.

$r < 0$: перепрогноз

Запас выше спроса → остаётся излишек → стоимость 1 за единицу.

Знак одного остатка теперь имеет разную прикладную цену.

Квантильная функция потерь: форма


ρ — традиционный символ; встречается название pinball loss.

$$\rho_{\tau}(r) = \tau \max(r, 0) + (1 - \tau) \max(-r, 0)$$

$$\rho_{\tau}(r) = \begin{cases} \tau r, & r \geq 0, \\ (\tau - 1)r, & r < 0. \end{cases}$$

$$R_{\tau}(\theta) = \frac{1}{n} \sum_i \rho_{\tau}(y_i - f_{\theta}(x_i))$$

$\tau > 0.5 \Rightarrow$ недопрогноз дороже



$$\tau = 0.5 \Rightarrow \rho_{0.5}(r) = \frac{1}{2}|r| \Rightarrow \rho_{0.5} \propto MAE$$

Символ «пропорционально» означает: минимум тот же, поскольку функции отличаются только положительным множителем.

Как стоимость ошибок задаёт τ

ПРИКЛАДНАЯ СТОИМОСТЬ

$$C(r) = 4 \max(r, 0) + \max(-r, 0)$$

КВАНТИЛЬНАЯ ФУНКЦИЯ

$$\rho_{\tau}(r) = \tau \max(r, 0) + (1 - \tau) \max(-r, 0)$$

Отношение наклонов должно совпасть с отношением стоимостей:

$$\frac{\tau}{1 - \tau} = \frac{4}{1} \Rightarrow \boxed{\tau = 0.8}$$

$$5\rho_{0.8}(r) = 4 \max(r, 0) + \max(-r, 0)$$

При линейной стоимости ошибок выбираем τ так, чтобы отношение наклонов двух ветвей совпало с отношением стоимостей недо- и перепрогноза.

Постоянный прогноз: разные критерии дают разные решения

40, 44, 46, 48, 49, 50, 52, 54, 57, 61, 66, 82

MSE

$$c_{\text{MSE}} = \bar{y} \approx 54.1$$

выбирает среднее

$P_T, \quad T = 0.8$

$$c_{0.8} = 61$$

выбирает 0.8-квантиль

0.8-квантиль — значение, ниже которого находится примерно 80% распределения спроса.

Более высокая цена дефицита сдвигает оптимальный постоянный прогноз вверх — от среднего к верхнему квантилю спроса.

Что мы уже поняли о функции потерь

Остаток описывает ошибку со знаком; функция потерь задаёт её цену для одного объекта.

Эмпирический риск агрегирует значения на train и становится целью обучения.

Форма функции задаёт чувствительность к крупным ошибкам, гладкость, масштаб и асимметрию.

Одна модель при разных функциях потерь может получить разные параметры.

Второй путь выбора функции потерь — вывести её из вероятностной модели данных.

Вероятностная модель регрессии

$$Y = f_{\theta}(X) + \varepsilon$$

 $f_{\theta}(X)$

систематическая часть зависимости

 ε

случайная вариативность



Систематическая часть задаёт положение условного распределения, а распределение случайной ошибки — характер отклонений вокруг него.

Формула Бернулли: вероятность результата

Бросаем одну и ту же монету $n = 10$ раз; вероятность орла в каждой броске равна p .


$$P(K = k \mid p) = \binom{n}{k} p^k (1 - p)^{n-k}$$

C_n^k : выбираем k бросков с орлом.

p^k : вероятность этих k орлов.

$(1-p)^{n-k}$: вероятность остальных исходов.

$n = 10, p = 0.7$: k меняется



Правдоподобие: результат уже получен

$$K = 7$$

$$\mathcal{L}(p; K = 7) = \binom{10}{7} p^7 (1 - p)^3$$

Данные фиксированы, p меняется.

Правдоподобие — функция параметра, а не распределение параметра.



Зачем максимизировать правдоподобие

MLE = Maximum Likelihood Estimation — метод максимального правдоподобия.

$$\hat{\theta}_{\text{MLE}} \in \arg \max_{\theta} \mathcal{L}(\theta; D)$$


р=0.2: семь орлов из десяти
мало правдоподобны.

р=0.7: такой результат правдоподобен.

Выбираем параметры, при которых наблюдаемые данные лучше согласуются с моделью.

Вероятность и правдоподобие: один экран

	Фиксируем	Меняется
Вероятность	параметр	результат
Likelihood	данные	параметр



Одна формула отвечает на два вопроса при разном выборе фиксированных величин.

Та же смена ролей в регрессии

ДО НАБЛЮДЕНИЯ ОТВЕТА

$$p_{\theta}(y \mid x)$$

x, θ фиксированы, Y случайна

Условная модель описывает возможные значения целевой переменной при данных признаках.

ПОСЛЕ НАБЛЮДЕНИЯ ОТВЕТА

$$p_{\theta}(y_i \mid x_i)$$

x_i, y_i фиксированы, θ меняется

То же выражение рассматриваем как функцию кандидата параметров.

Как у монеты: сначала параметры задают распределение возможных данных; после наблюдения данных сравниваем параметры.

В непрерывной регрессии используем условную плотность

$$Y \mid X = x_i$$

Условное распределение целевой переменной при фиксированных признаках объекта.

$$p_{\theta}(y \mid x_i)$$

Условная плотность возможных значений целевой переменной.

$$p_{\theta}(y_i \mid x_i)$$

После наблюдения конкретного y_i значение плотности в этой точке становится вкладом объекта в likelihood.

$$p_{\theta}(y \mid x_i) \geq 0, \quad \int_{-\infty}^{\infty} p_{\theta}(y \mid x_i) dy = 1$$

$$P(a \leq Y \leq b \mid X = x_i) = \int_a^b p_{\theta}(y \mid x_i) dy$$

Для непрерывного распределения вероятность отдельной точки равна нулю; значение плотности не является вероятностью и может превышать единицу.

Правдоподобие всей обучающей выборки

$$D = \{(x_i, y_i)\}_{i=1}^n$$

ПРИ ФИКСИРОВАННЫХ ПАРАМЕТРАХ

$$p_{\theta}(y_1, \dots, y_n \mid x_1, \dots, x_n)$$

совместная условная плотность наблюдаемых ответов

Если ответы условно независимы при заданных признаках и параметрах:

$$p_{\theta}(y_1, \dots, y_n \mid x_1, \dots, x_n) = \prod_{i=1}^n p_{\theta}(y_i \mid x_i)$$

ПОСЛЕ ФИКСАЦИИ НАБЛЮДЁННЫХ ДАННЫХ

$$\mathcal{L}(\theta; D) = \prod_{i=1}^n p_{\theta}(y_i \mid x_i)$$

От likelihood к log-likelihood и NLL

$$\arg \max_{\theta} \mathcal{L} = \arg \max_{\theta} \log \mathcal{L} = \arg \min_{\theta} [-\log \mathcal{L}]$$

Логарифм строго возрастает: максимум не меняется.

Знак минус превращает максимум в минимум.

$$\log \mathcal{L}(\theta; D) = \sum_i \log p_{\theta}(y_i | x_i)$$

log-likelihood

логарифмическое правдоподобие

NLL = negative log-likelihood

**отрицательное логарифмическое
правдоподобие**

NLL раскладывается в сумму функций потерь

Отрицательное логарифмическое правдоподобие — сумма отдельных вкладов объектов.

$$-\log \mathcal{L}(\theta; D) = \sum_i [-\log p_\theta(y_i | x_i)]$$

ИНДИВИДУАЛЬНЫЙ ВКЛАД ОПРЕДЕЛЯЕМ КАК ФУНКЦИЮ ПОТЕРЬ

$$L_i(\theta) = -\log p_\theta(y_i | x_i)$$

Выше условная плотность наблюдаемого значения при текущих параметрах → меньше вклад объекта в NLL.

Ниже условная плотность наблюдаемого значения при текущих параметрах → больше вклад объекта в NLL.

Мы снова получили знакомую форму: обучение минимизирует сумму или среднее функций потерь отдельных объектов.

$$R_n(\theta) = \frac{1}{n} \sum_i L_i(\theta) = \frac{1}{n} [-\log \mathcal{L}(\theta; D)]$$

Положительный множитель $1/n$ не меняет точку минимума.

Нормальный шум задаёт условное нормальное распределение

$$Y = f_{\theta}(X) + \varepsilon$$

$$\varepsilon_i \mid X_i = x_i \sim \mathcal{N}(0, \sigma^2)$$

$$Y_i \mid X_i = x_i \sim \mathcal{N}(f_{\theta}(x_i), \sigma^2)$$

$$f_{\theta}(x_i)$$

центр распределения и точечный прогноз

$$\sigma$$

масштаб вариативности вокруг центра

При нормальной модели значения y , расположенные ближе к центру условного распределения, имеют более высокую условную плотность.

Нормальная плотность превращается в квадрат остатка

$$p_{\theta}(y_i \mid x_i) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(y_i - f_{\theta}(x_i))^2}{2\sigma^2} \right)$$

1 В экспоненте находится квадрат остатка.

2

$$-\log p_{\theta}(y_i \mid x_i) = \frac{1}{2} \log(2\pi\sigma^2) + \frac{(y_i - f_{\theta}(x_i))^2}{2\sigma^2}$$

3

$$= C + \frac{r_i^2}{2\sigma^2}$$

Maximum likelihood превращается в МНК

$$-\log \mathcal{L}(\theta; D) = C + \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - f_{\theta}(x_i))^2$$

$$\hat{\theta}_{\text{MLE}} \in \arg \min_{\theta} \sum_i (y_i - f_{\theta}(x_i))^2$$



При предположении о нормальном шуме максимизация правдоподобия приводит к той же задаче минимизации суммы квадратов остатков — МНК.

Масштаб шума фиксирован и одинаков для всех объектов. Деление на n не меняет минимум.

Нормальная модель обосновывает MSE через правдоподобие; использовать MSE можно и без предположения о нормальности.

Нормальный шум → MSE; лапласовский шум → MAE

Вероятностное предположение о шуме определяет форму целевой функции



$$\varepsilon \mid X = x \sim \mathcal{N}(0, \sigma^2) \implies -\log p(r) = C + \frac{r^2}{2\sigma^2}$$

$$p(r) = \frac{1}{2b} e^{-|r|/b}$$

$$-\log p(r) = \log(2b) + \frac{|r|}{b}$$

Более тяжёлые хвосты дают медленнее растущий штраф за крупные отклонения.

$$\hat{\theta}_{\text{MLE}} \in \arg \min_{\theta} \sum_{i=1}^n |y_i - f_{\theta}(x_i)|$$

Распределения ошибок заданы при фиксированных признаках; масштабы σ и b фиксированы и одинаковы для всех объектов.

Что дал вероятностный взгляд

1 Задаём условную плотность.

$$p_{\theta}(y \mid x)$$

2 MLE выбирает параметры, при которых обучающая выборка наиболее правдоподобна.

3 Логарифм превращает произведение плотностей в сумму.

4 NLL превращает сумму в минимизируемый критерий; его слагаемые становятся функциями потерь.

5 $\mathcal{N} \rightarrow MSE,$ $Laplace \rightarrow MAE$

Функцию потерь можно мотивировать прикладной ценой ошибок или вероятностной моделью данных.

arg min задаёт цель, но не способ вычисления

$$\hat{\theta} \in \arg \min_{\theta} R_n(\theta)$$

Запись говорит, **что** ищем: параметры с минимальным значением цели.

Она не говорит, **как** вычислить эти параметры.



Для МНК есть специальная структура задачи и специализированные методы решения; для произвольной целевой функции такого может не быть.

Производная: локальный наклон

$$f'(w) = \lim_{h \rightarrow 0} \frac{f(w + h) - f(w)}{h}$$

$f'(w) > 0$: движение вправо увеличивает функцию.

$f'(w) < 0$: движение вправо уменьшает функцию.



При нескольких параметрах нужен градиент


$$\nabla f(\theta) = \begin{pmatrix} \partial f / \partial \theta_1 \\ \vdots \\ \partial f / \partial \theta_d \end{pmatrix}$$

Для дифференцируемой функции ненулевой градиент задаёт направление наискорейшего локального роста.

Достаточно малый шаг против ненулевого градиента уменьшает функцию.

Доказательство через производную по направлению — в appendix.

Градиент и линии уровня



$$f(\theta_1, \theta_2) = c$$

Вдоль линии значение постоянно.

Ненулевой градиент перпендикулярен гладкой линии уровня.

Достаточно малый шаг против градиента уменьшает функцию.

Ставим простейшую задачу минимизации


$$\min_w f(w), \quad f(w) = (w - 3)^2$$

$$w_0 = 0, \quad f'(w) = 2(w - 3)$$

$$f'(0) = -6$$

Производная отрицательна: небольшое увеличение w уменьшает f .

На каждом шаге локальный наклон вычисляется заново




Первый шаг градиентного спуска руками

$$\eta = 0.1$$

$$w_1 = w_0 - \eta f'(w_0) = 0.6$$

$$f'(0.6) = -4.8$$

$$w_2 = 0.6 - 0.1(-4.8) = 1.08$$



После каждого перемещения локальный наклон вычисляется заново.

Градиентный спуск: общий алгоритм

Градиентный спуск — итеративный алгоритм минимизации: вычисляем градиент в текущей точке и смещаем параметры в противоположную сторону.

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t \nabla f(\theta^{(t)})$$

 t

номер итерации

 $\theta^{(t)}$

текущие параметры

 η_t темп обучения

$$\tilde{f} = af, a > 0 \quad \Rightarrow \quad \nabla \tilde{f} = a \nabla f$$

Минимум тот же; для тех же шагов темп обучения делим на a .


Малый темп обучения

$$f(w) = (w - 3)^2$$

$$\eta = 0.05$$

Движение без перепрыгивания
через минимум.

Очень медленное приближение.



Показанное значение темпа обучения относится к этой параболе; в другой задаче его масштаб будет другим.

Два сходящихся режима движения

$$f(w) = (w - 3)^2$$

$$\eta = 0.25$$

Быстрое монотонное приближение.

$$\eta = 0.7$$

Сходящиеся колебания.



Показанные значения темпа обучения относятся к этой параболе; в другой задаче их масштаб будет другим.

Вечное перепрыгивание и расходимость


$$f(w) = (w - 3)^2$$

$$\eta = 1$$

Расстояние до минимума не уменьшается.

$$\eta = 1.02$$



Расстояние растёт, итерации расходятся.



Показанные значения темпа обучения относятся к этой параболе; в другой задаче их масштаб будет другим.

Невыпуклая функция: локальная информация имеет пределы

$\ell(x) = (x^2 - 1)^2 + 0.9x$: локальные минимумы имеют заметно разную глубину



$$\ell(x) = (x^2 - 1)^2 + 0.9x$$

Разные старты могут привести к разным локальным минимумам.


Градиент использует локальную информацию.

Поверхность и карта линий уровня


$$f(w_1, w_2) = (w_1 - 0.6)^2 + 3(w_2 + 0.4)^2$$

$$f(w_1, w_2) = (w_1 - 0.6)^2 + 3(w_2 + 0.4)^2$$

Траектория на поверхности



Та же траектория на карте линий уровня



3D-график показывает значение функции как третью координату.

Линии уровня задают множества одинаковых значений функции в плоскости параметров.

Одни и те же точки $(w_1^{(t)}, w_2^{(t)})$ нанесены слева на 3D-график функции, справа — на карту её линий уровня.

Градиентный спуск итеративный: когда остановиться?

Условия остановки сами по себе не гарантируют нахождение минимума.

Лимит итераций

$$t = T$$

Малое изменение цели

$$|f(\theta^{(t+1)}) - f(\theta^{(t)})| < \varepsilon$$

Малый градиент

$$\|\nabla f(\theta^{(t)})\|_2 < \varepsilon$$

Малый шаг параметров

$$\|\theta^{(t+1)} - \theta^{(t)}\|_2 < \varepsilon$$


$$f(w) = (w - 3)^2, \quad \eta = 1 : \quad 0 \leftrightarrow 6, \quad f = 9$$

Значение функции не меняется, но сходимости к минимуму нет.

Ранняя остановка по validation — отдельная идея.

Выпуклость: локальный минимум глобален

Геометрическое определение выпуклости



$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y), \quad 0 \leq \lambda \leq 1$$

$\lambda f(x) + (1 - \lambda)f(y)$ — координата по вертикали соответствующей точки на отрезке, соединяющем $(x, f(x))$ и $(y, f(y))$.

$$f(x) = x^2, \quad x = -1, \quad y = 1, \quad \lambda = \frac{1}{2}$$

$$z = \lambda x + (1 - \lambda)y = 0, \quad f(z) = 0$$

$$\frac{1}{2}f(-1) + \frac{1}{2}f(1) = 1, \quad 0 \leq 1$$

Следствие для оптимизации: у выпуклой функции любой локальный минимум является глобальным.

Выпуклость не гарантирует единственность параметров


$$x_2 = x_1$$

$$\beta_1 x_1 + \beta_2 x_2 = (\beta_1 + \beta_2) x_1$$

У выпуклой функции любой локальный минимум глобален, но глобальный минимум может быть не единственным.

При дефиците ранга коэффициенты могут быть неидентифицируемы.

Точная зависимость признаков: выпуклая MSE и бесконечно много коэффициентов с одинаковым прогнозом



Оптимизация на train и качество на новых данных — разные задачи

ОБУЧЕНИЕ

$$\hat{\theta} \in \arg \min_{\theta} R_{\text{train}}(\theta)$$


ОЦЕНИВАНИЕ

$$M_{\text{val/test}} = M(y, \hat{y}(\hat{\theta}))$$

$$R_{\text{train}} \downarrow \not\Rightarrow M_{\text{val/test}} \text{ улучшается}$$

Масштаб признаков меняет геометрию MSE

Масштаб столбцов X меняет форму MSE в пространстве коэффициентов



Разные масштабы дают вытянутые линии уровня.

Один η трудно подобрать; траектория часто меняет направление и может сходиться медленно.

$$x'_j = \frac{x_j - \mu_j}{s_j}$$

Стандартизация делает масштабы координат сопоставимее.

Средние и масштабы считаем на train и сохраняем для новых объектов. Постоянные столбцы не стандартизируем.

Стандартизация не добавляет информацию и не устраняет мультиколлинеарность.

Полный градиент: используем всю выборку

$$R_n(\theta) = \frac{1}{n} \sum_i L_i(\theta)$$

$$\nabla R_n(\theta) = \frac{1}{n} \sum_i \nabla L_i(\theta)$$

Все n объектов перед одним обновлением.

Точный градиент training objective.

Один шаг может быть дорогим.

Mini-batch: более дешёвая оценка градиента

Mini-batch — небольшое подмножество обучающих объектов, выбранное для текущего шага.

B_t : mini-batch, $|B_t|$: число объектов

$$g_t = \frac{1}{|B_t|} \sum_{i \in B_t} \nabla L_i(\theta^{(t)})$$

$$\theta^{(t+1)} = \theta^{(t)} - \eta_t g_t$$

Шаг дешевле, направление шумнее полного градиента.

$$\mathbb{E}[g_t \mid \theta^{(t)}] = \nabla R_n(\theta^{(t)})$$

На каждом шаге выбираем новый мини-батч равномерно из всей выборки, независимо от предыдущих выборов. Среднее по таким оценкам равно полному градиенту.

SGD: mini-batch размера 1


SGD = Stochastic Gradient
Descent

$$|B_t| = 1$$

Меняется способ оценить
градиент.

Модель и целевая функция
остаются теми же.

Цена одного шага и точность направления: полный градиент, mini-batch и SGD



При постоянном шаге и сохраняющемся шуме возможны колебания около решения, а не точная сходимость.

Возвращаемся к линейной регрессии

ПРОГНОЗЫ ПРИ ПОДБОРЕ

$$X\beta$$

ОСТАТКИ

$$r(\beta) = y - X\beta$$

ЭМПИРИЧЕСКИЙ РИСК

$$R(\beta) = \frac{1}{n} \|y - X\beta\|_2^2$$

После обучения: $\hat{y} = X\hat{\beta}$

Теперь выведем градиент MSE по коэффициентам линейной модели.

Что именно нужно продифференцировать

$$R(\beta) = \frac{1}{n} \sum_{i=1}^n r_i(\beta)^2$$

$$r_i(\beta) = y_i - \sum_{k=1}^q x_{ik} \beta_k$$

i — индекс объекта

j — выбранный коэффициент

k — индекс суммирования по коэффициентам

Нужна производная по одному выбранному коэффициенту β_j .

Один объект: применяем цепное правило

$$\frac{\partial r_i}{\partial \beta_j} = -x_{ij}$$



$$\frac{\partial r_i^2}{\partial \beta_j} = 2r_i \frac{\partial r_i}{\partial \beta_j} = -2x_{ij}r_i$$

Вклад одного объекта в производную — значение признака, умноженное на текущий остаток.

Суммируем вклады всех объектов

$$\frac{\partial R}{\partial \beta_j} = \frac{1}{n} \sum_{i=1}^n \frac{\partial r_i^2}{\partial \beta_j}$$



$$\frac{\partial R}{\partial \beta_j} = -\frac{2}{n} \sum_{i=1}^n x_{ij} r_i$$

Каждая координата градиента складывает такие вклады по всей обучающей выборке.

Все координаты собираются в $X^\top r$

$$X^\top r = \begin{pmatrix} \sum_i x_{i1} r_i \\ \vdots \\ \sum_i x_{iq} r_i \end{pmatrix}$$

$$\nabla_\beta R(\beta) = -\frac{2}{n} X^\top (y - X\beta)$$

$$X^\top \in \mathbb{R}^{q \times n}$$

$$r \in \mathbb{R}^n$$

$$X^\top r \in \mathbb{R}^q$$

Один шаг GD для линейной регрессии

$$\beta^{(t+1)} = \beta^{(t)} + \frac{2\eta}{n} X^\top (y - X\beta^{(t)})$$

1

Прогнозы

$$X\beta^{(t)}$$

2

Остатки

$$y - X\beta^{(t)}$$

3

Направление

$$X^\top r$$


4

Новые параметры

$$\beta^{(t+1)}$$

В общем правиле стоит минус; градиент MSE уже содержит минус, поэтому здесь появляется плюс.

Та же задача МНК, другой способ решения



$$\min_{\beta} \frac{1}{n} \|y - X\beta\|_2^2$$

`lstsq`

**специализированный численный
решатель задачи наименьших
квадратов**

Градиентный спуск

**приближается к тому же минимуму
последовательностью шагов**

Меняется способ поиска коэффициентов, а не модель и не целевая функция MSE.

Нулевой градиент возвращает знакомое условие

$$\nabla R(\hat{\beta}) = 0$$



$$X^{\top}(y - X\hat{\beta}) = 0$$



$$X^{\top}X\hat{\beta} = X^{\top}y$$


Градиент и ортогональность остатков приводят к тем же нормальным уравнениям.

Одна модель — разные функции потерь и способы оптимизации

Модель	Функция потерь	Способ поиска параметров
линейная	MSE	lstsq / аналитический МНК
линейная	MSE	градиентный спуск
линейная	MAE	специализированный метод негладкой оптимизации
линейная	Huber	градиентные методы

Нормальные уравнения характеризуют оптимум; lstsq — практический численный решатель.

Что теперь происходит внутри `fit` — и после него



- Функция потерь задаёт, какие ошибки считаются дорогими.
- Поведение GD зависит от геометрии, темпа обучения, масштаба и старта.

- Оптимизатор ищет параметры по целевой функции на train.
- Хороший минимум на train не гарантирует качество на новых данных.

Производная по направлению и линии уровня

ИЗМЕНЕНИЕ В НАПРАВЛЕНИИ u

$$D_u f(\theta) = \nabla f(\theta)^\top u$$

Для единичного u максимальный рост
при $u \parallel \nabla f$

КАСАТЕЛЬНАЯ К ЛИНИИ УРОВНЯ

$$f(\gamma(s)) = c$$



$$\nabla f(\theta_0)^\top \gamma'(0) = 0$$

Градиент перпендикулярен линии уровня.

Функция непрерывно дифференцируема в окрестности точки; градиент в ней ненулевой.

Student-t и тяжёлые хвосты

Вероятностное предположение о шуме определяет форму целевой функции



Тяжёлые хвосты делают крупные отклонения менее невероятными.

Соответствующая NLL растёт медленнее квадратичной.

Эта функция потерь не выпукла на всей числовой прямой.

Матричное дифференцирование MSE

$$\begin{aligned} R(\beta) &= \frac{1}{n} (y - X\beta)^\top (y - X\beta) \\ &= \frac{1}{n} (y^\top y - 2\beta^\top X^\top y + \beta^\top X^\top X\beta) \end{aligned}$$



$$\nabla_\beta R(\beta) = \frac{2}{n} (X^\top X\beta - X^\top y) = -\frac{2}{n} X^\top (y - X\beta)$$

Это тот же градиент, который получили по координатно на основных слайдах.