


Линейная классификация

От линейного score к вероятности и решению



Числовой код класса не делает его числовой величиной

ПОРЯДОК СОДЕРЖАТЕЛЕН

низкий → средний → высокий

ЕСТЕСТВЕННОГО ПОРЯДКА НЕТ

договор · резюме · счёт

Кодировка может отражать смысл задачи, но не должна незаметно добавлять порядок или расстояния между классами.

Бинарный случай: классы 0 и 1

$$Y \in \{0, 1\}$$

**0 —
отрицательный
класс**

**1 —
положительный
класс**

Пример: 1 — клиент отменил подписку в следующие 30 дней; 0 — сохранил её.

$$p(x) = P(Y = 1 \mid X = x)$$

вероятность принадлежности объекта к положительному классу

Для бинарной задачи удобно обозначить отрицательный класс нулём, а положительный — единицей.

У кодировки 0/1 есть полезное свойство

$$\mathbb{E}[Y \mid X = x]$$

↓


$$= 0 \cdot P(Y = 0 \mid X = x) + 1 \cdot P(Y = 1 \mid X = x)$$

$$\boxed{\mathbb{E}[Y \mid X = x] = P(Y = 1 \mid X = x) = p(x)}$$

Поэтому для бинарной целевой переменной условное среднее равно вероятности положительного класса.

При одинаковых признаках средний ответ равен доле положительного класса

Мысленный эксперимент: фиксируем один вектор признаков x ; модель не различает 10 объектов по X и прогнозирует всем одно значение c .



Какое одно число c минимизирует среднюю квадратичную ошибку?

$$\sum_{i=1}^{10} (y_i - c)^2$$

$$c = \bar{y} = \frac{3}{10} = 0.3$$

Линейная модель вероятности: моделируем $p(x)$ линейно, оцениваем МНК

МОДЕЛЬ ВЕРОЯТНОСТИ


$$P(Y = 1 \mid X = x) = \beta_0 + x^\top \beta$$

ОБУЧЕНИЕ

$$(\hat{\beta}_0, \hat{\beta}) \in \arg \min_{\beta_0, \beta} \sum_i (y_i - \beta_0 - x_i^\top \beta)^2$$

Наблюдаем $y_i \in \{0, 1\}$, а не готовые вероятности. OLS нацелен на $\mathbb{E}[Y \mid X = x] = P(Y = 1 \mid X = x)$.

Линейная вероятность может выйти за [0, 1]




$$\hat{p}(x) < 0$$

$$\hat{p}(x) > 1$$

МНК находит лучшую линейную аппроксимацию; её коэффициенты и локальное поведение могут быть полезны.

Ограничение задаёт глобальная прямая: за пределами [0, 1] её прогнозы теряют вероятностный смысл.

Хотим сохранить линейный score, но не саму вероятность




$$z(x) = \beta_0 + x^\top \beta \in \mathbb{R}$$

$$p(x) \in [0, 1]$$

Как связать всю числовую прямую с вероятностью?

Odds: 20 событий против 80 несобытий



$$20 : 80 = 1 : 4$$

$$p = 0.2$$

$$\text{odds}(p) = \frac{p}{1 - p} = \frac{1}{4}$$

odds — шансы: отношение событий к несобытиям.

Примеры odds при разных вероятностях

Вероятность p	События : несобытия	odds
0.2	20 : 80	1 : 4
0.5	50 : 50	1 : 1
0.8	80 : 20	4 : 1


$$0 < p < 1 \implies \text{odds}(p) \in (0, +\infty)$$

$$p = 0 \implies \text{odds}(p) = 0$$

$$p \rightarrow 1 \implies \text{odds}(p) \rightarrow +\infty$$

Вероятность вообще: $p \in [0, 1]$. Для перехода к logit рассматриваем $0 < p < 1$.

Чтобы получить вещественную шкалу, берём логарифм odds



$$(0, +\infty) \xrightarrow{\log} \mathbb{R}$$

log монотонен: порядок значений сохраняется.

Умножение превращается в сложение:

$$\log(ab) = \log a + \log b$$

Это преобразование называется logit

$$\text{logit}(p) = \log \frac{p}{1 - p}$$

$$0 < p < 1$$

p	odds	logit
0.2	1 : 4	-1.386
0.5	1 : 1	0
0.8	4 : 1	1.386

Logit — вещественное число, а не вероятность. Здесь и далее *log* означает натуральный логарифм.

Логистическая регрессия моделирует log-odds линейно

$$\text{logit } p(x) = \log \frac{p(x)}{1 - p(x)} = \beta_0 + x^\top \beta$$

Линейна не вероятность, а её log-odds.

Линейный score и logit — одна величина

$$z(x) = \beta_0 + x^\top \beta$$

$$z(x) = \text{logit } p(x)$$

$$z < 0 \Rightarrow p < 0.5$$

$$z = 0 \Rightarrow p = 0.5$$

$$z > 0 \Rightarrow p > 0.5$$

В логистической регрессии линейный score имеет вероятностный смысл: это log-odds положительного класса.

Решаем уравнение относительно вероятности p

$$z = \log \frac{p}{1-p}$$

$$e^z = \frac{p}{1-p}$$

$$e^z(1-p) = p$$

$$e^z - e^z p = p$$

$$e^z = p + e^z p$$


$$e^z = p(1 + e^z)$$

$$p = \frac{e^z}{1 + e^z} = \frac{1}{1 + e^{-z}}$$

Для конечного score z получаем $0 < p < 1$.

$$p \rightarrow 0^+ \Rightarrow \text{logit}(p) \rightarrow -\infty, \quad p \rightarrow 1^- \Rightarrow \text{logit}(p) \rightarrow +\infty$$

Сигмоида переводит любой score в вероятность



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$\sigma : \mathbb{R} \rightarrow (0, 1)$$

$$z \rightarrow -\infty \Rightarrow p \rightarrow 0$$

$$z = 0 \Rightarrow p = 0.5$$

$$z \rightarrow +\infty \Rightarrow p \rightarrow 1$$

Определение логистической регрессии

$$p(x) = P(Y = 1 \mid X = x) = \sigma(\beta_0 + x^\top \beta)$$



Модель определена. Теперь разберём смысл её коэффициентов, а затем перейдём к обучению.

Коэффициент: сдвиг log-odds и отношение шансов

Увеличиваем x_j на 1 при фиксированных остальных признаках.

ЛИНЕЙНАЯ МОДЕЛЬ ВЕРОЯТНОСТИ

$$p_{\text{new}} - p_{\text{old}} = \beta_j$$

постоянный эффект на вероятность

ЛОГИСТИЧЕСКАЯ РЕГРЕССИЯ

$$\log \text{odds}_{\text{new}} - \log \text{odds}_{\text{old}} = \beta_j$$

возводим e в степень обеих частей

$$\frac{\text{odds}_{\text{new}}}{\text{odds}_{\text{old}}} = e^{\beta_j}$$

$$\beta_j = \log 2 \Rightarrow e^{\beta_j} = 2$$

Увеличение x_j на единицу удваивает odds, а не вероятность.

Распределение Бернулли для бинарного ответа

$$Y_i \in \{0, 1\}$$

$$p_i = \sigma(x_i^\top \beta)$$

$$Y_i \mid X = x_i \sim \text{Bernoulli}(p_i)$$



$$P(Y_i = 0 \mid x_i) = 1 - p_i$$

$$P(Y_i = 1 \mid x_i) = p_i$$

$$P(Y_i = 1 \mid x_i) = p_i$$

$$P(Y_i = 0 \mid x_i) = 1 - p_i$$

Распределение Бернулли допускает $p \in [0, 1]$; здесь $p_i = \sigma(z_i) \in (0, 1)$ при конечном z_i .

Два случая объединяются одной формулой

$$P(Y_i = y_i \mid x_i) = p_i^{y_i} (1 - p_i)^{1-y_i}$$

ЕСЛИ $y_i = 1$

$$p_i^1 (1 - p_i)^0 = p_i$$

ЕСЛИ $y_i = 0$

$$p_i^0 (1 - p_i)^1 = 1 - p_i$$

Степени выбирают вероятность наблюдавшегося исхода.

Правдоподобие всей выборки

Наблюдаемые y_i фиксированы. Меняем β и спрашиваем, при каких параметрах эти значения наиболее правдоподобны.

$$\mathcal{L}(\beta) = \prod_{i=1}^n P(Y_i = y_i \mid x_i)$$

↓ подставляем Bernoulli

$$\mathcal{L}(\beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$

MLE: выбираем коэффициенты

Данные фиксированы; меняем параметры модели.

$$\hat{\beta} \in \arg \max_{\beta} \mathcal{L}(\beta)$$

Логарифм превращает произведение в сумму

$$\log \mathcal{L}(\beta) = \sum_i \log [p_i^{y_i} (1 - p_i)^{1-y_i}]$$

↓ степени становятся множителями

$$= \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

Логарифм монотонен: положение максимума likelihood не меняется.

Из максимума правдоподобия получаем минимум NLL

$$\arg \max_{\beta} \log \mathcal{L}(\beta) = \arg \min_{\beta} [-\log \mathcal{L}(\beta)]$$

↓ меняем знак

$$-\log \mathcal{L}(\beta) = -\sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

Модель Бернулли задаёт новую функцию потерь через отрицательное log-правдоподобие.

В языке эмпирического риска делим на n

$$R_n(\beta) = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

$$\arg \min_{\beta} [-\log \mathcal{L}(\beta)] = \arg \min_{\beta} R_n(\beta)$$

Произведение likelihood уже агрегирует все объекты.

Множитель $1/n$ переводит сумму в среднюю потерю на объект и не меняет минимум.

Log loss одного объекта

$$L(y, p) = -y \log p - (1 - y) \log(1 - p)$$

Здесь $0 < p < 1$: в логистической регрессии $p = \sigma(z)$, поэтому оба логарифма определены.

$$y = 1 \Rightarrow L = -\log p$$


$$y = 0 \Rightarrow L = -\log(1 - p)$$

$p_i = p_\beta(x_i) = \sigma(x_i^\top \beta)$: при обучении loss зависит от β через p_i .

binary cross-entropy (BCE) — распространённое альтернативное название той же функции.

Уверенная ошибка стоит дорого

$$y = 1 : \quad L(1, p) = -\log p$$



$$p = 0.9 \Rightarrow L \approx 0.105$$

$$p = 0.5 \Rightarrow L \approx 0.693$$

||

$$p = 0.01 \Rightarrow L \approx 4.605$$

Для $y = 0$ картина зеркальна.

Что должен выдавать хороший вероятностный прогноз?

100 случаев при одинаковом $X = x$

20 единиц

80 нулей

ИСТИННАЯ ВЕРОЯТНОСТЬ

$$q = P(Y = 1 \mid X = x) = 0.2$$

ПРОГНОЗ МОДЕЛИ

$$p \in (0, 1)$$

Какое p минимизирует среднюю log loss, если такие условия повторяются много раз?

От двух исходов к ожидаемой log loss

Фиксируем $X = x$ и используем один прогноз p при каждом повторении условий.

$$P(Y = 1 \mid X = x) = q$$

$$L(1, p) = -\log p$$

при $q = 0.2$ — около 20% случаев

$$P(Y = 0 \mid X = x) = 1 - q$$

$$L(0, p) = -\log(1 - p)$$

при $q = 0.2$ — около 80% случаев

$$\Phi(p) = \mathbb{E}[L(Y, p) \mid X = x] = qL(1, p) + (1 - q)L(0, p)$$

$$\Phi(p) = -q \log p - (1 - q) \log(1 - p)$$

Ожидаемая log loss — средняя цена одного прогноза p при многократном повторении условий $X = x$.

Почему минимум именно при $p = q$

$$\Phi'(p) = \frac{p - q}{p(1 - p)}, \quad 0 < p < 1 \Rightarrow p(1 - p) > 0$$


$$p < q \Rightarrow \Phi'(p) < 0$$

Увеличение p уменьшает потерю.

$$p = q \Rightarrow \Phi'(p) = 0$$

$$p > q \Rightarrow \Phi'(p) > 0$$

Увеличение p повышает потерю.



Функция убывает до $p = q$ и растёт после; важно само значение вероятности, а не только класс.

$$0 < q < 1 : \quad \arg \min_{p \in (0,1)} \mathbb{E}[L(Y, p) \mid X = x] = q = P(Y = 1 \mid X = x)$$

От модели Бернулли к целевой функции

МОДЕЛЬ БЕРНУЛЛИ

$$Y_i \mid x_i \sim \text{Bernoulli}(p_i) \rightarrow$$

ПРАВДОПОДОБИЕ И NLL

$$-\log \mathcal{L}(\beta) \rightarrow$$

ЭМПИРИЧЕСКИЙ РИСК

$$R_n(\beta) = \frac{1}{n} \sum_i L_i$$

Модель и целевая функция определены. Осталось получить градиент по параметрам.

Целевая функция уже известна; нужен градиент

ПРОГНОЗЫ

$$p = \sigma(X\beta)$$

ЦЕЛЕВАЯ ФУНКЦИЯ

$$R_n(\beta) = -\frac{1}{n} \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

Что передать уже знакомому градиентному спуску?

Для одного объекта есть цепочка $\beta \rightarrow z \rightarrow p \rightarrow L$



$$\frac{\partial L_i}{\partial z_i} = \frac{\partial L_i}{\partial p_i} \frac{\partial p_i}{\partial z_i}$$

Первая производная: log loss по p

$$L_i = -y_i \log p_i - (1 - y_i) \log(1 - p_i)$$

↓ дифференцируем по p_i

$$\frac{\partial L_i}{\partial p_i} = -\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i}$$

Вторая производная: sigmoid по z

$$p_i = \sigma(z_i)$$

↓ производная сигмоиды

$$\frac{\partial p_i}{\partial z_i} = p_i(1 - p_i)$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

Подставляем правило цепочки

$$\frac{\partial L_i}{\partial z_i} = \left(-\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i} \right) p_i(1 - p_i)$$

↓ подставляем и упрощаем

$$= -y_i(1 - p_i) + (1 - y_i)p_i$$

Красивое сокращение: $p_i - y_i$

$$-y_i(1 - p_i) + (1 - y_i)p_i$$

$$= -y_i + y_i p_i + p_i - y_i p_i$$

↓ одинаковые слагаемые сокращаются

$$\frac{\partial L_i}{\partial z_i} = p_i - y_i$$

Получили особенно простой результат: производная log loss по score равна $p_i - y_i$.

Нам нужна производная по параметрам β

$$\nabla_{\beta} L_i$$

$$z_i = x_i^{\top} \beta = x_{i1}\beta_1 + \dots + x_{iq}\beta_q$$

$$\frac{\partial z_i}{\partial \beta_j} = x_{ij}$$

↓ собираем производные по всем коэффициентам

$$\nabla_{\beta} z_i = x_i$$

Получили градиент loss по параметрам

$$\nabla_{\beta} L_i = \frac{\partial L_i}{\partial z_i} \nabla_{\beta} z_i$$

↓ подставляем два полученных результата

$$\nabla_{\beta} L_i = (p_i - y_i) x_i$$

Это то, что нужно оптимизатору для одного объекта.

Складываем вклады всех объектов

$$\nabla_{\beta} R_n(\beta) = \frac{1}{n} \sum_{i=1}^n \nabla_{\beta} L_i$$

↓ подставляем градиент одного объекта

$$= \frac{1}{n} \sum_{i=1}^n (p_i - y_i) x_i$$

Градиент риска — среднее вкладов всех обучающих объектов.

Та же сумма в матричной записи

$$X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_n^\top \end{pmatrix} \in \mathbb{R}^{n \times q}$$

$$p - y = \begin{pmatrix} p_1 - y_1 \\ \vdots \\ p_n - y_n \end{pmatrix} \in \mathbb{R}^n$$

$$X^\top (p - y) = \sum_{i=1}^n (p_i - y_i) x_i$$

i -я строка X и i -я ошибка вероятности образуют один взвешенный вклад.

$$\nabla_{\beta} R_n(\beta) = \frac{1}{n} X^\top (p - y)$$

Размерность результата — q : по одной компоненте градиента на каждый коэффициент.

Один шаг градиентного спуска


$$\beta^{(t+1)} = \beta^{(t)} - \eta \frac{1}{n} X^{\top} \left(p^{(t)} - y \right)$$

$$z^{(t)} = X\beta^{(t)}$$

$$p^{(t)} = \sigma(z^{(t)}) = \sigma(X\beta^{(t)})$$

После обновления коэффициентов score и вероятности пересчитываются заново.

Тот же цикл градиентного спуска, новые части логистической регрессии




Прогноз — новый.

Функция потерь — новая.

Формула градиента — новая.

Цикл оптимизатора — тот же.

Выпуклость: одна важная идея



У нерегуляризованной логистической регрессии $\log$ loss выпукла по коэффициентам.

На рисунке — срез целевой функции вдоль одного направления.

Выпуклость исключает отдельные локальные минимумы.

Полное доказательство через Hessian вынесено в приложение.

После обучения есть три разных уровня результата

$$\hat{z}(x) = x^\top \hat{\beta} \quad \text{score / log-odds}$$



$$\hat{p}(x) = \sigma(\hat{z}(x)) \quad \text{оценка вероятности}$$

↓ порог

$$\hat{y}_t(x) \quad \text{жёсткая метка класса}$$

Чтобы получить класс, к вероятности нужно добавить правило решения.


В scikit-learn эти уровни тоже разделены

Смысл	scikit-learn
score	<code>decision_function</code>
вероятности классов	<code>predict_proba</code>
жёсткая метка	<code>predict</code>

`predict_proba` возвращает оценки вероятностей, а не гарантированно точные частоты.


Порог превращает вероятность в метку

$$\hat{y}_t(x) = I[\hat{p}(x) \geq t], \quad 0 < t < 1$$



$I[\cdot] = 1$ при выполненном условии; иначе 0. Изменение порога не переобучает модель.

Почему порог 0.5 означает $\text{score} \geq 0$



$$\begin{aligned}\hat{p}(x) &\geq 0.5 \\ \iff \sigma(\hat{z}(x)) &\geq \sigma(0) \\ \iff \hat{z}(x) &\geq 0\end{aligned}$$

$$\iff x^\top \hat{\beta} \geq 0$$

Сигмоида строго возрастает, поэтому сохраняет порядок score.


При $t = 0.5$ граница решения — $z(x) = 0$

$$\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = 0$$

В двух признаках граница — прямая.

По разные стороны от неё score имеет разные знаки.

В большем числе признаков это гиперплоскость.



Любой порог вероятности можно перевести в порог score

$$0 < t < 1$$

$$\hat{p}(x) \geq t$$

$$\iff \text{logit}(\hat{p}(x)) \geq \text{logit}(t)$$

$$\iff x^\top \hat{\beta} \geq \log \frac{t}{1-t}$$

$$t = 0.2 \Rightarrow z \geq -1.386$$

$$t = 0.8 \Rightarrow z \geq 1.386$$

Порог 0.5 выделен только тем, что $\text{logit}(0.5) = 0$.

Одна модель, два порога, разные решения

$\hat{p}$	0.91	0.72	0.48	0.31	0.08
$T = 0.5$	1	1	0	0	0
$T = 0.3$	1	1	1	1	0

Вероятности не изменились; изменились только жёсткие решения.

Самая простая проверка жёстких меток: accuracy

y	1	0	1	1	0	0	1	0
$\hat{y}$	1 ✓	0 ✓	0	1 ✓	0 ✓	1	1 ✓	0 ✓

$$\text{accuracy} = \frac{1}{n} \sum_{i=1}^n I[\hat{y}_i = y_i]$$

Доля правильных классификаций: здесь 6 из 8, то есть 0.75.

Почему 0.5 не обязано быть правильным решением

Событие произошло, модель оставила класс 0

Пропустили событие.

События не было, модель поставила класс 1

Получили ложную тревогу.

Эти ошибки всегда одинаково дороги?

Нет: порог должен зависеть от задачи принятия решения.

Что осталось неразрешённым

- 1 Как отдельно считать разные типы ошибок?
- 2 Что делать, если положительный класс редкий?
- 3 Как выбирать порог, если цели конфликтуют?

Для этого понадобится больше одной метрики классификации.

Вся логистическая регрессия на одном экране

$$z = X\beta = \text{logit}(p)$$

↓ σ

$$p = P(Y = 1 \mid X)$$

↓

правдоподобие Бернулли

↓ $-\log$

log loss

↓

$$\nabla R = \frac{1}{n} X^\top (p - y)$$

↓ обновление β

$$\hat{p} \xrightarrow{t} \hat{y}$$

Score, вероятность и класс — разные объекты.

Модель Бернулли приводит к log loss; её градиент позволяет обучить параметры.


Цикл градиентного спуска остаётся тем же.

После обучения порог меняет решение, но не вероятностный прогноз.

Предельный эффект вероятности зависит от p

$$\frac{\partial p(x)}{\partial x_j} = \beta_j p(x)(1 - p(x))$$

Один и тот же сдвиг score сильнее меняет вероятность около $p = 0.5$.



Вторая кодировка: $-1/+1$ и отступ

$$\tilde{y} = 2y - 1, \quad M = \tilde{y}z$$

$$L(\tilde{y}, z) = \log(1 + e^{-\tilde{y}z})$$

$M > 0$ — правильная сторона границы.

$M < 0$ — неправильная сторона.

Почему целевая функция выпукла

$$\nabla^2 R_n(\beta) = \frac{1}{n} X^\top W X, \quad W = \text{diag}(p_i(1 - p_i))$$


↓ для любого v

$$v^\top \nabla^2 R_n v = \frac{1}{n} (Xv)^\top W (Xv) \geq 0$$

Диагональные элементы W неотрицательны, поэтому Hessian положительно полуопределён.

Perfect separation

Линейная разделимость — отдельное свойство данных



При полной линейной разделимости максимум правдоподобия нерегуляризованной модели может не достигаться при конечных коэффициентах.

Практическая оговорка о scikit-learn

```
LogisticRegression()
```

по умолчанию использует регуляризацию.

В основной части лекции мы выводили нерегуляризованную MLE-задачу.

Поэтому библиотечные коэффициенты могут не совпасть с ручным решением буквально.