

Метрики классификации и принятие решения

От *score* и вероятности —
к решению и оценке качества

$$x \longrightarrow \textit{score} / \hat{p}(x) \longrightarrow ?$$

12 объектов оценочной выборки

Модель уже обучена. Объекты отсортированы по убыванию $\hat{p}$.

Объект	$\hat{p}$	Настоящий класс y
1	0.95	1
2	0.88	0
3	0.82	1
4	0.75	1
5	0.68	0
6	0.61	0

Объект	$\hat{p}$	Настоящий класс y
7	0.55	1
8	0.48	0
9	0.35	1
10	0.30	0
11	0.18	0
12	0.08	0

Что делать с прогнозом 0.75?

$$\hat{p}(\text{мошенничество} \mid x_4) = 0.75$$

Пропустить

Отправить
на ручную проверку

Заблокировать

Один и тот же прогноз может вести к разным действиям — в зависимости от задачи.

Порог превращает прогноз в класс

$$\hat{y}_t(x) = \mathbb{I}[\hat{p}(x) \geq t]$$

Шкала вероятности: $0 \rightarrow 1$



0.5 — привычный выбор, а не универсальное правило.

Одно конкретное решение: порог 0.5

Оценка вероятности · по убыванию



7 объектов получили прогноз класса 1.

Как у каждого объекта
могут согласоваться прогноз и настоящий класс?

Четыре возможных исхода

TP

Мошенничество есть.

Модель предсказала класс 1.

FP

Мошенничества нет.

Модель предсказала класс 1.

FN

Мошенничество есть.

Модель предсказала класс 0.

TN

Мошенничества нет.

Модель предсказала класс 0.

«Положительный» означает класс 1, а не «хороший исход».

Отмечаем исход у каждого объекта

Оценка вероятности · по убыванию

1	2	3	4	5	6	7	8	9	10	11	12
0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
▲	■	▲	▲	■	■	▲	■	▲	■	■	■
1	1	1	1	1	1	1	0	0	0	0	0
TP	FP	TP	TP	FP	FP	TP	TN	FN	TN	TN	TN

▲ класс 1 ■ класс 0 t = 0.5

$$TP = 4, \quad FP = 3, \quad FN = 1, \quad TN = 4$$

Матрица ошибок (confusion matrix)

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

Строки — настоящий класс.

Столбцы — прогноз класса.

Те же четыре числа, другой способ организации.

Accuracy: доля правильных решений

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

$$Accuracy = \frac{TP + TN}{N} = \frac{8}{12}$$

Знаменатель:
все объекты.

Precision: кому можно доверять среди выбранных?

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

$$Precision = \frac{TP}{TP + FP} = \frac{4}{7}$$

Среди прогнозов класса 1:
какая доля действительно
принадлежит классу 1?

Recall: сколько положительных объектов нашли?

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

$$Recall = \frac{TP}{TP + FN} = \frac{4}{5}$$

Среди настоящих объектов класса 1: какую долю нашла модель?

Precision и Recall начинают с разных групп

НАЧИНАЕМ С РЕШЕНИЯ МОДЕЛИ

$$Precision = \hat{P}(Y = 1 \mid \hat{Y} = 1)$$

Насколько чиста
выбранная группа?

НАЧИНАЕМ С НАСТОЯЩЕГО КЛАССА

$$Recall = \hat{P}(\hat{Y} = 1 \mid Y = 1)$$

Какую долю класса 1
мы охватили?

Specificity: Recall отрицательного класса

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

$$Specificity = \frac{TN}{TN + FP} = \frac{4}{7}$$

Какую долю класса 0
правильно оставили отрицательной?

Specificity — это Recall класса 0.

Одна матрица — четыре вопроса

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

НАСТОЯЩИЙ КЛАСС 0

Specificity

Какую долю отрицательных не тревожим?

Проверим решение на редком классе

	Прогноз 0	Прогноз 1
Истинный 0	TN 9900	FP 0
Истинный 1	FN 100	TP 0

Accuracy = 99%

Recall = 0

Нет прогнозов класса 1:
Precision не определён.

Accuracy верна, но недостаточна для вопроса «находим ли мы редкий класс?»

Скрининг: какую ошибку опаснее допустить?

ПЕРВЫЙ ЭТАП

Дешёвый первичный скрининг



ПОЛОЖИТЕЛЬНЫЙ РЕЗУЛЬТАТ

Более точное
и дорогое обследование

Какая ошибка опаснее? Какой показатель вы бы контролировали?

FN · ПРОПУСК

Болезнь пропущена.
Важен высокий Recall.

Область задачи сама по себе не выбирает метрику.
Важны действие и последствия ошибок.

FP · ЛОЖНАЯ ТРЕВОГА

Перегружает второй этап, повышает расходы
и тревогу.
Precision тоже важен.

Антифрод: одна модель, два действия

АВТОМАТИЧЕСКАЯ БЛОКИРОВКА

Отклоняем платёж.

FP напрямую вредит
невиновному пользователю.

РУЧНАЯ ПРОВЕРКА

Формируем очередь проверки.


FP расходует время
и вместимость очереди.

**Нужны ли здесь одинаковые порог
и основная метрика?**

Последствия ошибок и ограничения различаются —
требования к решению тоже будут разными.

Те же вероятности — разные решения

$$t = 0.8$$



▲ истинный класс 1 ■ истинный класс 0 внизу — решение

Accuracy 0.67 · Precision 0.67 · Recall 0.40

Двигаем только порог. Модель не переобучаем.

Порог меняет матрицу ошибок

 $t = 0.3$

	Прогноз 0	Прогноз 1
Истинный 0	TN 2	FP 5
Истинный 1	FN 0	TP 5

 $t = 0.5$

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

 $t = 0.8$

	Прогноз 0	Прогноз 1
Истинный 0	TN 6	FP 1
Истинный 1	FN 3	TP 2

Что происходит, когда порог повышается?

Оценка вероятности · по убыванию




	Прогноз 0	Прогноз 1
Истинный 0	TN 3	FP 4
Истинный 1	FN 1	TP 4

$$t = 0.48 : \quad TP \rightarrow FN, \quad P = 4/8, \quad R = 4/5$$

Убрали положительный объект: Recall и Precision снизились.

Положительных прогнозов меньше; Recall не растёт.
Precision не монотонен; Accuracy может меняться в обе стороны.

Каждый порог даёт свой набор метрик



На конечной выборке метрики меняются ступенчато:
пока порог не пересёк наблюдаемый score, решение прежнее.

F1 требует одновременно высоких Precision и Recall

$$Precision = 0.9, \quad Recall = 0.1$$

$$\frac{Precision + Recall}{2} = 0.5$$

$$F_1 = \frac{2 Precision \cdot Recall}{Precision + Recall} = 0.18$$

Высокое значение одной метрики не компенсирует низкое значение другой.

Что означает F1

$$0 \leq F_1 \leq 1$$

1 — идеальное
решение

Больше — лучше

Precision и Recall
равноправны

F1 не знает стоимость ошибок вашей задачи.

F_β меняет приоритет в той же паре метрик

$$F_\beta = \frac{(1 + \beta^2) Precision \cdot Recall}{\beta^2 Precision + Recall}$$

$$Precision = 0.9, \quad Recall = 0.1$$

$$F_{0.5} \approx 0.346$$

При $\beta < 1$
важнее Precision.

$$F_1 = 0.18$$

При $\beta = 1$
равные приоритеты.

$$F_2 \approx 0.122$$

При $\beta > 1$
важнее Recall.

Меняя β , по-разному объединяем те же Precision и Recall.

Приоритет в F_β не задаёт стоимость FP/FN: $\beta = 2$ не означает, что пропуск вдвое дороже.

Сравним стоимость двух действий для объекта

Фиксируем один объект с признаками x . Его оценённые вероятности:

$$p = \hat{P}(Y = 1 \mid x), \quad 1 - p = \hat{P}(Y = 0 \mid x)$$

ДЕЙСТВИЕ $A = 1$

$$\mathbb{E}[C \mid a = 1] = c_{FP}(1 - p)$$

Платим при ложной тревоге.

ДЕЙСТВИЕ $A = 0$

$$\mathbb{E}[C \mid a = 0] = c_{FN}p$$

Платим при пропуске.

Сравниваем ожидаемые стоимости двух действий
для этого объекта.

Сначала правило решения — затем порог

Два действия: класс 1 или класс 0. Выбираем меньшую ожидаемую стоимость.

$$\mathbb{E}[C \mid x, a = 1] = c_{FP}(1 - p)$$

$$\mathbb{E}[C \mid x, a = 0] = c_{FN}p$$

Когда выбираем класс 1?

$$\hat{y} = 1 \iff \mathbb{E}[C \mid x, a = 1] \leq \mathbb{E}[C \mid x, a = 0]$$

$$c_{FP}(1 - p) \leq c_{FN}p$$

$$\iff p \geq \frac{c_{FP}}{c_{FP} + c_{FN}}$$

$$c_{FP} = c_{FN} \Rightarrow t^* = 0.5$$

$$\hat{y} = 1 \iff p \geq t$$

$$t^* = \frac{c_{FP}}{c_{FP} + c_{FN}}$$

$$c_{FN} = 9c_{FP} \Rightarrow t^* = 0.1$$

Нужны содержательные вероятности и постоянные стоимости, складывающиеся по объектам.

Решение при пороге: итог

$score / \hat{p} \longrightarrow t \longrightarrow \hat{y} \longrightarrow \text{матрица ошибок} \longrightarrow \text{метрики}$

Порог можно выбрать по метрике,
ограничению или модели стоимости.

Порог выбираем на валидационных данных;
тест оставляем для финальной оценки.

А если пока не выбирать один порог?

А если не фиксировать один порог?

Оценка вероятности · по убыванию

1	2	3	4	5	6	7	8	9	10	11	12
0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
▲	■	▲	▲	■	■	▲	■	▲	■	■	■
1	1	1	1	1	1	1	1	1	0	0	0

▲ класс 1 ■ класс 0 Отобраны первые 9

Насколько хорошо модель
упорядочивает объекты?

Знакомые доли: TPR и FPR

$$TPR = Recall = \frac{TP}{TP + FN}$$

Какую долю положительных нашли?


$$TPR = \frac{TP}{N_+}, \quad N_+ = 5$$

$$FPR = \frac{FP}{FP + TN} = 1 - Specificity$$

Какую долю отрицательных ошибочно выбрали?

$$FPR = \frac{FP}{N_-}, \quad N_- = 7$$


Снижаем порог: наблюдаем TPR и FPR



Убираем порог с оси — получаем ROC

$$t \longmapsto (FPR(t), TPR(t))$$

Каждый порог —
точка в этих координатах.




Строим ROC по одному объекту

Каждому порогу соответствует точка (FPR, TPR). Меняем порог — получаем ROC-кривую.

Оценка вероятности · по убыванию


1	0.95	▲	1
2	0.88	■	1
3	0.82	▲	1
4	0.75	▲	1
5	0.68	■	1
6	0.61	■	1
7	0.55	▲	1
8	0.48	■	1
9	0.35	▲	1
10	0.30	■	1
11	0.18	■	1
12	0.08	■	1



$$(FPR, TPR) = \left(\frac{7}{7}, \frac{5}{5} \right)$$

Одинаковые score пересекают порог вместе: обе координаты могут измениться сразу.

Как читать ROC



(0, 0): никого не выбираем.

(1, 1): выбираем всех.

(0, 1): идеальная точка.


Лучше — ближе к верхнему левому углу.

Случайный порядок: доли выбранных объектов обоих классов растут примерно одинаково.

$$TPR \approx FPR$$

Конечная случайная кривая не обязана лежать точно на диагонали.

Как прочитать одну ROC-точку?




$$(FPR, TPR) = \left(\frac{1}{7}, \frac{3}{5} \right)$$

$$\approx (0.14, 0.60)$$

Нашли 60%
положительных объектов.

Ошибочно выбрали около 14%
отрицательных объектов.

Та же механика — больше значений score




Отдельный пример:
2000 объектов,
100 положительных.

Много небольших шагов
выглядят почти как гладкая
кривая.

Каждая точка по-прежнему
соответствует порогу.

ROC: ограничение задаётся процессом проверки




Хотим найти не менее 90%
мошенничества.

Какой минимальный FPR возможен?

$$TPR \geq 0.9$$

ROC-AUC: площадь под ROC-кривой



AUC

Area Under the ROC Curve —
площадь под ROC-кривой.

Есть и другой полезный смысл:
через пары положительных
и отрицательных объектов.

Возьмём одну положительно-отрицательную пару



Положительный объект



Отрицательный объект

Выбираем по одному объекту каждого класса
равномерно случайно.

Окажется ли score положительного выше?

$$5 \cdot 7 = 35 \text{ пар}$$

Считаем правильно упорядоченные пары

		0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
		▲	■	▲	▲	■	■	▲	■	▲	■	■	■
Положительный score	Отрицательных ниже												
	0.95	7											
	0.82	6											
	0.75	6											
	0.55	4											
	0.35	3											
	Итого	26											

$$5 \cdot 7 = 35 \text{ пар}$$

26 из 35 положительно-отрицательных пар упорядочены правильно.

Это число и есть ROC-AUC:

$$ROC-AUC = \frac{26}{35} \approx 0.743$$

ROC-AUC: общая попарная формула

В учебном примере посчитали правильные пары.

Запишем тот же подсчёт для произвольной выборки без равных оценок.

$$\text{ROCAUC} = \frac{1}{N_+ N_-} \sum_{i:y_i=1} \sum_{j:y_j=0} 1(s_i > s_j)$$

s_i — числовая оценка модели для объекта.

$N_+ N_-$ — число положительно-отрицательных пар.

Индикатор равен 1, если оценка положительного объекта выше.

Если оценки совпали

Положительный и отрицательный объекты получили одинаковый score.

Модель не определяет их взаимный порядок.

При случайном разрешении такой ничьей
правильный порядок возник бы в половине случаев.

$$\text{ROCAUC} = \frac{1}{N_+ N_-} \sum_{i:y_i=1} \sum_{j:y_j=0} \left[1(s_i > s_j) + \frac{1}{2} 1(s_i = s_j) \right]$$

Как понимать $AUC \approx 0.743$?

$$AUC = \frac{26}{35} \approx 0.743$$

Случайно выбираем один положительный и один отрицательный объект. Положительный получит более высокий score примерно в 74.3% пар.

При равных score пара вносит половину победы.


Это не Accuracy = 74.3%.

Это не «вероятности верны на 74.3%».

AUC сначала называли площадью, затем посчитали через пары. Почему два способа дают одно и то же число?

Один отрицательный объект — один прямоугольник под ROC

№1	№2	№3	№4	№5	№6	№7	№8	№9	№10	№11	№12
0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
▲	■	▲	▲	■	■	▲	■	▲	■	■	■



Один новый FP: объект №5 (0.68, класс 0).

Выше — №1, №3 и №4: уже найдены 3 TP.

Ширина: шаг FPR

$$\frac{1}{N_-} = \frac{1}{7}$$


Высота: TPR

$$\frac{3}{N_+} = \frac{3}{5}$$

$$\text{площадь} = \frac{1}{7} \cdot \frac{3}{5} = \frac{3}{35}$$

Это вклад трёх правильно упорядоченных пар с объектом №5.

Складываем вклады всех отрицательных объектов



Число положительных выше
каждого из семи отрицательных:

1, 3, 3, 4, 5, 5, 5

Суммарная площадь:

$$\frac{1 + 3 + 3 + 4 + 5 + 5 + 5}{35} = \frac{26}{35}$$

Каждая правильно упорядоченная пара учтена ровно один раз.

Суммарная площадь — те же 26 пар из 35.

Крайние значения ROC-AUC

$$AUC = 1$$

Идеальный порядок

$$AUC = 0.5$$

Случайный порядок

$$AUC < 0.5$$

Ошибочно упорядоченных
пар больше

AUC описывает качество ранжирования.

Score и sigmoid дают одинаковый порядок

$$z_i > z_j \iff \sigma(z_i) > \sigma(z_j)$$

Линейный score z · по убыванию

1	2	3	4	5	6	7	8	9	10	11	12
2.94	1.99	1.52	1.10	0.75	0.45	0.20	-0.08	-0.62	-0.85	-1.52	-2.44
▲	■	▲	▲	■	■	▲	■	▲	■	■	■

Оценка вероятности · по убыванию

1	2	3	4	5	6	7	8	9	10	11	12
0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
▲	■	▲	▲	■	■	▲	■	▲	■	■	■

▲ класс 1 ■ класс 0

Строго возрастающее преобразование не меняет ранжирование.

Что нам дала ROC — и чего она не показывает

ROC

$$t \longmapsto (FPR, TPR)$$

Все рабочие режимы
при изменении порога.

ROC-AUC

$$26/35 \approx 0.743$$

Качество ранжирования
в одном числе.

Насколько «чистой» окажется группа объектов,
которым модель дала положительный прогноз?

Та же ROC-точка — разная чистота выбранной группы

$$N = 10000, \quad TPR = 0.8, \quad FPR = 0.05$$

ПОЛОЖИТЕЛЬНЫХ 20%

$$TP = 1600, \quad FP = 400$$

$$Precision = \frac{1600}{2000} = 80\%$$

ПОЛОЖИТЕЛЬНЫХ 1%

$$TP = 80, \quad FP = 495$$

$$Precision = \frac{80}{575} \approx 14\%$$

Precision зависит от распространённости положительного класса.

Почему доля класса меняет Precision

$$TPR = \frac{TP}{TP + FN} = \frac{TP}{N_+} \qquad FPR = \frac{FP}{FP + TN} = \frac{FP}{N_-}$$

$$\pi = \frac{N_+}{N} \Rightarrow N_+ = \pi N, \quad N_- = (1 - \pi)N$$

$$TP = TPR \cdot N_+ = \pi N \cdot TPR \qquad FP = FPR \cdot N_- = (1 - \pi)N \cdot FPR$$

$$Precision = \frac{TP}{TP + FP} = \frac{\pi TPR}{\pi TPR + (1 - \pi)FPR}$$

TPR: знаменатель — все настоящие положительные, $TP + FN$.

FPR: знаменатель — все настоящие отрицательные, $FP + TN$.

Precision: знаменатель — все прогнозы класса 1, $TP + FP$.

Вернёмся к очереди ручной проверки

ROC показывает охват двух настоящих классов при разных порогах;
чистоту выбранной положительной группы показывает пара Precision–Recall.

Какую долю всего мошенничества
поймаем?

Какая доля проверяемых платежей
действительно мошенническая?

Recall

Precision


$$t \longmapsto (\textit{Recall}(t), \textit{Precision}(t))$$

Две стороны одного отбора: охват класса 1 и чистота очереди.

Строим PR по тем же порогам

Оценка вероятности · по убыванию

1	0.95	▲	1
2	0.88	■	1
3	0.82	▲	1
4	0.75	▲	1
5	0.68	■	1
6	0.61	■	1
7	0.55	▲	1
8	0.48	■	1
9	0.35	▲	1
10	0.30	■	1
11	0.18	■	1
12	0.08	■	1




$$(Recall, Precision) = \left(\frac{5}{5}, \frac{5}{12} \right)$$

Вошёл отрицательный: Recall прежний, Precision уменьшился.

Точки — отдельные пороговые состояния. Ступени — выбранный способ изображения между ними.

PR на большой выборке: много маленьких ступеней




Те же 2000 объектов,
100 положительных.

При большом числе объектов
ступени очень мелкие.

$$Precision_{\text{random}} \approx \pi = 0.05$$

При случайном порядке ожидаемая
Precision примерно равна доле класса
1.

PR: требования к очереди ручной проверки



Хотим поймать хотя бы 80% мошенничества.

Какой максимальный Precision возможен?

$$Recall \geq 0.8$$

Как свести PR-ранжирование к одному числу?

При снижении порога Recall растёт только при нахождении положительного объекта.
Посмотрим на Precision именно в эти моменты.

Оценка вероятности · по убыванию

1	2	3	4	5	6	7	8	9	10	11	12
0.95	0.88	0.82	0.75	0.68	0.61	0.55	0.48	0.35	0.30	0.18	0.08
▲	■	▲	▲	■	■	▲	■	▲	■	■	■

▲ класс 1 ■ класс 0

Precision@1

$$= 1$$

Precision@3

$$= \frac{2}{3}$$

Precision@4

$$= \frac{3}{4}$$

Precision@7

$$= \frac{4}{7}$$

Precision@9

$$= \frac{5}{9}$$

Считаем от начала списка до этой позиции включительно.

Отрицательный объект меняет Precision, но Recall при этом не растёт.

Average Precision: усредняем по найденным положительным

$$AP = \frac{1}{5} \left(1 + \frac{2}{3} + \frac{3}{4} + \frac{4}{7} + \frac{5}{9} \right) \approx 0.709$$

Когда в списке появляется очередной положительный объект, смотрим Precision среди всех объектов от начала списка до этой позиции включительно.

Чем ближе положительные объекты к началу списка и чем меньше отрицательных перед ними, тем выше AP.

Здесь средняя Precision на позициях 1, 3, 4, 7 и 9 равна 0.709.

Почему в общей формуле появляется прирост Recall

Каждый найденный положительный увеличивает Recall на:

$$\Delta Recall = \frac{1}{N_+} = \frac{1}{5}$$


$$AP = \frac{1}{5} \cdot 1 + \frac{1}{5} \cdot \frac{2}{3} + \frac{1}{5} \cdot \frac{3}{4} + \frac{1}{5} \cdot \frac{4}{7} + \frac{1}{5} \cdot \frac{5}{9}$$

$$AP = \sum_k \Delta Recall_k \cdot Precision_k$$

Если Recall не изменился, $\Delta Recall = 0$:

такой шаг не добавляет отдельного веса в AP.

AP как площадь под ступенчатой PR-кривой



ширина = $\Delta Recall_k$

высота = $Precision_k$

Площадь прямоугольника:


$$\Delta Recall_k \cdot Precision_k$$

$$AP = \sum_k \Delta Recall_k \cdot Precision_k$$

Площадь здесь — геометрическое изображение уже определённой AP, а не новая формула: используем соответствующую ступенчатую конструкцию.

AP и площадь с линейной интерполяцией — не одно и то же

Одни PR-точки — два разных способа заполнить промежутки



AP — площадь ступенчатой конструкции;
трапеции соответствуют другой интерполяции между теми же точками.

Average Precision · `average_precision_score`

Площадь трапеций · `auc(recall, precision)`

Ранжирование: итог и следующий вопрос

ROC-AUC

Попарное качество порядка.

Не требует одного фиксированного порога.

PR / AP

Качество положительного отбора.

Зависит от доли положительного класса.

Обе группы показателей оценивают порядок и отбор, но не говорят, можно ли доверять числу 0.8 как вероятности 80%.

**Следующий вопрос:
что означают сами численные вероятности?**

Один порядок — две вероятностные шкалы

Порядок групп одинаковый, вероятностные шкалы разные.

Наблюдаемая частота события	Модель А	Модель В
0.10	0.10	0.0122
0.30	0.30	0.1552
0.50	0.50	0.5000
0.70	0.70	0.8448
0.90	0.90	0.9878

Модель А согласуется с наблюдаемыми частотами; модель В даёт более крайние значения.
ROC-AUC и AP одинаковы: ранжирование не изменилось.

Согласуется ли вероятность с частотой?

Рассмотрим группу, где событие наблюдалось примерно в 70% случаев.

Наблюдаемая частота = 0.70

МОДЕЛЬ А

0.70

Совпадает с наблюдаемой частотой.

МОДЕЛЬ В

0.8448

Вероятность события завышена.

Калибровка — согласование прогнозируемых вероятностей с наблюдаемыми частотами среди объектов с похожими прогнозами.

От групп данных к reliability diagram

Для группы B_k :

$$\bar{p}_k = \frac{1}{|B_k|} \sum_{i \in B_k} \hat{p}_i$$


Средний прогноз модели В в группе.

$$\bar{y}_k = \frac{1}{|B_k|} \sum_{i \in B_k} y_i$$

Наблюдаемая доля положительных исходов.


$$(\bar{p}_k, \bar{y}_k)$$

$$(\bar{p}_1, \bar{y}_1) = (0.0122, 0.10)$$



3. Наносим все пять пар:
получаем калибровочную диаграмму.

Как читать reliability diagram



Модель А — на диагонали:
вероятность равна частоте.

Модель В ниже диагонали:
вероятность завышена.

Модель В выше диагонали:
вероятность занижена.

Эмпирическая диагностика: форма зависит от размера выборки и группировки.

Хорошая калибровка: различает ли модель объекты?

Положительный класс составляет 10% выборки.

МОДЕЛЬ 1 · ПОСТОЯННЫЙ ПРОГНОЗ

$$\hat{p}(x) = 0.10$$

Всем объектам выдаёт 0.10.
Около 10% положительных —
прогноз откалиброван.

Вероятности одинаковы:
модель не различает объекты.

Обе модели откалиброваны, но вторая различает группы.

Калибровка показывает соответствие шкалы частотам; для сравнения вероятностных прогнозов одним числом посмотрим на Log loss и Brier.

МОДЕЛЬ 2 · ДВЕ ГРУППЫ

Половине объектов выдаёт 0.02;
в этой группе около 2% положительных.

Другой половине — 0.18;
там около 18% положительных.

$$\frac{1}{2} \cdot 0.02 + \frac{1}{2} \cdot 0.18 = 0.10$$

Log loss: один объект и вся выборка

LOSS ОДНОГО НАБЛЮДЕНИЯ

$$L(y_i, \hat{p}_i) = -y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)$$

СРЕДНЯЯ LOG LOSS НА ОЦЕНОЧНОЙ ВЫБОРКЕ

$$\text{LogLoss} = \frac{1}{N} \sum_{i=1}^N L(y_i, \hat{p}_i)$$

На обучении это была эмпирическая целевая функция R_n .

На отложенных прогнозах то же выражение — метрика качества.

Уверенная ошибка дорого стоит

$$y = 1$$

$$p = 0.9 \Rightarrow -\log p \approx 0.105$$

$$p = 0.01 \Rightarrow -\log p \approx 4.605$$

Меньше — лучше. Сравниваем модели на одной оценочной выборке:
между собой и с baseline — например, постоянным прогнозом базовой частоты.

Brier score: MSE вероятностных прогнозов

$$y = 1, p = 0.9 \Rightarrow (1 - 0.9)^2 = 0.01 \qquad y = 1, p = 0.2 \Rightarrow (1 - 0.2)^2 = 0.64$$

$$Brier = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{p}_i)^2$$

Меньше — лучше. Сравниваем модели на одной выборке и с baseline.

$$Y \in \{0, 1\} \implies \mathbb{E}[Y \mid X = x] = P(Y = 1 \mid X = x)$$

Поэтому квадратичная ошибка бинарного Y естественно нацелена на вероятность.

Диаграмма и численная оценка дополняют друг друга

Инструмент	Что показывает
Reliability diagram	Где вероятности систематически завышены или занижены
Log loss / Brier	Общее качество вероятностных прогнозов одним числом

Одно число удобно для сравнения моделей;
диаграмма показывает структуру ошибок калибровки.

Меньшие Log loss или Brier сами по себе не доказывают лучшую калибровку.

Один прогноз — три вопроса о качестве

$$score / \hat{p}(x)$$



РЕШЕНИЕ ПРИ ПОРОГЕ

Матрица ошибок
Precision / Recall / F1



РАНЖИРОВАНИЕ

ROC-AUC
PR / AP



СМЫСЛ ВЕРОЯТНОСТЕЙ

Калибровка
Log loss / Brier

Сначала формулируем задачу и действие.
Потом выбираем способ оценки.

От PR-точки к ROC-точке

$$\textit{Precision} = P, \quad \textit{Recall} = R, \quad r = \frac{N_+}{N}$$

Выразите TPR и FPR через P , R , r .

Кратко поясните, почему появляется r .