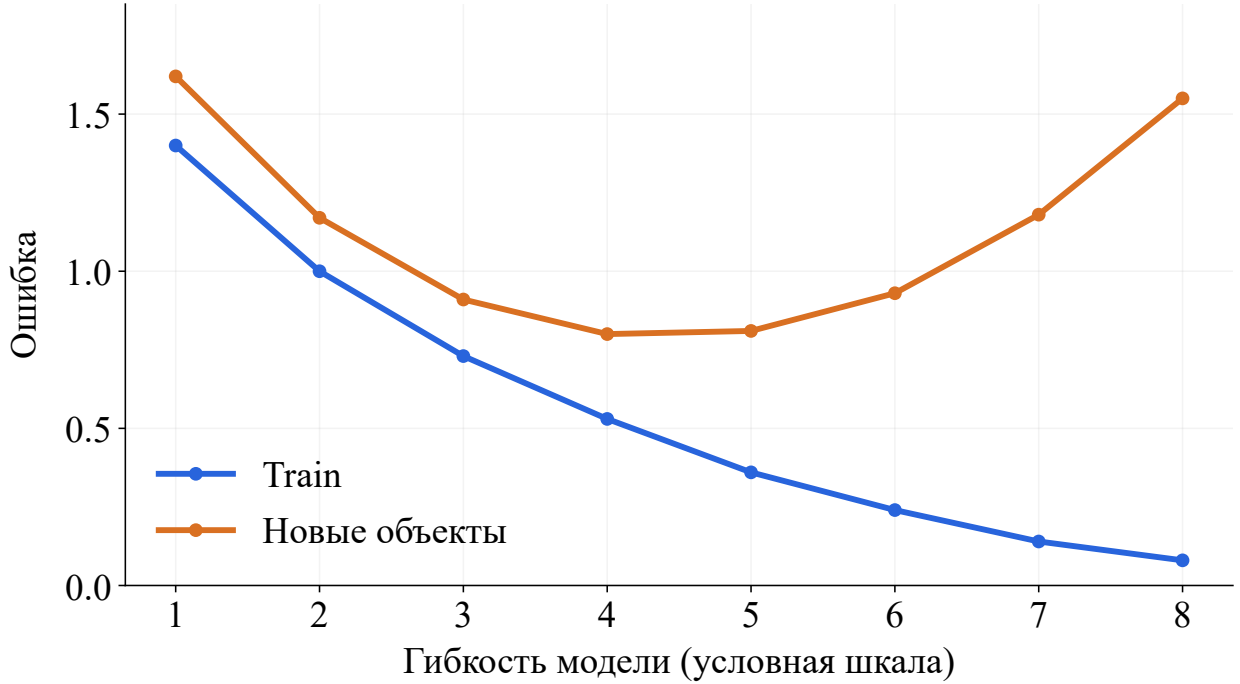
КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ · НЕДЕЛЯ 6

Регуляризация и кросс-валидация

Как ограничивать подгонку?

Как надёжнее оценивать модель?

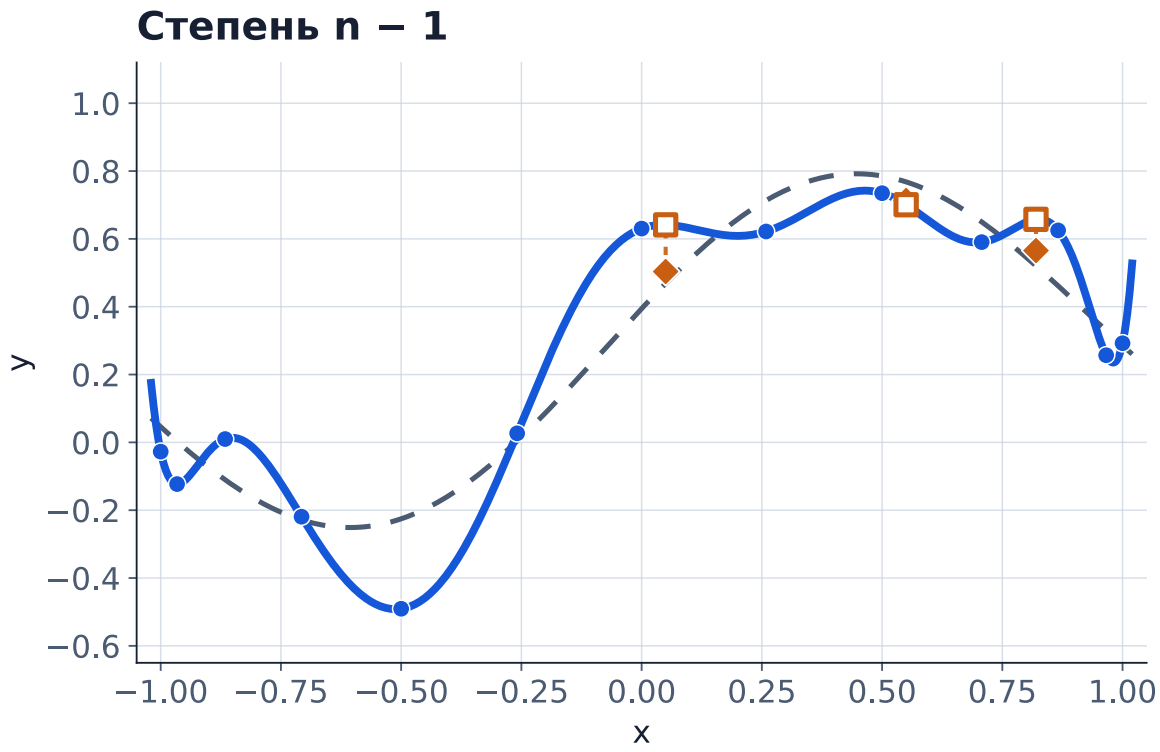
Меньше ошибка на train — лучше новые прогнозы?



Если ошибка на обучении уменьшилась, обязательно ли она уменьшилась на новых наблюдениях?

Схематические кривые: показывают возможное поведение ошибок при росте гибкости. Их конкретная форма зависит от данных и модели.

Гибкая модель может подстроиться к шуму



Один признак, одни обучающие точки.

Более гибкая функция проходит через все наблюдения — вместе с их случайными отклонениями.

Малая train-ошибка может сопровождаться худшими прогнозами между точками.

- Обучающие наблюдения
- Прогнозы для новых объектов
- Новые фактические значения
- Исходная синтетическая зависимость

Связанные признаки: две модели стоимости квартир

Общая площадь — x_1, жилая — x_2. Прогноз — в условных единицах; свободного члена нет.

$$f_A(x) = 3x_1 - 3x_2, \qquad f_B(x) = x_1$$

Квартира	x_1 Общая, м²	x_2 Жилая, м²	A	B
1	60	40	60	60
2	75	50	75	75

При $x_2 = \frac{2}{3}x_1$ обе модели дают один и тот же прогноз.

Новое соотношение площадей — разные прогнозы

$$f_A(x) = 3x_1 - 3x_2, \qquad f_B(x) = x_1$$

Квартира	x_1 Общая, м²	x_2 Жилая, м²	A	B
1	60	40	60	60
2	75	50	75	75
Новая	60	50	30	60

$$f_A(60, 50) = 180 - 150 = 30 \qquad f_B(60, 50) = 60$$

Общая площадь осталась 60 м², жилая выросла с 40 до 50 м². Прогноз A снизился с 60 до 30, прогноз B остался 60.

Регуляризация: ограничиваем выбор решения

Регуляризация — управление обучением с помощью ограничений на сложность модели или штрафов в целевой функции.

Контроль переобучения

Сдерживать подстройку к случайным особенностям обучающих данных.

Устойчивость решения

Сдерживать большие компенсирующие коэффициенты и их реакцию на изменение данных.

В линейных моделях будем ограничивать величину коэффициентов при сопоставимых масштабах признаков.

Слишком сильное ограничение может ухудшить прогнозы. Его пользу проверяем по отложенным данным.

Исходная задача — метод наименьших квадратов

$$f_{\beta_0,\beta}(x) = \beta_0 + x^\top \beta$$

β_0 — свободный член; $\beta = (\beta_1, \ldots, \beta_p)^\top$ — коэффициенты при признаках.

$$R_n(\beta_0, \beta) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \beta_0 - x_i^\top \beta)^2$$

$$(\hat{\beta}_0, \hat{\beta}) \in \arg\min_{\beta_0,\beta} R_n(\beta_0, \beta)$$

МНК выбирает минимальную MSE; R_n — эмпирический риск.

При одинаковых столбцах МНК видит только сумму

$$x_2 = x_1, \quad \beta_0 = 0 \quad \Rightarrow \quad f(x) = (\beta_1 + \beta_2)x_1$$

β_1	β_2	Сумма
3	-2	1
1	0	1
0.5	0.5	1

Если сумма коэффициентов равна 1, прогнозы и MSE одинаковы на всех таких обучающих объектах.

Если один набор оптимален по МНК, то оптимальны и все наборы с той же суммой. Коэффициенты определяются неоднозначно.

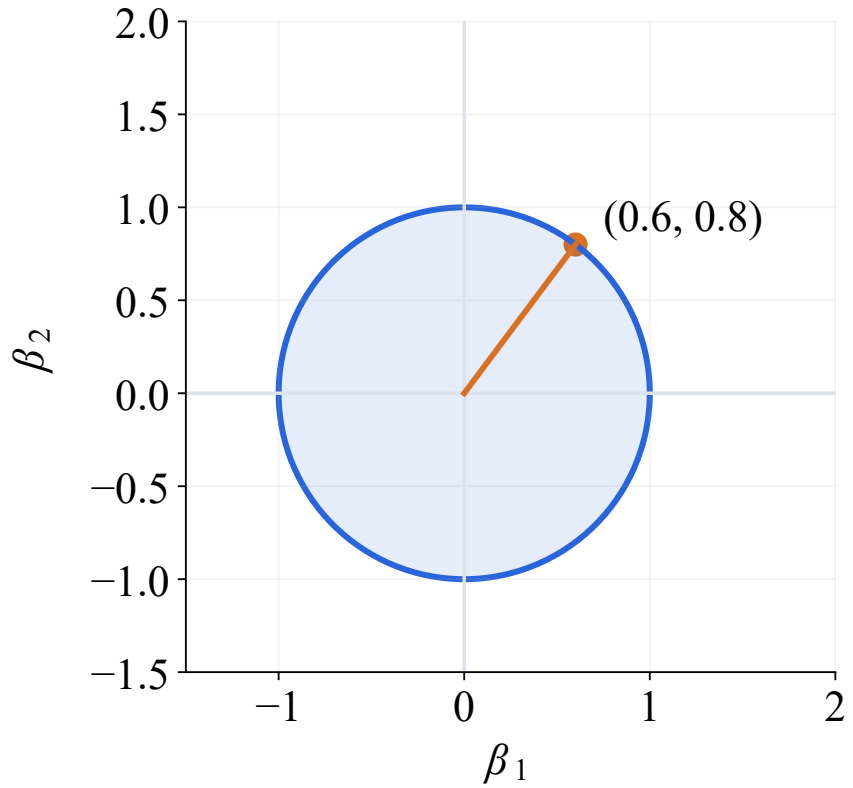
Добавим требование к величине коэффициентов

β_1	β_2	Сумма	$\|\|\beta\|\|_2^2$
3	-2	1	13
1	0	1	1
0.5	0.5	1	0.5

Одинаковая подгонка допускает и большие компенсирующие коэффициенты, и более умеренные.

Идея Ridge: учитывать величину всего вектора коэффициентов при выборе решения.

L2-норма — длина вектора коэффициентов



$$\|\beta\|_2 = \sqrt{\sum_{j=1}^{p} \beta_j^2}$$

$$\|\beta\|_2^2 = \sum_{j=1}^{p} \beta_j^2$$

$$\|\beta\|_2^2 \leq t$$

В двух координатах — диск радиуса $\sqrt{t}$.

Ridge: минимизируем MSE в допустимой области

$$\min_{\beta_0,\beta} R_n(\beta_0, \beta)$$

$$\text{при } \|\beta\|_2^2 \leq t, \qquad t \geq 0$$

Меньшее t оставляет более узкую область допустимых коэффициентов. Ищем лучшую подгонку внутри неё.

$t = 1:$ $(3, -2)$ недопустимы: квадрат нормы 13. $(1, 0),\ (0.5, 0.5)$ допустимы: квадрат нормы 1 и 0,5.

Если решение МНК лежит внутри области, ограничение сохраняет его.

Та же идея через штраф: цена больших коэффициентов

$$J_\lambda^{\text{Ridge}}(\beta_0, \beta) = R_n(\beta_0, \beta) + \lambda \|\beta\|_2^2$$

Первое слагаемое — ошибка подгонки.

Второе — цена величины коэффициентов.

$$\lambda \geq 0, \qquad \lambda = 0 \;\Rightarrow\; \text{МНК}$$

При большем λ уменьшение нормы получает больший вес относительно уменьшения MSE.

При согласованном выборе t и λ ограниченная и штрафная задачи имеют общее оптимальное решение.

При равной MSE штраф различает решения

$$R_n = 2, \qquad \lambda = 0.2, \qquad J_\lambda = R_n + \lambda \|\beta\|_2^2$$

β_1	β_2	Сумма	$\|\beta\|_2^2$	Штраф	$J_{0.2}$
3	-2	1	13	2,6	4,6
1	0	1	1	0,2	2,2
0.5	0.5	1	0.5	0,1	2,1

Из трёх кандидатов меньший критерий у (0,5; 0,5).

Во всей задаче Ridge сопоставляет оба слагаемых: возможен обмен небольшой прибавки MSE на существенное уменьшение нормы.

Чувствительность: изменим только второй признак

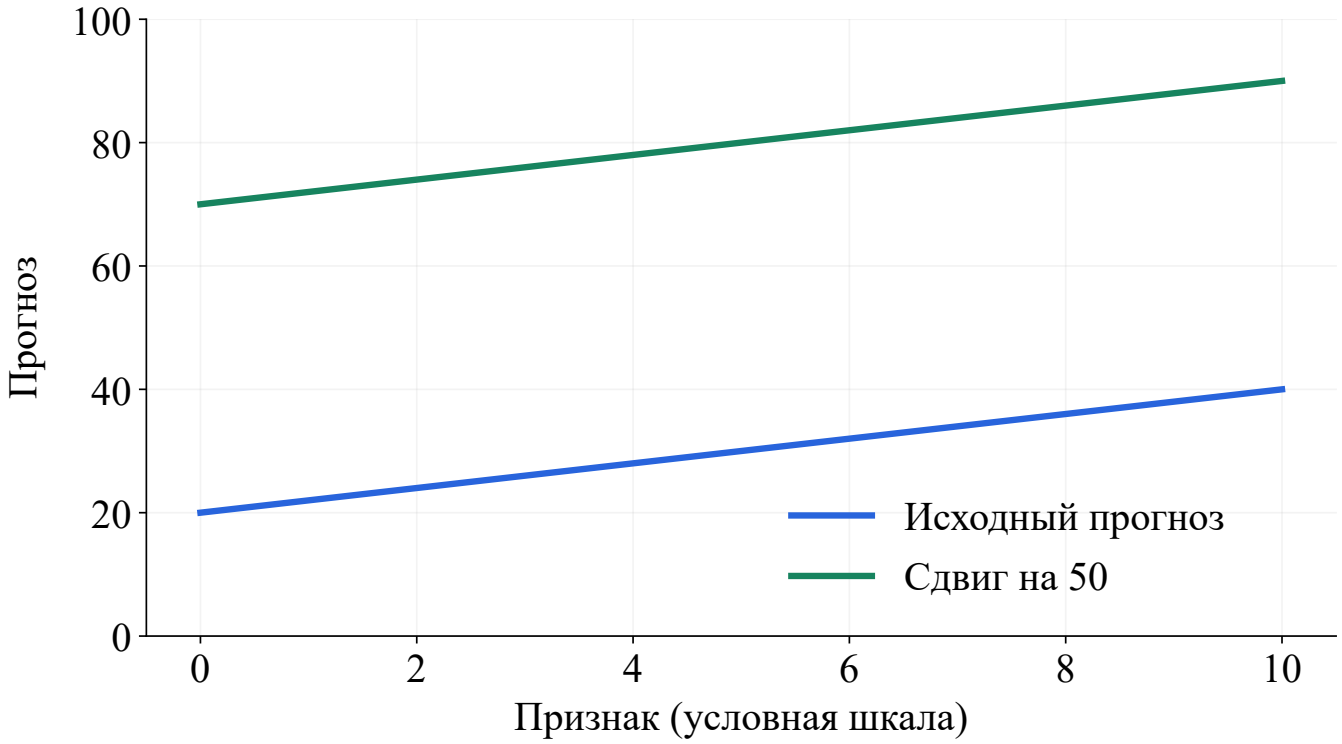
$$x = (10, 10), \qquad x' = (10, 10.1), \qquad f(x) = 10$$

Коэффициенты	Новый прогноз	Изменение
(30; −29)	7,1	−2,9
(3; −2)	9,8	−0,2
(1; 0)	10	0
(0,5; 0,5)	10,05	+0,05

$$\Delta f = \beta^\top \Delta x$$

При коэффициенте −29 изменение признака на 0,1 сдвигает прогноз на −2,9.

Свободный член отвечает за сдвиг прогноза



$$y_i' = y_i + 50$$

$$\beta_0' = \beta_0 + 50, \quad \beta' = \beta$$

Остатки и MSE сохраняются. Штраф на наклоны тоже остаётся прежним.

Обычно не штрафуем свободный член: смена уровня у должна сдвигать прогнозы, сохраняя наклоны.

Как изменились нормальные уравнения Ridge?

Центрируем признаки и y. X_c содержит p признаков без столбца единиц; свободный член восстановим отдельно.

МНК

$$X_c^\top X_c \hat{\beta} = X_c^\top y_c$$

Ridge

$$(X_c^\top X_c + n\lambda I)\hat{\beta} = X_c^\top y_c$$

При λ > 0 матрица Ridge обратима и коэффициенты единственны — даже при линейно зависимых признаках.

$$\hat{\beta}_0 = \bar{y} - \bar{x}^\top \hat{\beta}$$

Множитель n появляется из нормировки $R_n = RSS/n$; I — единичная матрица размера p × p.

Эксперимент: повторные выборки со связанными признаками

$$x_1 = z + \varepsilon_1, \qquad x_2 = z + \varepsilon_2$$

$$y = 3z + \varepsilon_y$$

Оба признака повторяют одну скрытую величину z с небольшим независимым шумом.

100 независимых выборок по 70 объектов.

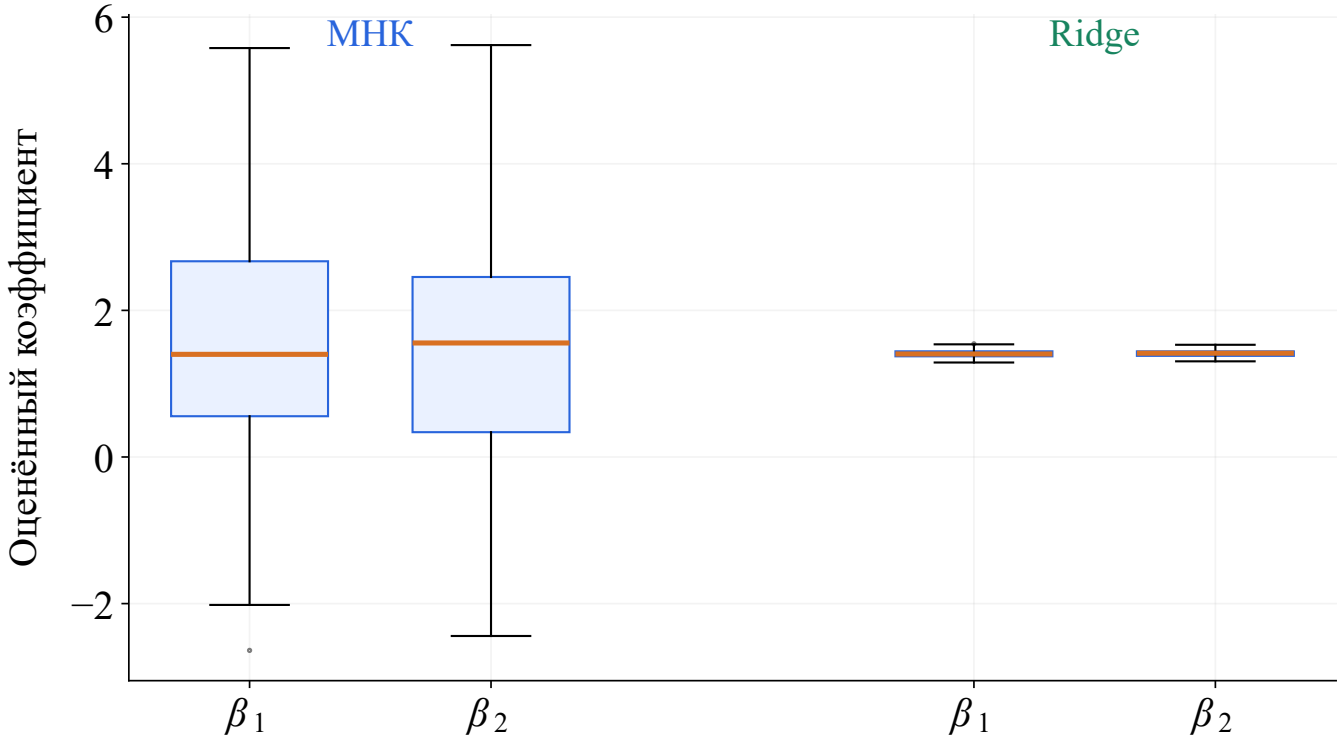
На каждой заново обучаем МНК и Ridge, записываем два коэффициента.

$$\lambda = 8/70 \approx 0.114$$

z — стандартная нормальная величина; стандартные отклонения шумов признаков 0,035, шума y — 0,75.

Насколько меняются коэффициенты от выборки к выборке?

Ridge уменьшает разброс оценённых коэффициентов



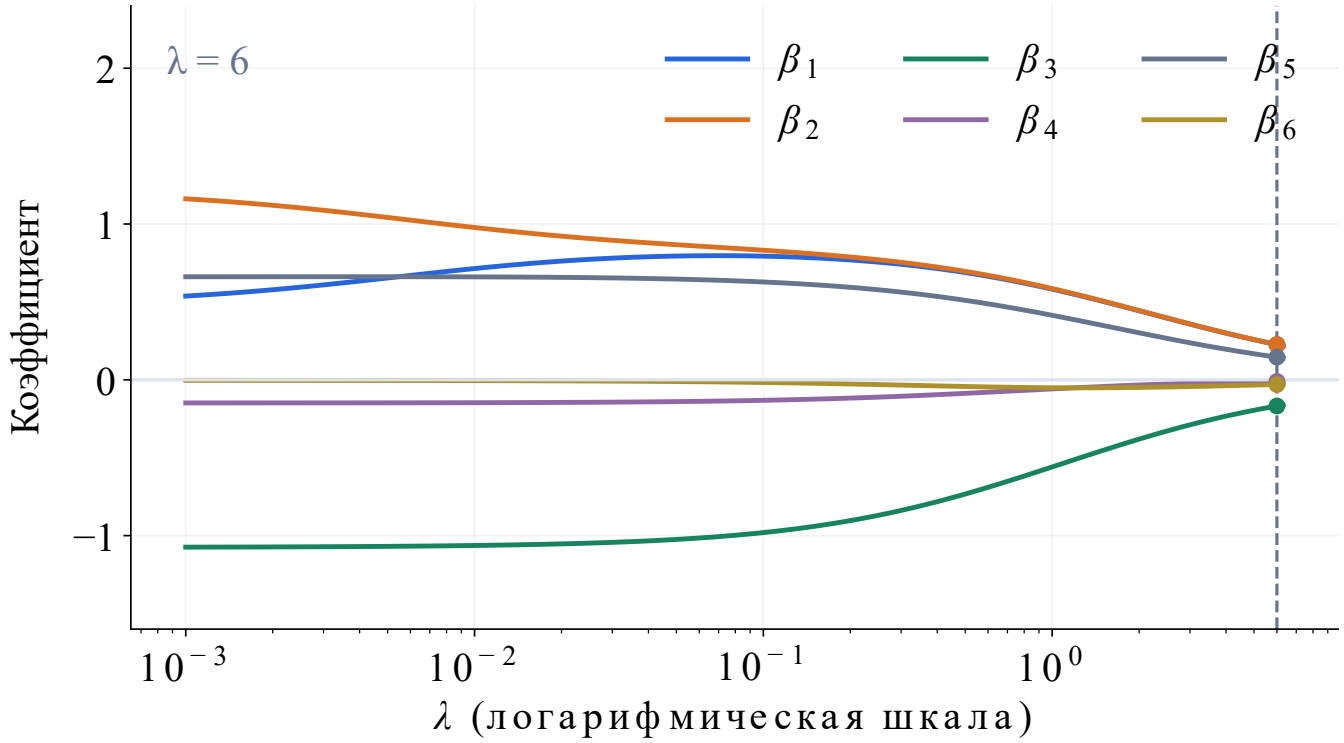
Один прямоугольник — центральные 50% из 100 оценок соответствующего коэффициента; линия внутри — медиана.

У МНК большие положительные и отрицательные вклады компенсируют друг друга.

При выбранном штрафе Ridge оценки заметно менее изменчивы.

Качество на новых объектах проверяем отдельной валидацией.

Траектории Ridge: одна выборка, разные λ



Признаки 1–2 сильно коррелируют; 3 и 5 информативны; 4 и 6 — шумовые.

Для каждого λ обучаем отдельную модель на тех же данных.

130 объектов; 6 стандартизированных признаков. Каждая линия — один $\hat{\beta}_j(\lambda)$.

Общий квадрат нормы не растёт. Отдельные коэффициенты могут перераспределять вклад.

При сильном штрафе наклоны стремятся к нулю, а прогнозы — к среднему y.

Одни прогнозы — разные единицы и штрафы

Площадь в м²

$$x = 60, \quad \beta = 20$$

$$\beta x = 1200$$

$$\beta^2 = 400$$

Та же площадь в см²

$$x' = 600\,000, \quad \beta' = 0.002$$

$$\beta' x' = 1200$$

$$(\beta')^2 = 0.000004$$

Прогноз сохранился, цена этого коэффициента в L2-штрафе изменилась в 10^8 раз.

$$x_{ij}^{\text{std}} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

Перед регуляризацией приводим признаки к сопоставимому масштабу. Средние и s считаем по обучающим данным.

От Ridge к Lasso: ограничим сумму модулей

$$\text{Ridge: } \|\beta\|_2^2 = \sum_j \beta_j^2$$

$$\text{Lasso: } \|\beta\|_1 = \sum_j |\beta_j|, \qquad \|(3,-2)\|_1 = 5$$

Ограниченная задача

$$\min_{\beta_0,\beta} R_n \quad \text{при } \|\beta\|_1 \le t$$

Штрафная задача

$$J_\lambda^{\text{Lasso}} = R_n + \lambda\|\beta\|_1$$

Lasso сдерживает величину коэффициентов с помощью L1. Формула линейного прогноза остаётся прежней; свободный член не штрафуется.

L1 может давать разреженное решение

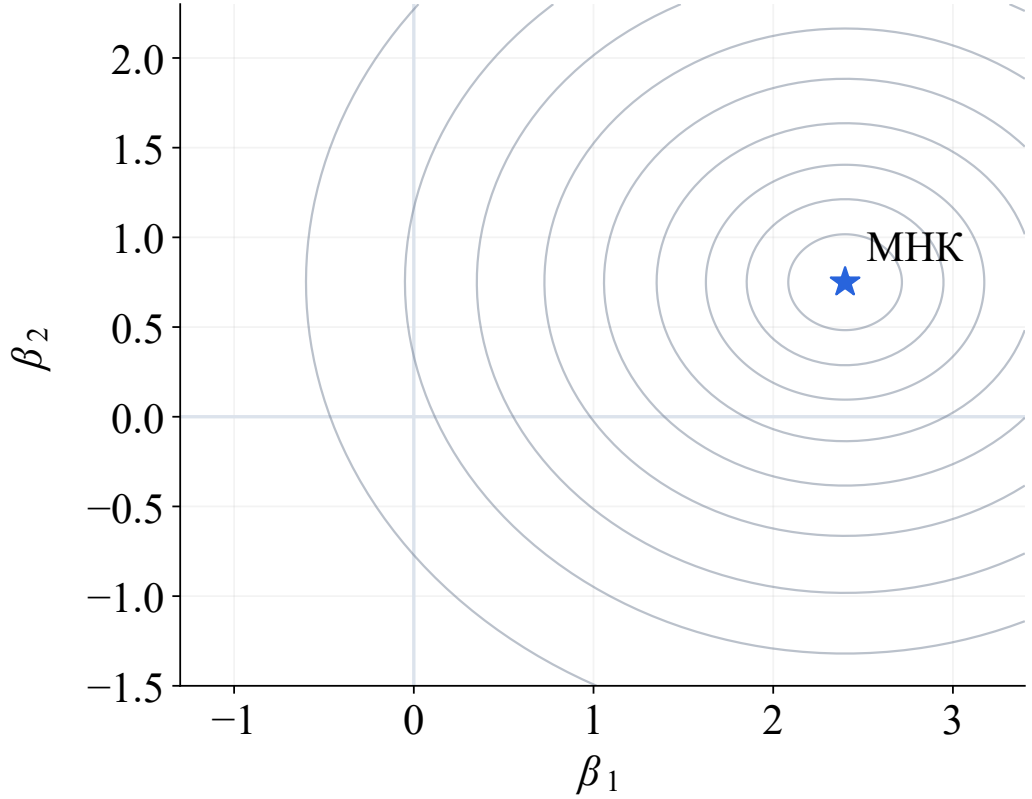
L1-штраф имеет изломы при нулевых коэффициентах. Минимум может оказаться в одной из таких точек — механизм увидим на геометрии.

$$f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3$$

$$\hat{\beta}_2 = 0 \quad \Rightarrow \quad \hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_3 x_3$$

Нулевой коэффициент исключает признак из правила прогноза. Если многие коэффициенты равны нулю, решение называют разреженным.

Плоскость коэффициентов и линии уровня

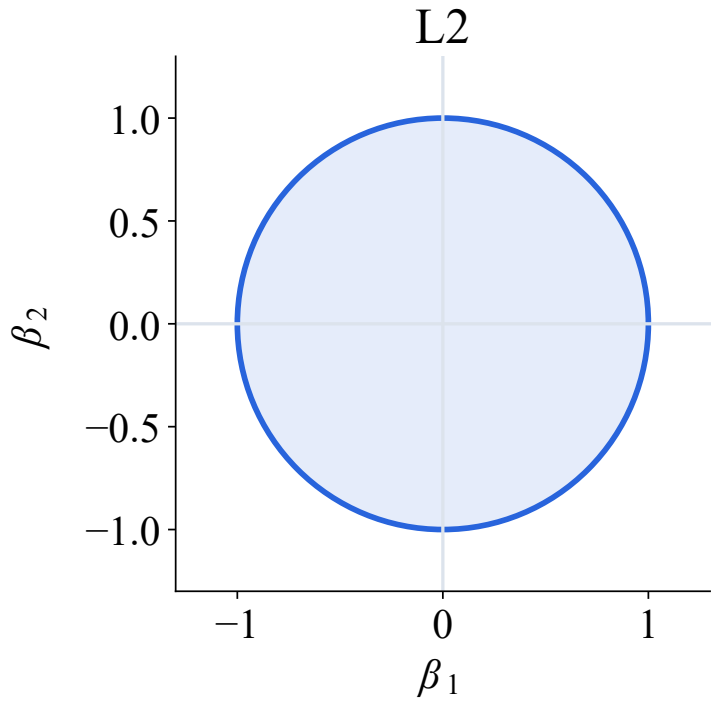


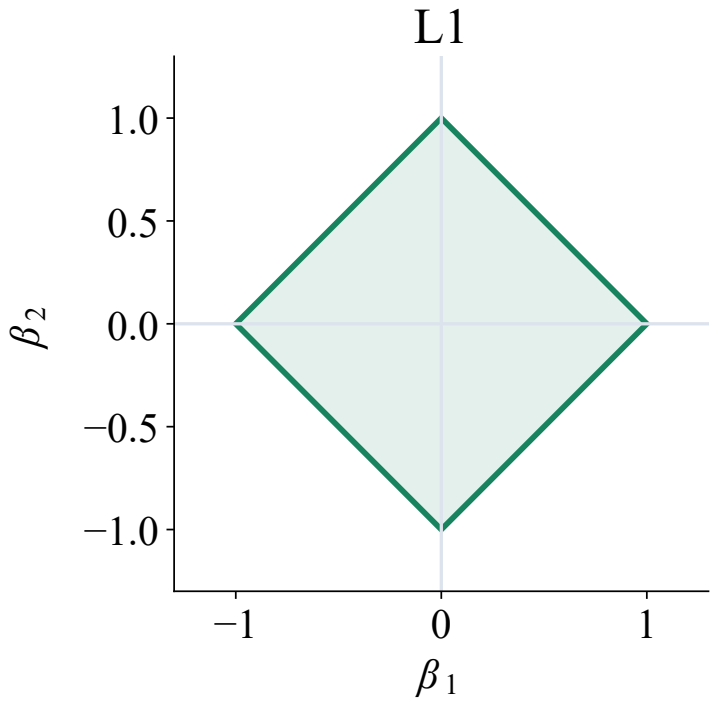
Каждая точка (β_1, β_2) — одна модель.

На одной линии уровня — одинаковая MSE.

Если решение МНК единственно, линии уровня MSE в пространстве двух коэффициентов образуют вложенные эллипсы. В центре — минимум МНК.

Круг L2 и ромб L1



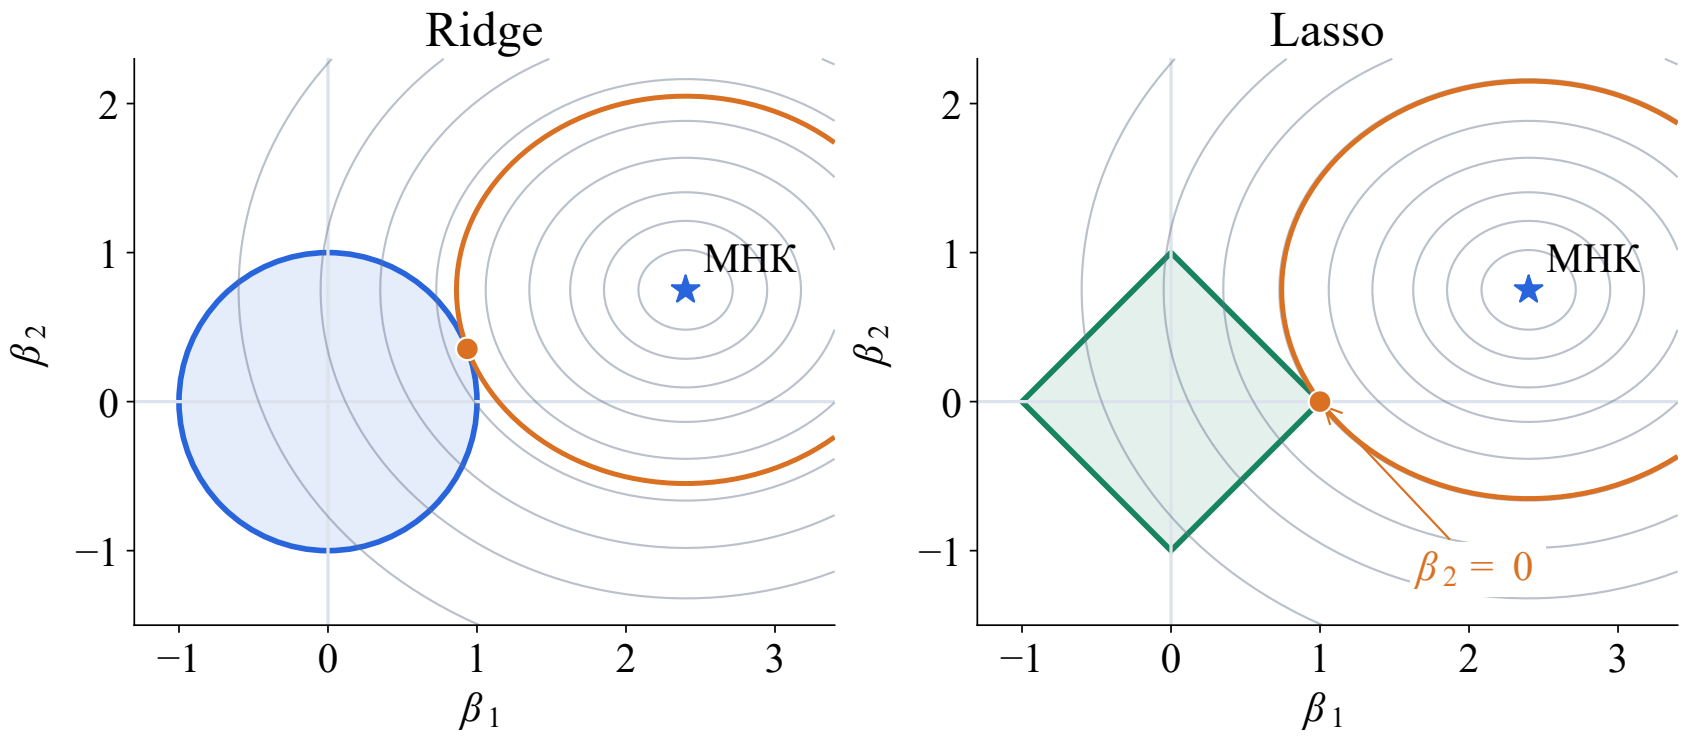


$$\beta_1^2 + \beta_2^2 \leq t$$

$$|\beta_1| + |\beta_2| \leq t$$

Области допустимых коэффициентов; на рисунке t = 1.

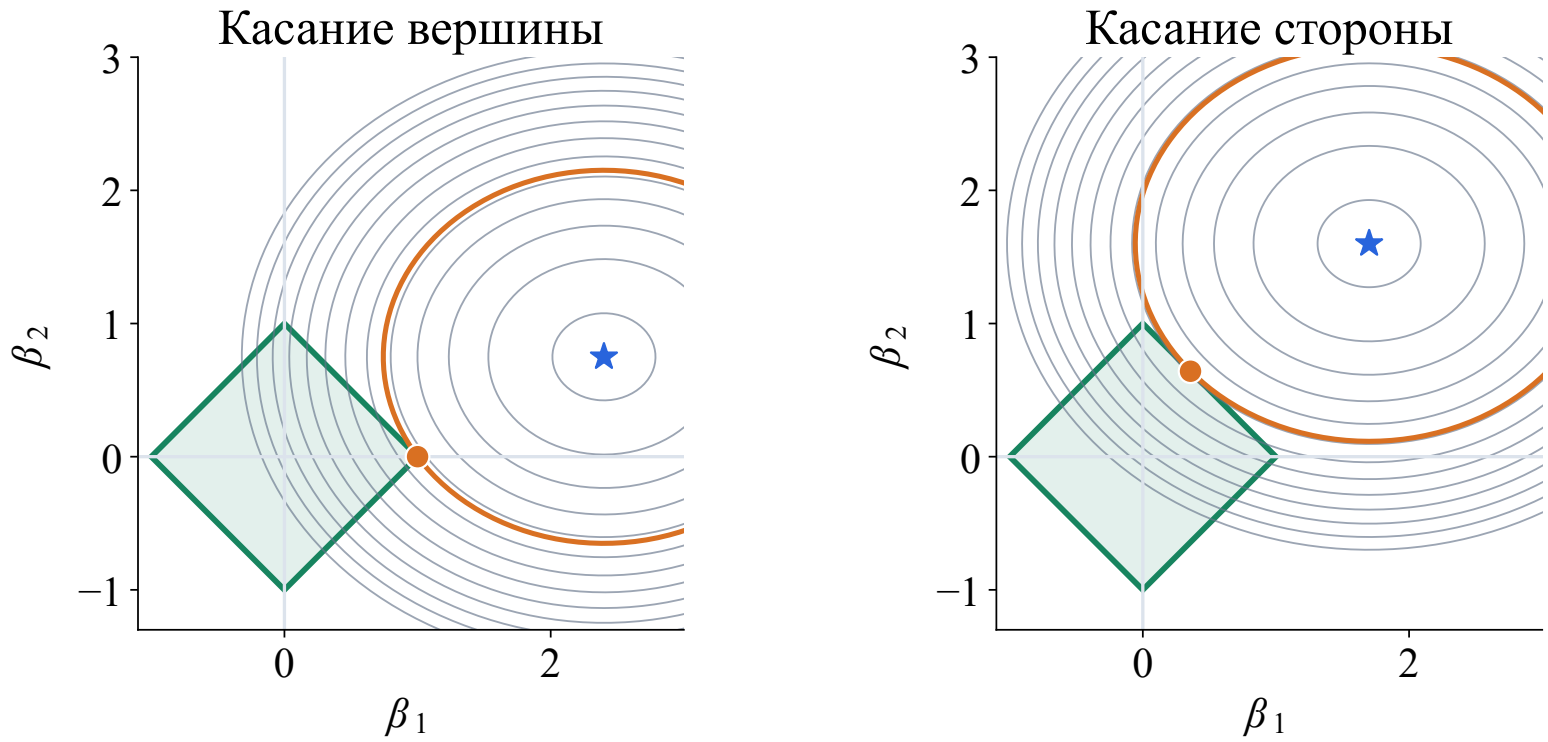
Как ограничение сдвигает минимум



Касание вершины: второй коэффициент равен нулю.

От центра расширяем линии уровня до первого касания с областью.

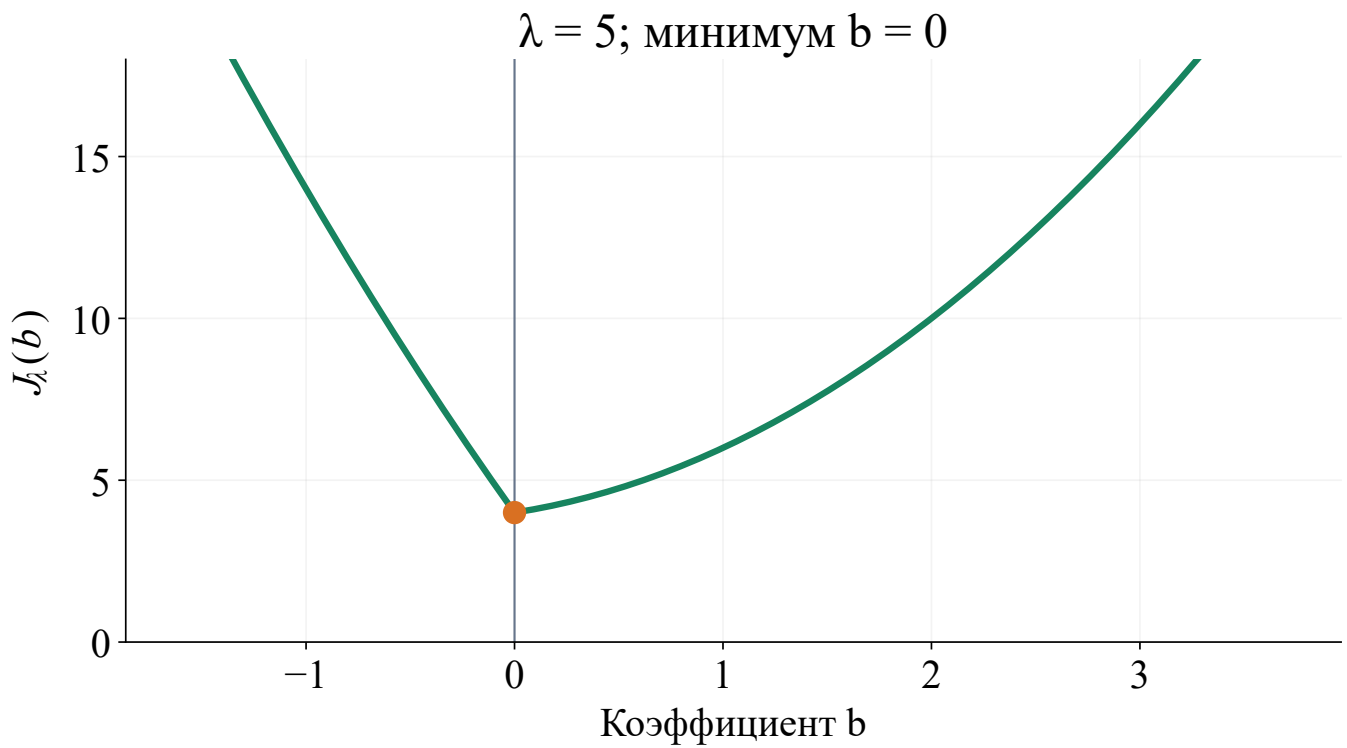
Два варианта касания L1-области



Касание может происходить в вершине или на стороне.

Lasso способствует разреженности; результат зависит от данных и λ.

Излом может быть минимумом без обычной производной



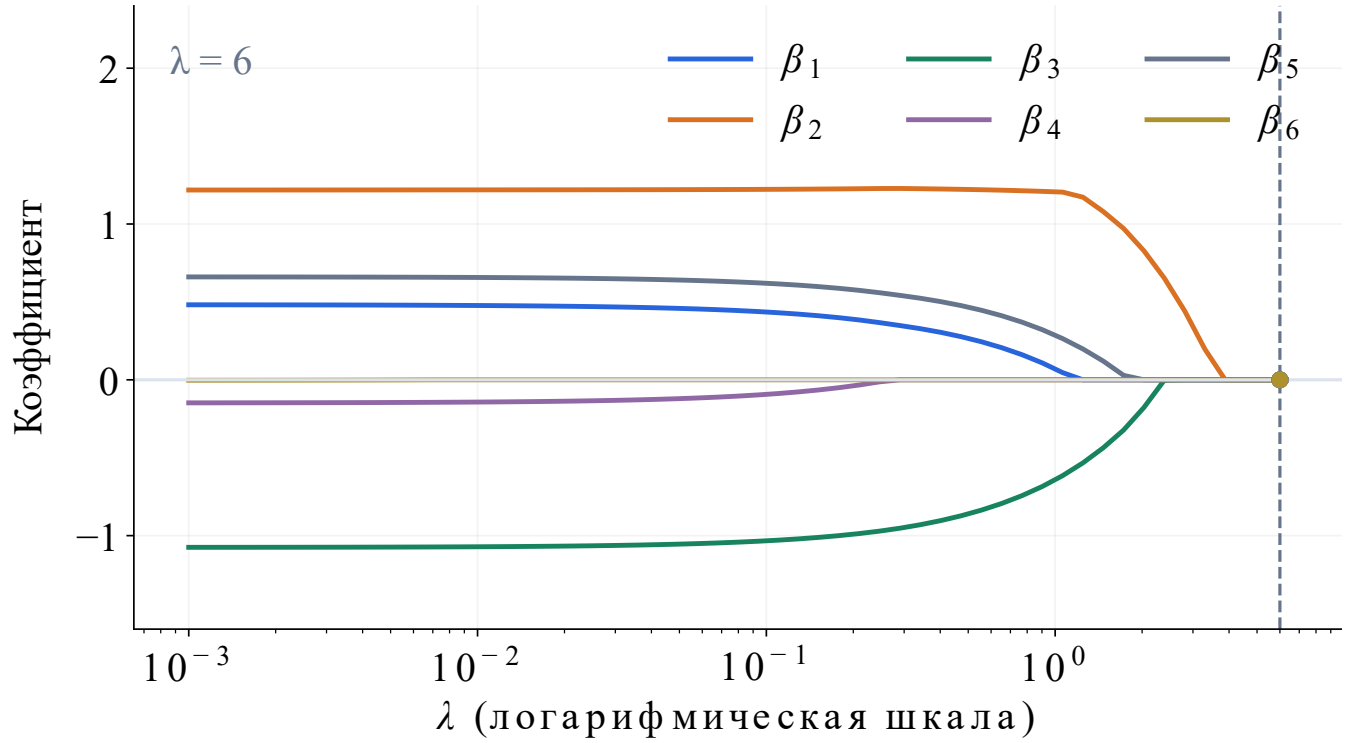
$$J_\lambda(b) = (b-2)^2 + \lambda|b|$$

При λ = 5 минимум остаётся в b = 0.

При λ ≥ 4 движение из нуля в любую сторону увеличивает функцию.

В изломе нет обычной производной, но сравнение значений слева и справа всё равно определяет минимум.

Траектории Lasso: координаты доходят до нуля



Признаки 1–2 сильно коррелируют; 3 и 5 информативны; 4 и 6 — шумовые.

Те же данные, что для Ridge: 130 объектов, 6 стандартизированных признаков.

Ненулевых коэффициентов: 0

Lasso подбирает коэффициенты совместно: снижение ошибки сопоставляется с L1-штрафом.

При сильном штрафе все наклоны нулевые — остаётся постоянный прогноз.

Какие признаки исключены в этом эксперименте?

Признаки 1 и 2 почти дублируются; 3 и 5 связаны с y; 4 и 6 — шумовые. Коэффициенты оценены совместно на тех же данных.

λ	β_1	β_2	β_3	β_4	β_5	β_6
0.01	0,48	1,22	-1,07	-0,14	0,66	**0,00**
0.3	0,34	1,23	-0,95	**0,00**	0,54	**0,00**
3	**0,00**	0,35	**0,00**	**0,00**	**0,00**	**0,00**

При λ = 0,3 шумовые координаты нулевые.

При λ = 3 исчезает и полезный третий признак, из связанной пары остаётся второй.

Elastic Net сочетает L1 и L2

$$J_{\lambda,\rho} = R_n + \lambda \left[\rho \|\beta\|_1 + \frac{1-\rho}{2} \|\beta\|_2^2 \right]$$

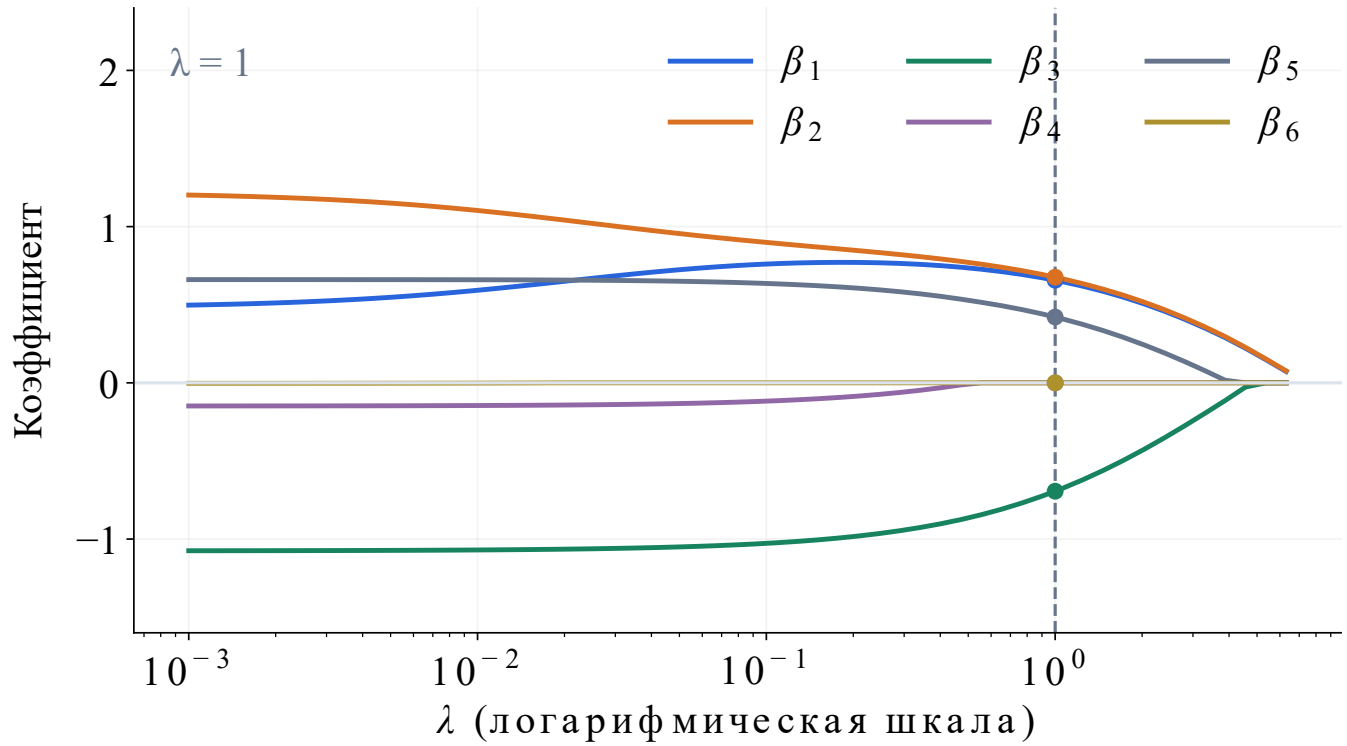
$$\lambda \geq 0, \qquad 0 \leq \rho \leq 1$$

$$\rho = 1 : \ \text{Lasso} \qquad \rho = 0 : \ \text{L2 с весом } \lambda/2$$

L1 сохраняет возможность отбора признаков; L2 помогает распределять вклад между связанными признаками.

λ задаёт общую силу регуляризации, ρ — соотношение двух штрафов.

Группирующий эффект: близкие признаки делят вклад



ρ = 0,5. Корреляция первых двух признаков ≈ 0,994.

$$\lambda = 0.1$$
$$(\hat{\beta}_1, \hat{\beta}_2) \approx (0.76, 0.90)$$

$$\lambda = 1$$
$$(\hat{\beta}_1, \hat{\beta}_2) \approx (0.66, 0.68)$$

L2-часть способствует более равномерному распределению вклада близких признаков.

K log loss тоже можно добавить штраф

$$p_{\beta_0,\beta}(x) = \sigma(\beta_0 + x^\top \beta)$$

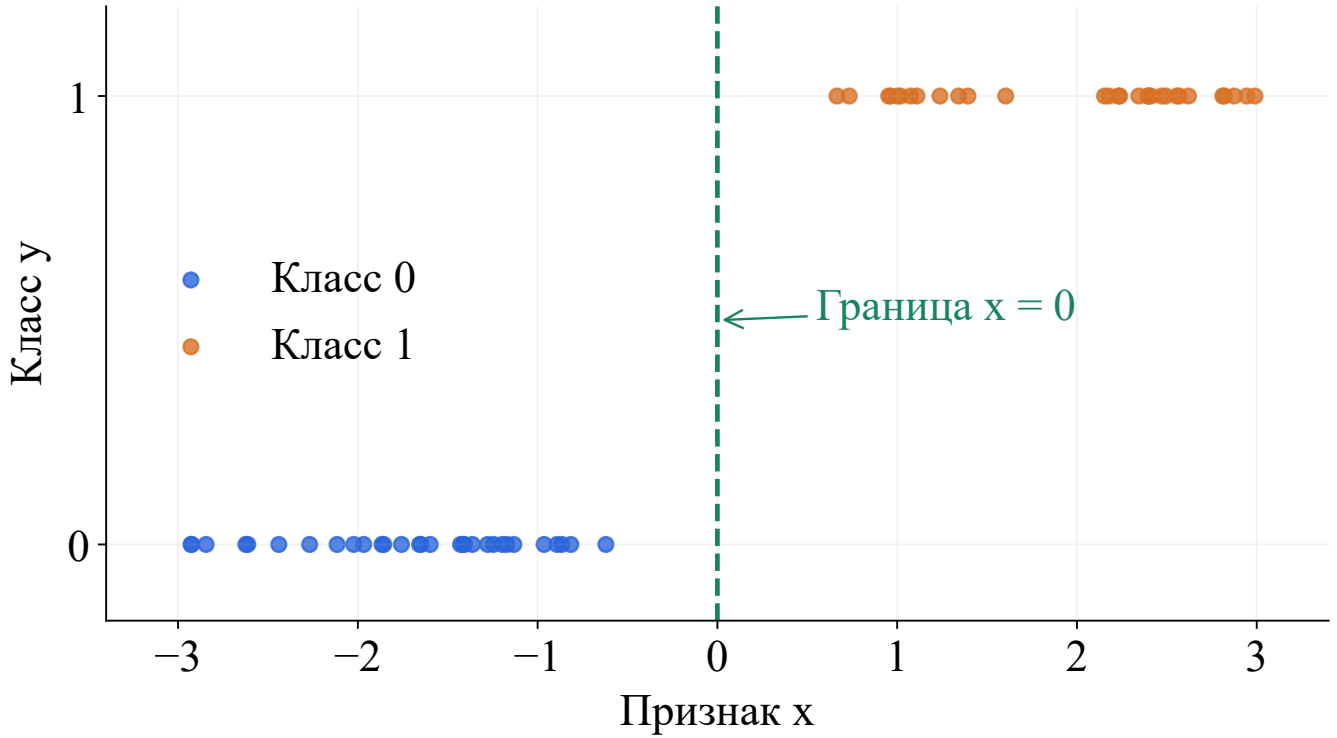
$$R_n^{\log} = \frac{1}{n} \sum_i L(y_i, p_i)$$

$$J_\lambda^{\log} = R_n^{\log} + \lambda \|\beta\|_2^2$$

L1 или L2 ограничивают коэффициенты логистической регрессии. Это может стабилизировать решение и сдерживать подгонку к шуму.

Формула вероятности прежняя; меняется критерий обучения и найденные параметры.

Особый случай: классы линейно разделимы



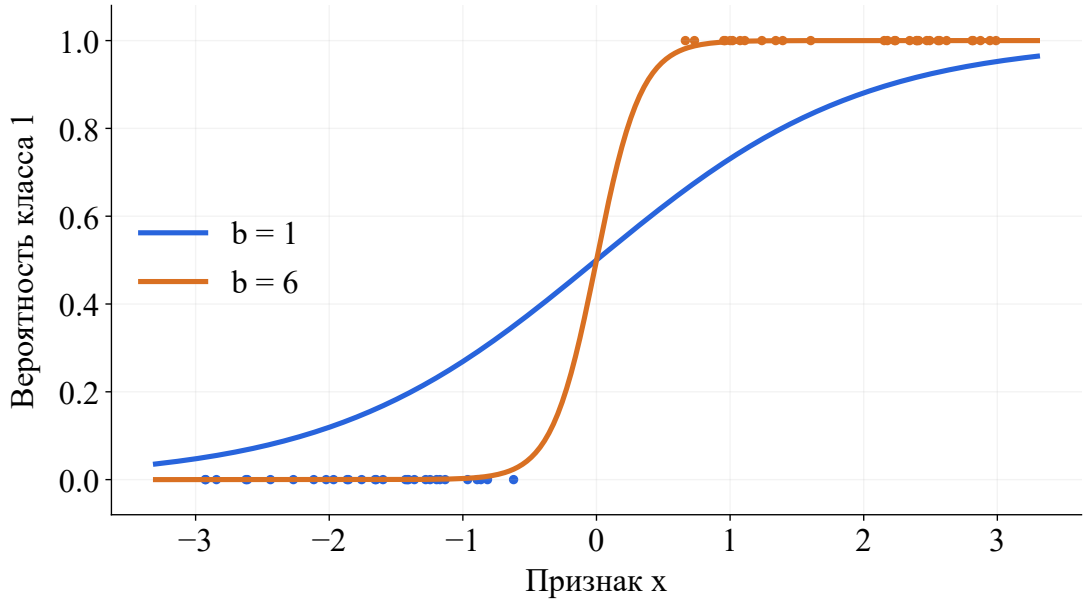
Все объекты класса 0 слева от нуля, класса 1 — справа.

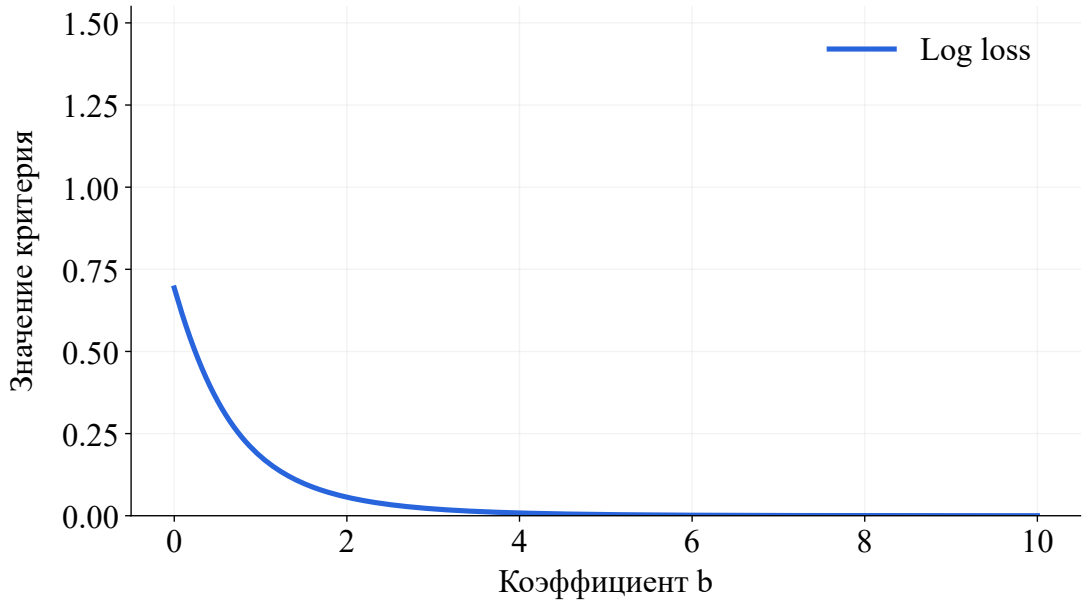
$$p_b(x) = \sigma(bx), \qquad b > 0$$

При пороге 0,5 метки уже правильные для любого b > 0.

Что будет с вероятностями и log loss, если увеличить b?

Почему log loss продолжает уменьшаться?

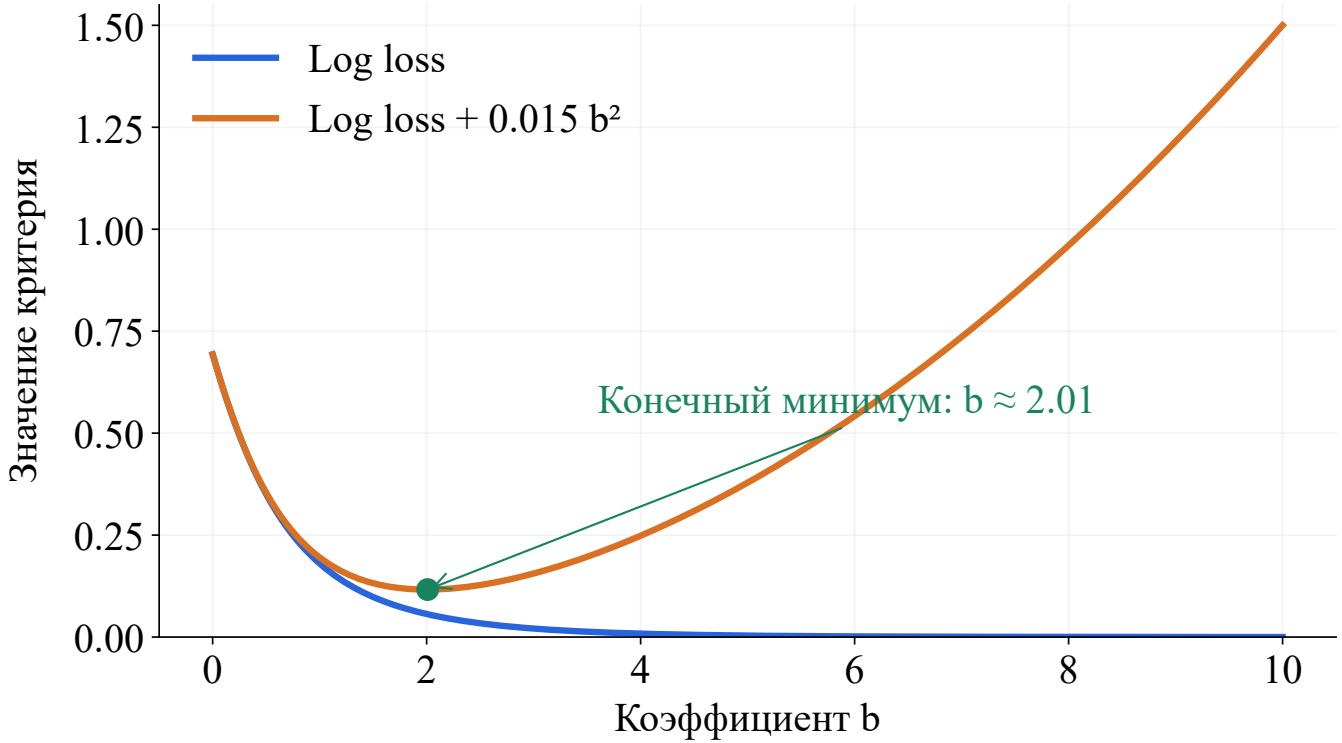




$$p_b(x) = \sigma(bx), \quad b > 0$$

Для разделимых данных растёт уверенность в правильных классах; log loss уменьшается к нулю при b → ∞.

L2 создаёт конечный минимум



$$J_\lambda^{\log}(b) = R_n^{\log}(b) + \lambda b^2$$

На рисунке λ = 0,015.

Log loss уменьшается, но квадратный штраф растёт.

Оптимальный коэффициент становится конечным.

Регуляризация: что меняется в обучении?

Метод	Штраф	Типичное действие
Ridge	$\|\beta\|_2^2$	Сжатие и стабилизация коэффициентов
Lasso	$\|\beta\|_1$	Возможность разреженности и отбора признаков
Elastic Net	L1 + L2	Разреженность и совместный вклад связанных признаков

$$J_\lambda = R_n + \lambda\Omega$$

Тот же принцип добавления штрафа работает и для log loss.

Сила регуляризации настраивается. Её влияние на новые прогнозы ещё предстоит оценить.

Вспомним train/test: обучение и независимая проверка

Разделяем данные до обучения, чтобы проверить прогнозы на объектах, которые модель ещё не видела.



Train — обучение

По этим объектам находим параметры модели.

Test — финальная проверка

Сравниваем прогнозы готовой модели с фактическими ответами.

Для сравнения вариантов внутри разработки используем train/validation. Финальный test оставляем отдельно от выбора.

Может ли оценка на отложенных объектах измениться, если по-другому разделить те же данные?

Одно разбиение: обучаем и оцениваем

30 объектов из синтетической выборки. Фиксированная процедура: стандартизация по train → Ridge с λ = 1 → MSE на validation.

Train: 24 объекта Validation: 6 объектов



24 train
Обучающие объекты

→

Модель 1
Обучаем заново

→

MSE = 2,235
На 6 validation-объектах

Validation: № 1, 6, 12, 19, 22, 24

Что изменится, если выбрать другие train/validation-объекты?

Изменили состав частей — обучаем новую модель

Те же 30 объектов, та же процедура и λ = 1. Изменилось только разбиение; часть объектов поменяла роль.

Train: 24 объекта Validation: 6 объектов Обводка — объект сменил роль



24 train
Обучающие объекты

→

Модель 2
Обучаем заново

→

MSE = 0,694
На 6 validation-объектах

Validation: № 5, 10, 11, 14, 22, 24

Оценка зависит и от обучающих объектов, и от состава отложенной части.

Кросс-валидация повторяет обучение и проверку

Кросс-валидация (CV) оценивает процедуру обучения на нескольких разбиениях данных.

Текущие train и validation → Заново обучаем на train → Оцениваем на validation

Повторяем цикл на других разбиениях и объединяем полученные оценки.

Пока фиксируем модель, настройки, преобразования и метрику. Каждый проход даёт отдельную обученную модель.

K-fold: от исходных данных к фолдам внутри dev

100 исходных объектов

80 — данные для разработки (dev)

F_1	F_2	F_3	F_4	F_5
16 объектов	16 объектов	16 объектов	16 объектов	16 объектов

20 — test

Откладываем для финальной проверки

K-fold: делим dev на K непересекающихся частей — фолдов.

Из 100 объектов 20 отложены для финального test, остальные 80 — для разработки и CV. При K = 5 каждый dev-объект проверяем ровно один раз.

Другой validation-фолд — другая обученная модель

Train Validation

Финальный test — вне CV

Проход	F_1	F_2	F_3	F_4	F_5	Модель	Ошибка
2	Train	Valid	Train	Train	Train	Модель 2	$\mathrm{MSE}_2 = 4{,}7$

Обучаем новую модель на 64 объектах → проверяем на 16 других.

На прошлом проходе: Модель 1, validation — первый фолд, MSE = 4,1.

Когда F_2 становится validation, F_1 возвращается в train. Обучающая часть меняется — коэффициенты находим заново.

Пять моделей, пять ошибок, одно среднее

Train Validation

Финальный test — вне CV

Проход	F_1	F_2	F_3	F_4	F_5	Модель	Ошибка
1	Valid	Train	Train	Train	Train	Модель 1	$\mathrm{MSE}_1 = 4{,}1$
2	Train	Valid	Train	Train	Train	Модель 2	$\mathrm{MSE}_2 = 4{,}7$
3	Train	Train	Valid	Train	Train	Модель 3	$\mathrm{MSE}_3 = 3{,}9$
4	Train	Train	Train	Valid	Train	Модель 4	$\mathrm{MSE}_4 = 5{,}8$
5	Train	Train	Train	Train	Valid	Модель 5	$\mathrm{MSE}_5 = 4{,}5$

$$\text{CV-MSE} = \frac{4{,}1 + 4{,}7 + 3{,}9 + 5{,}8 + 4{,}5}{5} = 4{,}6$$

CV-оценка относится к процедуре обучения

Пять проходов CV

Каждая модель: 64 train → 16 validation.

$$\text{CV-MSE} = 4.6$$

Средняя отложенная ошибка пяти моделей при этих разбиениях.

Одна итоговая модель

Заново обучим на всех 80 dev-объектах.

Её параметры и размер обучения отличаются от CV-моделей. Для проверки выбранного решения сохранён test.

Мы оценили работу заданного способа обучения на 64 объектах, а не одну окончательную модель на 80.

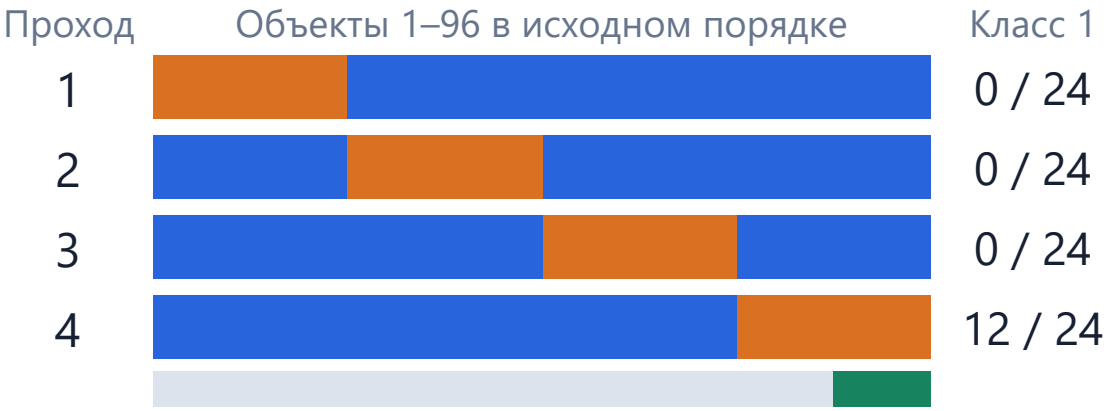
Обучающие части пересекаются; пять ошибок не являются независимыми экспериментами.

K-fold и ShuffleSplit: как меняется состав проверки

Train Validation

Нижняя полоса: Класс 0 Класс 1

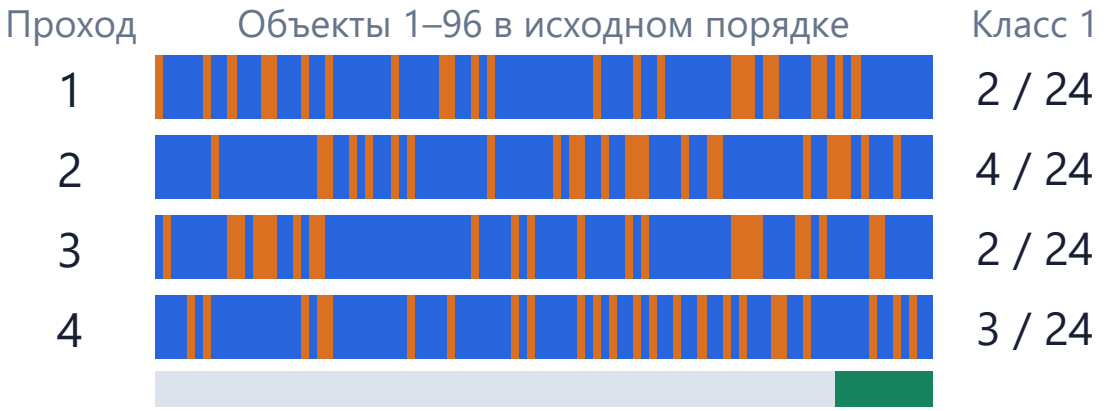
K-fold



84 объекта класса 0 · 12 объектов класса 1

Четыре непересекающихся фолда. В исходном порядке классы сгруппированы: все положительные попали в последний фолд.

ShuffleSplit



84 объекта класса 0 · 12 объектов класса 1

Четыре случайных разбиения заново. Один объект может проверяться несколько раз, другой — ни разу.

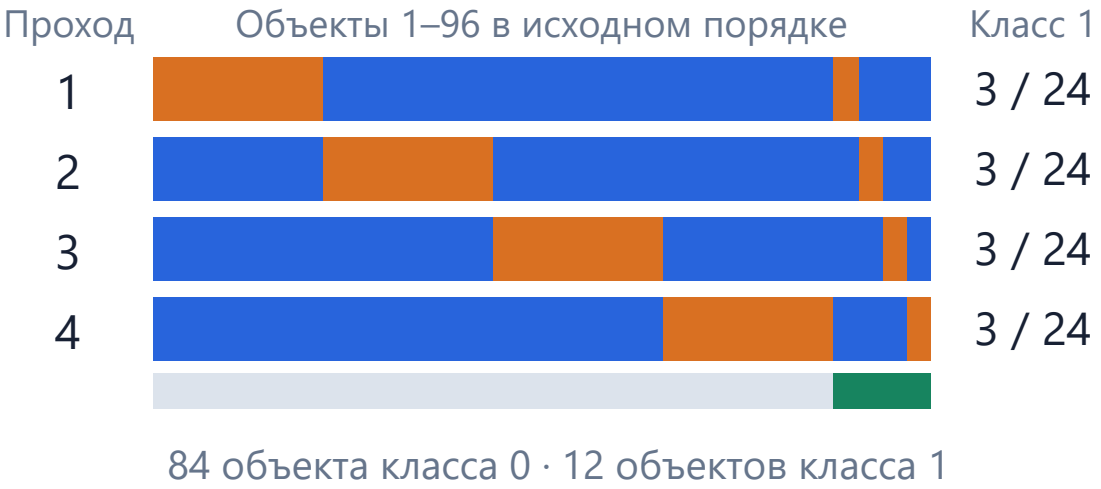
96 объектов; на каждом из четырёх проходов 24 объекта используются для валидации.

Стратификация и группы отвечают разным задачам

Train Validation

Нижняя полоса: Класс 0 Класс 1

Stratified K-fold



В каждом фолде 3 положительных и 21 отрицательный объект: сохраняем доли классов.

Group K-fold



12 пациентов по 8 записей. Проверяем на новых пациентах: все записи выбранного пациента целиком в validation.

Кросс-валидация: повторяем и объединяем оценки

- На каждом проходе заново обучаем модель, включая преобразования, по текущему train.
- Проверяем на объектах, которые не участвовали в этом обучении.
- Объединяем оценки; схему разбиений выбираем под будущие новые объекты.
- CV оценивает фиксированную процедуру и позволяет сравнивать несколько вариантов.

Leave-one-out: K = n; каждый раз проверяем один объект, обучаем на остальных. Нужно n обучений.

Теперь применим уже изученную CV для выбора настройки модели.

Параметры и гиперпараметры

$$\hat{\beta}_0,\ \hat{\beta}$$

Параметры

Находятся по данным внутри конкретного обучения.

$$\lambda,\ \rho$$

Гиперпараметры

Задаются до обучения; сравниваем процедуры с разными настройками.

Почему минимальная train-MSE не выбирает полезный штраф

МНК уже минимизирует MSE на данной обучающей выборке.

$$\min_{\beta_0,\beta} R_n \le R_n(\hat{\beta}_{0,\lambda}, \hat{\beta}_\lambda)$$

Выбор по train-MSE предпочитает отсутствие регуляризации.

Для новых прогнозов сравниваем ошибку на отложенных объектах.

Учебный пример одной validation-части

λ	MSE на train	MSE на validation
0	1,2	3,8
0,1	1,4	2,6
1	1,9	2,2
10	3,1	3,4

CV-подбор Ridge: один набор данных и общие фолды

Рассмотрим новый эксперимент: 150 объектов для разработки, 60 взаимосвязанных признаков и зашумлённая целевая переменная.

$$\Lambda = \{0.0001,\ 0.001,\ 0.01,\ 0.1,\ 1,\ 10,\ 100\}$$

F_1	F_2	F_3	F_4	F_5
30 объектов	30 объектов	30 объектов	30 объектов	30 объектов

Для каждого λ: пять новых моделей, 120 train / 30 validation на проходе. Для всех кандидатов используем одни и те же фолды.

Средние и стандартные отклонения признаков оцениваем отдельно на train каждого прохода.

Первое λ: пять обучений и пять ошибок

$\lambda = 0.0001$

Вычисляем среднее пяти ошибок

F_1 30 объектов	F_2 30 объектов	F_3 30 объектов	F_4 30 объектов	F_5 30 объектов

Пять отдельных моделей → пять отложенных ошибок → одна CV-MSE

λ	F_1	F_2	F_3	F_4	F_5	Среднее
0,0001	3,425	6,159	3,282	3,817	4,072	4,151
0,001	—	—	—	—	—	—

$$\text{CV-MSE}(\lambda) = \frac{\text{MSE}_1 + \cdots + \text{MSE}_5}{5}$$

Усредняем пять ошибок внутри одной строки.

Второе λ: повторяем весь CV-цикл

$\lambda = 0.001$

Вычисляем среднее пяти ошибок

F_1 30 объектов	F_2 30 объектов	F_3 30 объектов	F_4 30 объектов	F_5 30 объектов

Пять отдельных моделей → пять отложенных ошибок → одна CV-MSE

λ	F_1	F_2	F_3	F_4	F_5	Среднее
0,0001	3,425	6,159	3,282	3,817	4,072	4,151
0,001	3,333	5,978	3,178	3,698	3,972	4,032

$$\text{CV-MSE}(\lambda) = \frac{\text{MSE}_1 + \cdots + \text{MSE}_5}{5}$$

Усредняем пять ошибок внутри одной строки.

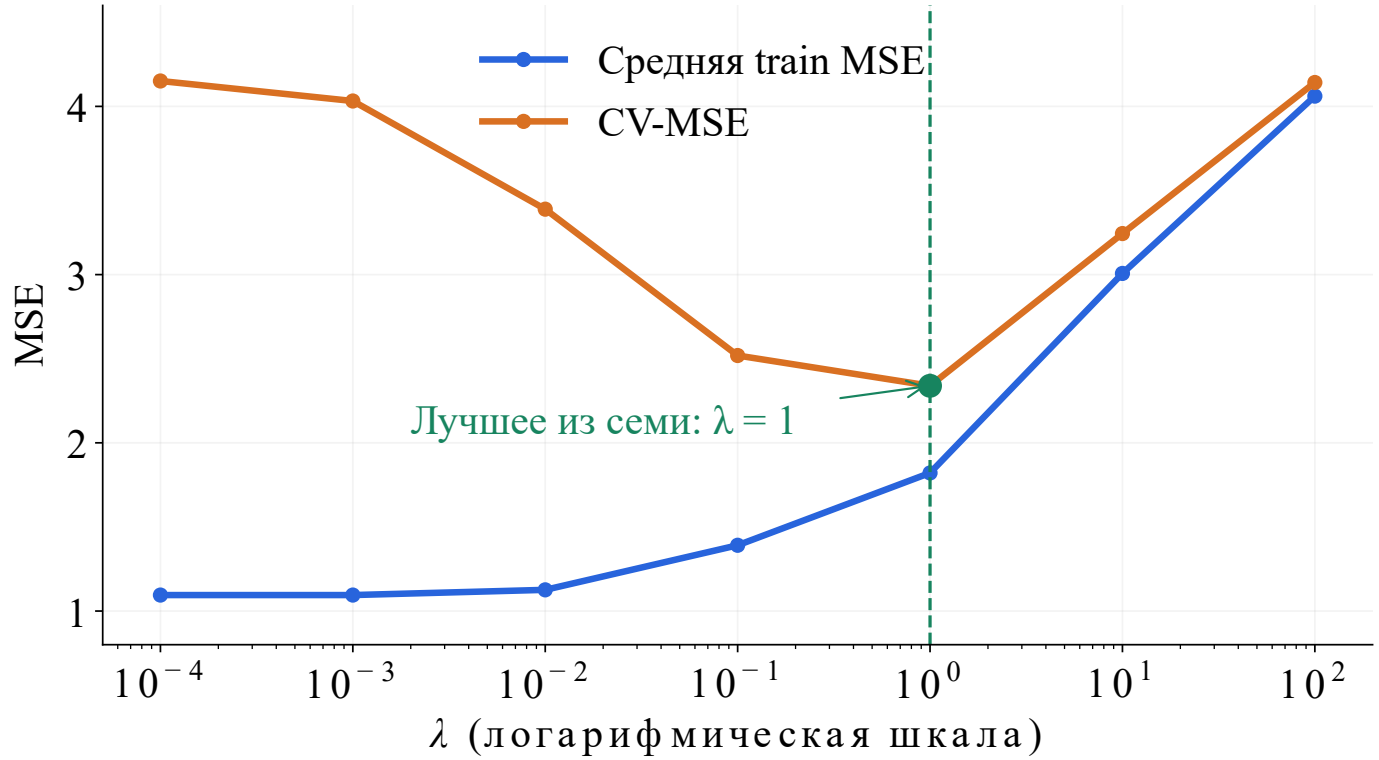
Полная таблица: сравниваем средние семи кандидатов

λ	F_1	F_2	F_3	F_4	F_5	CV-MSE
0,0001	3,425	6,159	3,282	3,817	4,072	**4,151**
0,001	3,333	5,978	3,178	3,698	3,972	**4,032**
0,01	2,768	5,054	2,602	3,071	3,448	**3,389**
0,1	1,891	3,815	2,022	2,241	2,626	**2,519**
1	2,033	3,450	2,141	1,884	2,185	**2,339**
10	3,503	4,441	3,249	2,466	2,562	**3,244**
100	4,434	5,387	4,225	3,329	3,336	**4,142**

Каждая ячейка — валидационная ошибка. Фолды в столбцах одинаковы для всех λ; среднее в строке — CV-MSE.

Наименьшая средняя ошибка: λ = 1, CV-MSE = 2,339.

Кривая CV — те же средние из таблицы



λ = 1 — лучший из семи проверенных кандидатов на этих данных.

Откуда берутся значения сетки?

$$\lambda \geq 0$$

$$\Lambda = \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 10^{2}\}$$

Логарифмическая сетка покрывает несколько порядков величины.

Минимум на краю → расширяем диапазон.

При необходимости уточняем сетку рядом с лучшим кандидатом.

Универсального полезного диапазона λ нет.

Поиск по сетке с двумя настройками

$\lambda \backslash \rho$	0,25	0,75
0.01	A	B
0.1	C	D
1	E	F

$$3 \cdot 2 = 6 \text{ комбинаций;} \qquad 6 \cdot 5 = 30 \text{ обучений}$$

Для каждой комбинации заново проводим CV. GridSearchCV автоматизирует этот перебор.

35 обучений для выбора — и новое обучение после него

Выбор: 7 значений λ × 5 фолдов

35 обучений

Сравниваем CV-MSE.
Выбираем λ = 1.

Окончательное обучение — refit

1 новая модель

Обучаем стандартизатор и Ridge при $\lambda = 1$ на всех 150 dev.

Пять CV-моделей выбранного λ дали среднюю ошибку 2,339. Их коэффициенты не объединяем: итоговую модель обучаем заново.

Стандартизацию обучаем внутри каждого прохода

Порядок для каждого CV-прохода

1. На 120 train оцениваем средние и стандартные отклонения.
2. По этим статистикам преобразуем train и 30 validation.
3. Обучаем Ridge на преобразованном train.
4. Прогнозируем для validation и считаем MSE.

При refit и статистики стандартизации, и Ridge обучаем на всех dev. Test только преобразуем и используем для итоговой оценки.

Финальный протокол: dev и test идут разными ветвями



CV-MSE использована для выбора λ. Финальный test отдельно проверяет уже зафиксированное решение.

Что мы научились делать?

Регуляризация

- Менять выбор коэффициентов с помощью ограничения или штрафа.
- Использовать Ridge для сжатия и устойчивости, Lasso — для разреженности, Elastic Net — для сочетания этих свойств.

Кросс-валидация

- Заново обучать и оценивать процедуру на нескольких разбиениях.
- Сравнивать настройки по средней отложенной ошибке, обучая преобразования внутри каждого train.

После выбора заново обучаем на всех dev и один раз проверяем на независимом test.