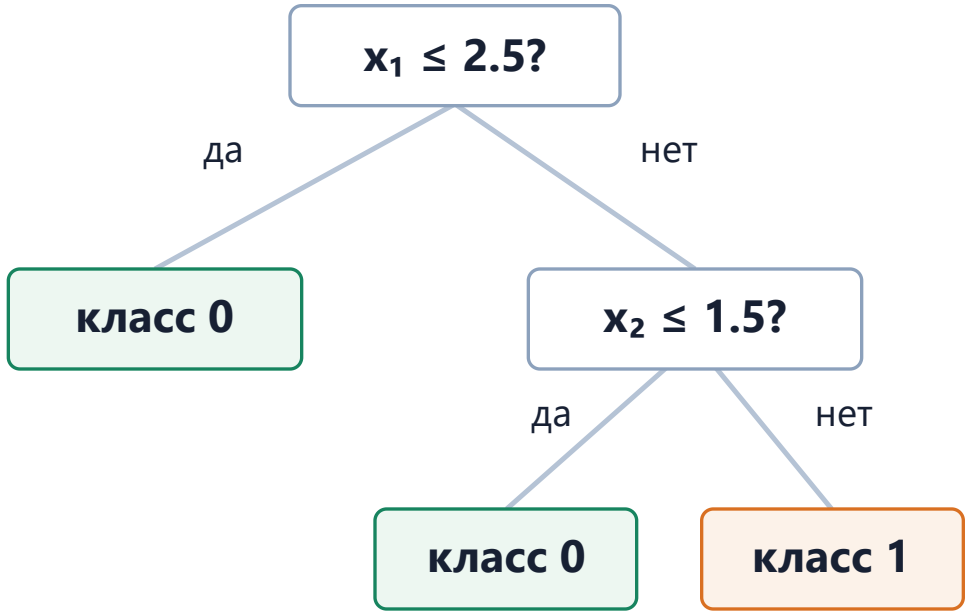
Модель из пороговых условий

Решающие деревья

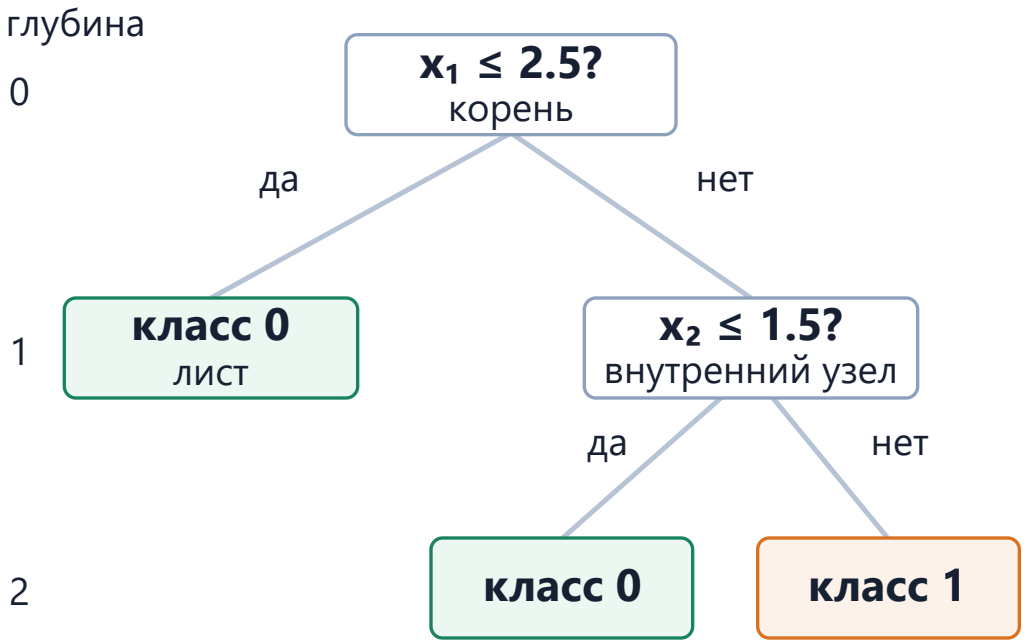
Как последовательность простых вопросов становится моделью?

Разбиваем объекты на группы,
в которых достаточно простого прогноза.



Готовая модель

Устройство дерева



Корень — начальный узел дерева. Над ним нет других узлов.

Внутренний узел проверяет условие. **Лист** возвращает прогноз.

Ветвь выбирается по ответу: да → налево, нет → направо.

> Глубина узла — число рёбер от корня. В дереве из одного листа корень сам является листом.

Готовая модель

Пороговое условие

$$x_j \le t$$

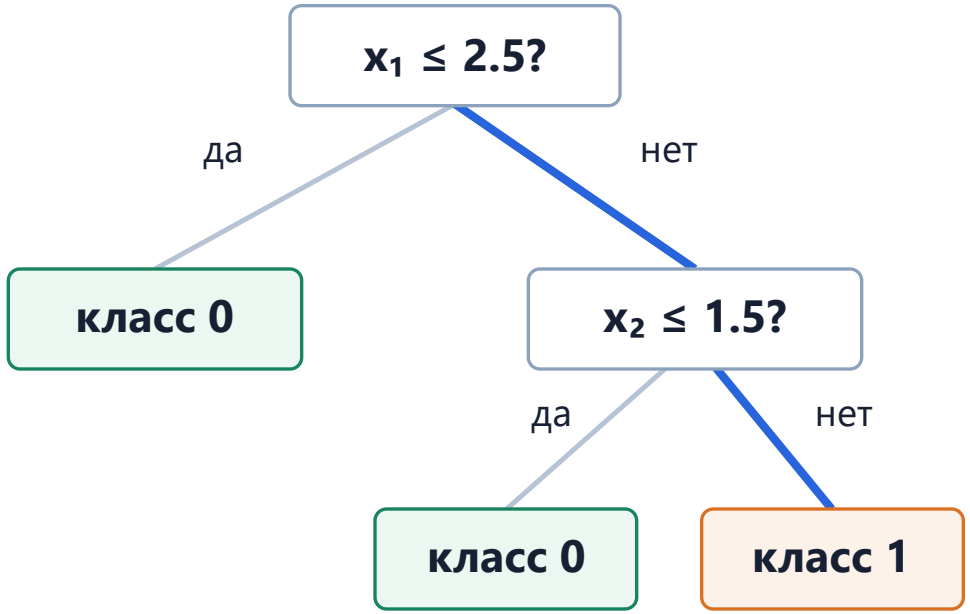
Выбираем признак **j** + Выбираем порог **t** → Получаем ответ **да / нет**

$$\mathbb{I}\{x_j \le t\} = \begin{cases} 1, & \text{условие выполнено,} \\ 0, & \text{условие не выполнено.} \end{cases}$$

Такую проверку называют предикатом. Значение индикатора — не прогноз класса.

Готовая модель

Путь нового объекта



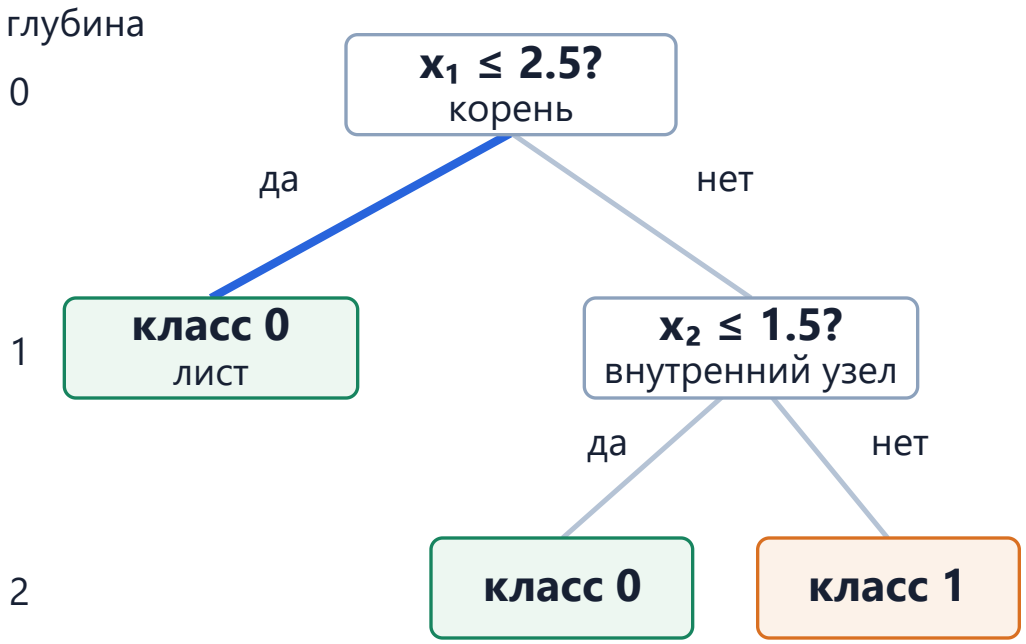
$3.4 \le 2.5$? Нет

$2.2 \le 1.5$? Нет

Достигнут правый нижний лист.
Прогноз: **класс 1**.

Готовая модель

Длина пути



Для x = (1, 3) первое условие выполнено: 1 ≤ 2.5.

> Левый лист: класс 0.
> Путь содержит одно ребро, глубина этого листа — 1.

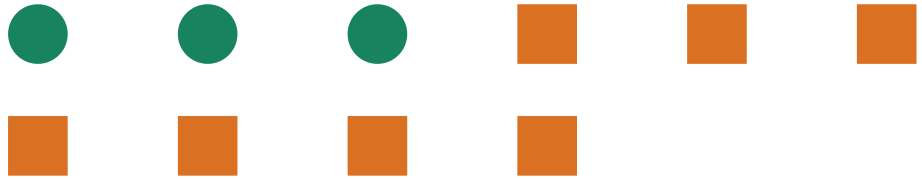
У разных объектов путь по одному дереву может иметь разную длину.

Готовая модель

Прогнозы листа

В другой задаче в достигнутый лист при обучении попали 10 объектов.

3 нуля · 7 единиц



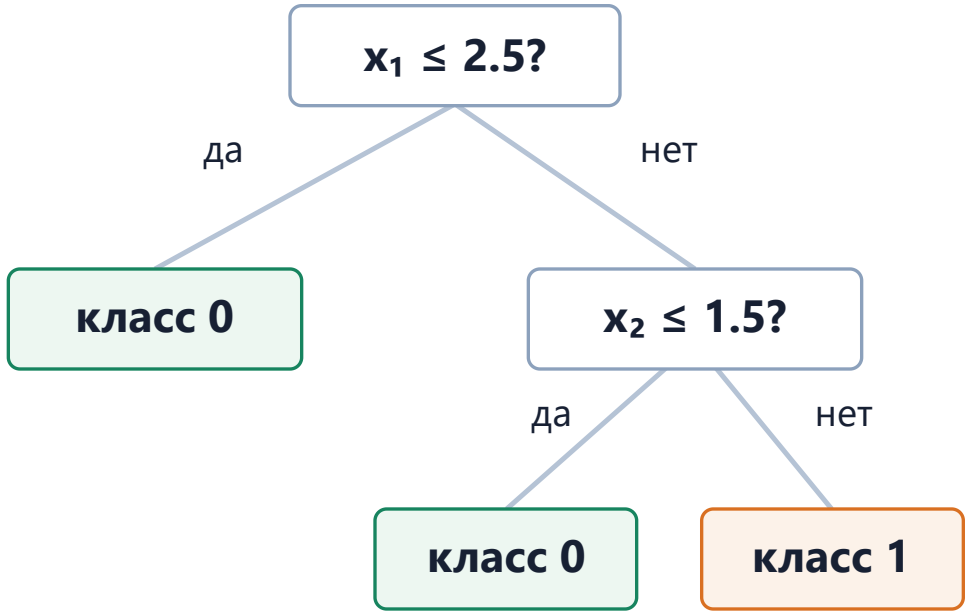
$$\hat{p}_k(x) = \frac{n_{\text{leaf},k}}{n_{\text{leaf}}}$$

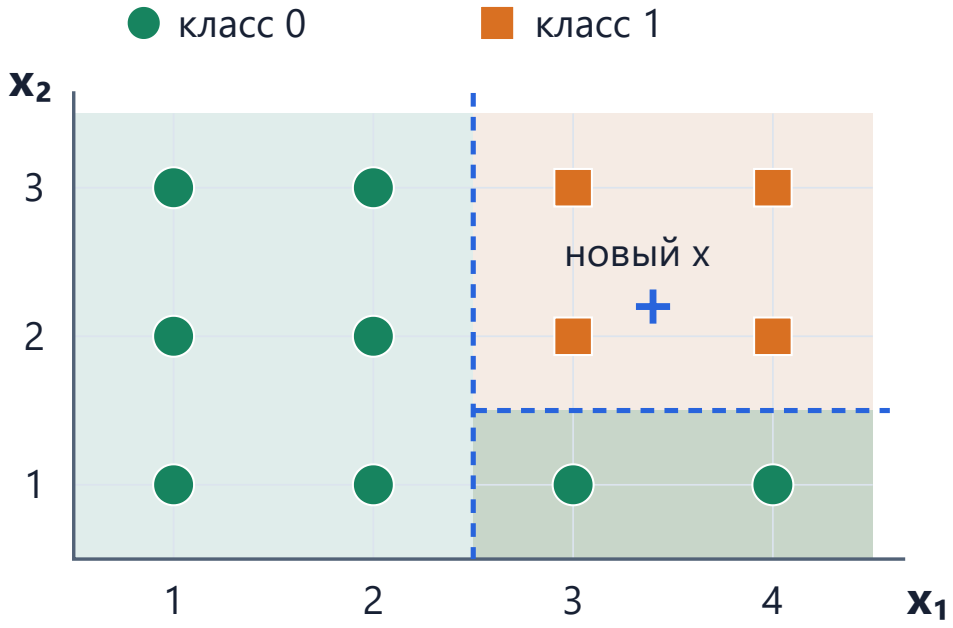
$$\hat{p}_0(x) = 0.3, \quad \hat{p}_1(x) = 0.7$$

predict: класс большинства — 1.
predict_proba: (0.3, 0.7), доли обучающих объектов этого листа.

Готовая модель

Области постоянного прогноза

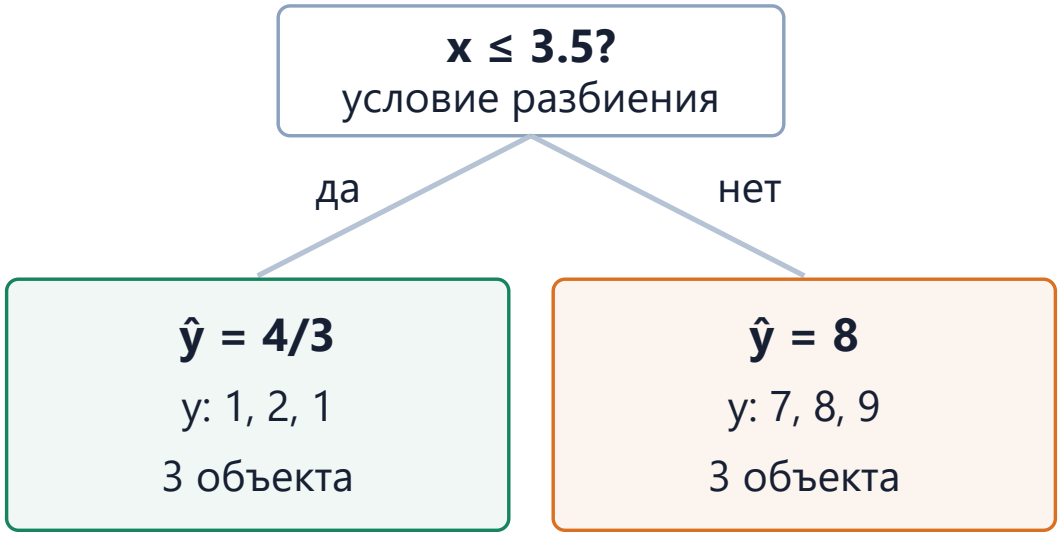


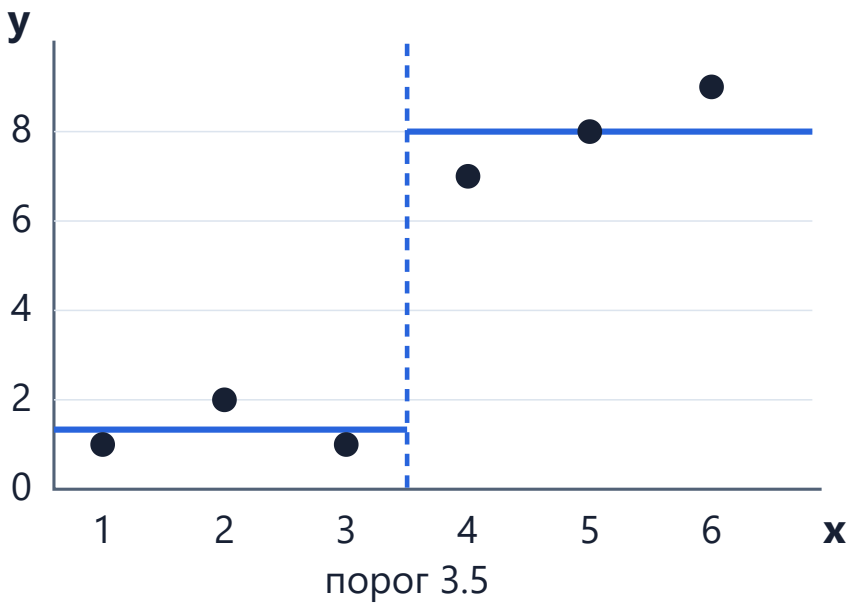


Первый порог делит всю плоскость. Второй — только правую область.
Внутри каждой конечной области прогноз постоянен.

Готовая модель

Регрессионное дерево





В регрессии листья хранят числа. Каждому листу соответствует интервал с постоянным прогнозом — ступенька графика.

Готовая модель

От условий к прогнозу

Внутренние узлы
проверяют условия

→

Путь объекта
выбирает область

→

Лист
возвращает прогноз

Классификация

Класс большинства и доли классов в листе.

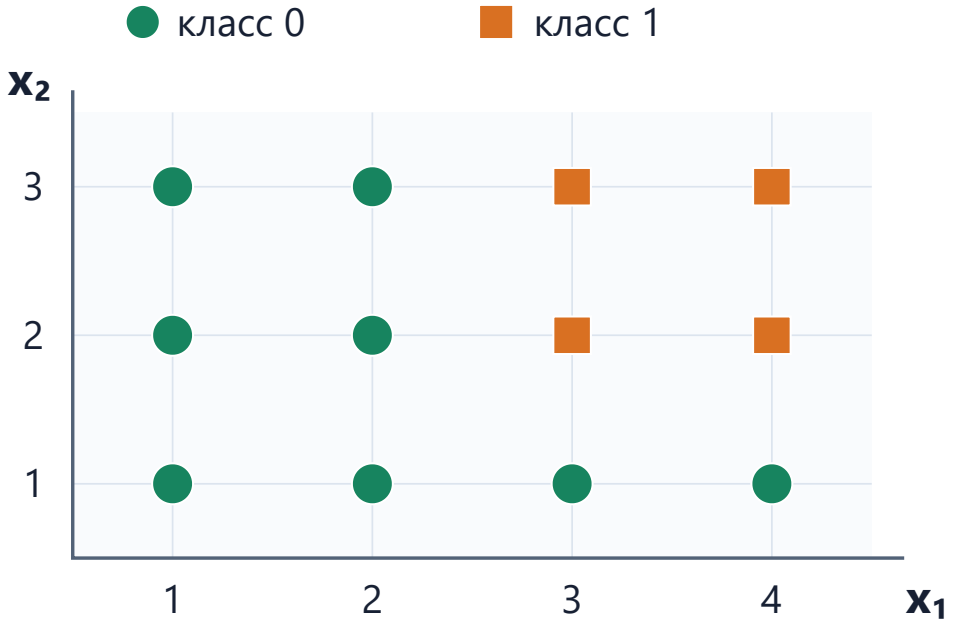
Регрессия

Постоянное число в каждом листе.

> Теперь нужно научиться находить условия и прогнозы листьев по данным.

Обучение: общий принцип

Дерево из одного листа

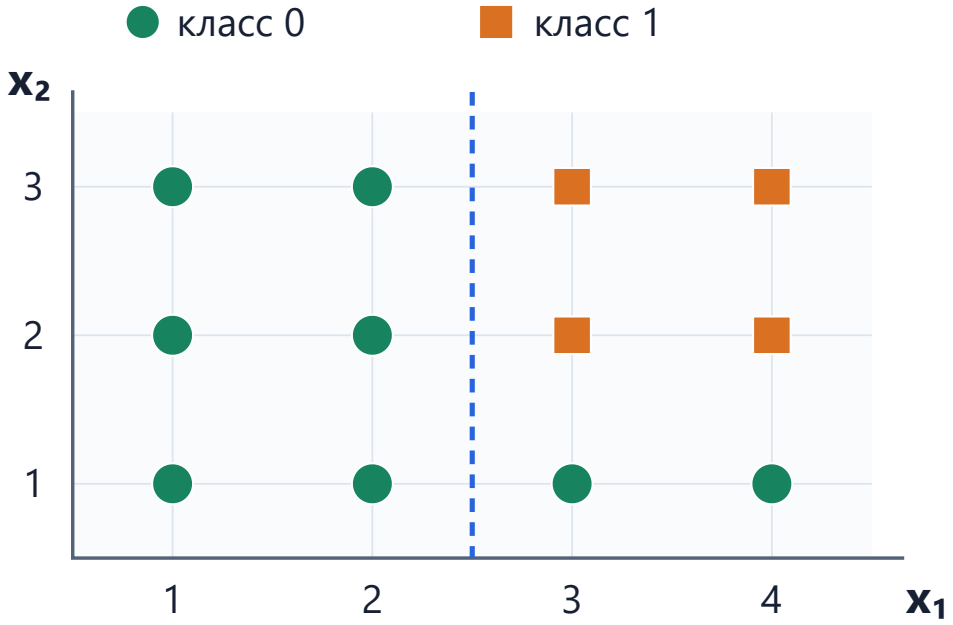


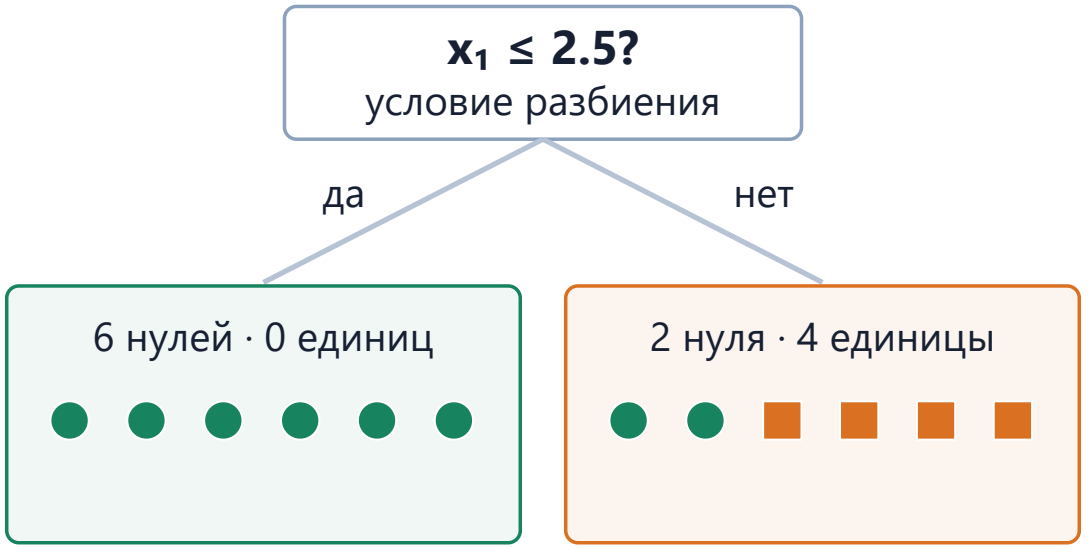


Начальная модель состоит из одного листа: всем 12 объектам назначается класс большинства — 0.

Обучение: общий принцип

Кандидаты на разбиение





Проверка условия создаёт две дочерние группы. Меняя признак и порог, получаем разные разбиения тех же объектов.

Обучение: общий принцип

Рекурсивный рост



Покажем возможное продолжение роста: левый узел чист, правый ещё смешан.

> В правом узле повторяем тот же поиск условия, используя только его объекты. Это рекурсивный шаг.

Пока демонстрируем механизм. После введения критерия проверим, какие условия действительно лучшие.

Обучение: общий принцип

Когда узел становится листом



Поиск в узле заканчивается, когда:

- все объекты имеют один класс;
- нет допустимого разбиения;
- достигнуто ограничение сложности.

> Если дальше не разбиваем, узел становится листом. В нём сохраняем прогноз по объектам этого узла.

Обучение: общий принцип

Обучение и применение

fit: найти структуру

Выбрать условия разбиения и посчитать прогнозы листьев по train.

predict: применить структуру

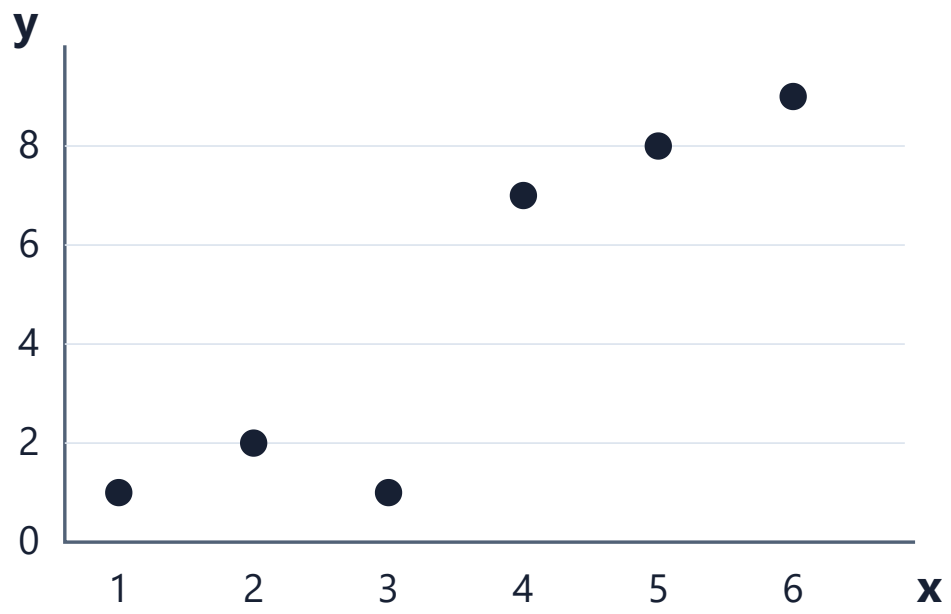
Пройти по сохранённым условиям и вернуть прогноз листа.

Как сравнить два варианта разбиения?

> Нужна численная мера того, насколько уменьшилась неоднородность ответов в дочерних группах.

Регрессия: выбор разбиения

Данные для регрессии

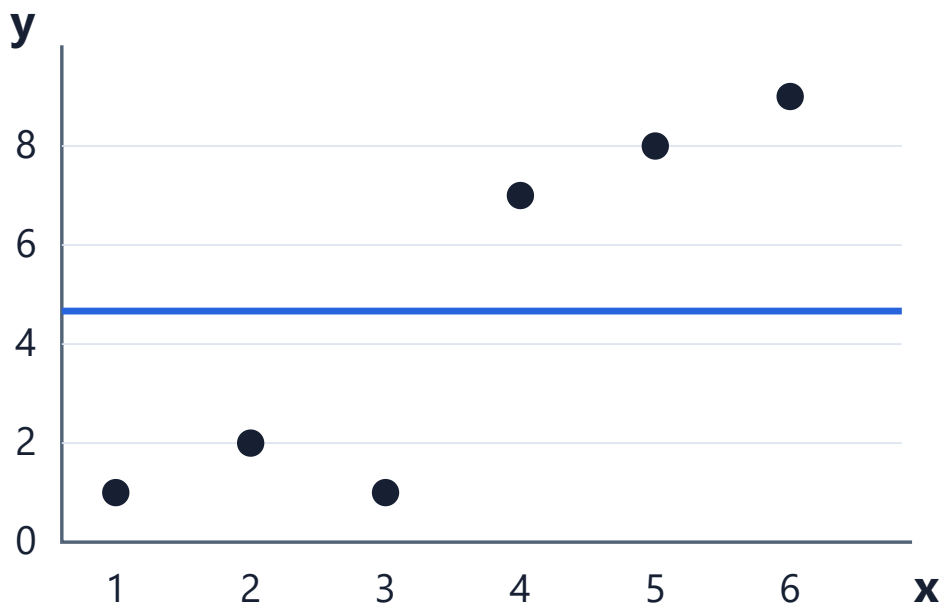


x	1	2	3	4	5	6
y	1	2	1	7	8	9

Какой постоянный прогноз выбрать в одном листе?

Регрессия: выбор разбиения

Среднее в листе



$$\hat{y}_{\text{leaf}} = \bar{y} = \frac{1}{n}\sum_{i=1}^{n} y_i$$

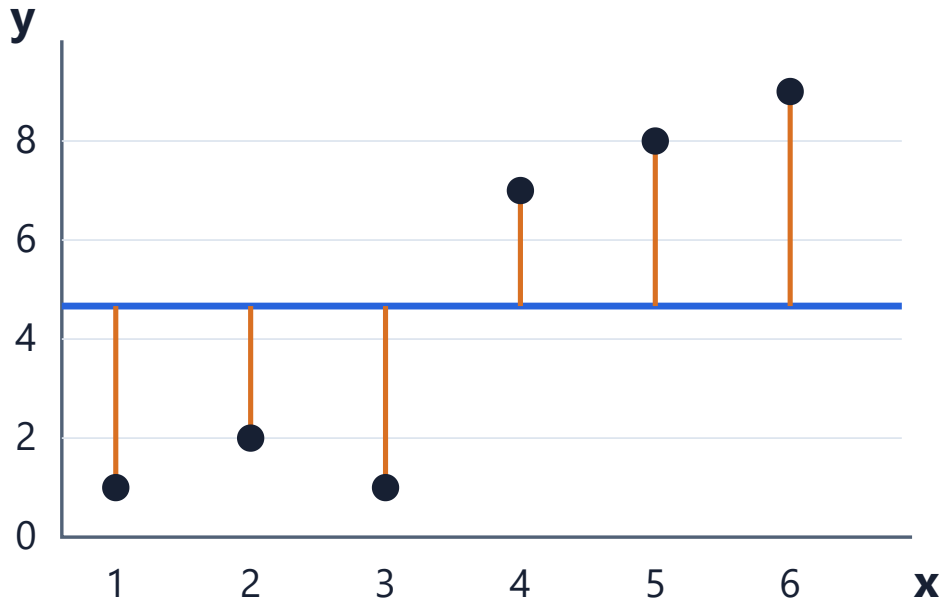
$$\bar{y} = \frac{1+2+1+7+8+9}{6}$$

$$\bar{y} = \frac{14}{3} \approx 4.67$$

Среднее минимизирует сумму квадратов отклонений от постоянного прогноза.

Регрессия: выбор разбиения

RSS и MSE



$$\mathrm{RSS}(S) = \sum_{i \in S} (y_i - \bar{y}_S)^2$$

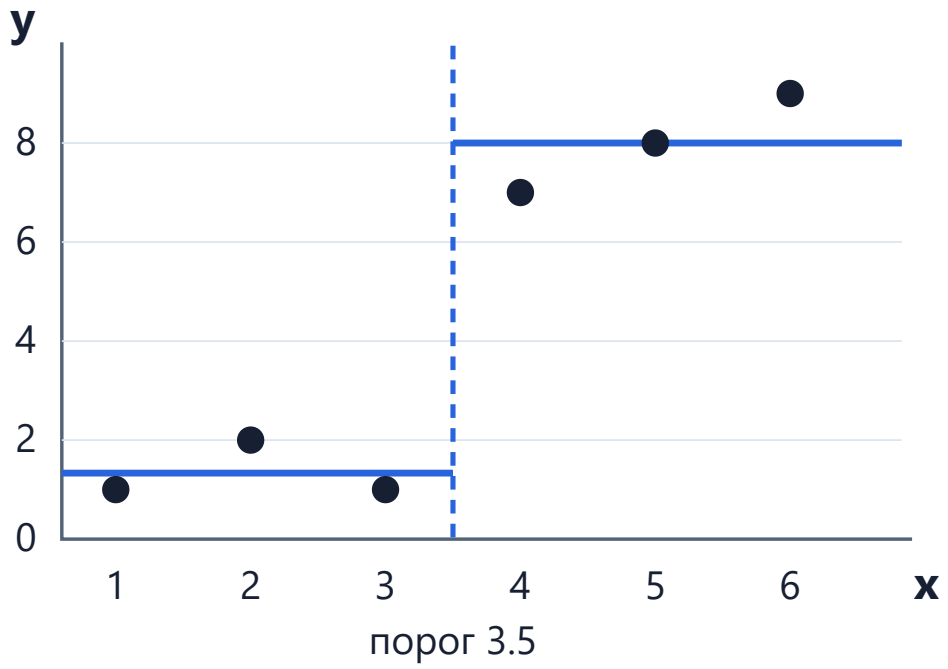
$$\mathrm{RSS} = \frac{208}{3} \approx 69.33$$

$$\mathrm{MSE} = \frac{\mathrm{RSS}}{6} = \frac{104}{9} \approx 11.56$$

RSS — сумма. MSE — средняя квадратичная ошибка на объект.

Регрессия: выбор разбиения

Порог 3.5



Слева: y = (1, 2, 1).

$$\bar{y}_L = \frac{4}{3}$$

Справа: y = (7, 8, 9).

$$\bar{y}_R = 8$$

Порог x ≤ 3.5 выделил группы объектов с низкими и высокими значениями y.

Регрессия: выбор разбиения

Ошибка двух листьев

$$\mathrm{RSS}_L = (1 - \tfrac{4}{3})^2 + (2 - \tfrac{4}{3})^2 + (1 - \tfrac{4}{3})^2 = \frac{2}{3}$$

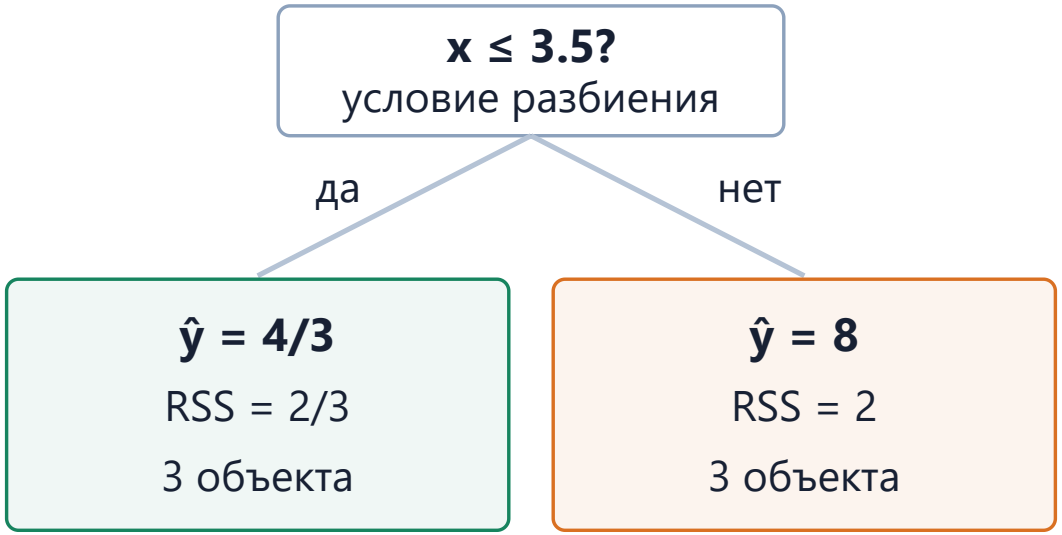
$$\mathrm{RSS}_R = (7 - 8)^2 + (8 - 8)^2 + (9 - 8)^2 = 2$$

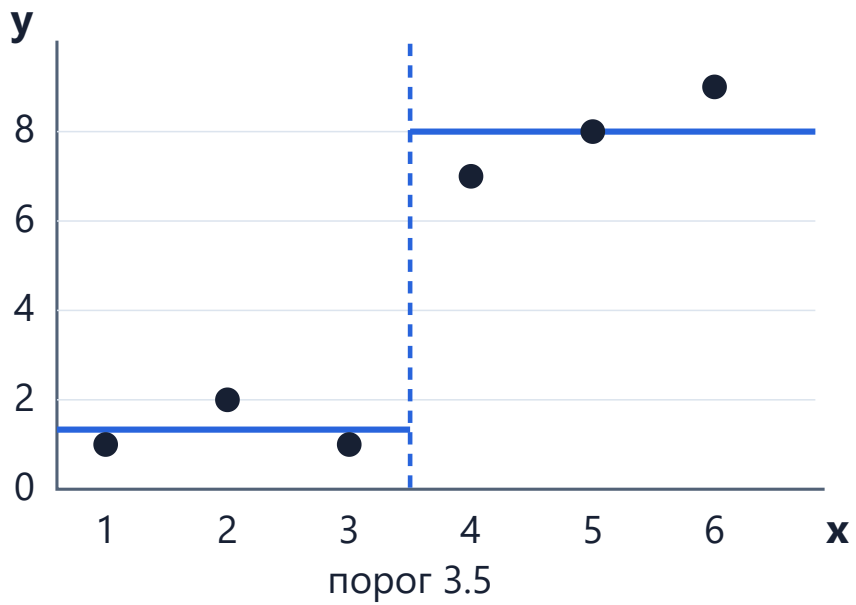
$$\mathrm{RSS}_{\text{after}} = \frac{2}{3} + 2 = \frac{8}{3} \approx 2.67$$

Было 69.33 → стало 2.67 на тех же шести объектах.

Регрессия: выбор разбиения

От одного листа к двум

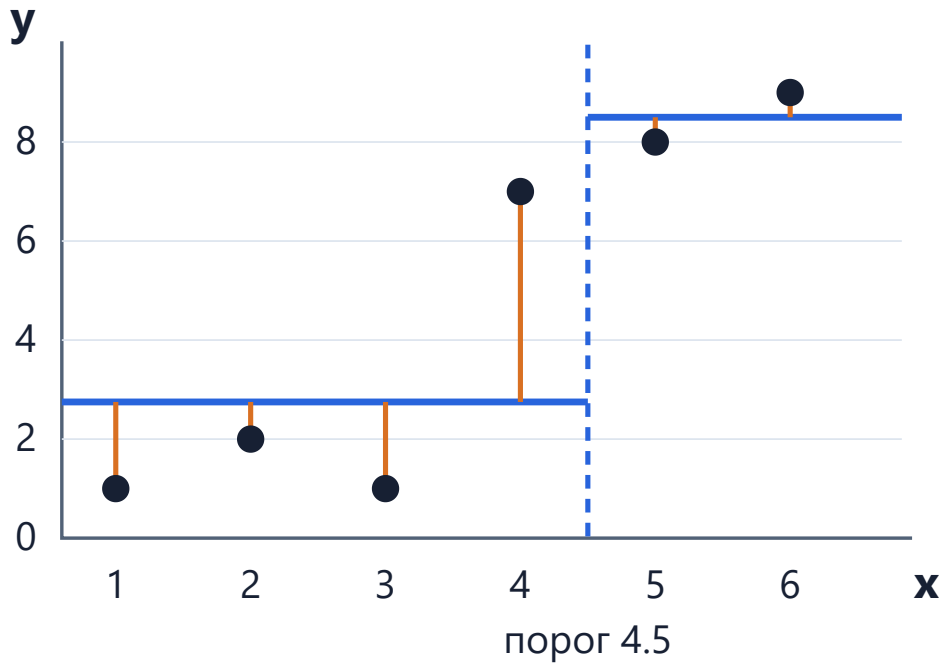




Порог 3.5 создаёт два листа со своими средними.
Сумма их RSS равна 8/3 вместо 208/3 у исходного листа.

Регрессия: выбор разбиения

Порог 4.5



Слева: (1, 2, 1, 7), среднее 2.75.
Справа: (8, 9), среднее 8.5.

$$\mathrm{RSS}_L = 24.75, \quad \mathrm{RSS}_R = 0.5$$

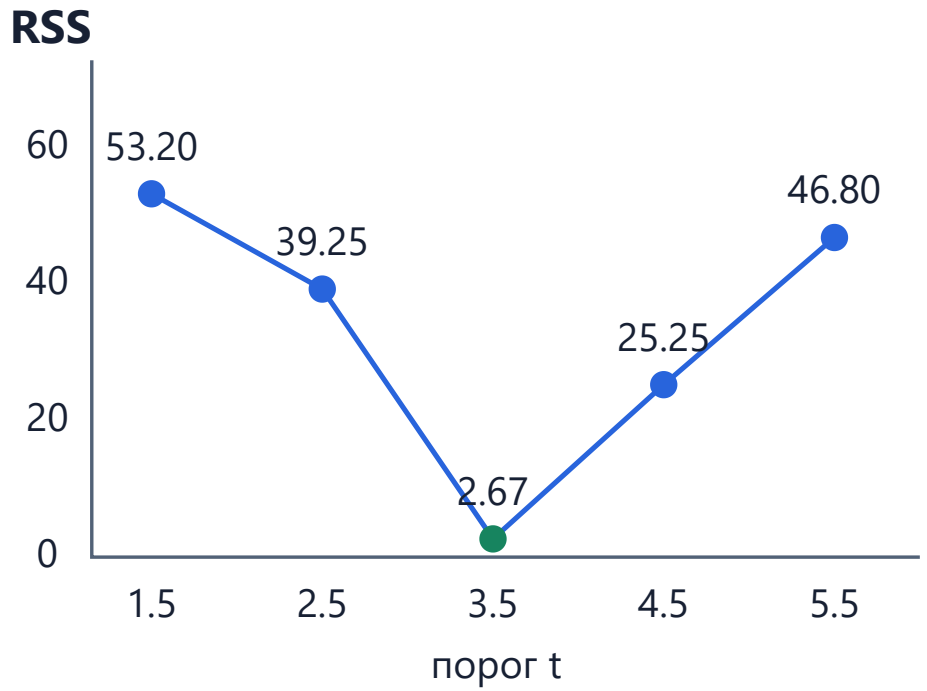
$$\mathrm{RSS}_{\text{after}} = \mathrm{RSS}_L + \mathrm{RSS}_R = 25.25$$

Порог 3.5 лучше: суммарная ошибка меньше.

Каждая RSS уже суммирует ошибки всех объектов своей группы. Складываем суммы без дополнительных весов.

Регрессия: выбор разбиения

Перебор порогов



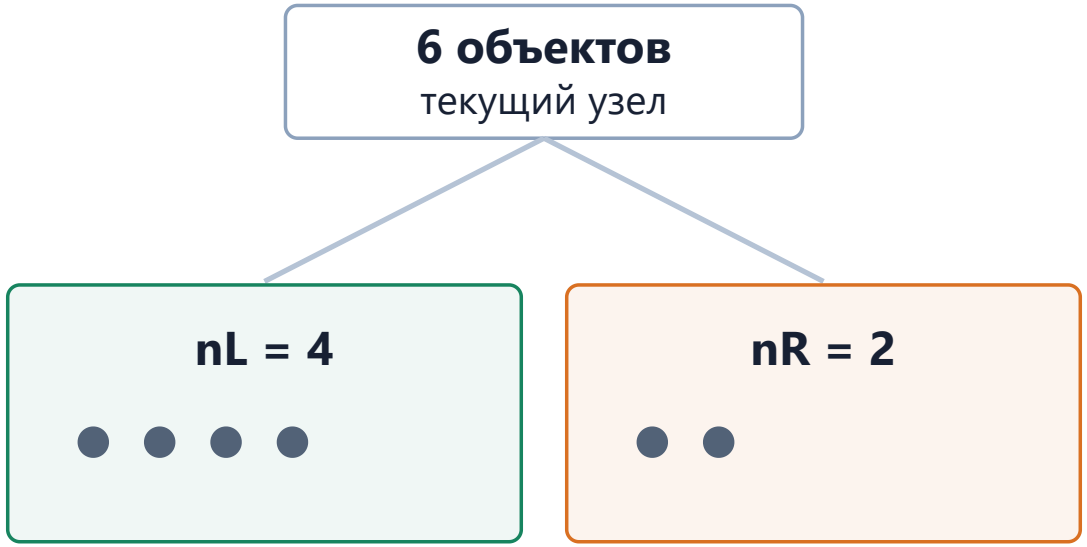
Упорядоченные x:
1, 2, 3, 4, 5, 6.

Кандидаты:
1.5, 2.5, 3.5, 4.5, 5.5.

> Минимум RSS — при 3.5.
> Сравниваем разбиения одних и тех же объектов.

Регрессия: выбор разбиения

От суммы ошибок к средней



Тот же порог 4.5: четыре объекта и два

Теперь хотим среднюю ошибку на объект. MSE каждой группы — её RSS, делённая на размер.

$$\mathrm{MSE}_L = \frac{24.75}{4} = 6.1875$$

$$\mathrm{MSE}_R = \frac{0.5}{2} = 0.25$$

$$\mathrm{MSE}_{\text{after}} = \frac{4}{6} \cdot 6.1875 + \frac{2}{6} \cdot 0.25 = \frac{25.25}{6} \approx 4.2083$$

В среднюю по всем объектам большая группа вносит больший вклад.

Выбор разбиения: общая схема

Мера неоднородности узла

S — объекты текущего узла; S_L и S_R — левая и правая дочерние группы.
H(S) — выбранная для задачи мера неоднородности ответов.

$$n = |S|, \qquad n_L = |S_L|, \qquad n_R = |S_R|, \qquad n_L + n_R = n$$

После разбиения усредняем неоднородности дочерних групп с весами по долям объектов:

$$H_{\text{after}} = \frac{n_L}{n} H(S_L) + \frac{n_R}{n} H(S_R)$$

> Для нашей регрессии выбираем H(S) = MSE(S).
> В классификации понадобится другая функция H.

Регрессия: выбор разбиения

RSS и взвешенная MSE

Подставим H(S) = MSE(S) = RSS(S) / |S| в общую формулу.

$$H_{\text{after}} = \frac{n_L}{n}\frac{\text{RSS}_L}{n_L} + \frac{n_R}{n}\frac{\text{RSS}_R}{n_R}$$

$$H_{\text{after}} = \frac{\text{RSS}_L + \text{RSS}_R}{n}$$

> Для одного исходного узла n постоянно. Минимум суммарной RSS и минимум взвешенной MSE выбирают одно и то же разбиение.

Регрессия: выбор разбиения

Взвешенная MSE: порог 3.5

Вернёмся к лучшему порогу: по три объекта в каждой группе, RSS слева — 2/3, справа — 2.

$$H(S_L) = \frac{2/3}{3} = \frac{2}{9}, \qquad H(S_R) = \frac{2}{3}$$

$$H_{\text{after}} = \frac{3}{6} \cdot \frac{2}{9} + \frac{3}{6} \cdot \frac{2}{3} = \frac{4}{9}$$

Та же ошибка в другом масштабе:

$$\frac{\text{RSS}_L + \text{RSS}_R}{n} = \frac{8/3}{6} = \frac{4}{9}$$

Выбор разбиения: общая схема

Уменьшение неоднородности

Для каждого допустимого условия сравниваем неоднородность до и после разбиения:

$$\Delta H = H(S) - H_{\text{after}}$$

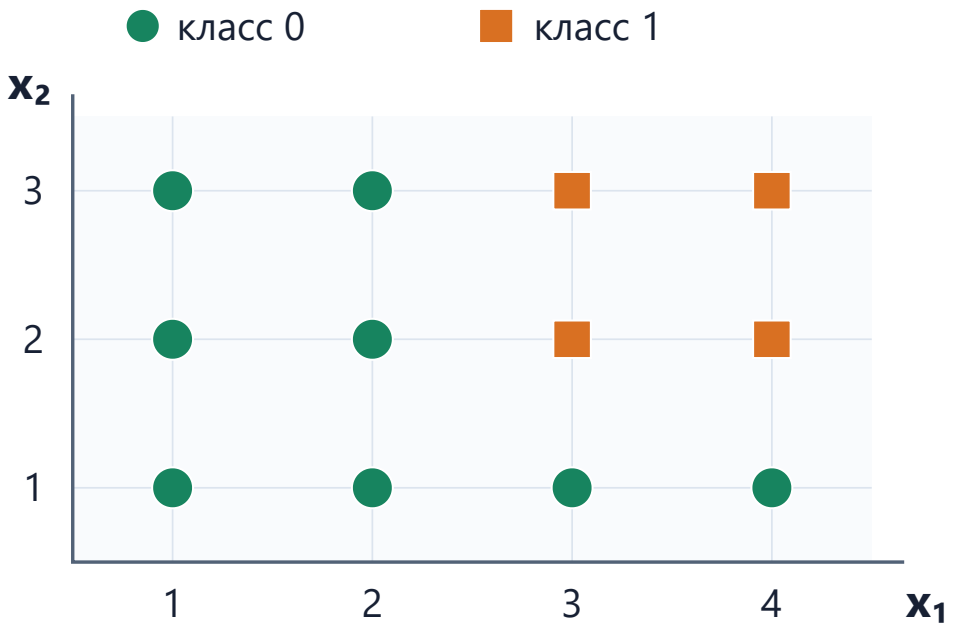
Выбираем наибольший ΔH. При фиксированном узле это означает наименьший H_{after}.

$$\Delta H_{\text{MSE}} = \frac{104}{9} - \frac{4}{9} = \frac{100}{9} \approx 11.11$$

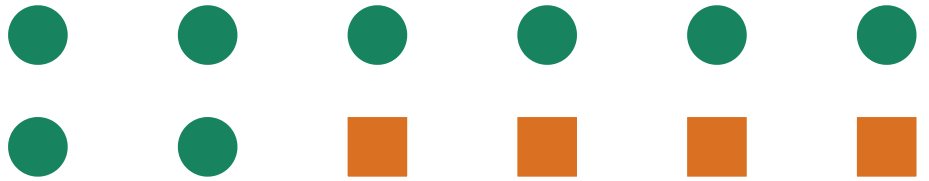
> В регрессии использовали MSE. Для классификации сохраним схему выбора, но определим другую неоднородность H.

Классификация: выбор разбиения

Выбор разбиения для классов



8 нулей · 4 единицы

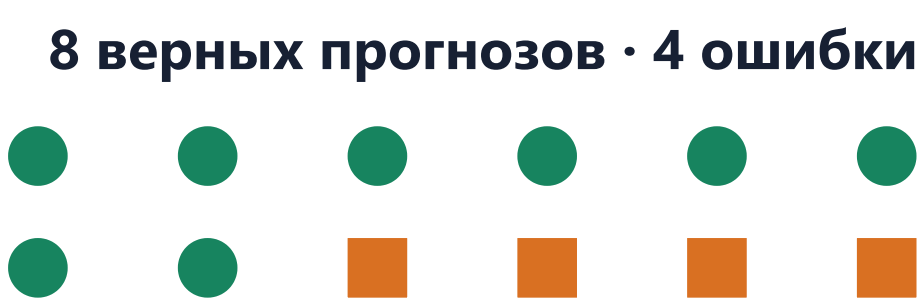


Вернёмся к тем же 12 объектам. В листе предсказываем класс большинства.

Можно ли взять долю ошибок как неоднородность H?

Классификация: выбор разбиения

Ошибка класса большинства



Лучший постоянный прогноз — класс большинства. Доля верных ответов равна наибольшей доле класса p_k.

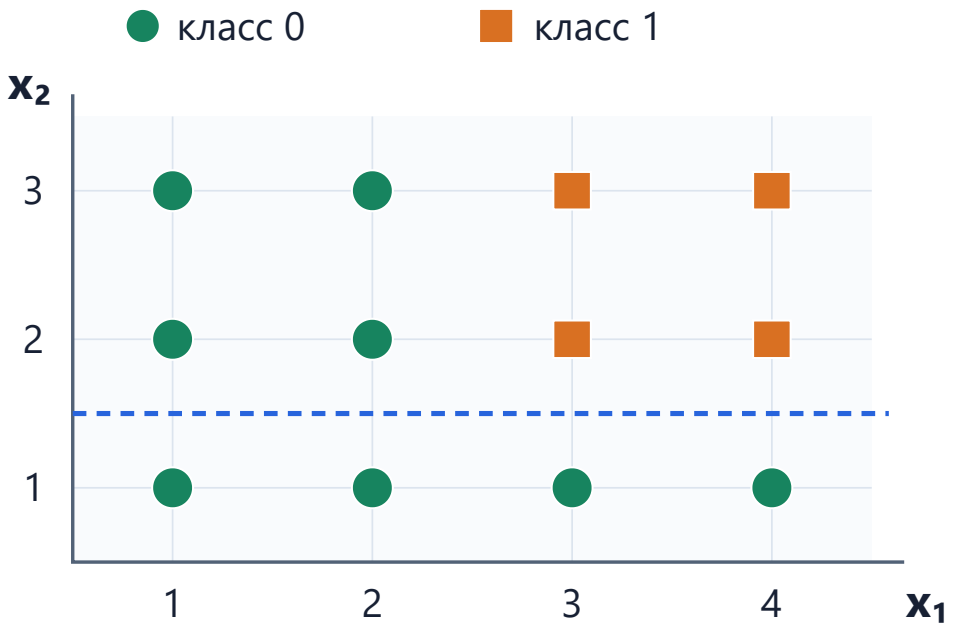
$$H_{\text{error}}(S) = 1 - \max_k p_k$$

$$H_{\text{error}}(S) = 1 - \frac{8}{12} = \frac{1}{3}$$

> Это мера неоднородности: у чистого узла она равна 0. Для двух классов максимум — 1/2, когда классы представлены поровну.

Классификация: выбор разбиения

Разбиение без снижения ошибки



Слева: 4 нуля.

Чистый лист, ошибок 0.

Справа: 4 нуля и 4 единицы.

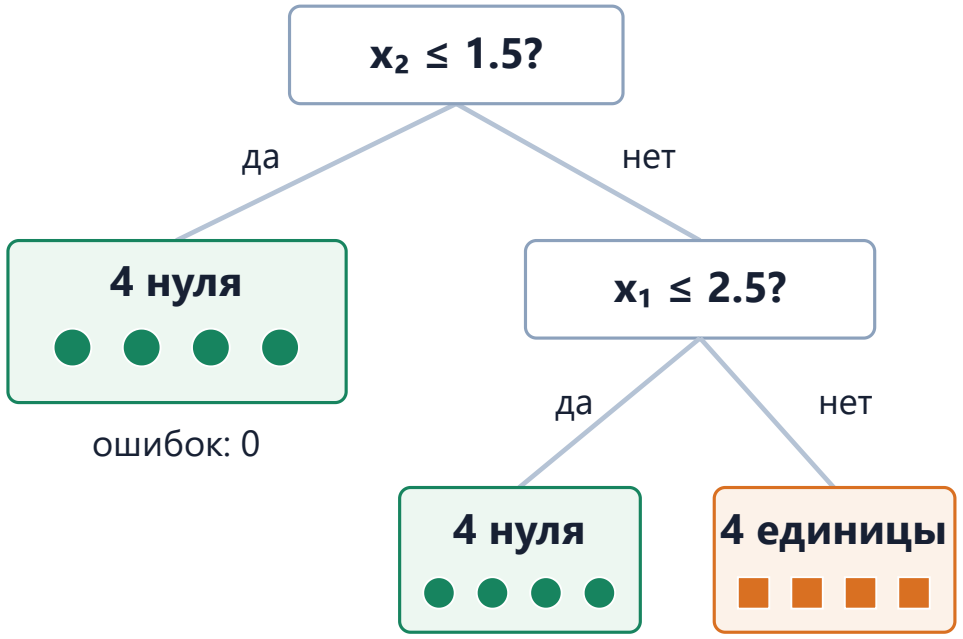
При любом выборе класса — 4 ошибки.

$$H_{\text{after}} = \frac{4}{12} \cdot 0 + \frac{8}{12} \cdot \frac{1}{2} = \frac{1}{3}$$

Было 4 ошибки → осталось 4.

Классификация: выбор разбиения

Полезный промежуточный шаг



Один из возможных маршрутов

До: 8 нулей и 4 единицы.
Прогноз класса 0 → 4 ошибки.

После $x_2 \le 1.5$: чистая группа и смешанная 4/4 → всё ещё 4 ошибки.

> В смешанной группе проверка $x_1 \le 2.5$ даёт две чистые группы → 0 ошибок на train.

Нужен критерий, замечающий изменение долей классов ещё до уменьшения числа ошибок.

Классификация: выбор разбиения

Неоднородность Gini

$$G(S) = 1 - \sum_{k=1}^{K} p_k^2, \qquad p_k = \frac{n_k}{n}$$

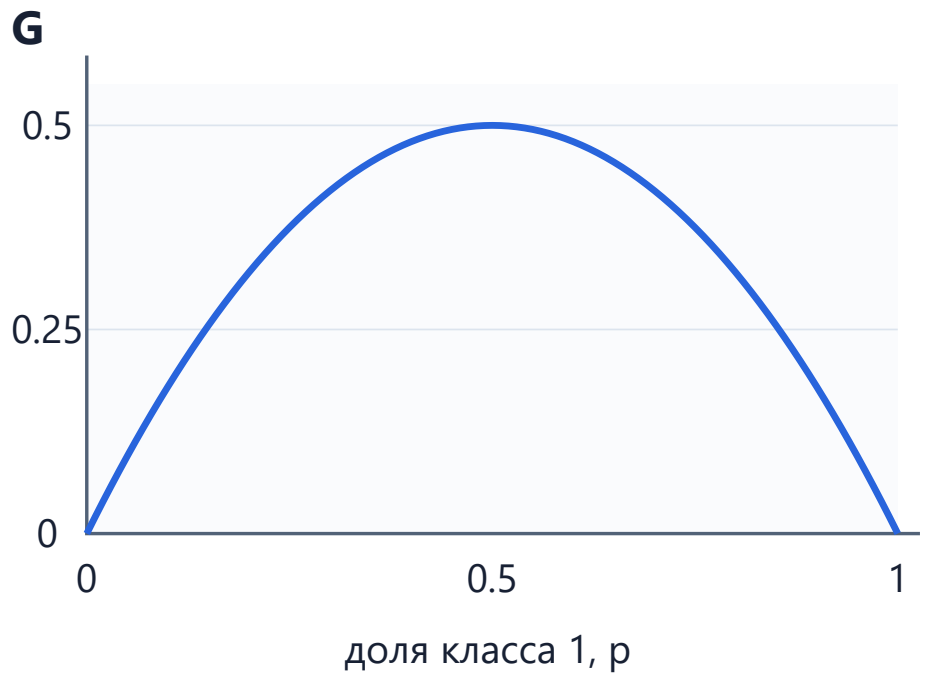
p_k — доля класса k среди объектов текущего узла.
Сумма долей классов равна 1.

> Меньше Gini → классы смешаны слабее.
> У чистого узла Gini равен 0.

Здесь Gini — критерий неоднородности классов.

Классификация: выбор разбиения

Gini для двух классов



Бинарный случай: K = 2,
p — доля класса 1 в узле.

$$G(p) = 1 - p^2 - (1-p)^2$$

$$G(p) = 2p(1-p)$$

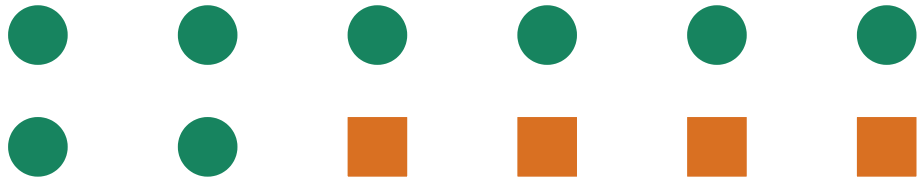
Чистый узел: G = 0.
При 50/50: G = 0.5, максимум.

> p = 0.2 → G = 0.32.

Классификация: выбор разбиения

Gini исходного узла

8 нулей · 4 единицы



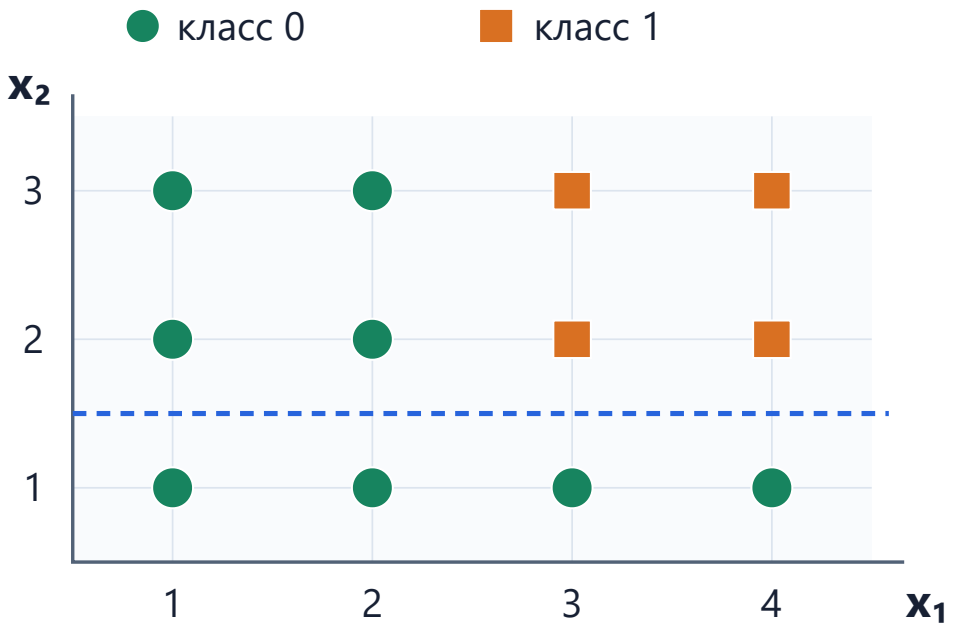
$$p_0 = \frac{8}{12} = \frac{2}{3}, \quad p_1 = \frac{4}{12} = \frac{1}{3}$$

$$G(S) = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}$$

Это общая отправная точка для всех кандидатов в данном узле.

Классификация: выбор разбиения

Кандидат A: $x_2 \le 1.5$



Слева: (4 нуля, 0 единиц), G = 0.

Справа: (4 нуля, 4 единицы), G = 1/2.

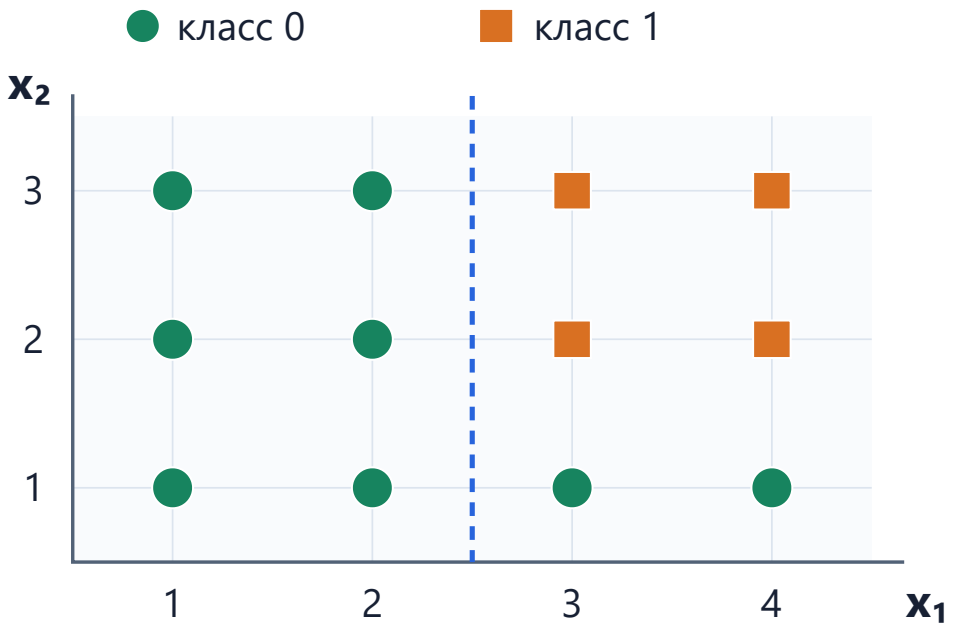
$$G_{\text{after}} = \frac{4}{12} \cdot 0 + \frac{8}{12} \cdot \frac{1}{2} = \frac{1}{3}$$

$$\Delta G_A = \frac{4}{9} - \frac{1}{3} = \frac{1}{9}$$

Gini заметил полезное изменение.

Классификация: выбор разбиения

Кандидат B: $x_1 \le 2.5$



Слева: 6 нулей, G = 0.

Справа: 2 нуля и 4 единицы.

$$G_R = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

$$G_{\text{after}} = \frac{6}{12} \cdot 0 + \frac{6}{12} \cdot \frac{4}{9} = \frac{2}{9}$$

$$\Delta G_B = \frac{4}{9} - \frac{2}{9} = \frac{2}{9}$$

Классификация: выбор разбиения

Выбор по Gini

Кандидат	Размеры групп	G после	ΔG
A: $x_2 \le 1.5$	4 и 8	1/3	1/9
B: $x_1 \le 2.5$	**6 и 6**	**2/9**	**2/9**

> Gini заметил улучшение состава групп при A и больший выигрыш при B. Оцениваем всё разбиение с учётом размеров групп.

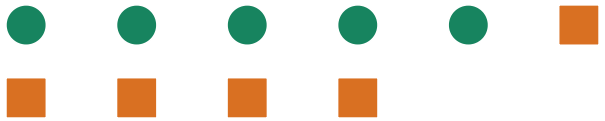
Gini — не единственная мера: можно оценивать неопределённость класса через энтропию.

Классификация: выбор разбиения

Неопределённость класса

Известны доли классов в узле. Хотим измерить неопределённость класса случайного объекта до того, как узнаем его значение.

50% / 50%



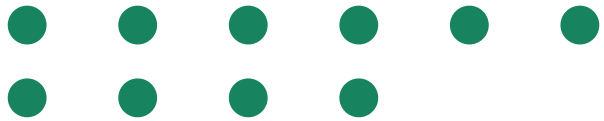
Два одинаково вероятных класса.

90% / 10%



Один класс встречается гораздо чаще.

100% / 0%



Класс уже известен.

Как количественно измерить эту неопределённость?

Классификация: энтропия

Сообщить значение класса

Из узла случайно выбран объект. Его метка известна отправителю.

Отправитель

Знает истинную метку выбранного объекта:

y = 1

Заранее согласованный двоичный код

→

Передаём значение y

Получатель

Знает классы 0/1 и доли 50/50, но пока не знает y.

> Сообщение здесь — метка класса. При повторном выборе объектов спросим: сколько бит в среднем нужно на одну метку?

Мысленный эксперимент: сравним средние затраты на сообщение меток при разных долях классов.

Классификация: энтропия

Один бит: два варианта

Как передать одну из двух равновероятных меток?

Класс 0 → `0` p = 1/2

Класс 1 → `1` p = 1/2

> Один двоичный знак различает два варианта. В этой равновероятной ситуации он сообщает 1 бит информации.

Договорившись о коде, получатель восстанавливает метку по одному символу: 0 или 1.

Классификация: энтропия

Восемь вариантов: три вопроса

Восемь равновероятных вариантов. Ищем 6; ответы 0/1 — биты кода.

1 2 3 4 5 6 7 8	→	Номер больше 4? **Да → бит 1**	→	5 6 7 8
5 6 7 8	→	Номер больше 6? **Нет → бит 0**	→	5 6
5 6	→	Номер больше 5? **Да → бит 1**	→	6

Код 101: три бинарных ответа сузили 8 вариантов до 1.
Последовательно осталось 8 → 4 → 2 → 1 вариантов.

Классификация: энтропия

От числа вариантов к логарифму

Каждый дополнительный двоичный знак удваивает число различимых вариантов.

Равновероятных вариантов m	Битов b	Вероятность одного исхода
2	1	1/2
4	2	1/4
8	3	1/8
16	4	1/16

$$m = 2^b \quad \Rightarrow \quad b = \log_2 m, \qquad p = \frac{1}{m} \quad \Rightarrow \quad b = -\log_2 p$$

> Пока получили эту связь для равновероятных исходов.

Классификация: энтропия

Если метки встречаются не поровну

Для объяснения кодов временно возьмём четыре класса A–D. Получатель знает их вероятности.

Метка	A	B	C	D
Вероятность	1/2	1/4	1/8	1/8

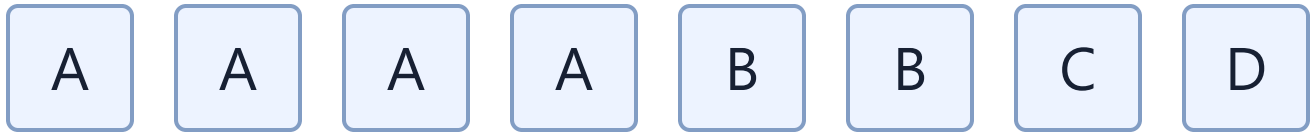


Иллюстрация частот: четыре A, два B, один C и один D.

Обязательно ли записывать каждую метку одинаковым числом битов?

Классификация: энтропия

Код постоянной длины

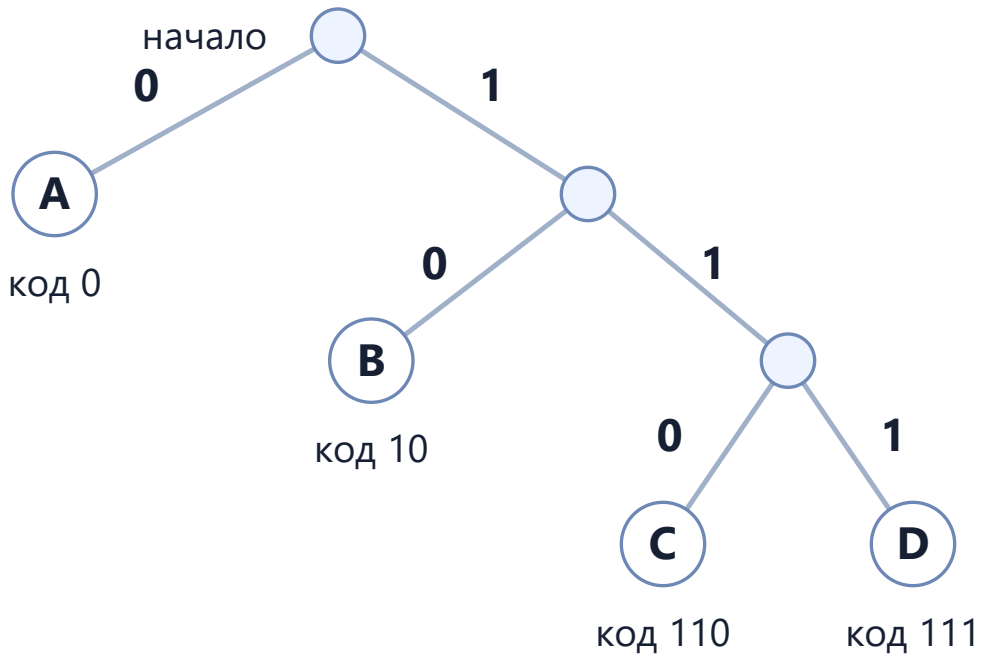
Метка	Вероятность	Код	Длина
A	1/2	`00`	2 бита
B	1/4	`01`	2 бита
C	1/8	`10`	2 бита
D	1/8	`11`	2 бита

$$\bar{L} = \frac{1}{2}\cdot 2 + \frac{1}{4}\cdot 2 + \frac{1}{8}\cdot 2 + \frac{1}{8}\cdot 2 = 2 \text{ бита}$$

> Всегда передаём два бита на метку. Частоты классов на длину этого кода не влияют.

Классификация: энтропия

Код переменной длины



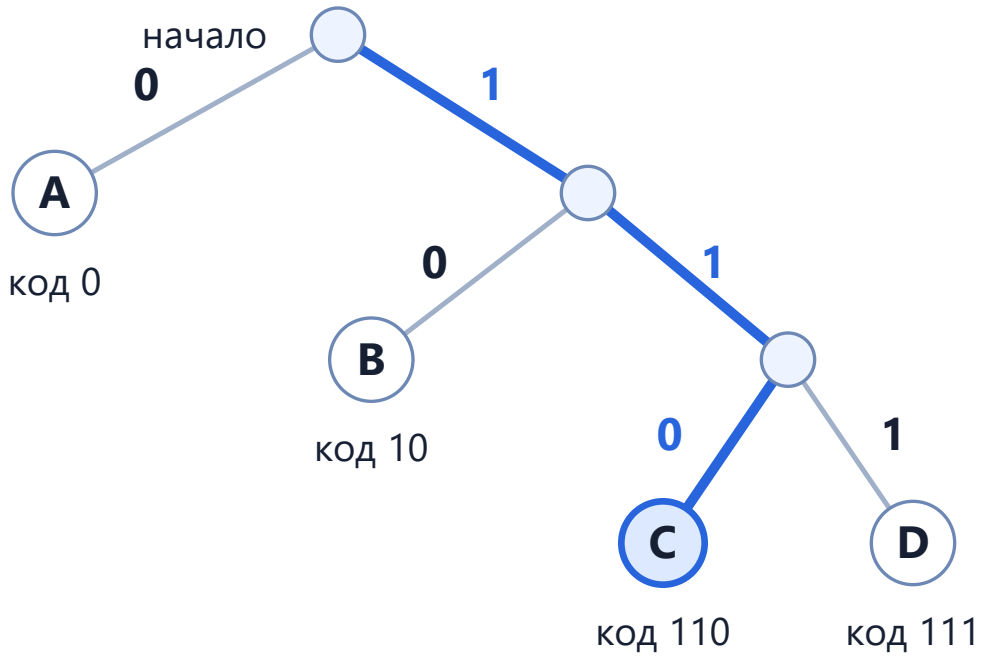
Метка	Код	Длина
A	`0`	1
B	`10`	2
C	`110`	3
D	`111`	3

Ни одно кодовое слово не является началом другого. Дойдя до листа, получатель знает, где закончилась метка.

Это дерево декодирования: ветви — биты сообщения. В CART ветвь выбирается проверкой признаков объекта.

Классификация: энтропия

Как прочитать код 110



Получены биты: `110`

Начинаем в верхнем узле.

Первый бит 1 → правая ветвь.

Второй бит 1 → снова направо.

> Третий бит 0 → налево.
> Достигнут лист C: метка восстановлена.

Читаем биты слева направо: каждый следующий бит выбирает следующую ветвь.

Классификация: энтропия

Средняя длина стала меньше

Серия с четырьмя A, двумя B, одним C и одним D:

	A	A	A	A	B	B	C	D	
Равная длина	0 0	0 0	0 0	0 0	0 1	0 1	1 0	1 1	**16 бит**
Разная длина	0	0	0	0	1 0	1 0	1 1 0	1 1 1	**14 бит**

$$\bar{L} = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75 \text{ бита}$$

Частый A получает короткий код; более длинные C и D встречаются реже.

Классификация: энтропия

Длина кода и вероятность

С чем совпали длины выбранного кода?

Метка	p(y)	Код	Длина	$-\log_2 p(y)$
A	1/2	`0`	1	1
B	1/4	`10`	2	2
C	1/8	`110`	3	3
D	1/8	`111`	3	3

> Для этих вероятностей — степеней 1/2 — длины точно равны $-\log_2 p(y)$. У произвольного распределения такого точного совпадения может не быть.

Классификация: энтропия

Информация независимых исходов

Монета честная; О — орёл, Р — решка. Сопоставим один исход и последовательность двух независимых бросков.

Получили Р

$$p = \frac{1}{2}, \qquad -\log_2 p = 1 \text{ бит}$$

Получили РО

$$p = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

$$-\log_2 \frac{1}{4} = 2 \text{ бита}$$

$$-\log_2(pq) = -\log_2 p - \log_2 q$$

Вероятности независимых исходов перемножаются, а информация о них складывается. Логарифм согласуется с этим свойством.

Классификация: энтропия

Информация об одном исходе

Обобщим мотивированную связь: информационное содержание исхода y с вероятностью p(y) > 0 определяем как

$$h(y) = -\log_2 p(y)$$

p(y)	0.9	0.5	0.1
h(y), бит	≈ 0.152	1	≈ 3.322

> Редкий исход статистически более неожиданен. Практическую важность или полезность сообщения эта мера не оценивает.

Дробные h(y) измеряют информацию; длина отдельного двоичного кодового слова — целое число битов.

Классификация: энтропия

Известный, равновероятный, редкий

Сравним три ситуации, в которых вероятность наступившего исхода различается.

Метка заранее известна

$$p(y) = 1$$

$$h(y) = -\log_2 1 = 0$$

Получатель уже знает ответ: новой информации 0 бит.

Равновероятные 0 и 1

$$p(y) = 1/2$$

$$h(y) = -\log_2(1/2) = 1$$

Один бит различает два возможных исхода.

Редкий C в примере A–D

$$p(C) = 1/8$$

$$h(C) = -\log_2(1/8) = 3$$

Здесь 3 бита информации совпали с длиной кода `110`.

> Заранее известный результат не сообщает нового. Редкий наступивший исход статистически более неожиданен.

Классификация: энтропия

Средняя информация о метке

Метка Y	Вероятность	h(y), бит
A	1/2	1
B	1/4	2
C	1/8	3
D	1/8	3

Сколько информации получаем в среднем?

Y — случайная метка. Усредним h(Y), учитывая частоты всех возможных исходов.

$$H(Y) = \mathbb{E}[h(Y)] = \sum_k p_k h(k)$$

$$H(Y) = \frac{1}{2}\cdot 1 + \frac{1}{4}\cdot 2 + \frac{1}{8}\cdot 3 + \frac{1}{8}\cdot 3 = 1.75 \text{ бита}$$

h(y) относится к одному исходу; H(Y) характеризует всё распределение до наблюдения метки.

Классификация: энтропия

Энтропия Шеннона

Подставим информацию одного исхода в формулу среднего:

$$h(k) = -\log_2 p_k, \qquad H(Y) = \sum_{k=1}^{K} p_k h(k)$$

$$H(Y) = -\sum_{k=1}^{K} p_k \log_2 p_k$$

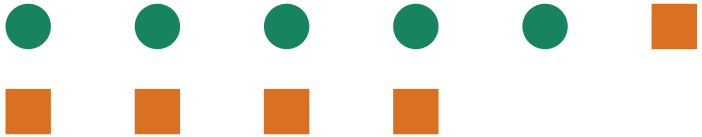
> Энтропия Шеннона — неопределённость класса до наблюдения метки, равная средней информации от её раскрытия.

В специальном примере A–D получили H(Y) = 1.75 бита; это совпало со средней длиной показанного кода.

Классификация: энтропия

Средняя информация: два примера

50% / 50%

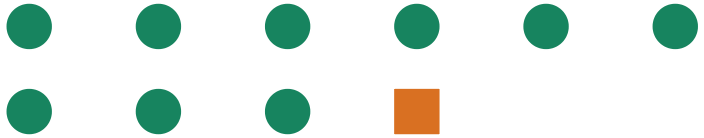


$$-\log_2 0.5 = 1$$

$$H(Y) = 0.5 \cdot 1 + 0.5 \cdot 1 = 1$$

Каждый исход даёт 1 бит.

90% / 10%



$$-\log_2 0.9 \approx 0.152$$

$$-\log_2 0.1 \approx 3.322$$

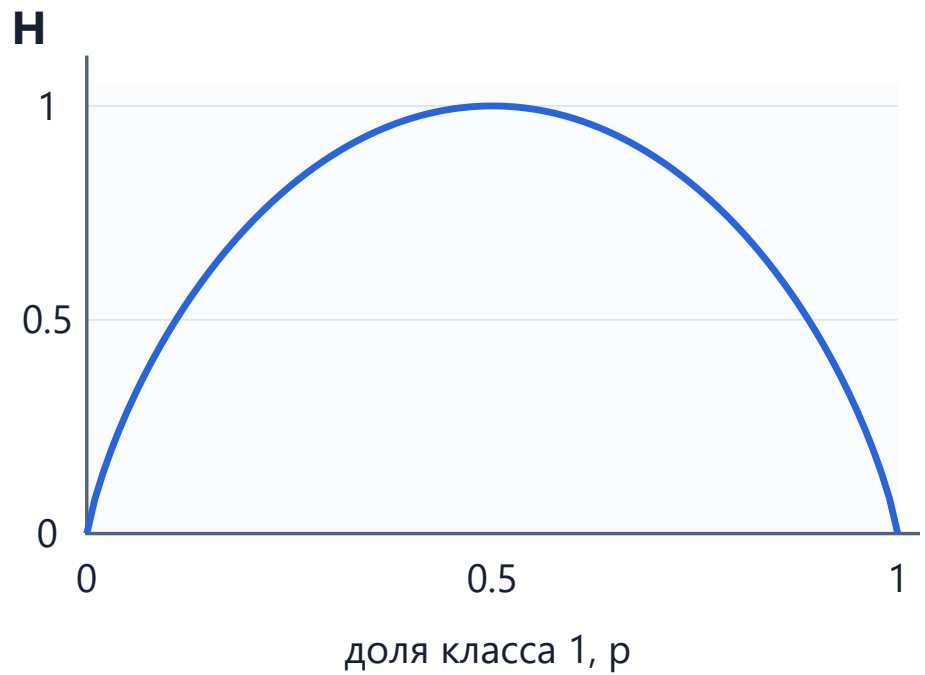
$$H(Y) = -0.9 \log_2 0.9 - 0.1 \log_2 0.1$$

$$\approx 0.469 \text{ бита}$$

> Редкий исход даёт много информации только в 10% случаев. Поэтому средняя неопределённость при 90/10 ниже, чем при 50/50.

Классификация: энтропия

Энтропия двух классов



p — доля класса 1,
1 – p — доля класса 0.

$$H(p) = -(1-p)\log_2(1-p) - p\log_2 p$$

> Чистый узел: 0 бит.
> Доли 50/50: максимум 1 бит.

Как и Gini, энтропия — мера неоднородности классов.

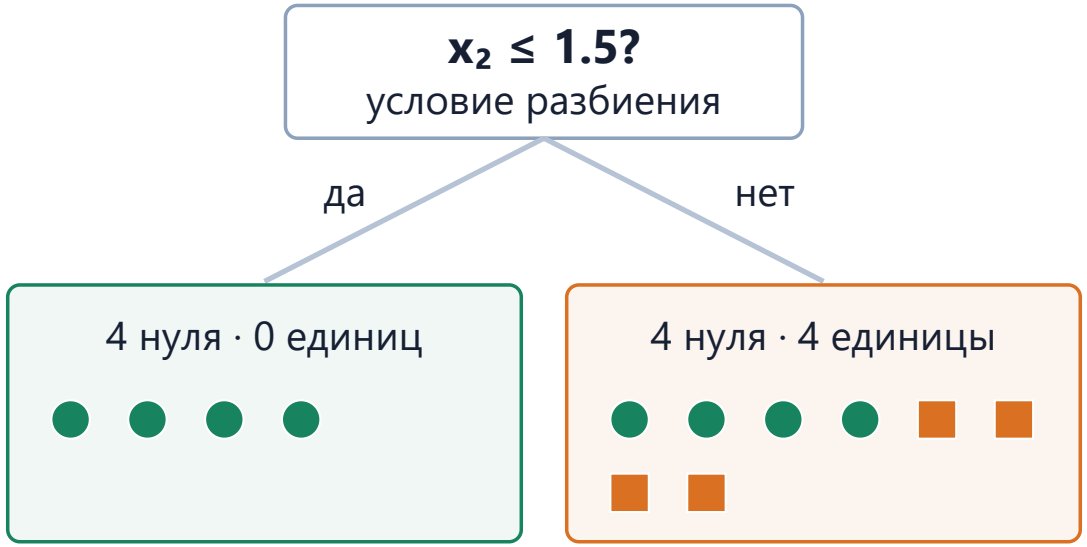
Для отсутствующего класса вклад принимаем равным 0: это предел $-p \log_2 p$ при $p \to 0+$, а не подстановка $\log_2 0$.

Классификация: выбор разбиения

Энтропия в узлах дерева

Снова прежние 12 обучающих объектов: 8 нулей и 4 единицы. Энтропию долей классов узла S обозначаем $H_{ent}(S)$.

$$H_{\text{ent}}(S) = -\frac{8}{12}\log_2\frac{8}{12} - \frac{4}{12}\log_2\frac{4}{12} \approx 0.918 \text{ бита}$$



Слева доли (1, 0): класс уже известен.

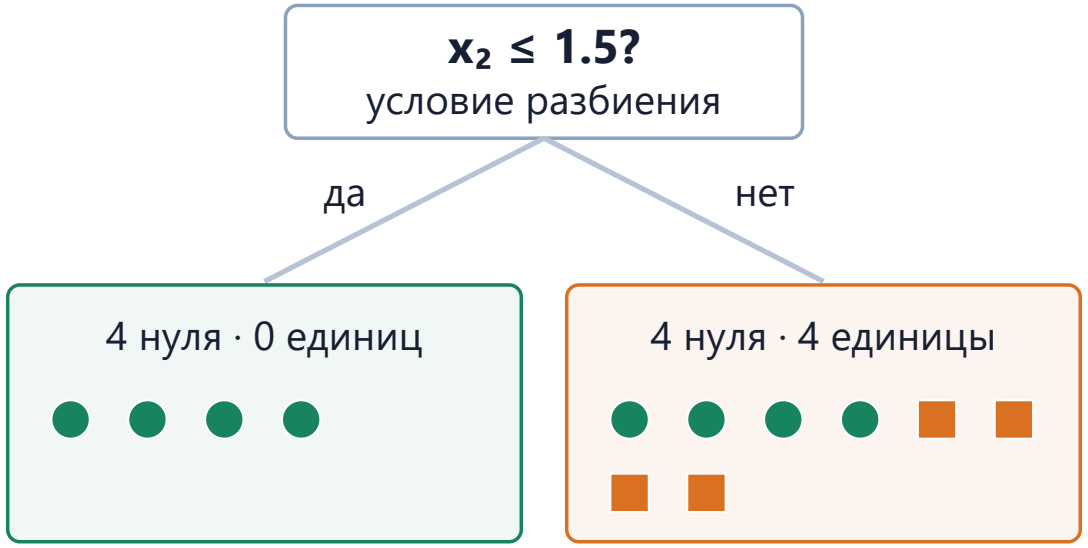
$$H_{\text{ent}}(S_L) = -1\log_2 1 = 0$$

Справа доли (1/2, 1/2):

$$H_{\text{ent}}(S_R) = -\frac{1}{2}\log_2\frac{1}{2} - \frac{1}{2}\log_2\frac{1}{2} = 1$$

Классификация: выбор разбиения

Информационный выигрыш



Используем энтропию как H в общей схеме. До разбиения $H_{ent}(S) \approx 0.918$ бита.

$$H_{\text{ent,after}} = \frac{4}{12} \cdot 0 + \frac{8}{12} \cdot 1 = \frac{2}{3}$$

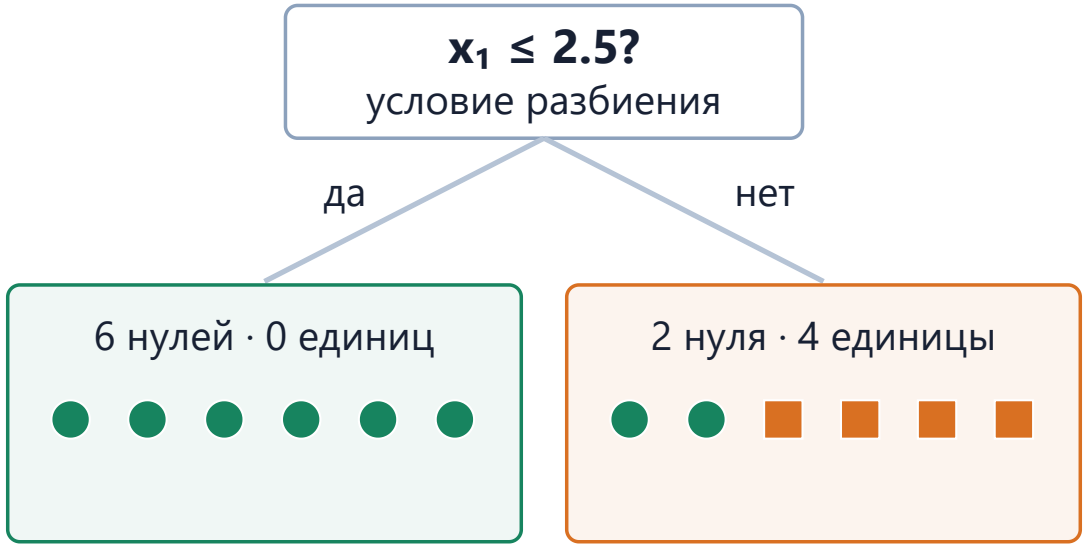
$$\begin{aligned} IG &= H_{\text{ent}}(S) - H_{\text{ent,after}} \\ &\approx 0.918296 - 0.666667 \\ &\approx 0.252 \text{ бита} \end{aligned}$$

IG — среднее уменьшение неопределённости истинной метки, когда известна дочерняя группа объекта.

IG не равен числу бит в ответе на условие. Качество прогнозов на validation проверяют отдельно.

Классификация: выбор разбиения

Энтропия после разбиения B



Слева 6 нулей: $H_{ent}(S_L) = 0$.

Справа 2 нуля и 4 единицы: доли (1/3, 2/3).

$$H_{\text{ent}}(S_R) = H_{\text{ent}}(1/3, 2/3) \approx 0.918$$

Это те же доли 2/3 и 1/3, что в исходном узле, только в обратном порядке.

$$H_{\text{ent,after},B} = \frac{6}{12} \cdot 0 + \frac{6}{12} \cdot 0.918296 \approx 0.459148$$

Обе группы содержат по 6 из 12 объектов: их веса равны 1/2.

Классификация: выбор разбиения

Выбор по информационному выигрышу

Берём H = H_{ent}: для 12 объектов $H_{ent}(S) \approx 0.918296$ бита.

$$H_{\text{after}} = \frac{n_L}{n} H(S_L) + \frac{n_R}{n} H(S_R), \quad IG = \Delta H = H(S) - H_{\text{after}}$$

Разбиение	Энтропия после, бит	IG, бит
A: $x_2 \le 1.5$	$2/3 \approx 0.667$	≈ 0.252
B: $x_1 \le 2.5$	**$(1/2) \cdot H_{ent}(1/3, 2/3) \approx 0.459$**	**≈ 0.459**

> Больший IG у B: 0.918296 − 0.459148 ≈ 0.459 бита.
> В этом примере и Gini, и энтропия выбирают B.

В других данных критерии могут ранжировать кандидатов по-разному. Далее строим CART по Gini.

Классификация: выбор разбиения

Что сравнивает алгоритм

Распределение классов
в текущем узле

→

Gini или энтропия
выбираем меру H

→

Наибольший ΔH
выбираем условие

> Gini и энтропия — альтернативные меры неоднородности классов.

Далее построим CART целиком, используя Gini.

Рекурсивное обучение CART

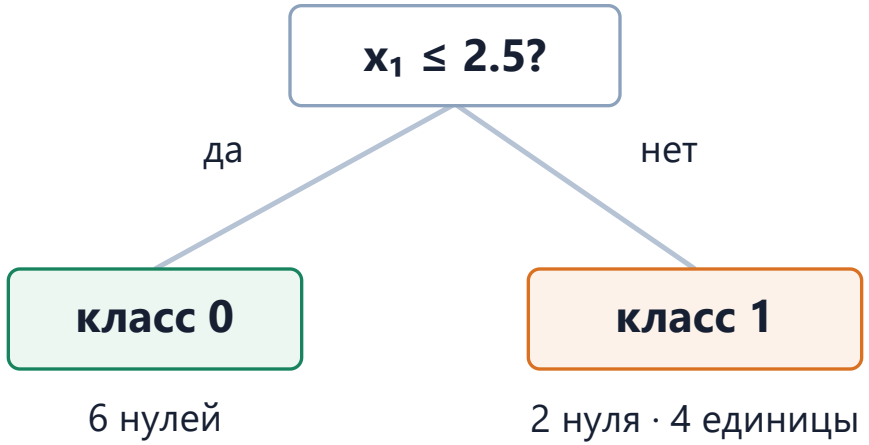
Пять кандидатов в корне

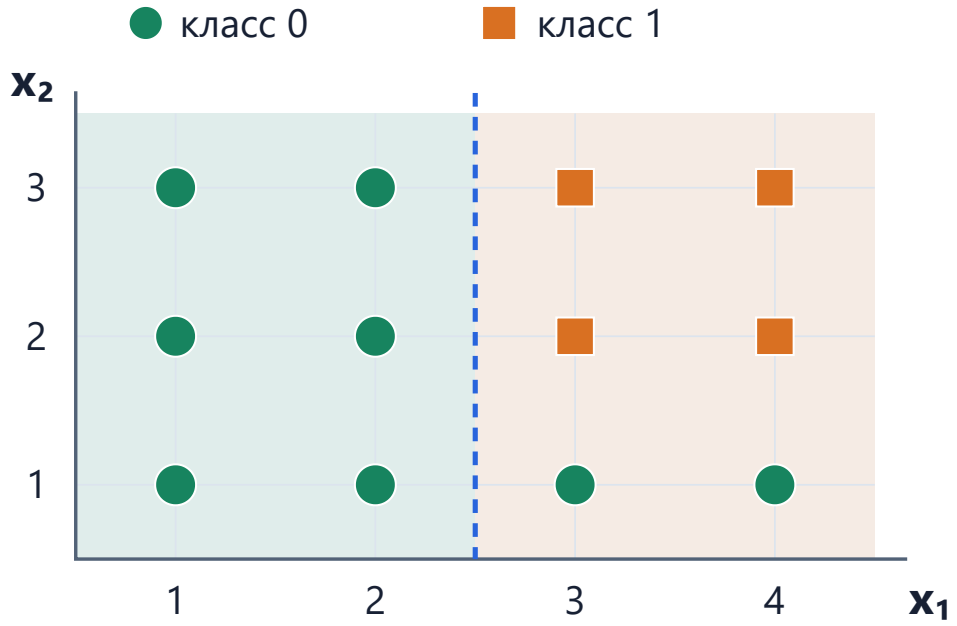
Условие	nL / nR	Выигрыш Gini
$x_1 \le 1.5$	3 / 9	2/27 ≈ 0.074
$x_1 \le 2.5$	**6 / 6**	**2/9 ≈ 0.222**
$x_1 \le 3.5$	9 / 3	2/27 ≈ 0.074
$x_2 \le 1.5$	4 / 8	1/9 ≈ 0.111
$x_2 \le 2.5$	8 / 4	1/36 ≈ 0.028

12 объектов, 8 нулей и 4 единицы. Во всех строках Gini до разбиения равен 4/9.

Рекурсивное обучение CART

Первое выбранное условие

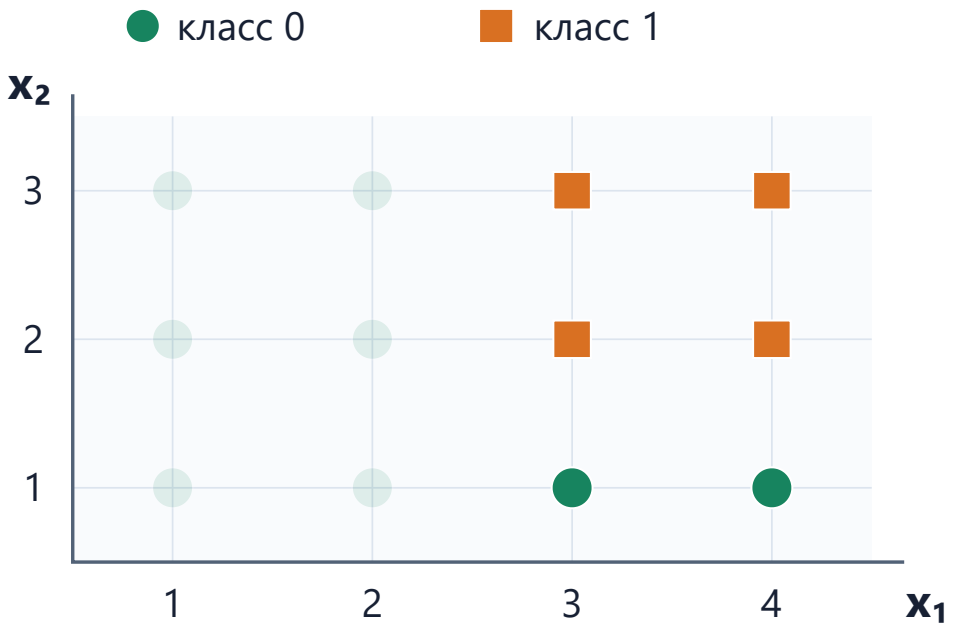




Слева — чистый лист. Справа — ещё смешанная группа.
Продолжаем обучение только в правом узле.

Рекурсивное обучение CART

Правый дочерний узел



2 нуля · 4 единицы



$$G(S_R) = 1 - \left(\frac{1}{3}\right)^2 - \left(\frac{2}{3}\right)^2 = \frac{4}{9}$$

Доли, веса и кандидатов теперь считаем по шести объектам, а не по двенадцати.

Рекурсивное обучение CART

Три локальных кандидата

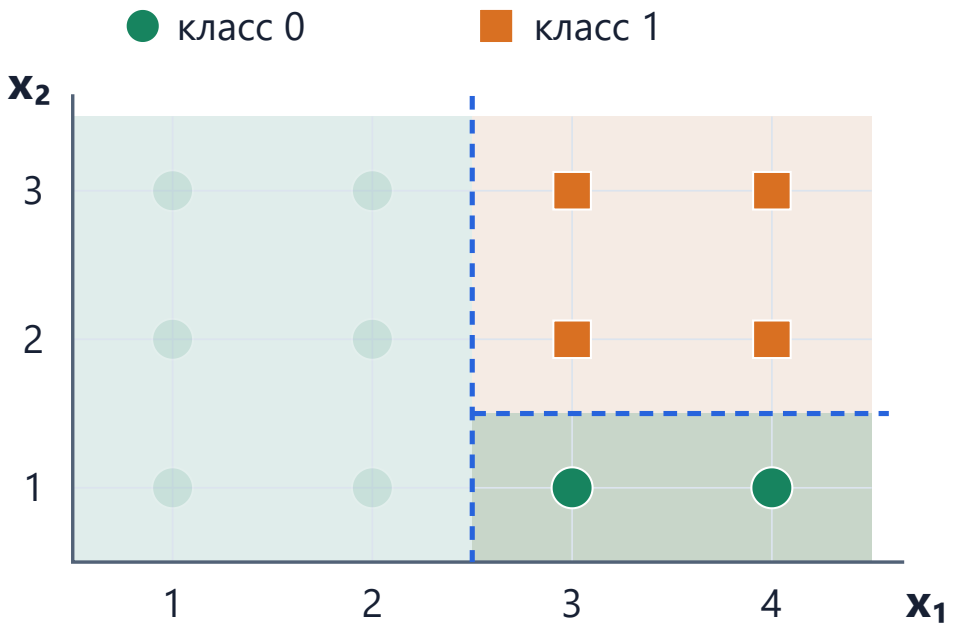
Условие	nL / nR	Выигрыш Gini
$x_1 \le 3.5$	3 / 3	0
$x_2 \le 1.5$	**2 / 4**	**4/9**
$x_2 \le 2.5$	4 / 2	1/9

После $x_2 \le 1.5$ оба дочерних узла чистые:

$$\Delta G = \frac{4}{9} - \left(\frac{2}{6} \cdot 0 + \frac{4}{6} \cdot 0 \right) = \frac{4}{9}$$

Рекурсивное обучение CART

Второе выбранное условие



$x_2 \le 1.5$ → два объекта класса 0.

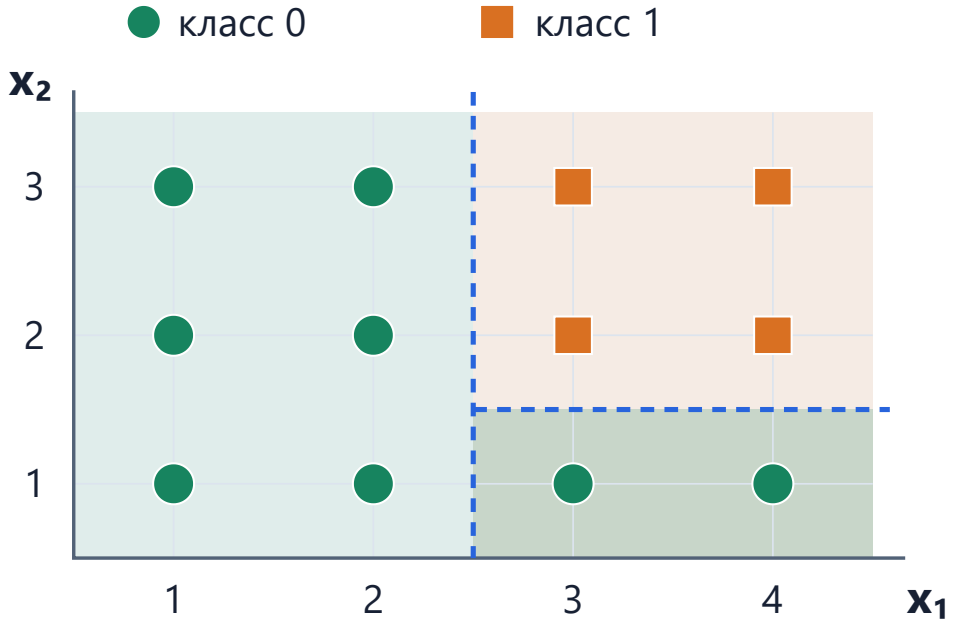
$x_2 > 1.5$ → четыре объекта класса 1.

> Все конечные узлы чистые.
> На этих данных можно остановиться.

Рекурсивное обучение CART

Обученная модель





Fit завершён: оба условия выбраны по обучающим данным, в листьях сохранены прогнозы. Получили три чистых листа и три области постоянного прогноза.

Рекурсивное обучение CART

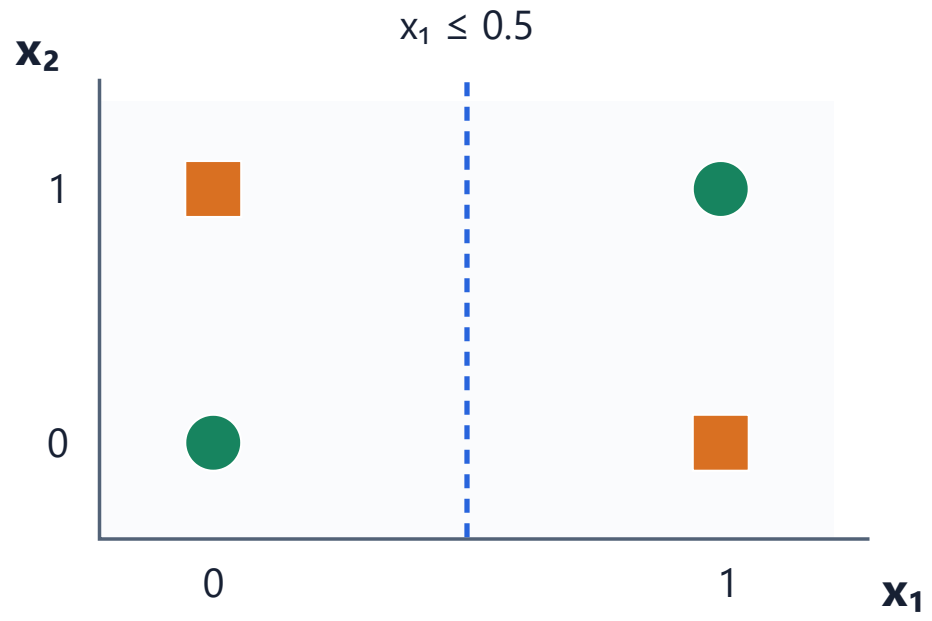
Алгоритм CART

1. Получить объекты текущего узла S.
2. Проверить остановку; если она выполнена, сохранить прогноз листа.
3. Перебрать допустимые условия и выбрать наибольшее уменьшение неоднородности.
4. Разделить S и повторить процедуру для каждого дочернего узла.

> CART — Classification and Regression Trees.
> Жадный поиск выбирает лучшее текущее условие, не перебирая будущие деревья целиком.

Рекурсивное обучение CART

Нулевой первый выигрыш: XOR



В исходном узле классы поровну: G = 1/2.

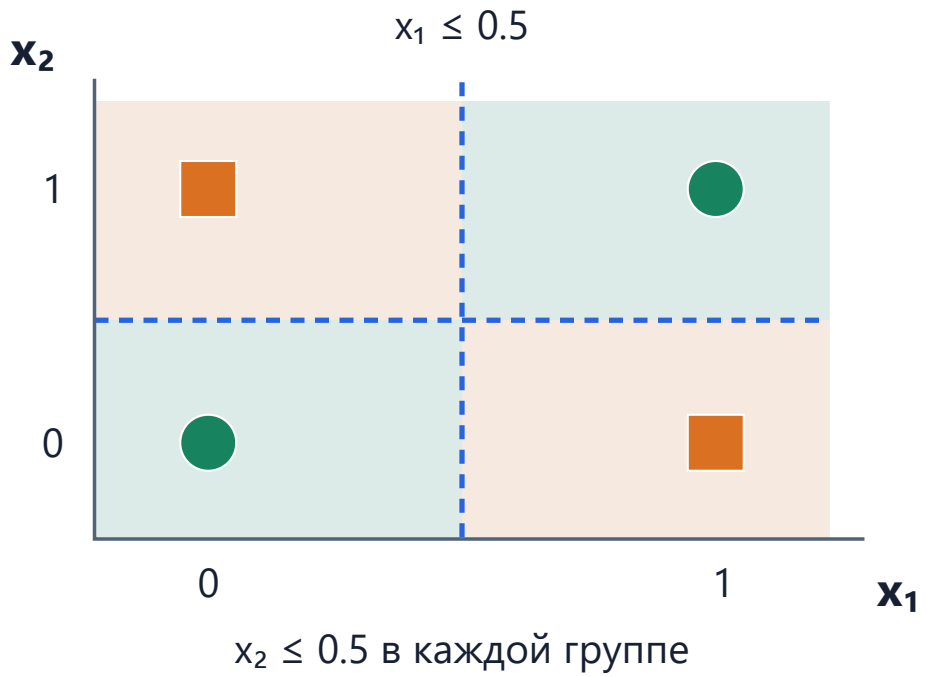
После первого вопроса в каждой группе снова по одному объекту каждого класса.

$$\Delta G = \frac{1}{2} - \left(\frac{1}{2} \cdot \frac{1}{2} + \frac{1}{2} \cdot \frac{1}{2} \right) = 0$$

> Первый шаг не уменьшает неоднородность.

Рекурсивное обучение CART

Полезный второй уровень: XOR



$x_2 \le 0.5$ в каждой группе

В каждой из двух групп задаём вопрос $x_2 \le 0.5$.

> Получаем четыре чистые области: G каждого листа равен 0.

Если нулевой выигрыш разрешён, дерево для XOR можно построить. Если требуется строго положительное улучшение, алгоритм остановится до полезного второго уровня.

Сложность и переобучение

Переобучение дерева



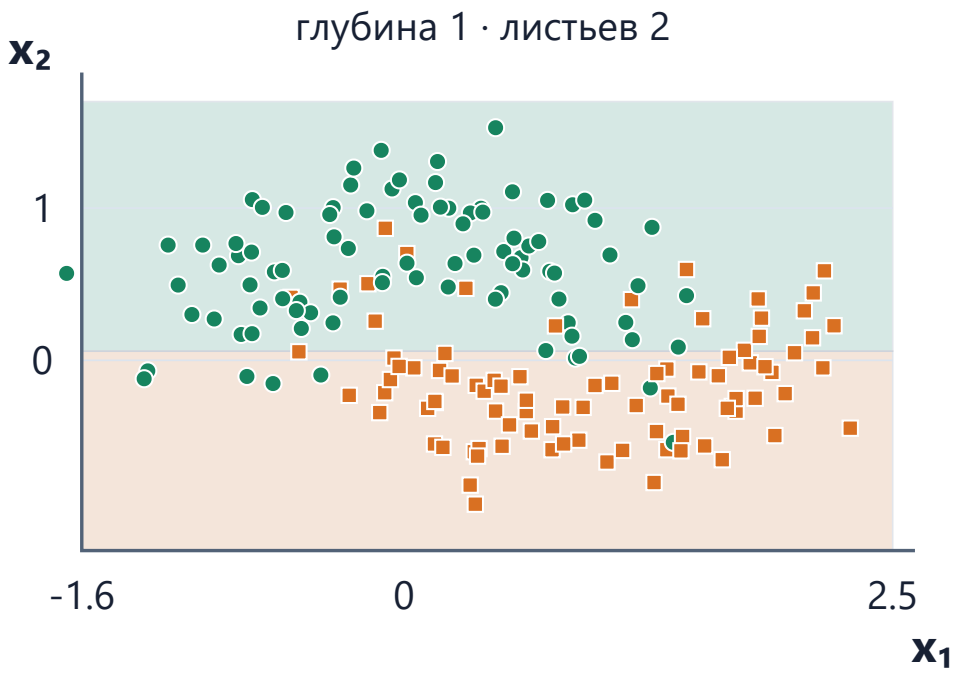
Разбиения могут становиться всё мельче.

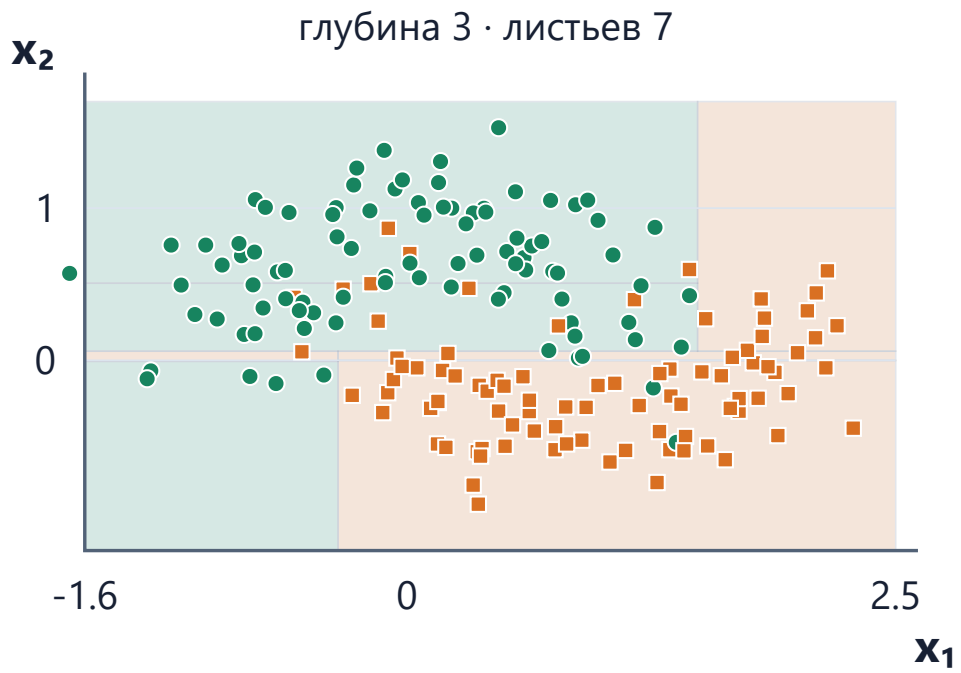
Дерево подстраивается и под закономерность, и под случайные особенности отдельных наблюдений.

> Хорошее качество на train нужно проверить на новых объектах.

Сложность и переобучение

Глубина и граница классов

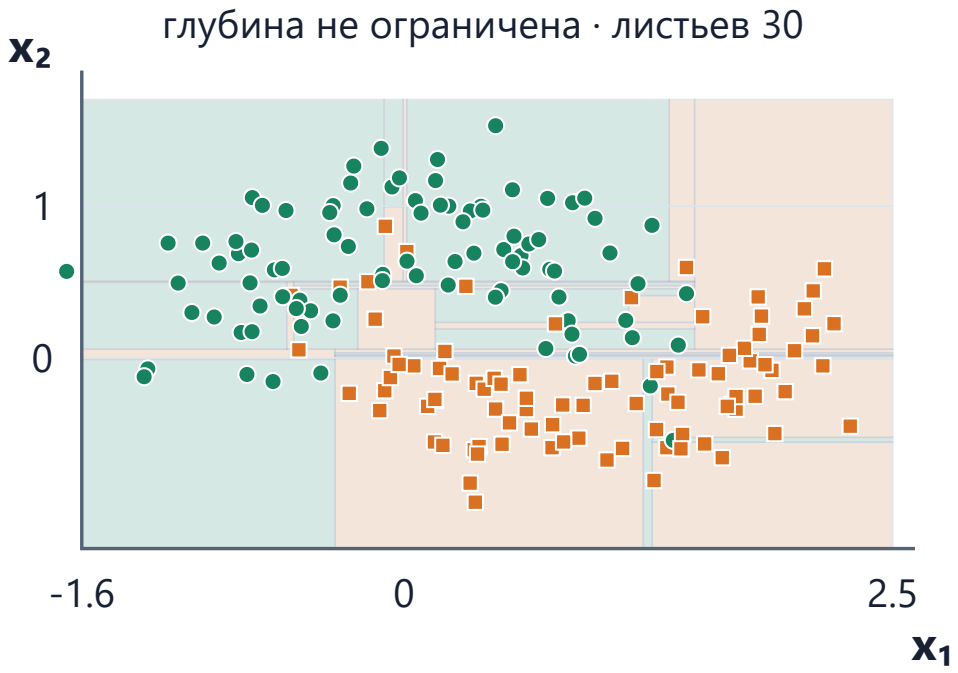




Те же 180 объектов; цветные области — прогноз модели, точки и квадраты — истинные классы.

Сложность и переобучение

Мелкие области и шум



Некоторые листья обслуживают очень небольшие группы.

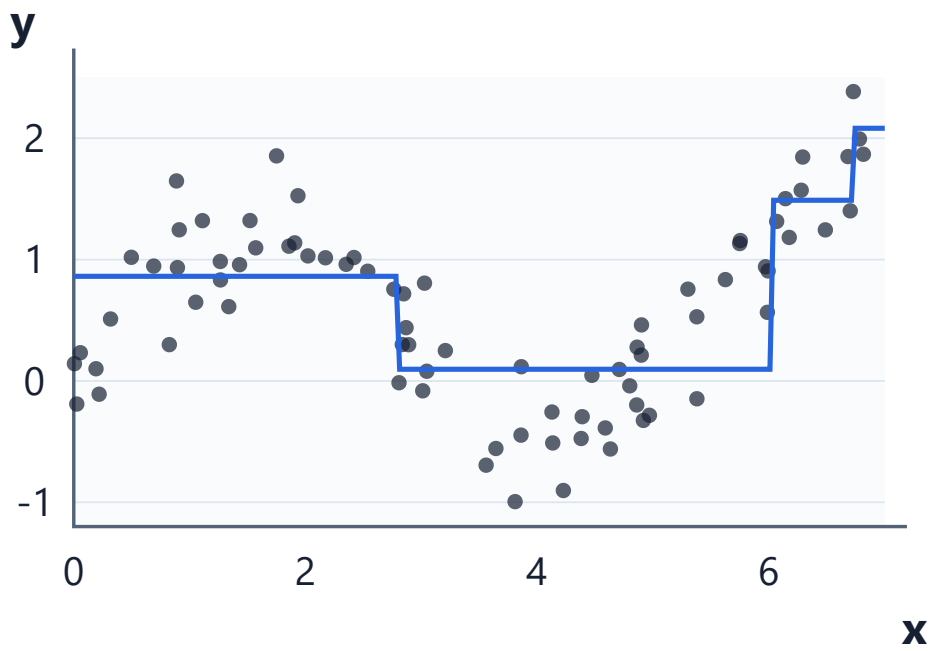
Вместе с закономерностью дерево подстраивается под шум.

> Нулевая ошибка на train не означает нулевую ошибку на validation.

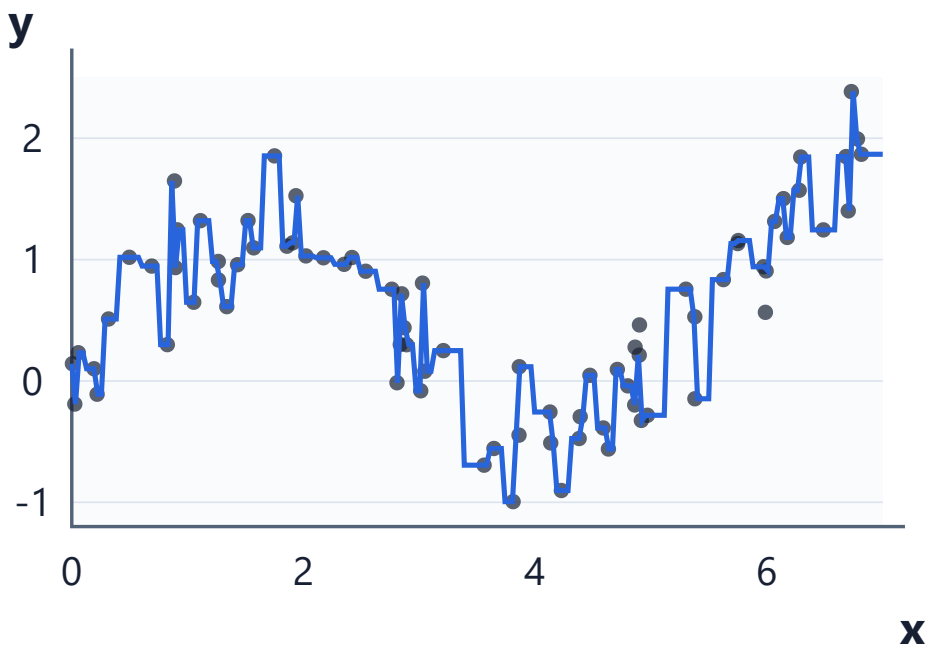
Сложность и переобучение

Глубина регрессионного дерева

Глубина 2



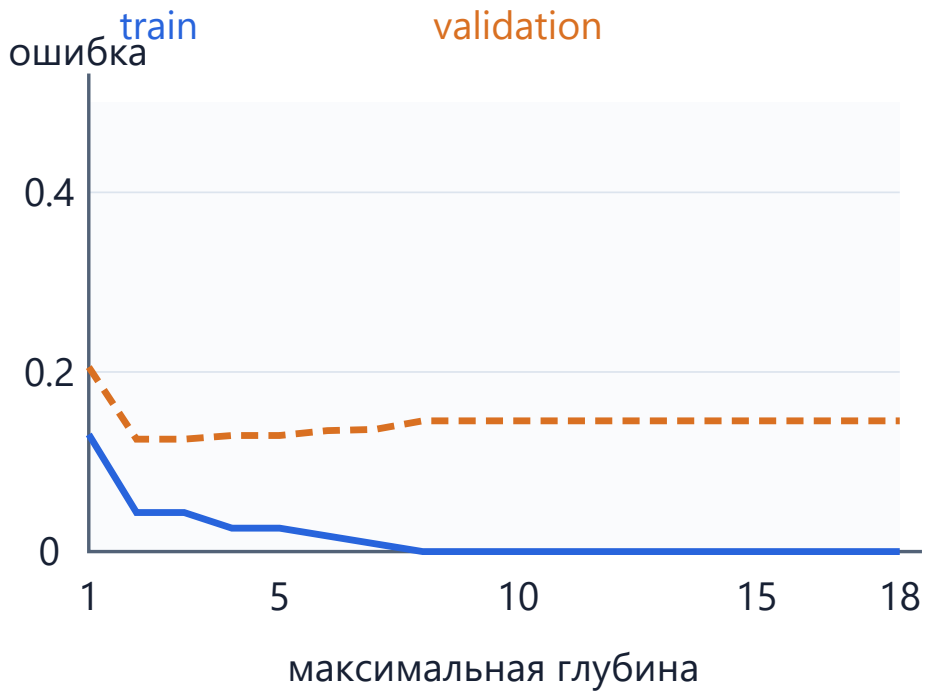
Без ограничения глубины



Независимый синтетический пример: 80 наблюдений с шумом. Справа дерево реагирует на локальные колебания y.

Сложность и переобучение

Ошибка на новых объектах



В этом опыте — 115 train и 735 validation-объектов.

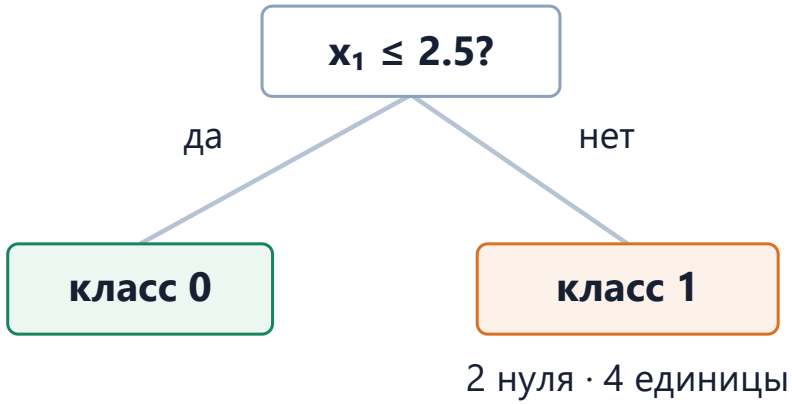
С ростом глубины train-ошибка снижается, но validation перестаёт улучшаться.

> Сложность выбираем по validation или CV.

Сложность и переобучение

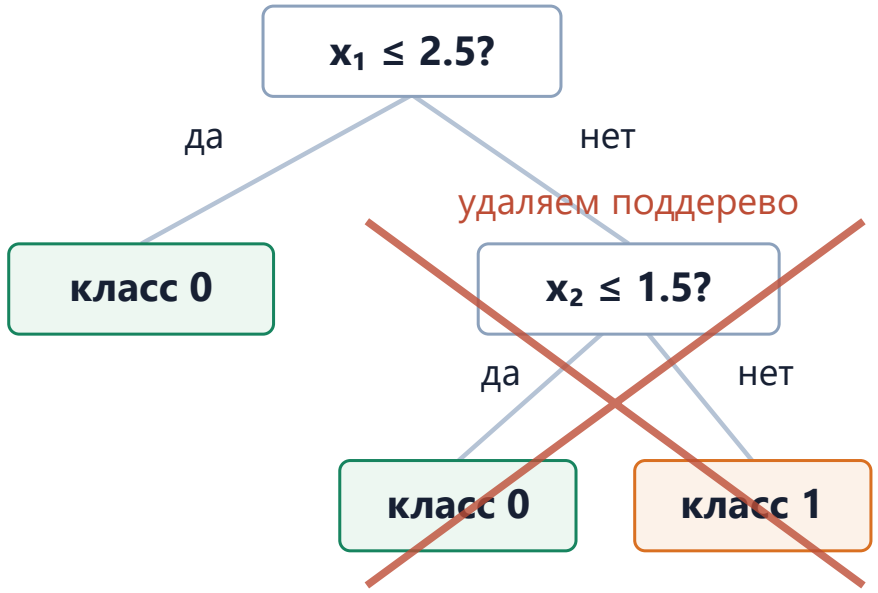
Два способа ограничить дерево

Pre-pruning



Заранее ограничить рост: не создавать слишком сложные разбиения.

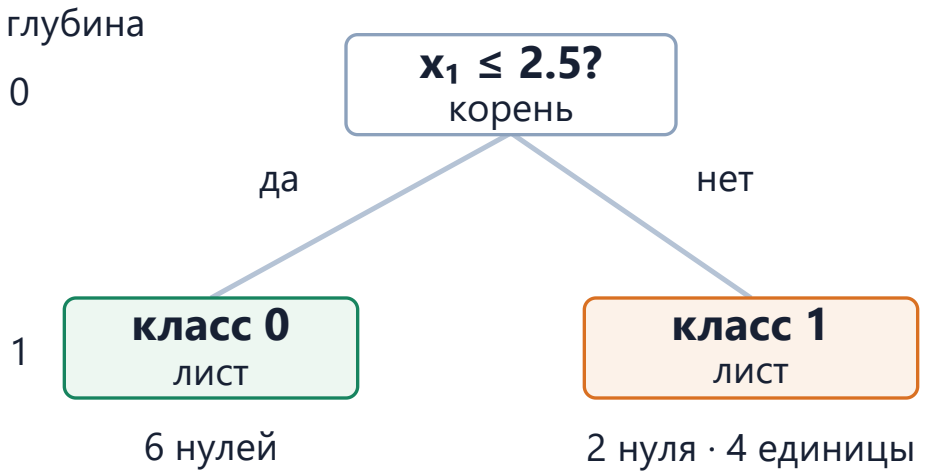
Post-pruning



Сначала вырастить дерево, затем заменить часть поддеревьев листьями.

Сложность и переобучение

Ограничение глубины



`max_depth = 1`

Корень — глубина 0.
Следующий уровень — глубина 1.

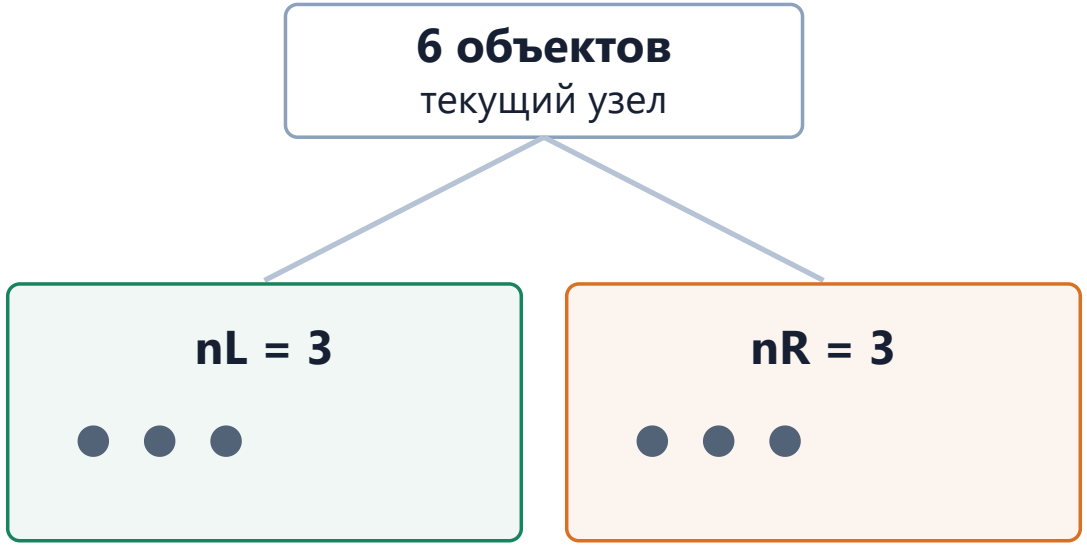
> Правый узел остаётся смешанным: новый уровень запрещён.

Короткий путь не позволяет последовательно выделять всё более мелкие особенности и шум.

Сложность и переобучение

Минимальный размер текущего узла

`min_samples_split = 6`



Проверяем число объектов до поиска разбиения.

> 6 объектов: поиск разбиения разрешён.

В маленькой группе отдельные наблюдения сильнее влияют на выбранное условие.

Сложность и переобучение

Минимальный размер дочерних узлов

`min_samples_leaf = 4`



Для каждого кандидата проверяем обе получившиеся группы.

> 3 + 9: недопустимо, в левой группе меньше 4 объектов.

Так ограничиваем появление маленьких листьев с неустойчивыми прогнозами.

Сложность и переобучение

Размер листа и устойчивость долей

Лист из двух объектов

До



Выделенная метка: 1 → 0

После



$$\hat{p}_1 : \quad \frac{2}{2} = 1 \longrightarrow \frac{1}{2} = 0.5$$

Лист из десяти объектов

До



Выделенная метка: 1 → 0

После



$$\hat{p}_1 : \quad \frac{7}{10} = 0.7 \longrightarrow \frac{6}{10} = 0.6$$

Одна метка 1 → 0. В малом листе доля класса меняется сильнее.

Сложность и переобучение

Минимальный выигрыш

Условный числовой пример:

$$H_{\text{before}} = 0.32, \quad H_{\text{after}} = 0.31$$

$$\Delta H = 0.01 < 0.02$$

> Если требуем улучшение не меньше 0.02,
> такое разбиение не принимается.

Это ещё один способ остановить рост, когда следующий шаг почти не улучшает состав групп.

Сложность и переобучение

Что проверяет pre-pruning

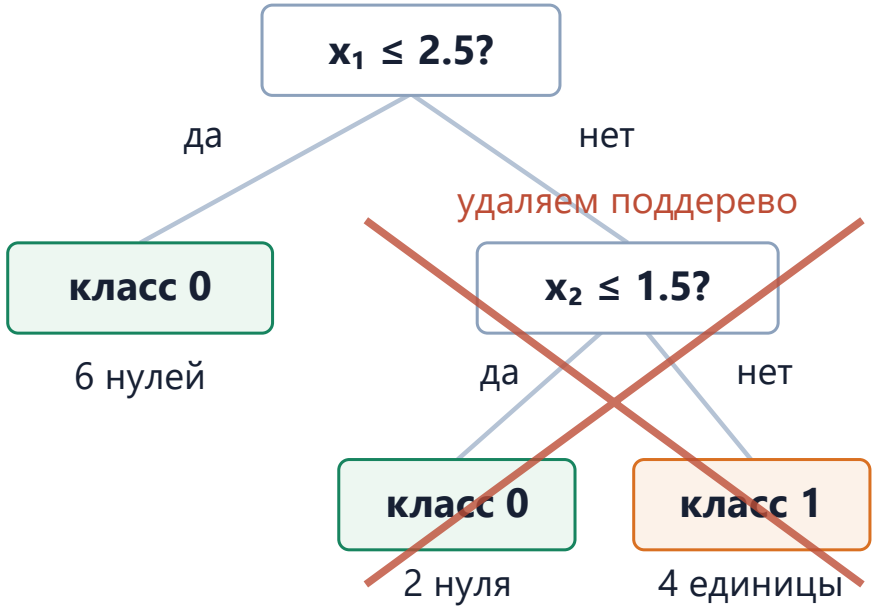
Ограничение	Вопрос перед новым разбиением
Глубина	Разрешён ли следующий уровень?
Размер текущего узла	Достаточно ли объектов для поиска условия?
Размер дочерних узлов	Достаточно ли объектов в каждой новой группе?
Минимальный выигрыш	Достаточно ли уменьшилась неоднородность?

> Эти проверки управляют ростом дерева во время обучения.

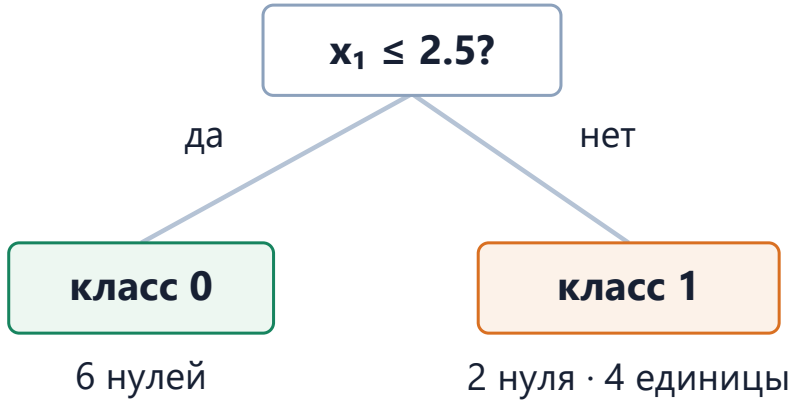
Сложность и переобучение

Удаление поддерева

Удаляем выделенную часть



Сохраняем один лист



Новый лист объединяет объекты удалённого поддерева: 2 нуля и 4 единицы. Его прогноз — класс 1.

Сложность и переобучение

Как работает post-pruning

Вырастить достаточно большое дерево → Последовательно заменять поддеревья листьями → Сравнить варианты сложности

После упрощения часть обучающих объектов может классифицироваться хуже.

> Выбираем поддерево по качеству на новых объектах — через validation или CV.

Сложность и переобучение

Контроль сложности и проверка качества

Pre-pruning	Post-pruning
Настраиваем ограничения до роста	Выбираем упрощённое поддерево после роста
Не допускаем часть новых разбиений	Удаляем часть уже построенных разбиений

> В обоих подходах сравниваем сложность по validation/CV.
> Критерий узла помогает обучать, внешняя метрика — выбирать модель.

После выбора итоговую процедуру обучаем на всех dev-данных. Независимый test сохраняем для финальной оценки.

Свойства деревьев

Следствия пороговых разбиений

Пороговые условия создают области, в которых прогноз постоянен.

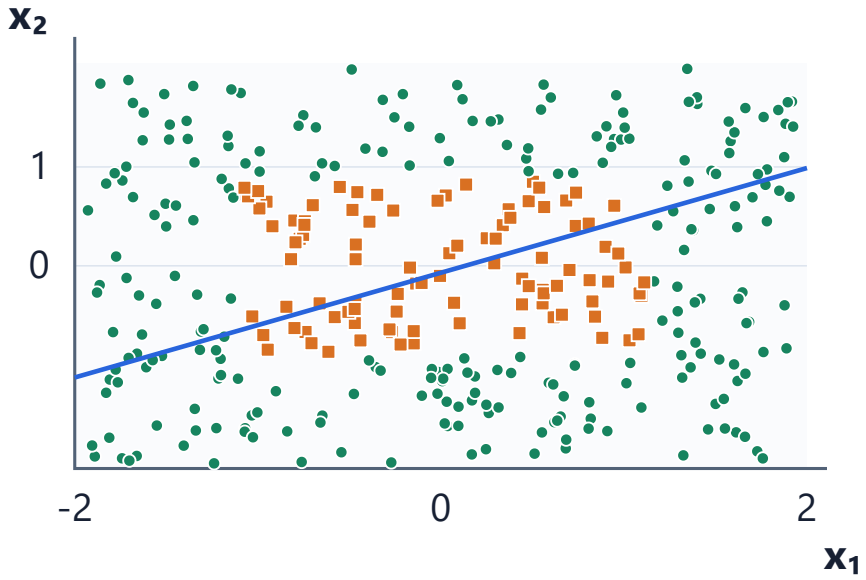
Форма этих областей определяет нелинейность и взаимодействия, отношение к масштабу, экстраполяцию и устойчивость модели.

> Рассмотрим каждое свойство на конкретной схеме или эксперименте.

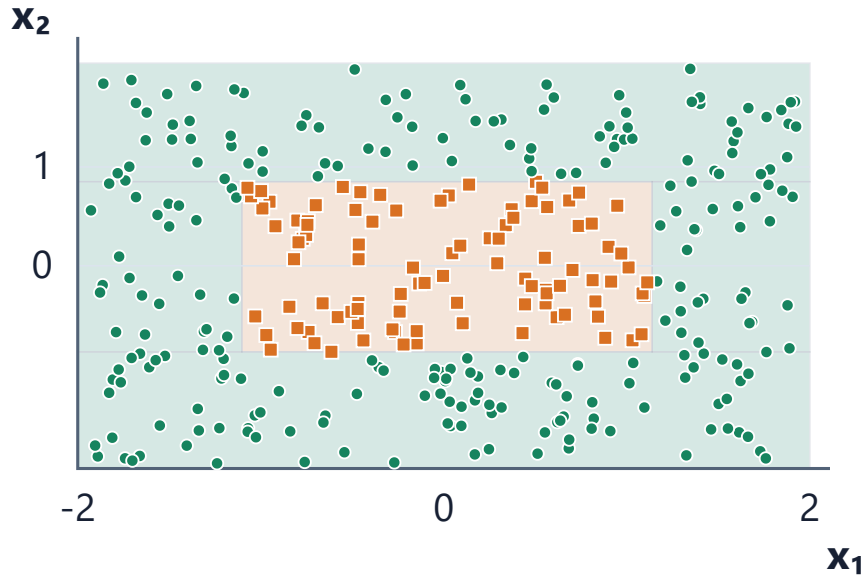
Свойства деревьев

Нелинейные границы

Линейный классификатор



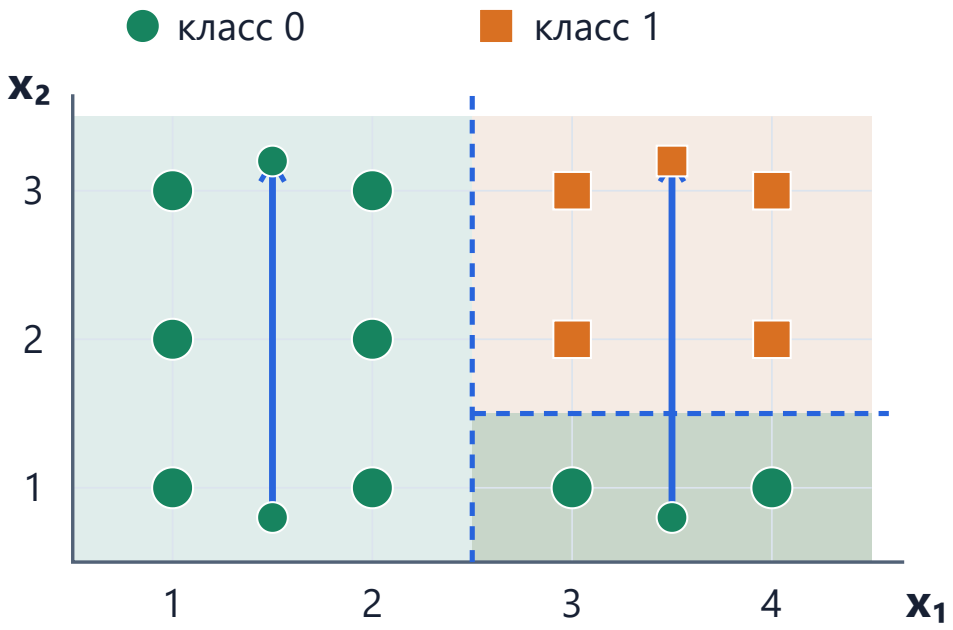
Дерево



Одной прямой нельзя выделить центральную область.
Дерево собирает её из условий по двум признакам.

Свойства деревьев

Взаимодействие признаков



Синие стрелки: меняем x_2, сохраняя x_1.

$x_1 \le 2.5$: прогноз остаётся 0 при любом x_2.

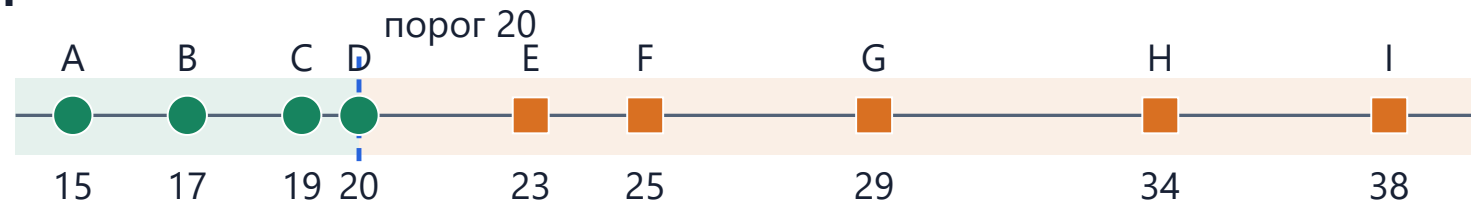
$x_1 > 2.5$: переход через $x_2 = 1.5$ меняет прогноз с 0 на 1.

> Влияние x_2 зависит от того, какое условие выполнено по x_1.

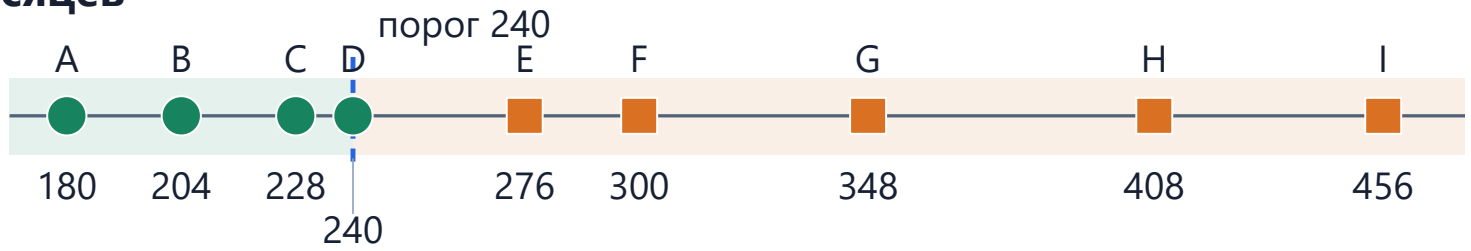
Свойства деревьев

Смена единиц измерения

Возраст, лет



Возраст, месяцев

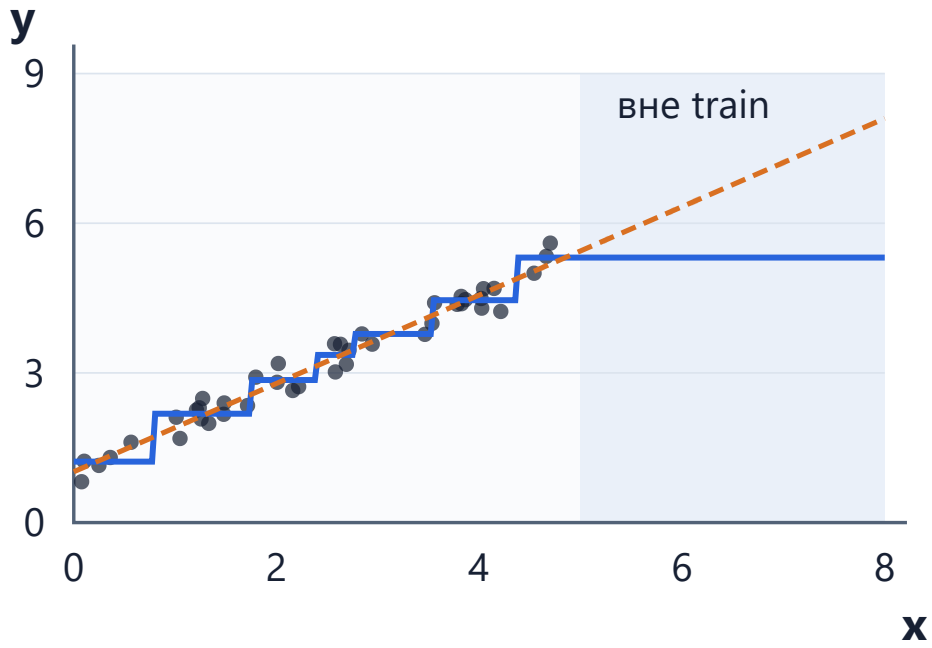


> Годы → месяцы: порог 20 → 240, обе группы сохранились.
> StandardScaler дереву обычно не требуется.

В kNN изменение относительных масштабов нескольких признаков может менять расстояния и соседей. Одномерная смена единиц сама по себе этого не показывает.

Свойства деревьев

Экстраполяция дерева



Сплошная: дерево.
Штриховая: линейная регрессия.

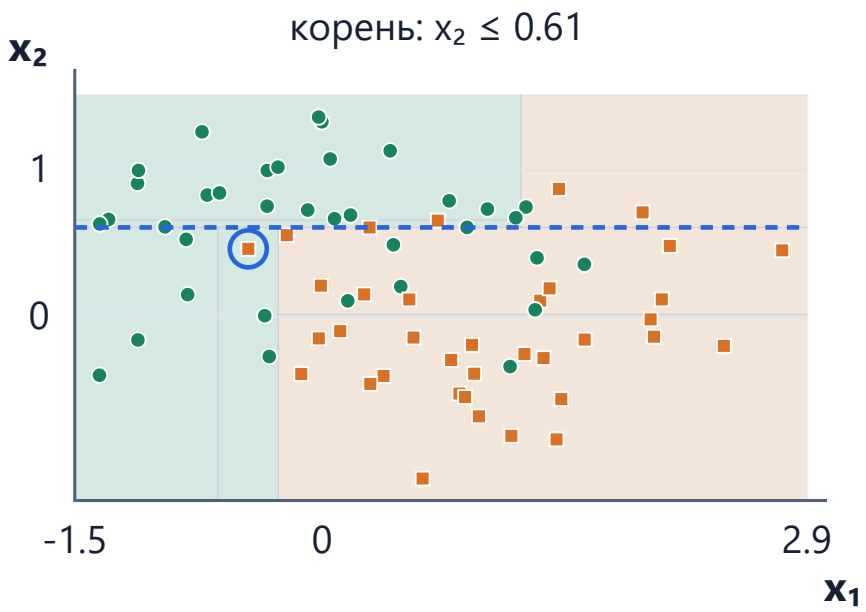
> За пределами train регрессионное дерево продолжает возвращать среднее крайнего листа.

Ступень остаётся постоянной и не продолжает наблюдаемый тренд.

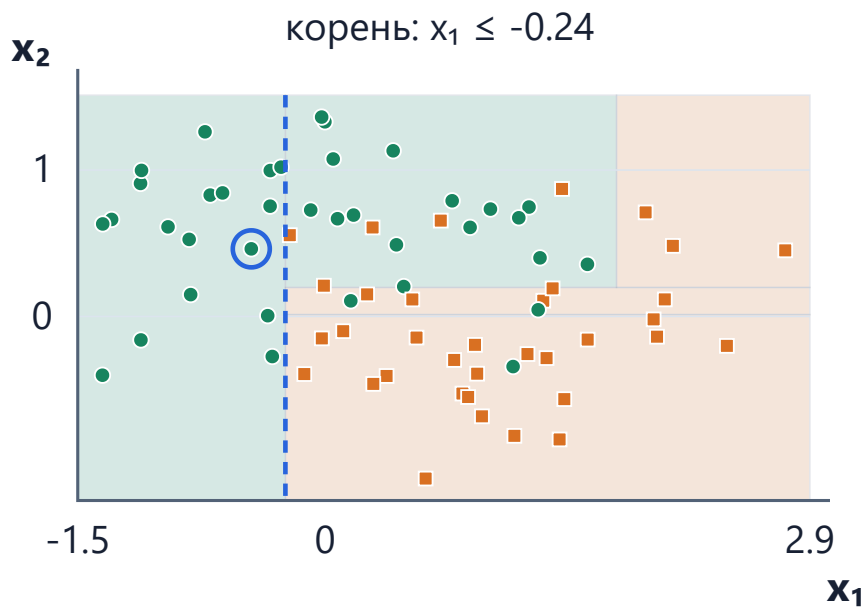
Свойства деревьев

Нестабильность структуры

Исходные данные



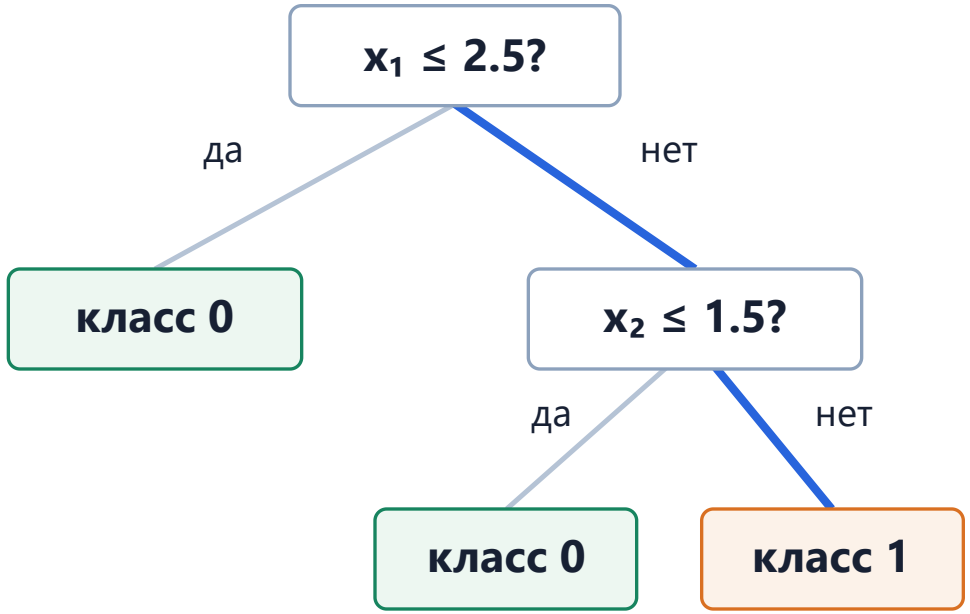
Изменили одну метку



Синяя обводка — изменённый объект. Изменился корневой вопрос, а вслед за ним — состав групп и последующие разбиения.

Свойства деревьев

Интерпретация правил



$$x_1 > 2.5 \quad \text{и} \quad x_2 > 1.5 \quad \Rightarrow \quad \hat{y} = 1$$

Путь объясняет, какие условия модели определили прогноз объекта.

> Небольшое дерево читают целиком, у большого анализируют отдельные пути. Правила объясняют прогноз, но не устанавливают причинные связи.

Категории и пропуски

Категориальный признак

В таблице есть номинальный признак «город». Естественного порядка между значениями нет.

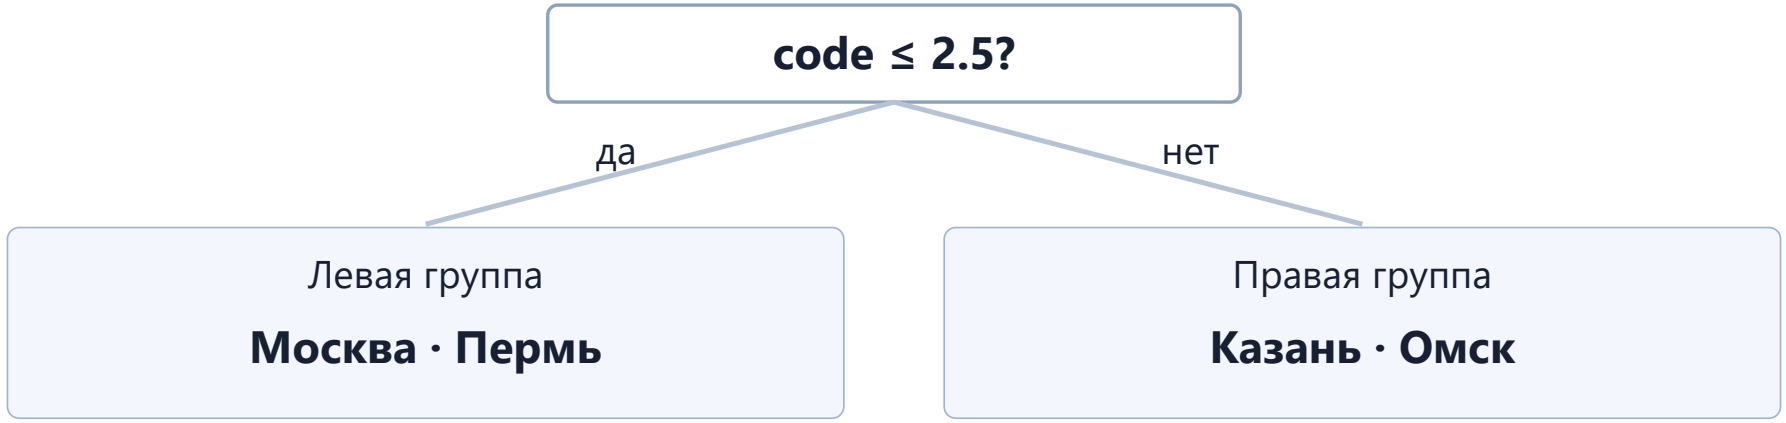
Объект	Город
A	Москва
B	Казань
C	Пермь
D	Омск

Как задавать условия для такого признака?

Категории и пропуски

Произвольные числовые коды

Город	Москва	Казань	Пермь	Омск
Код	1	3	2	4



Меняем коды Казани и Перми — тот же порог выделяет другие города. Произвольные коды задают порядок и ограничивают доступные разбиения.

Категории и пропуски

One-hot: индикаторы категорий

Город	Москва	Казань	Пермь	Омск
Москва	1	0	0	0
Казань	0	1	0	0
Пермь	0	0	1	0
Омск	0	0	0	1

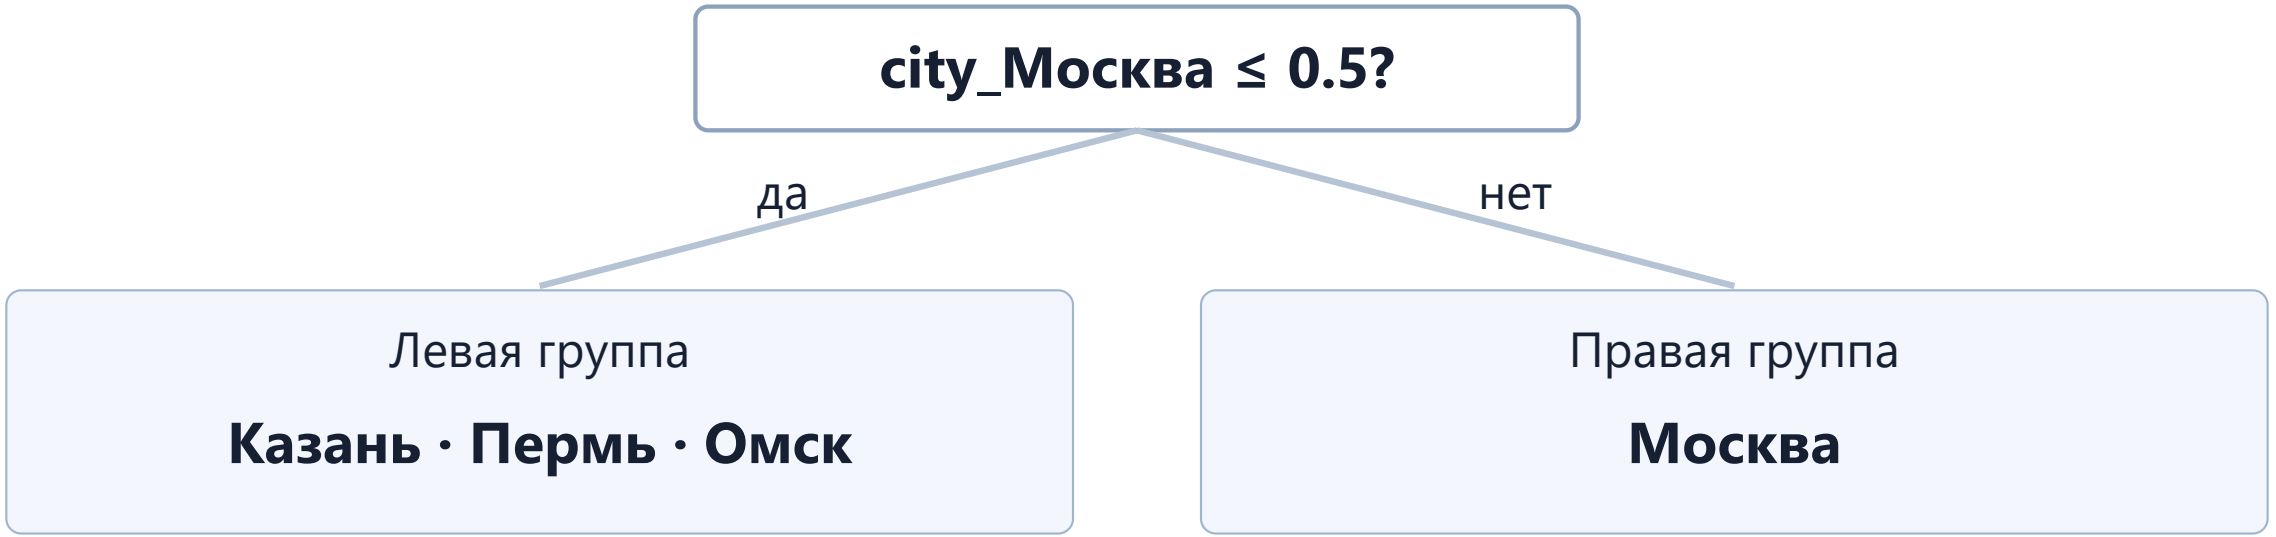
Названия индикаторов сокращены: «Москва» означает столбец city_Москва.

$$\text{city_Москва} \leq 0.5\ ?$$

> Условие проверяет наличие одной категории.
> Числовой порядок между городами не возникает.

Категории и пропуски

Разбиение по бинарному столбцу



Индикатор Москвы равен 0 у трёх остальных городов: они идут налево. Значение 1 направляет Москву в правую ветвь.

Категории и пропуски

Прямое разбиение по множеству



> Некоторые реализации проверяют принадлежность группе категорий напрямую. Здесь одним условием выделены две категории из четырёх.

Обычный sklearn DecisionTreeClassifier принимает числовую матрицу. Нативную поддержку категорий проверяют у конкретной реализации.

Категории и пропуски

Компромисс one-hot кодирования

Чтобы выделить Москву и Пермь среди четырёх городов, можно последовательно проверить два индикатора.

city_Москва > 0.5?
Да → нужная группа

нет →

city_Пермь > 0.5?
Да → нужная группа

нет →

Казань
или Омск

> One-hot сохраняет номинальный смысл категорий, но увеличивает размерность. Выделение группы может потребовать нескольких бинарных проверок.

Категории и пропуски

Пропуск в условии

Новый объект
age = NaN

→

Условие
age ≤ 30?

→

Как выбрать
ветвь?

Неизвестное значение нельзя сравнить с порогом обычным способом.

Рассмотрим две стратегии: восстановить значение или выучить направление для NaN при обучении дерева.

Категории и пропуски

Стратегия 1: импутация

Обучение: сохраняем медиану возраста на train — 29



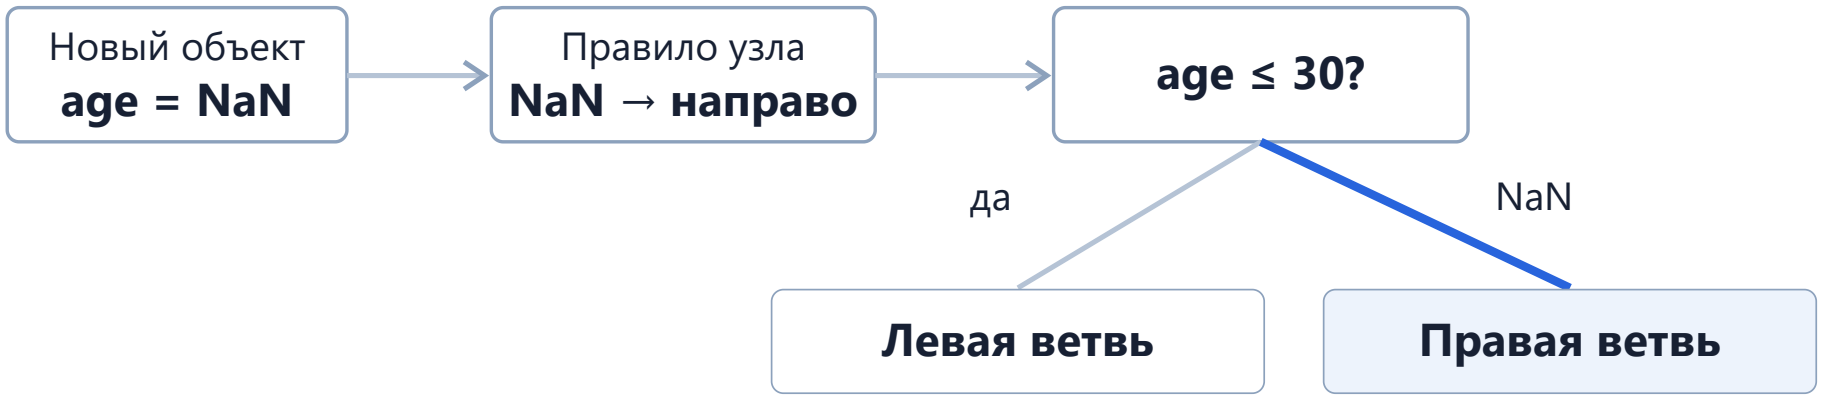
> Вместо пропуска подставили сохранённую медиану train — 29.
> Дальше выполняется обычная проверка: 29 ≤ 30, идём налево.

При необходимости добавляют индикатор пропуска. Статистики импутации обучают внутри train-фолда.

Категории и пропуски

Стратегия 2: направление для NaN

Обучение: выбрано и сохранено направление NaN → направо



После сравнения на train в этом узле сохранено правило «NaN направо». Новый объект использует его без восстановления возраста.

Поддержка такого механизма зависит от версии и конфигурации реализации.

Категории и пропуски

Что сохраняется после обучения

Стратегия	Что выучили на train	Что делаем при predict
Импутация	Статистику, например медиану 29	Подставляем 29 и проверяем порог
Направление NaN	Ветвь для пропуска в каждом узле	Следуем сохранённой ветви

> Для нового объекта используется сохранённая стратегия.
> Его целевая переменная неизвестна и не нужна для маршрутизации.

В современных sklearn DecisionTreeClassifier и DecisionTreeRegressor нативная обработка NaN доступна при поддерживаемых конфигурациях. Импутация остаётся отдельной рабочей стратегией.

Категории и пропуски

Подготовка данных для дерева

Признаки	Практическое решение
Числовые	Масштабирование самому дереву чаще не требуется
Номинальные категории	One-hot либо подходящая нативная поддержка
Пропуски	Импутация либо поддерживаемый механизм NaN

> Импутацию и другие обучаемые преобразования обучаем только на train, в CV — внутри train-фолдов. Стратегии сравниваем по validation/CV.

Поддержка NaN зависит от версии, критерия, splitter и других настроек. Проверяйте документацию используемой версии sklearn.

Главные выводы

Итак: решающие деревья

- **Модель:** условия разбивают пространство на области с постоянным прогнозом.
- **Обучение:** рекурсивно выбираем лучшее текущее разбиение по уменьшению неоднородности.
- **Критерии:** MSE для регрессии; Gini или энтропия для классификации.
- **Сложность:** глубокие деревья могут переобучаться. Pre-/post-pruning настраиваем по validation/CV.
- **Свойства и данные:** нелинейность и взаимодействия, слабая экстраполяция, нестабильность; категории и пропуски требуют подходящей обработки.