Бинарная классификация: вероятность, метрики и решение

КЛАССИЧЕСКОЕ МАШИННОЕ ОБУЧЕНИЕ · МАГИСТРАТУРА · НЕДЕЛЯ 3

Модель оценивает риск мошенничества.
Как использовать прогноз и как проверить качество?

score → **вероятность** → **решение** → **оценка качества**

Сквозной пример: направить транзакцию на дополнительную проверку.

Бинарная классификация: что прогнозируем?

ОБЪЕКТ — ТРАНЗАКЦИЯ

$$x = (x_1, \ldots, x_d)$$

Признаки известны
к моменту прогноза.

$$Y \in \{0, 1\}$$

0 — обычная операция;
1 — мошенническая операция.

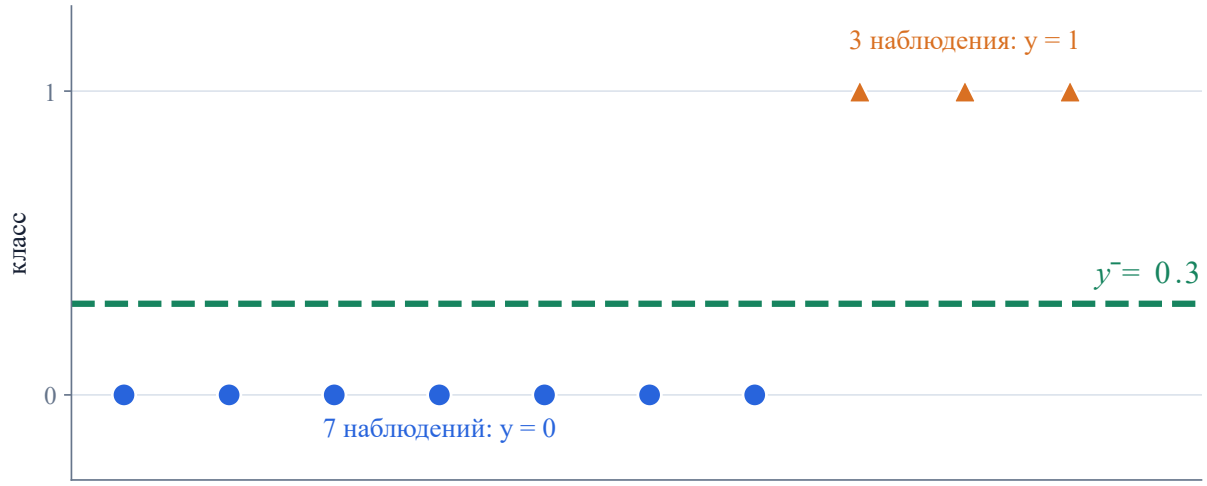
$$p(x) = P(Y = 1 \mid X = x)$$

Оцениваем вероятность положительного класса,
чтобы затем выбрать действие.

При одинаковых признаках прогнозируем одно число

Мысленный эксперимент: фиксируем один вектор признаков $X=x$.

Все 10 объектов получают один и тот же прогноз c.



МИНИМИЗИРУЕМ СУММУ КВАДРАТОВ

$$\hat{c} = \arg\min_{c} \sum_{i=1}^{10} (y_i - c)^2$$

$$\hat{c} = \bar{y} = \frac{3}{10} = 0.3$$

0.3 — наблюдаемая доля положительного класса.

Истинная вероятность при этих признаках неизвестна; доля помогает её оценить.

Линейная модель вероятности: модель и обучение

МОДЕЛЬ

$$p_\beta(x) = \beta_0 + x^\top \beta$$

Линейно приближаем вероятность класса 1.

ОЦЕНИВАНИЕ МНК

$$(\hat\beta_0, \hat\beta) \in \arg\min_{\beta_0,\beta} R_n$$

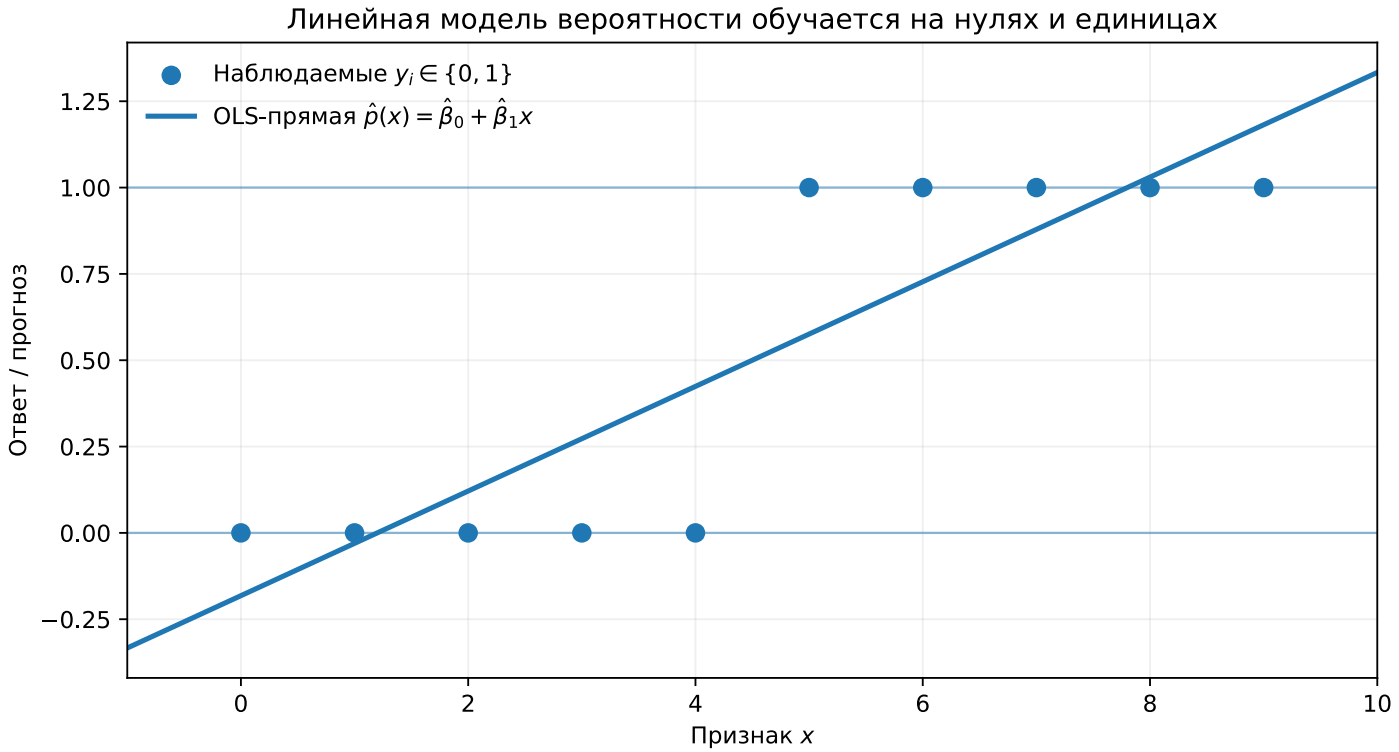
$$R_n = \frac{1}{n}\sum_i (y_i - \beta_0 - x_i^\top \beta)^2$$

> МНК нацелен на условное среднее. Для бинарного ответа:

$$\begin{aligned}\mathbb{E}[Y \mid X = x] &= 0 \cdot P(Y = 0 \mid X = x) + 1 \cdot P(Y = 1 \mid X = x) \\ &= P(Y = 1 \mid X = x).\end{aligned}$$

Наблюдаем ответы $y_i \in \{0, 1\}$, а не готовые вероятности.

Линейная вероятность может выйти за [0, 1]



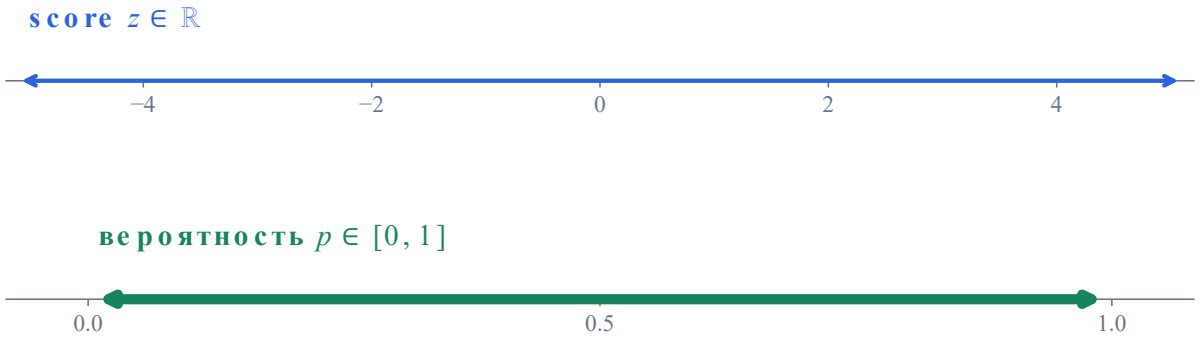
$$\hat{p}(x) < 0$$

$$\hat{p}(x) > 1$$

МНК находит лучшую линейную аппроксимацию; её коэффициенты и локальное поведение могут быть полезны.

Ограничение задаёт глобальная прямая: за пределами [0, 1] её прогнозы теряют вероятностный смысл.

Хотим сохранить линейный score, но не саму вероятность

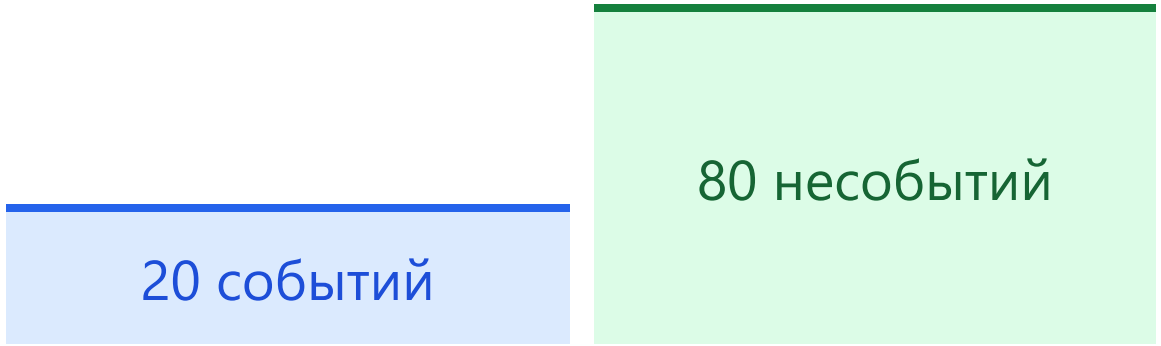


$$z(x) = \beta_0 + x^\top \beta \in \mathbb{R}$$

$$p(x) \in [0, 1]$$

Как связать всю числовую прямую с вероятностью?

Odds: 20 событий на 80 несобытий



$$p = 20/100 = 0.2$$

$$\text{odds}(p) = \frac{p}{1-p} = \frac{1}{4}$$

20 : 80 = 1 : 4

odds — шансы: отношение событий к несобытиям.

Примеры odds при разных вероятностях

Вероятность p	События : несобытия	odds
0.2	20 : 80	1 : 4
0.5	50 : 50	1 : 1
0.8	80 : 20	4 : 1

$$0 < p < 1 \quad \Longrightarrow \quad \text{odds}(p) \in (0, +\infty)$$

$p = 0 \Rightarrow \text{odds}(p) = 0$

$p \to 1 \Rightarrow \text{odds}(p) \to +\infty$

Вероятность вообще: $p \in [0, 1]$. Для перехода к logit рассматриваем $0 < p < 1$.

Логарифм шансов даёт вещественную шкалу

$$\operatorname{logit}(p) = \log \frac{p}{1-p}$$

$$0 < p < 1$$

Здесь и далее log — натуральный логарифм.

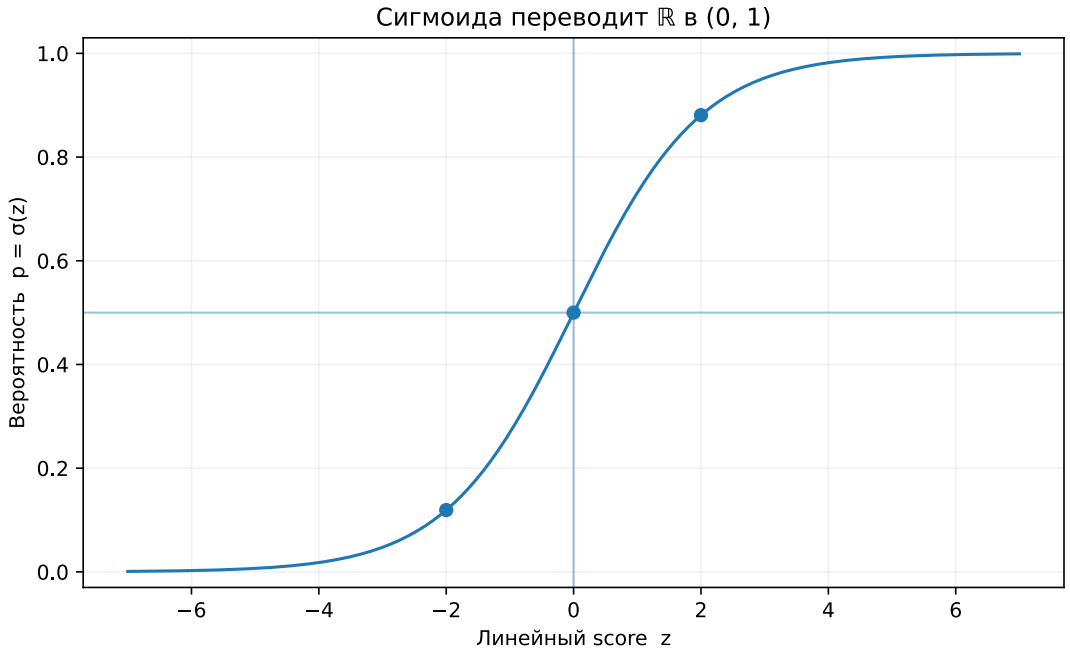
$$(0,1) \xrightarrow{\text{odds}} (0,+\infty) \xrightarrow{\log} \mathbb{R}$$

p	odds	logit
0.2	1 : 4	−1.386
0.5	1 : 1	0
0.8	4 : 1	1.386

Логит переводит вероятность из (0, 1) на всю вещественную прямую.

Сигмоида возвращает score на шкалу вероятности

$$e^z = \frac{p}{1-p} \implies e^z(1-p) = p \implies p = \frac{1}{1+e^{-z}}$$



$$\sigma : \mathbb{R} \to (0, 1)$$

$$\sigma(0) = 0.5$$

Строго возрастает: порядок объектов сохраняется.

При z → −∞ вероятность стремится к 0; при z → +∞ — к 1.

Логистическая регрессия: определение модели

$$\operatorname{logit}\big(p_\beta(x)\big) = \beta_0 + x^\top \beta$$

ЛИНЕЙНЫЙ SCORE

$$z_\beta(x) = \beta_0 + x^\top \beta \in \mathbb{R}$$

ВЕРОЯТНОСТЬ

$$p_\beta(x) = \sigma\big(z_\beta(x)\big) \in (0,1)$$

$$x \longrightarrow z_\beta(x) \longrightarrow p_\beta(x)$$

Коэффициенты задают score.
Сигмоида превращает его в вероятностный прогноз.

Коэффициент задаёт множитель шансов

Увеличиваем один признак на 1, остальные фиксируем.

$$\log \text{odds}_{\text{new}} - \log \text{odds}_{\text{old}} = \beta_j$$

$$\frac{\text{odds}_{\text{new}}}{\text{odds}_{\text{old}}} = e^{\beta_j}$$

$$\beta_j = \log 2 \quad \Rightarrow \quad \text{odds} \times 2$$

$$p: \quad 0.20 \longrightarrow \frac{1}{3}$$

Вероятность меняется нелинейно: получаем не 0.4.

Семейство прогнозов задано; коэффициенты неизвестны

$$p_\beta(x) = \sigma\left(\beta_0 + x^\top \beta\right)$$

МОДЕЛЬ

Линейный score и сигмоида.

ЦЕЛЕВАЯ ФУНКЦИЯ

Что считать хорошими коэффициентами?

ОПТИМИЗАТОР

Как найти эти коэффициенты?

Как выбрать параметры по наблюдённым ответам 0 и 1?

Распределение Бернулли: два исхода и их вероятности

$$Y_i \mid X_i = x_i \sim \text{Bernoulli}(p_i)$$

Мошенническая операция

$$P(Y_i = 1 \mid x_i) = p_i$$

Обычная операция

$$P(Y_i = 0 \mid x_i) = 1 - p_i$$

$p_i = p_\beta(x_i)$ — прогноз логистической модели для этого объекта.

Bernoulli допускает p ∈ [0, 1]; при конечном score наша модель выдаёт $p_i \in (0, 1)$.

Оба исхода записываются одной формулой

$$y_i = 1: \quad p_i^1 (1 - p_i)^0 = p_i$$

$$y_i = 0: \quad p_i^0 (1 - p_i)^1 = 1 - p_i$$

$$P_\beta(Y_i = y_i \mid x_i) = p_i^{y_i} (1 - p_i)^{1 - y_i}$$

Наблюдённая метка выбирает нужную вероятность.

Далее для краткости включаем свободный член в β, а единицу — в x_i: $z_i = x_i^\intercal \beta$.

Независимые ответы дают произведение вероятностей

При заданных признаках и параметрах считаем ответы объектов условно независимыми.

$$\mathcal{L}(\beta; D) = \prod_{i=1}^{n} p_i^{y_i} (1 - p_i)^{1 - y_i}$$

ДВА НАБЛЮДЁННЫХ ОТВЕТА

$$y = (1, 0), \quad p = (0.8, 0.3)$$

$$\mathcal{L} = 0.8 \cdot (1 - 0.3) = 0.56$$

Ответы и признаки зафиксированы.
Меняя β, меняем вероятности этих ответов.

Выбираем параметры по правдоподобию ответов

Те же ответы y = (1, 0). Две гипотетические настройки модели:

Настройка	p_1	p_2	Вероятность ответов (1, 0)
A	0.8	0.3	0.8 × 0.7 = 0.56
B	0.6	0.4	0.6 × 0.6 = 0.36

$$\hat{\beta}_{\text{MLE}} \in \arg\max_{\beta} \mathcal{L}(\beta; D)$$

Параметры выбираем по максимальному правдоподобию.

Правдоподобие — функция параметров, а не вероятность самих параметров.

Логарифм превращает произведение в сумму

$$\log \mathcal{L}(\beta) = \sum_i \log \left[p_i^{y_i} (1 - p_i)^{1 - y_i} \right]$$

↓ степени становятся множителями

$$= \sum_i \left[y_i \log p_i + (1 - y_i) \log (1 - p_i) \right]$$

Логарифм монотонен: положение максимума likelihood не меняется.

Из максимума правдоподобия получаем среднюю log loss

МЕНЯЕМ ЗНАК

$$\max \log \mathcal{L} \iff \min(-\log \mathcal{L})$$

ДЕЛИМ НА N > 0

$$R_n(\beta) = -\frac{1}{n} \log \mathcal{L}(\beta; D)$$

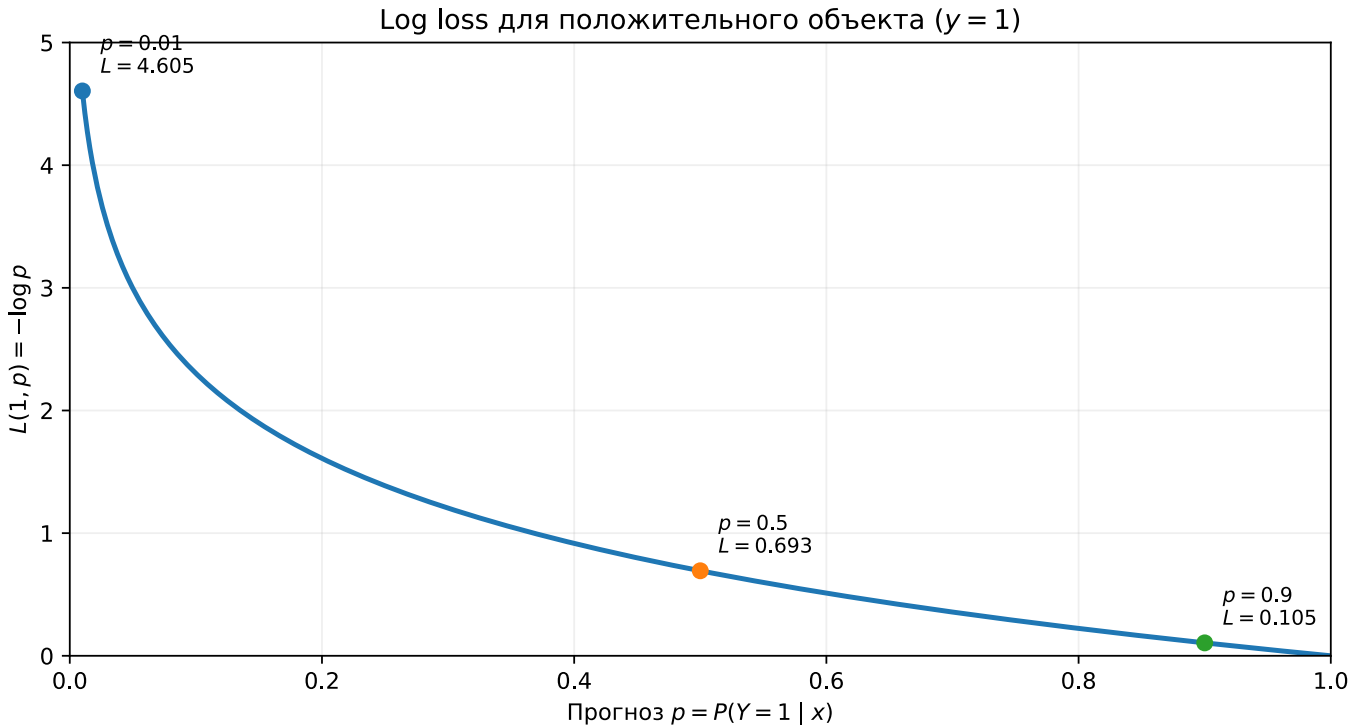
$$L(y, p) = -y \log p - (1 - y) \log(1 - p), \quad 0 < p < 1$$

$$R_n(\beta) = \frac{1}{n} \sum_{i=1}^{n} L(y_i, p_i)$$

Смена знака заменяет максимум минимумом; положительный множитель не меняет положение минимума.

Уверенная ошибка стоит дорого

$$y = 1: \qquad L(1, p) = -\log p$$



$$p = 0.9 \Rightarrow L \approx 0.105$$

$$p = 0.5 \Rightarrow L \approx 0.693$$

$$p = 0.01 \Rightarrow L \approx 4.605$$

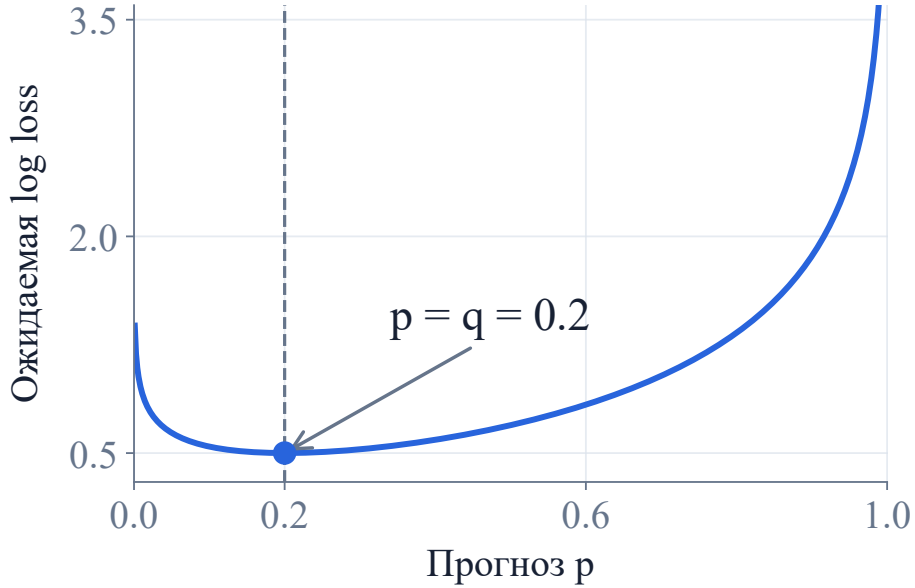
Для y = 0 картина зеркальна.

Log loss поощряет верную вероятностную шкалу

$$q = P(Y = 1 \mid X = x)$$

q — истинная вероятность.
p ∈ (0, 1) — прогноз, который выбираем.

При повторении условий X = x:
исход 1 встречается с вероятностью q,
исход 0 — с вероятностью 1 − q.



$$\Phi(p) = qL(1,p) + (1-q)L(0,p)$$

$$0 < q < 1: \qquad \arg\min_{p \in (0,1)} \Phi(p) = q$$

Это свойство ожидаемой потери; конечная обученная модель может ошибаться в вероятностях.

Средний градиент и знакомый шаг спуска

X — матрица признаков со столбцом единиц; $p = \sigma(X\beta)$.

$$\nabla_\beta R_n(\beta) = \frac{1}{n} X^\top (p - y)$$

p − y: ошибки вероятностных прогнозов на обучающих объектах.

X^T собирает вклады ошибок по каждому признаку.

$$\beta^{(t+1)} = \beta^{(t)} - \eta \nabla_\beta R_n\left(\beta^{(t)}\right)$$

Тот же цикл оптимизации; теперь минимизируем log loss.

Подробный вывод градиента приведён в тексте лекции.

Один объект: от признаков к вероятности

Отдельная учебная иллюстрация: коэффициенты заданы для примера, а не оценены по 12 транзакциям.

$$\hat{z}(x) = -1.5 + 1.0x_1 + 0.5x_2$$

ПРИЗНАКИ

$$x_1 = 2, \quad x_2 = 1$$

SCORE

$$\hat{z} = -1.5 + 2 + 0.5 = 1$$

ВЕРОЯТНОСТЬ

$$\hat{p} = \sigma(1) \approx 0.731$$

Модель выдала вероятность.
Для действия понадобится правило решения.

Таким образом: обучение даёт вероятностную модель

МОДЕЛЬ

Линейный score
и сигмоида.

КРИТЕРИЙ ОБУЧЕНИЯ

Bernoulli → правдоподобие
→ средняя log loss.

ОПТИМИЗАТОР

Находит коэффициенты $\hat{\beta}$,
минимизируя критерий.

$$\widehat{\beta} \longrightarrow \hat{z}(x) = x^{\top}\widehat{\beta} \longrightarrow \hat{p}(x) = \sigma\big(\hat{z}(x)\big)$$

Прогноз готов. Как решим, какие операции отправить на проверку?

Наш пример: 12 транзакций, вероятности и истинные метки

ID	$\hat{p}$	y	ID	$\hat{p}$	y
1	0.95	1	7	0.55	1
2	0.88	0	8	0.48	0
3	0.82	1	9	0.35	1
4	0.75	1	10	0.30	0
5	0.68	0	11	0.18	0
6	0.61	0	12	0.08	0

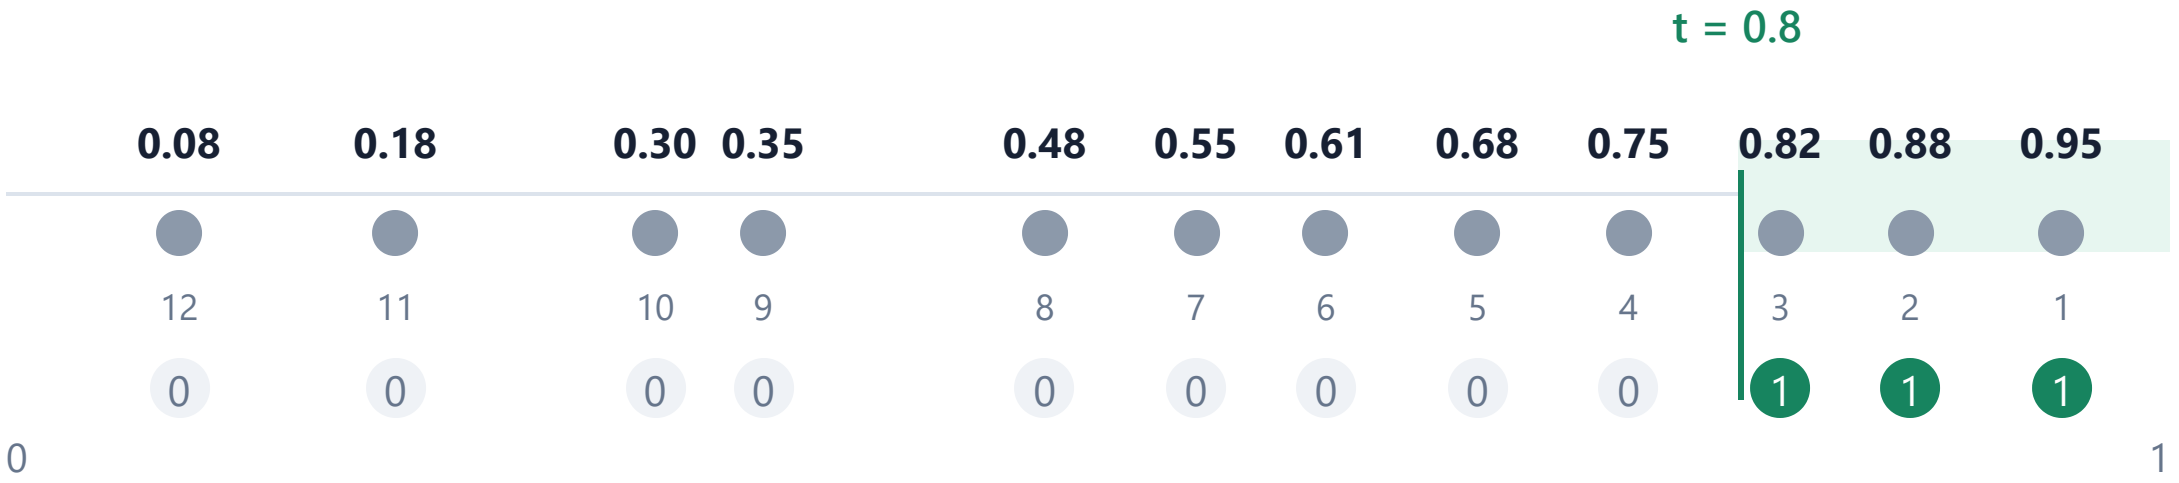
Цель — направить подозрительные операции на дополнительную проверку.

Учебные синтетические данные. Доля 5/12 не типична для реального потока мошенничества.

Порог превращает вероятность в решение

$$\hat{y}_t(x) = \mathbb{I}[\hat{p}(x) \geq t], \quad 0 < t < 1$$

Шкала вероятности: 0 → 1

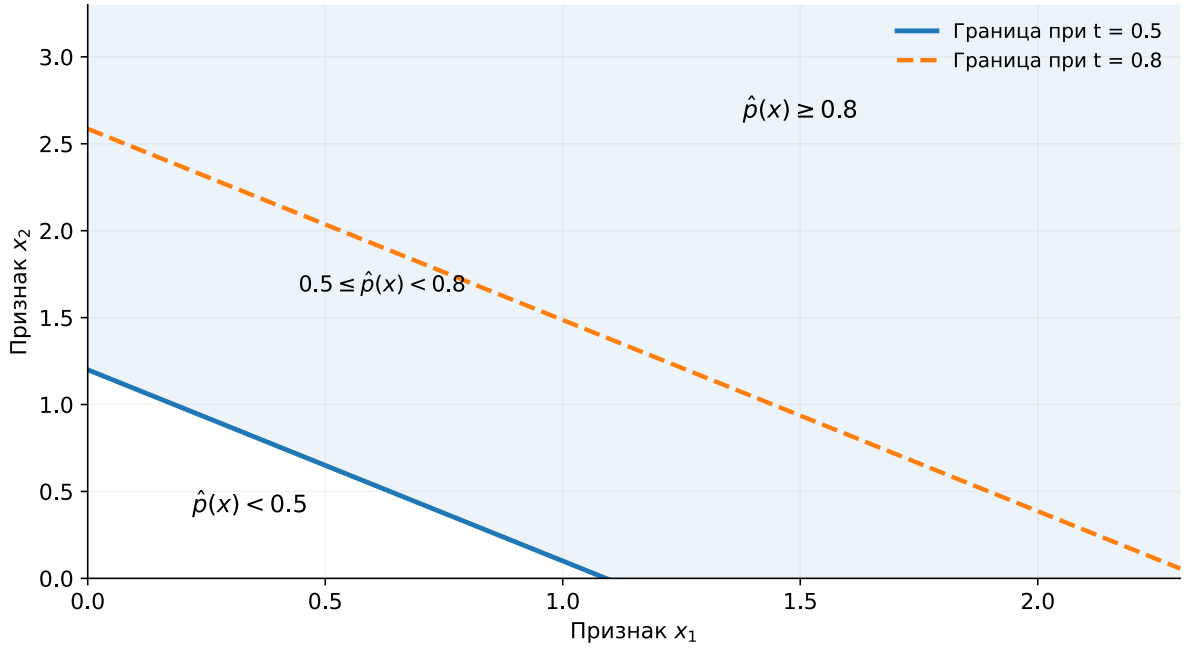


внизу — решение

Ручная проверка и автоматическая блокировка могут требовать разных порогов.

Порог сдвигает границу решения

$$\hat{p}(x) \geq t \quad \Longleftrightarrow \quad \hat{z}(x) \geq \log \frac{t}{1-t}, \qquad 0 < t < 1$$



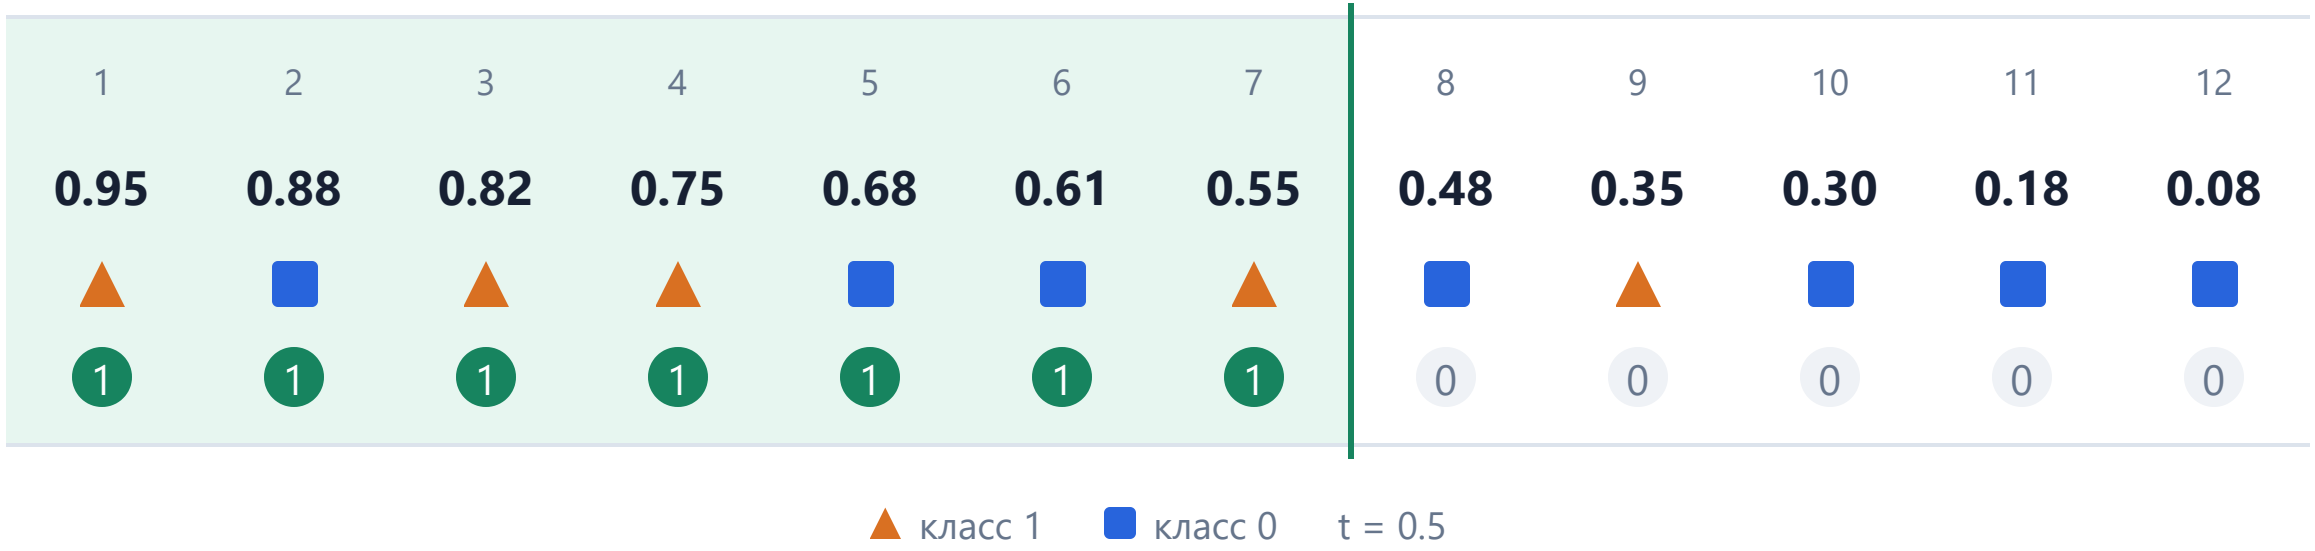
ДВА ПРИЗНАКА

$$\hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = \operatorname{logit}(t)$$

Меняем порог — сдвигаем прямую. Коэффициенты фиксированы.

Двенадцать транзакций: фиксируем порог 0.5

Оценка вероятности · по убыванию



7 объектов получили прогноз класса 1.

Как у каждого объекта могут согласоваться прогноз и настоящий класс?

Учебный набор искусственный; высокая доля мошенничества здесь нетипична для реального потока.

Четыре вида исходов: TN, FP, FN, TP

	Прогноз 0	Прогноз 1
Истинный 0	**TN**	**FP**
Истинный 1	**FN**	**TP**

TN: обычную операцию пропустили.

FP: обычную отправили на проверку.

FN: мошенничество пропустили.

TP: мошенничество направили на проверку.

Строки — истинный класс, столбцы — прогноз. Положительный класс 1 означает мошенничество.

Заполняем матрицу для порога 0.5

Оценка вероятности · по убыванию

1	0.95	▲	1	TP
2	0.88	■	1	FP
3	0.82	▲	1	TP
4	0.75	▲	1	TP
5	0.68	■	1	FP
6	0.61	■	1	FP
7	0.55	▲	1	TP
8	0.48	■	0	TN
9	0.35	▲	0	FN
10	0.30	■	0	TN
11	0.18	■	0	TN
12	0.08	■	0	TN

▲ класс 1 ■ класс 0 t = 0.5

	Прогноз 0	Прогноз 1
Истинный 0	TN 4	FP 3
Истинный 1	FN 1	TP 4

$$TP + FN = 5, \qquad TN + FP = 7$$

$$TP + FP = 7, \qquad N = 12$$

Accuracy: сколько правильных из всех?

	Прогноз 0	Прогноз 1
Истинный 0	**TN** 4	**FP** 3
Истинный 1	**FN** 1	**TP** 4

$$Accuracy = \frac{TP + TN}{N}$$

$$= \frac{8}{12} \approx 0.667$$

Знаменатель:
все объекты.

Precision: насколько чиста очередь проверки?

	Прогноз 0	Прогноз 1
Истинный 0	**TN** 4	**FP** 3
Истинный 1	**FN** 1	**TP** 4

$$Precision = \frac{TP}{TP + FP} = \frac{4}{7}$$

Среди прогнозов класса 1: какая доля действительно принадлежит классу 1?

Recall: какую долю мошенничества обнаружили?

	Прогноз 0	Прогноз 1
Истинный 0	**TN** 4	**FP** 3
Истинный 1	**FN** 1	**TP** 4

$$Recall = \frac{TP}{TP + FN} = \frac{4}{5}$$

Среди настоящих объектов класса 1: какую долю нашла модель?

Precision и Recall начинают с разных групп

НАЧИНАЕМ С РЕШЕНИЯ МОДЕЛИ

$$Precision = \widehat{P}(Y = 1 \mid \hat{Y} = 1)$$

Насколько чиста
выбранная группа?

НАЧИНАЕМ С НАСТОЯЩЕГО КЛАССА

$$Recall = \widehat{P}(\hat{Y} = 1 \mid Y = 1)$$

Какую долю класса 1
мы охватили?

Specificity: Recall для класса 0

	Прогноз 0	Прогноз 1
Истинный 0	**TN** 4	**FP** 3
Истинный 1	**FN** 1	**TP** 4

$$Specificity = \frac{TN}{TN + FP} = \frac{4}{7}$$

Какую долю класса 0
правильно оставили отрицательной?

Specificity — это Recall класса 0.

$$FPR = 1 - Specificity$$

Одна матрица — четыре вопроса

	Прогноз 0	Прогноз 1
Истинный 0	**TN** 4	**FP** 3
Истинный 1	**FN** 1	**TP** 4

НАСТОЯЩИЙ КЛАСС 0

Specificity

Какую долю отрицательных не тревожим?

F1: гармоническое среднее Precision и Recall

$$F_1 = \frac{2\,Precision \cdot Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}$$

	Прогноз 0	Прогноз 1
Истинный 0	**TN** **4**	**FP** **3**
Истинный 1	**FN** **1**	**TP** **4**

$$TP = 4, \quad FP = 3, \quad FN = 1$$

$$F_1 = \frac{8}{8 + 3 + 1} = \frac{2}{3} \approx 0.667$$

F1 объединяет две доли. Стоимость ошибок и ресурс проверки задаём отдельно.

Как параметр F-меры меняет приоритет

$$F_\beta = \frac{(1+\beta^2)\,Precision \cdot Recall}{\beta^2 Precision + Recall}$$

$$Precision = 0.9, \qquad Recall = 0.1$$

$F_{0.5} \approx 0.346$

При $\beta < 1$ важнее Precision.

$F_1 = 0.18$

При $\beta = 1$ равные приоритеты.

$F_2 \approx 0.122$

При $\beta > 1$ важнее Recall.

Меняя β, по-разному объединяем те же Precision и Recall.

β здесь — параметр F-меры, не коэффициенты модели. Приоритет не задаёт стоимость FP/FN: $\beta = 2$ не означает, что пропуск вдвое дороже.

Проверим решение на редком классе

	Прогноз 0	Прогноз 1
Истинный 0	**TN** **9900**	**FP** **0**
Истинный 1	**FN** **100**	**TP** **0**

Accuracy = 99%

Recall = 0

Нет прогнозов класса 1:
Precision не определён.

Accuracy верна, но недостаточна для вопроса «находим ли мы редкий класс?»

Скрининг: сначала задаём допустимый пропуск

ПЕРВЫЙ ЭТАП

Дешёвый первичный скрининг



ПОЛОЖИТЕЛЬНЫЙ РЕЗУЛЬТАТ

Более точное
и дорогое обследование

Какая ошибка опаснее? Какой показатель вы бы контролировали?

FN · ПРОПУСК

Болезнь пропущена.
Важен высокий Recall.

FP · ЛОЖНАЯ ТРЕВОГА

Перегружает второй этап, повышает расходы и тревогу.
Precision тоже важен.

Например, требуем Recall ≥ 0.98.
Среди допустимых порогов оцениваем Precision и нагрузку второго этапа.

Антифрод: одна модель, два действия

АВТОМАТИЧЕСКАЯ БЛОКИРОВКА

Отклоняем платёж.

FP напрямую вредит невиновному пользователю.

РУЧНАЯ ПРОВЕРКА

Формируем очередь проверки.

FP расходует время и вместимость очереди.

Нужны ли здесь одинаковые порог и основная метрика?

Последствия ошибок и ограничения различаются — требования к решению тоже будут разными.

Лимит проверки: не более 50 из 200

Отдельная очередь из 200 операций.
Упорядочим их по убыванию score и проверим первые 50.

№1–50	№51–100	№101–150	№151–200

$$Precision@50 = \frac{TP@50}{50}$$

$$Recall@50 = \frac{TP@50}{N_+}$$

TP@50 — число положительных в верхних 50; N_+ — во всех 200.
Для расчёта нужны истинные y: оцениваем очередь на размеченной validation.

Для нового потока ответы ещё неизвестны. Численные TP для этих 200 объектов здесь не заданы.

Высокая F1 не заменяет прикладное ограничение

$Recall \geq 0.98$	$Precision \geq 0.4$	**Не более 50**
Найти достаточно много событий.	**Получить достаточно чистую очередь.**	**Уложиться в ресурс ручной проверки.**

F1 объединяет две доли, но сама не задаёт ни один из этих лимитов.

Почему Accuracy одинакова при трёх разных порогах?

$$t = 0.35$$



Accuracy 0.67 · Precision 0.56 · Recall 1.00

Во всех трёх режимах TP + TN = 8 из 12.

Меняется состав ошибок; модель остаётся прежней.

Порог меняет матрицу ошибок

$t = 0.80$

	Прогноз 0	Прогноз 1
Истинный 0	**TN** **6**	**FP** **1**
Истинный 1	**FN** **3**	**TP** **2**

$t = 0.50$

	Прогноз 0	Прогноз 1
Истинный 0	**TN** **4**	**FP** **3**
Истинный 1	**FN** **1**	**TP** **4**

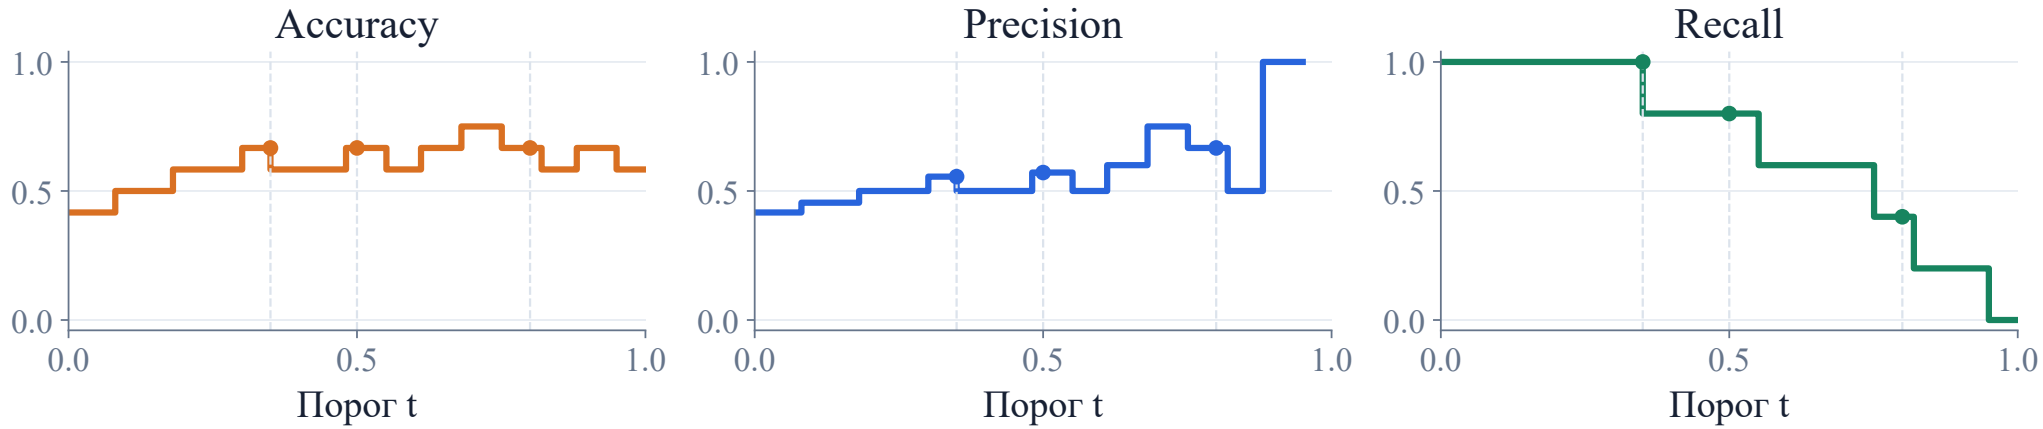
$t = 0.35$

	Прогноз 0	Прогноз 1
Истинный 0	**TN** **3**	**FP** **4**
Истинный 1	**FN** **0**	**TP** **5**

Те же 12 объектов. Модель и вероятности не изменяются.

При снижении порога Recall не убывает

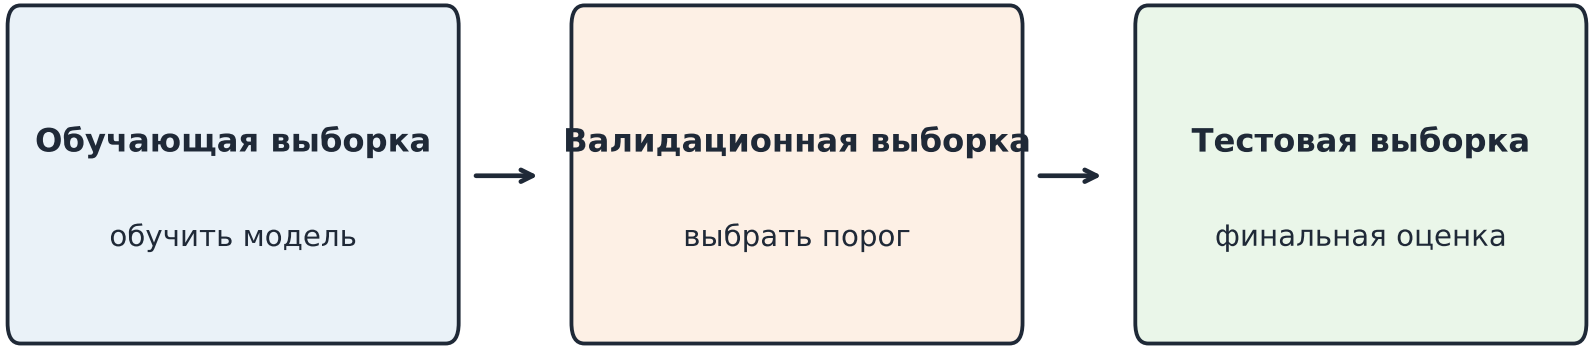
t	TP	FP	FN	TN	Precision	Recall
0.80	2	1	3	6	2/3	0.40
0.50	4	3	1	4	4/7	0.80
0.35	5	4	0	3	5/9	1.00



Recall не убывает; Precision может и расти, и падать.

Порог выбираем на validation; test оставляем для проверки

Разные выборки выполняют разные роли



Train:
обучаем коэффициенты.

Validation:
выбираем порог.

Test:
проверяем готовую систему.

На маленькой validation-выборке выбранный порог может быть неустойчив.

Один порог — одно решение; все пороги — ранжирование

$$\hat{p}(x) \geq t \quad \Longrightarrow \quad \hat{y}_t(x) = 1$$

ПОРОГ ЗАДАН

Получаем метки, матрицу ошибок и значения метрик.

ПОРОГ ЕЩЁ ВЫБИРАЕМ

Изучаем все рабочие режимы и качество порядка объектов.

Как увидеть все сочетания найденных событий и ложных тревог?

Знакомые доли: TPR и FPR

$$TPR = Recall = \frac{TP}{TP + FN}$$

Какую долю положительных нашли?

$$TPR = \frac{TP}{N_+}, \quad N_+ = 5$$

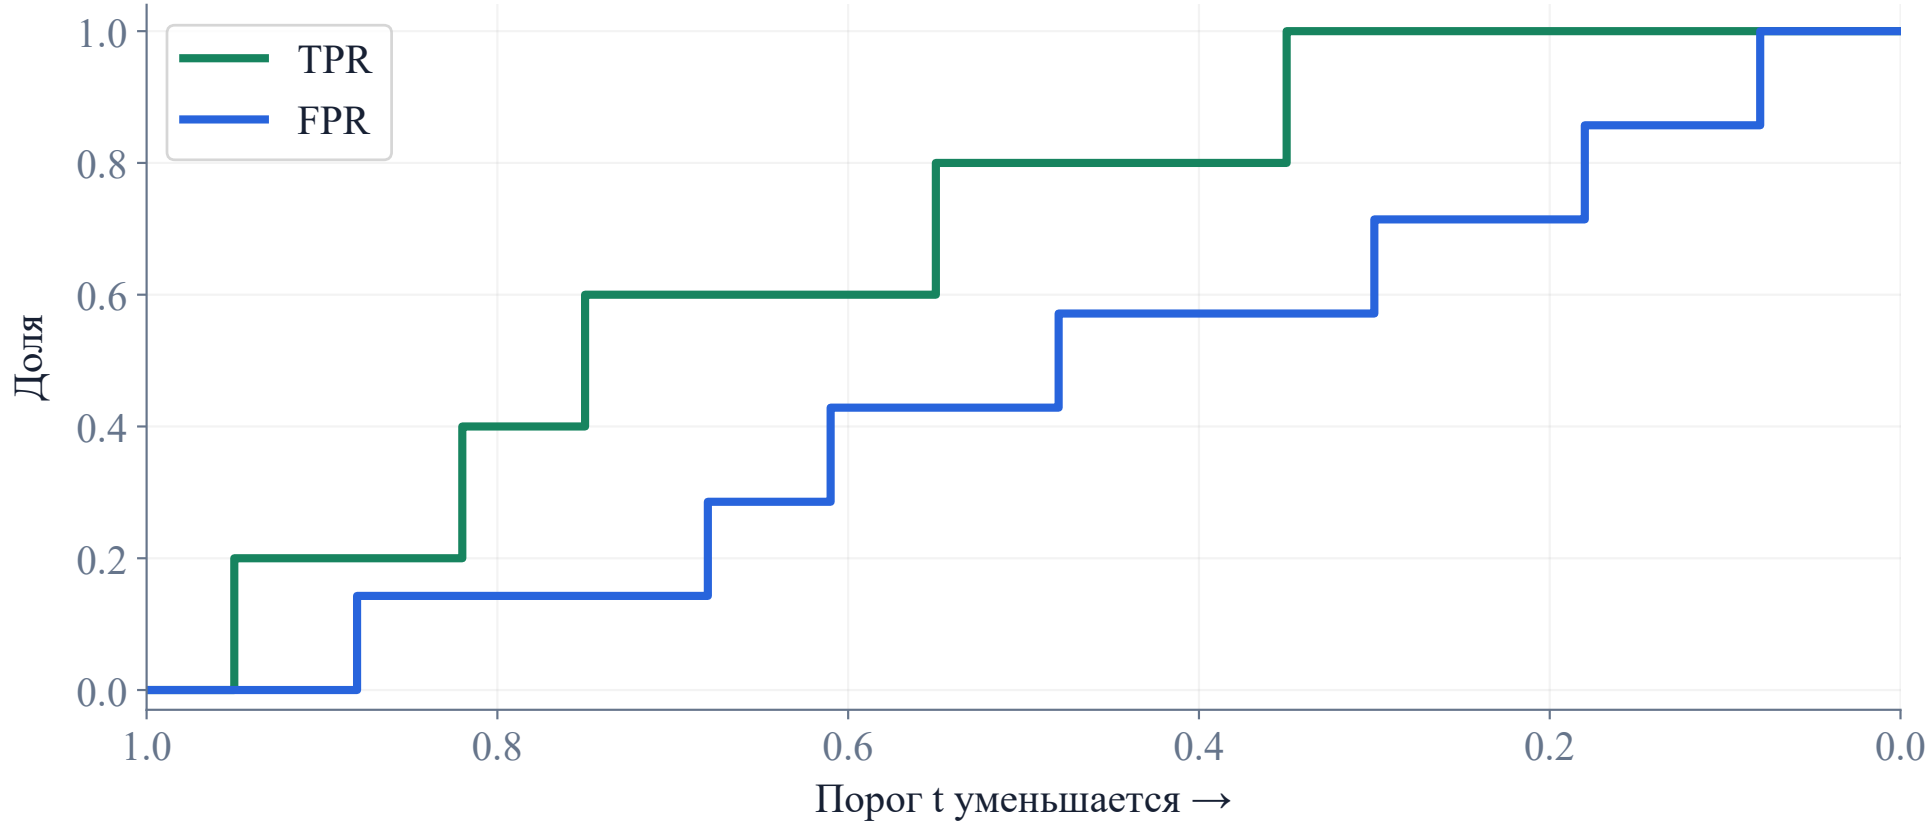
$$FPR = \frac{FP}{FP + TN}$$

$$FPR = 1 - Specificity$$

Какую долю отрицательных ошибочно выбрали?

$$FPR = \frac{FP}{N_-}, \quad N_- = 7$$

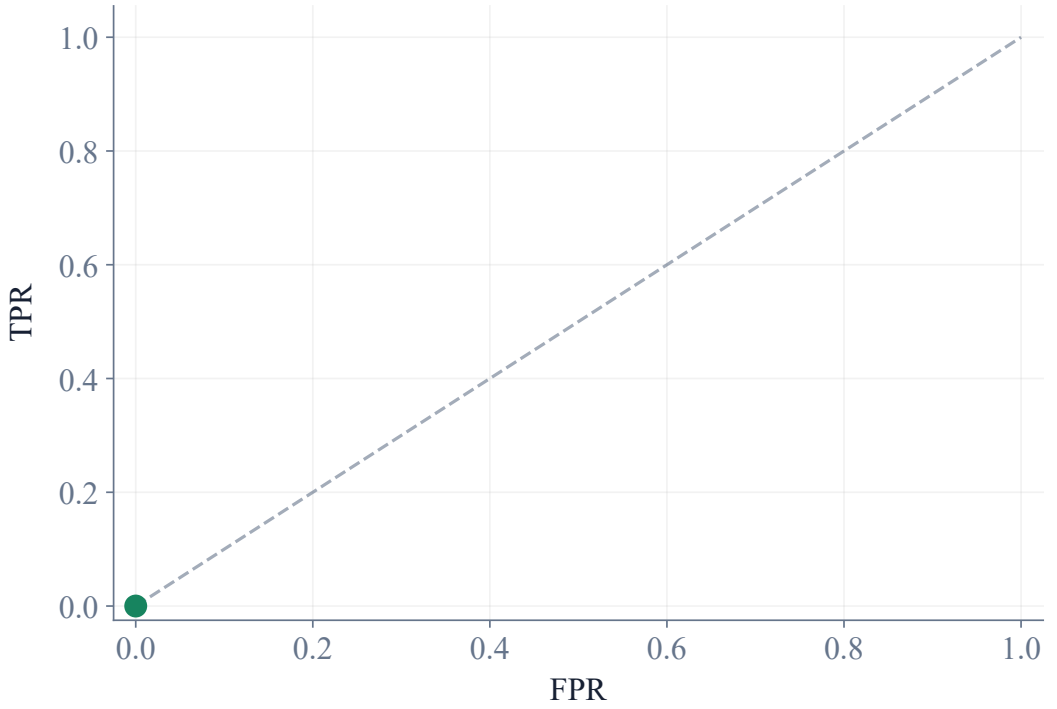
Снижаем порог: наблюдаем TPR и FPR



Убираем порог с оси — получаем ROC

$$t \longmapsto (FPR(t), TPR(t))$$

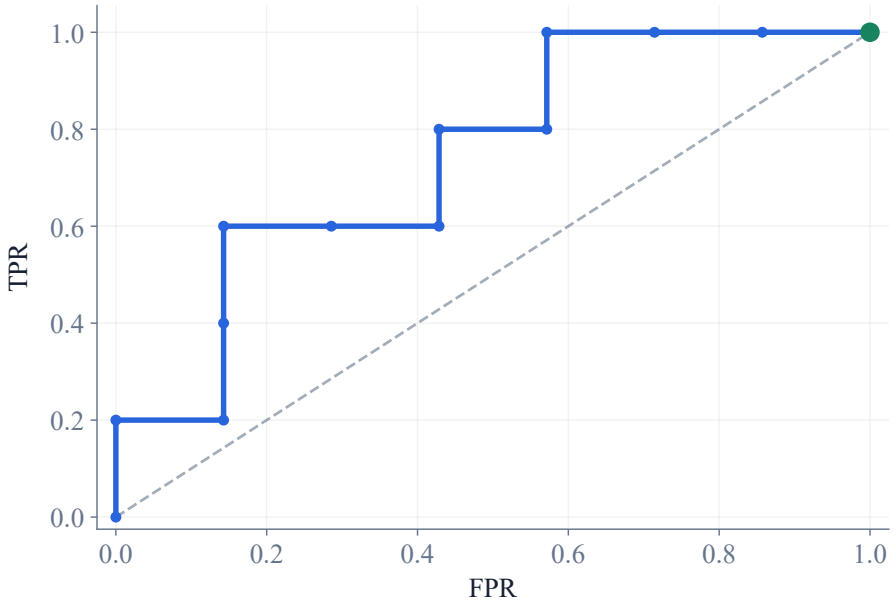
Каждый порог —
точка в этих координатах.



Строим ROC: проходим все 12 объектов

Класс 1: шаг вверх по TPR на 1/5; класс 0: шаг вправо по FPR на 1/7.

Оценка вероятности · по убыванию			
1	**0.95**	▲	1
2	**0.88**	■	1
3	**0.82**	▲	1
4	**0.75**	▲	1
5	**0.68**	■	1
6	**0.61**	■	1
7	**0.55**	▲	1
8	**0.48**	■	1
9	**0.35**	▲	1
10	**0.30**	■	1
11	**0.18**	■	1
12	**0.08**	■	1

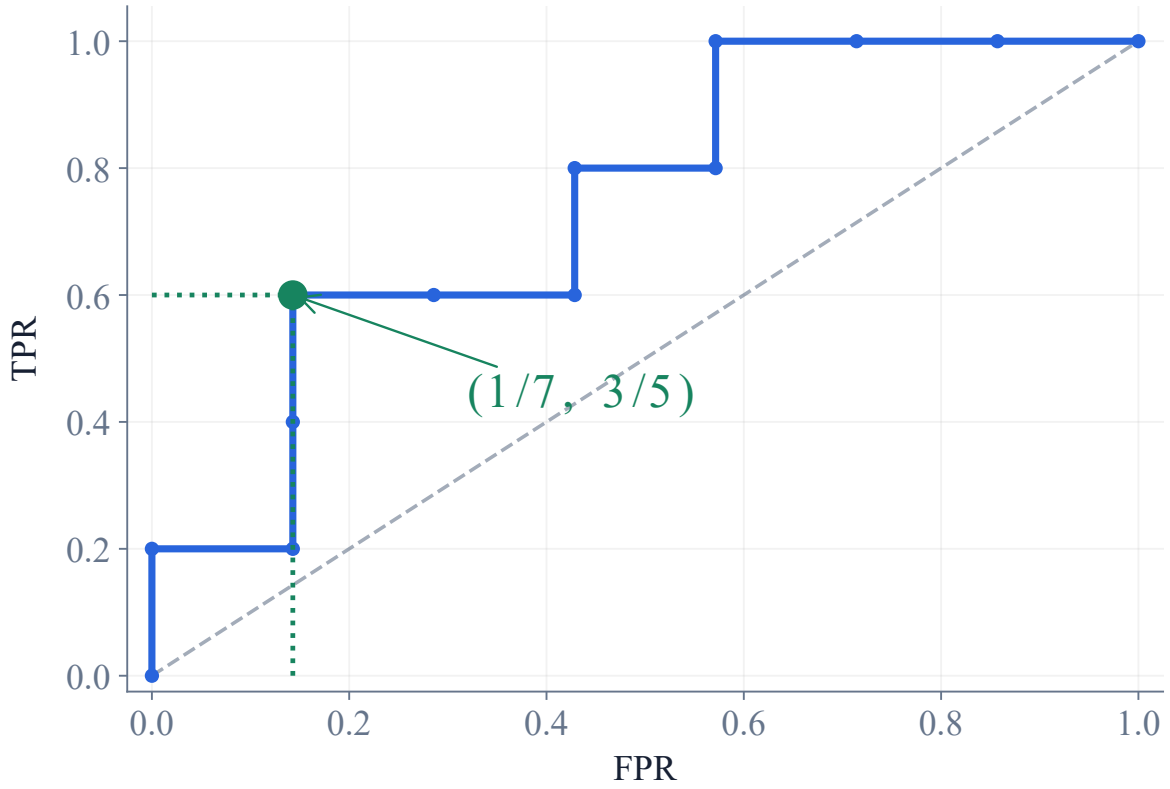


$$(FPR, TPR) = \left(\frac{7}{7}, \frac{5}{5}\right)$$

Выбрали всех: пришли в (1, 1).

Здесь оценки различны. При равных score объекты пересекают порог вместе.

Как прочитать ROC-точку и диагональ



$$(FPR, TPR) = \left(\frac{1}{7}, \frac{3}{5}\right)$$

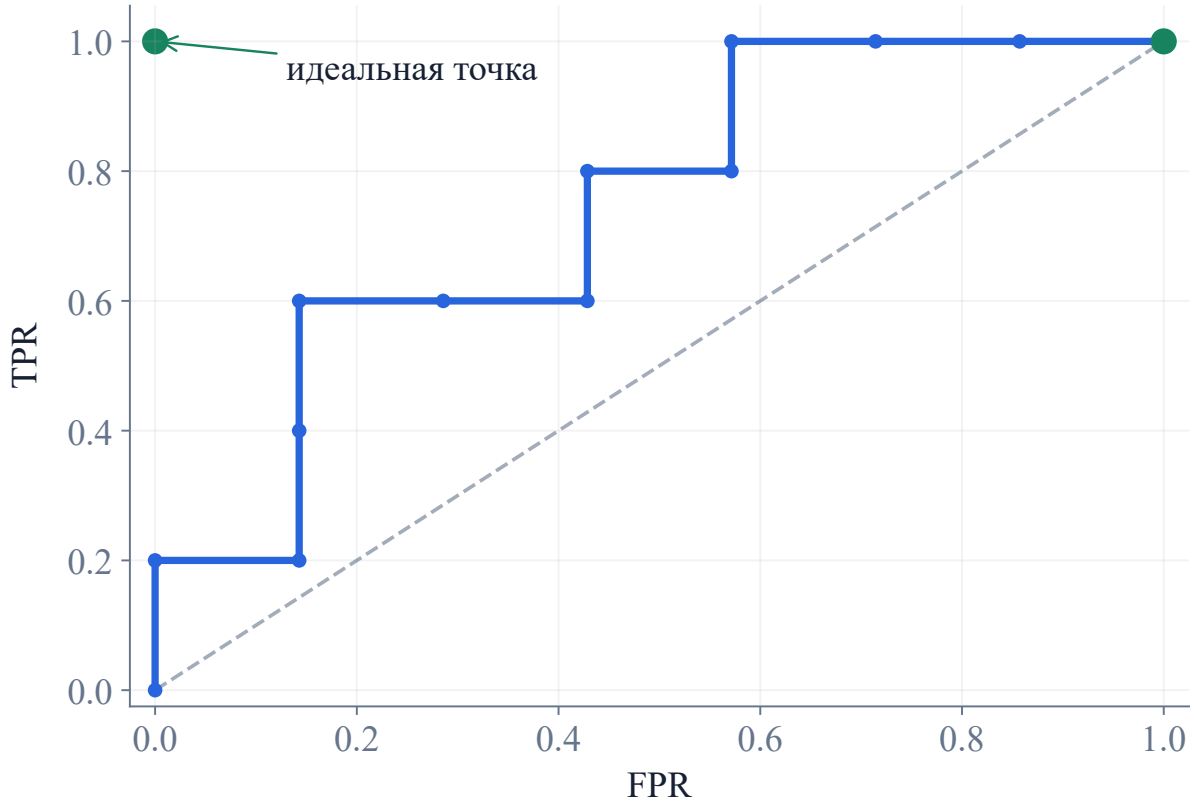
$$\approx (0.14, 0.60)$$

Нашли 60% положительных объектов.

Ошибочно выбрали около 14% отрицательных объектов.

Диагональ TPR ≈ FPR — ориентир случайного порядка; на конечной выборке совпадение не обязано быть точным.

Как читать ROC



(0, 0): никого не выбираем.
(1, 1): выбираем всех.

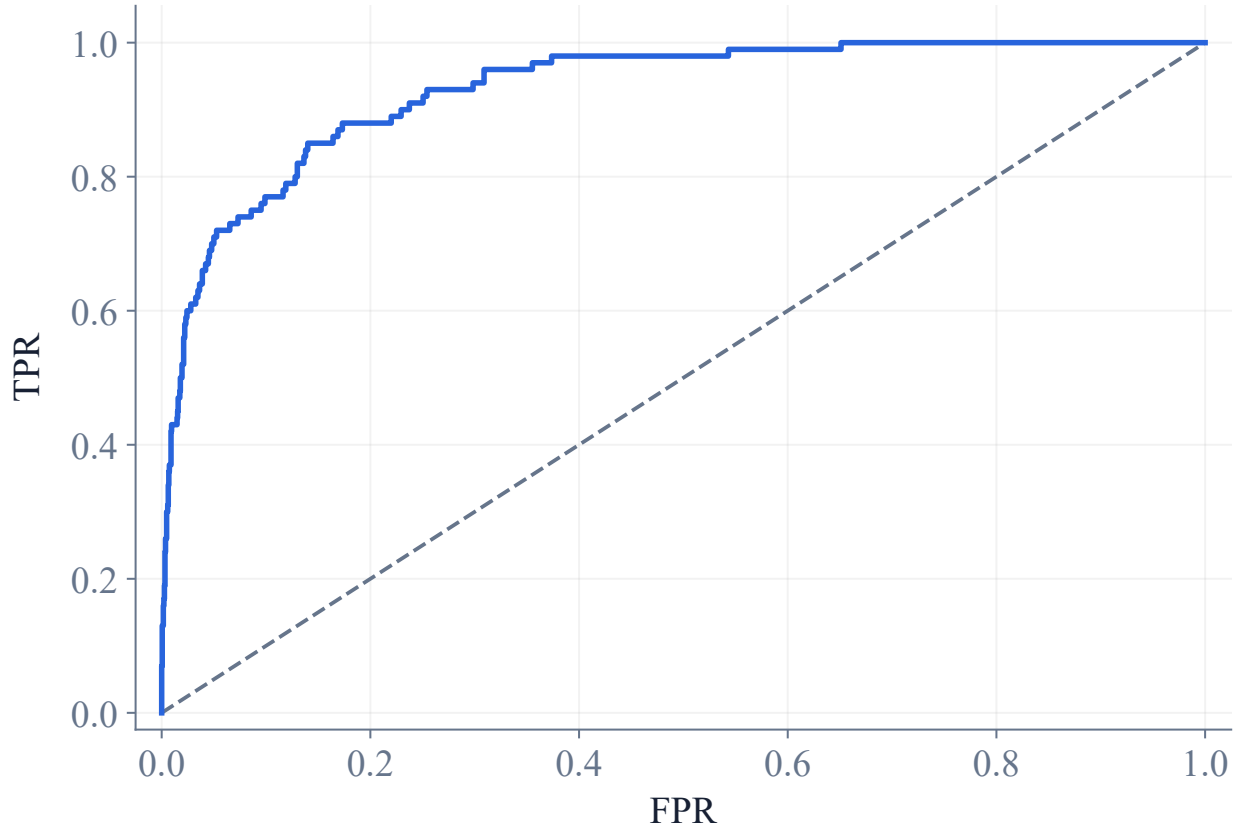
(0, 1): идеальная точка.
Лучше — ближе к верхнему левому углу.

Случайный порядок: доли выбранных объектов обоих классов растут примерно одинаково.

$$TPR \approx FPR$$

Конечная случайная кривая не обязана лежать точно на диагонали.

Та же механика — больше значений score

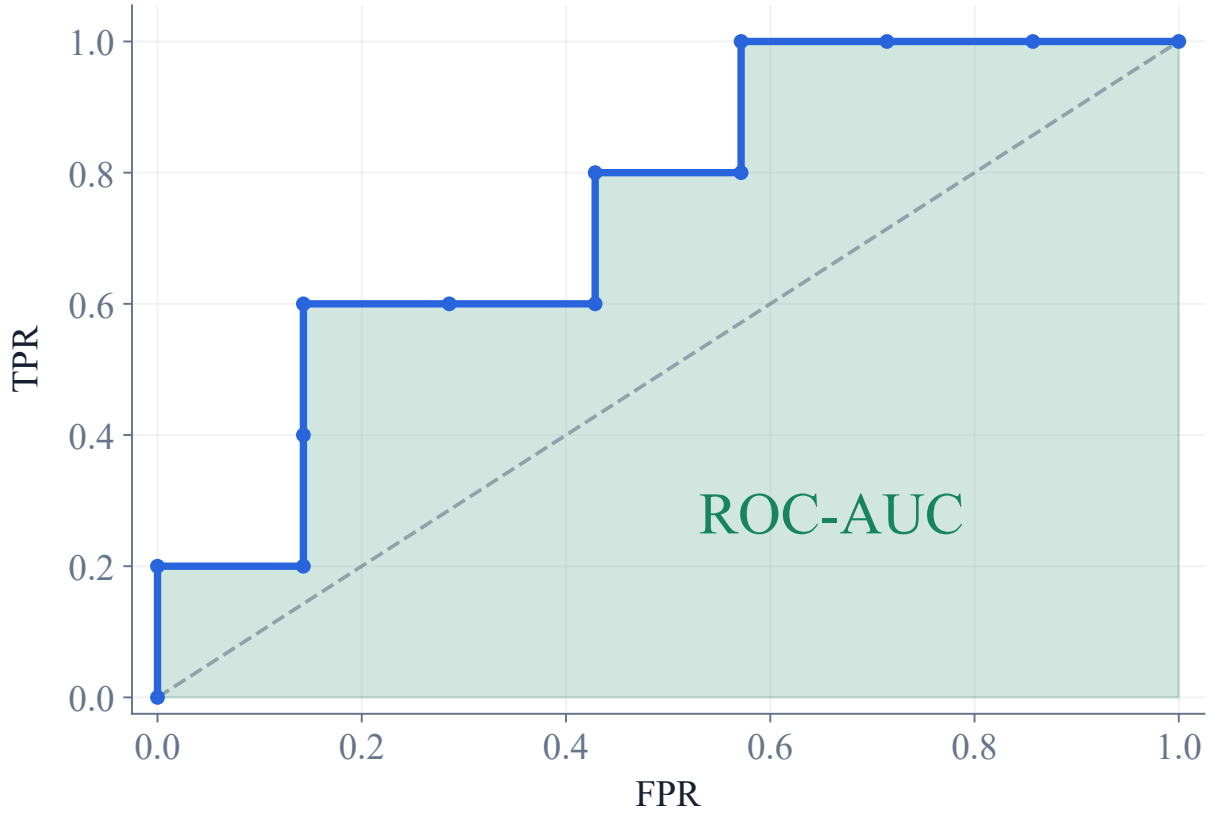


Отдельный пример:
2000 объектов,
100 положительных.

Много небольших шагов выглядят почти как гладкая кривая.

Каждая точка по-прежнему соответствует порогу.

ROC-AUC: площадь под ROC-кривой



AUC

Area Under the ROC Curve — площадь под ROC-кривой.

AUC лежит в [0, 1].
0.5 — ориентир случайного порядка;
ниже — обратное ранжирование.

Положительно-отрицательная пара: кто выше?

Выбираем случайно по одному объекту каждого класса.

ПАРА 1

$$score_+ = 0.75 > score_- = 0.68$$

Правильный порядок.

ПАРА 2

$$score_+ = 0.55 < score_- = 0.61$$

Неправильный порядок.

При равных оценках паре засчитываем половину. Здесь все оценки различны.

Из 35 пар правильно упорядочены 26

Класс 1 ↓ / Класс 0 →	0.88	0.68	0.61	0.48	0.30	0.18	0.08
0.95	✓	✓	✓	✓	✓	✓	✓
0.82	×	✓	✓	✓	✓	✓	✓
0.75	×	✓	✓	✓	✓	✓	✓
0.55	×	×	×	✓	✓	✓	✓
0.35	×	×	×	×	✓	✓	✓

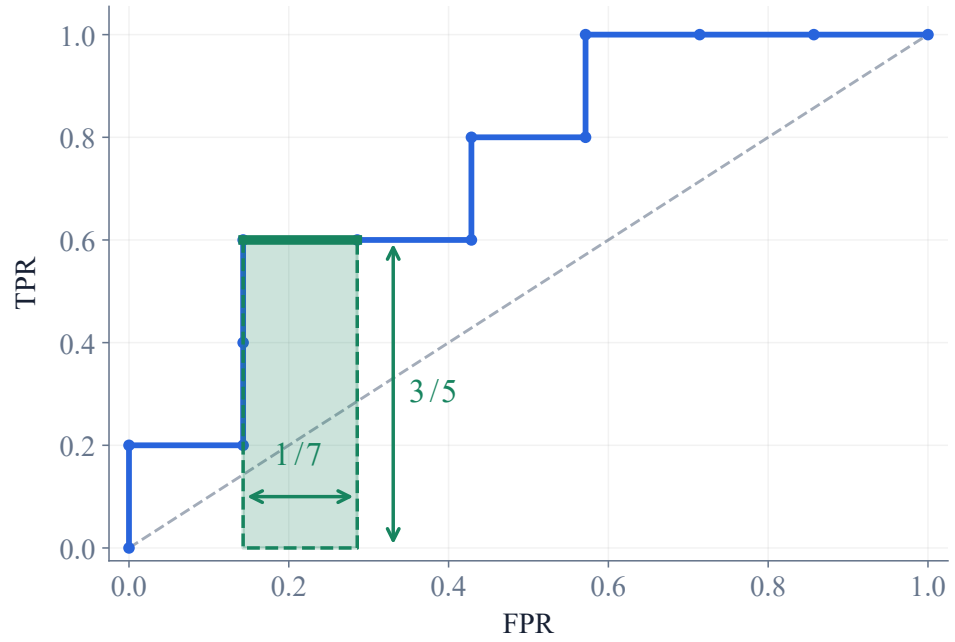
$$5 \cdot 7 = 35, \quad 7 + 6 + 6 + 4 + 3 = 26$$

$$AUC = \frac{26}{35} \approx 0.743$$

Это доля правильно упорядоченных пар, а не доля верных меток.

Один отрицательный объект — один прямоугольник под ROC

№1	№2	№3	№4	№5	№6	№7	№8	№9	№10	№11	№12
0.95	**0.88**	**0.82**	**0.75**	**0.68**	**0.61**	**0.55**	**0.48**	**0.35**	**0.30**	**0.18**	**0.08**
▲	■	▲	▲	■	■	▲	■	▲	■	■	■



Один новый FP: объект №5 (0.68, класс 0).

j — число положительных с большим score.

Выше №5 — №1, №3, №4: j = 3.

Ширина: шаг FPR

$$\frac{1}{N_-} = \frac{1}{7}$$

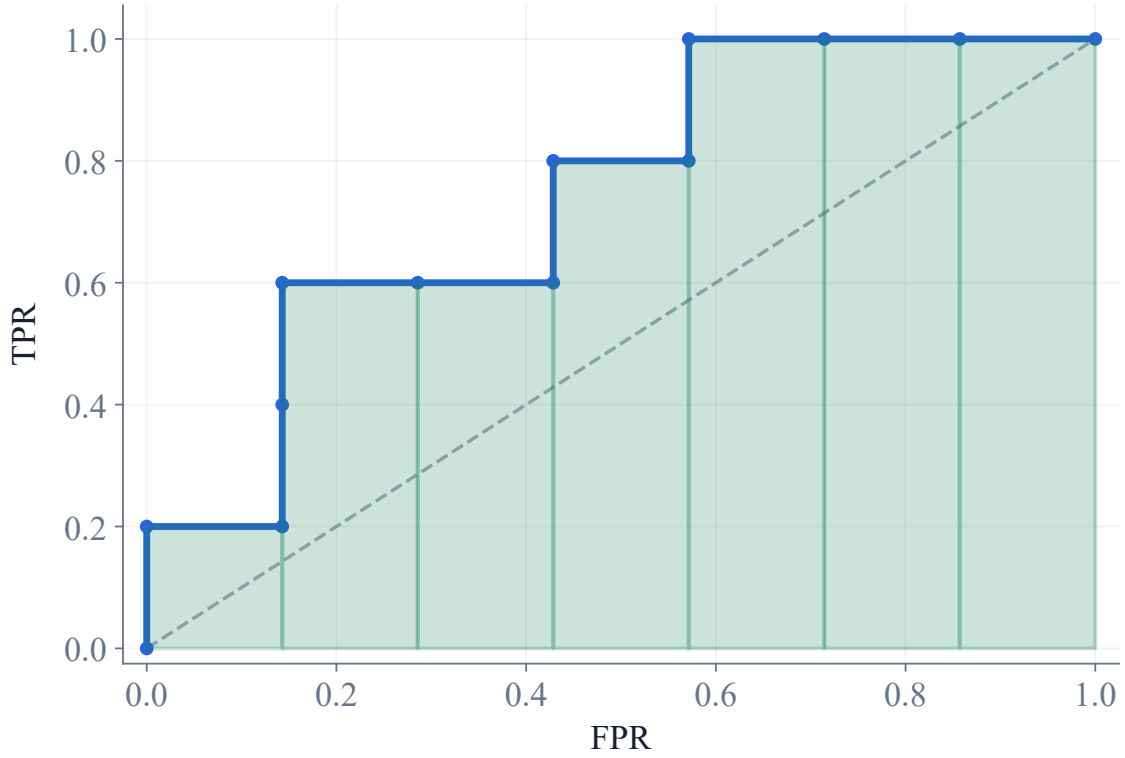
Высота: TPR

$$\frac{3}{N_+} = \frac{3}{5}$$

$$\text{площадь} = \frac{1}{7} \cdot \frac{3}{5} = \frac{3}{35}$$

Это вклад трёх правильно упорядоченных пар с объектом №5.

Складываем вклады всех отрицательных объектов



Число положительных выше каждого из семи отрицательных:

$$1,\ 3,\ 3,\ 4,\ 5,\ 5,\ 5$$

Суммарная площадь:

$$\frac{1+3+3+4+5+5+5}{35} = \frac{26}{35}$$

Каждая правильно упорядоченная пара учтена ровно один раз.
Суммарная площадь — те же 26 пар из 35.

Та же ROC-точка — разная чистота выбранной группы

Два отдельных потока по 10 000 объектов; одинаковые TPR и FPR.

$$N = 10000, \quad TPR = 0.8, \quad FPR = 0.05$$

ПОЛОЖИТЕЛЬНЫХ 20%

$$TP = 1600, \quad FP = 400$$

$$Precision = \frac{1600}{2000} = 80\%$$

ПОЛОЖИТЕЛЬНЫХ 1%

$$TP = 80, \quad FP = 495$$

$$Precision = \frac{80}{575} \approx 14\%$$

Precision зависит от распространённости положительного класса.

Что нам дала ROC — и чего она не показывает

ROC

$$t \longmapsto (FPR, TPR)$$

Все рабочие режимы
при изменении порога.

ROC-AUC

$$26/35 \approx 0.743$$

Качество ранжирования
в одном числе.

Чистоту выбранной очереди ROC напрямую не показывает.
Для этого перейдём к Precision и Recall.

Вернёмся к очереди ручной проверки

ROC показывает охват двух настоящих классов при разных порогах;
чистоту выбранной положительной группы показывает пара Precision–Recall.

Какую долю всего мошенничества поймаем?

$$Recall$$

Какая доля проверяемых платежей действительно мошенническая?

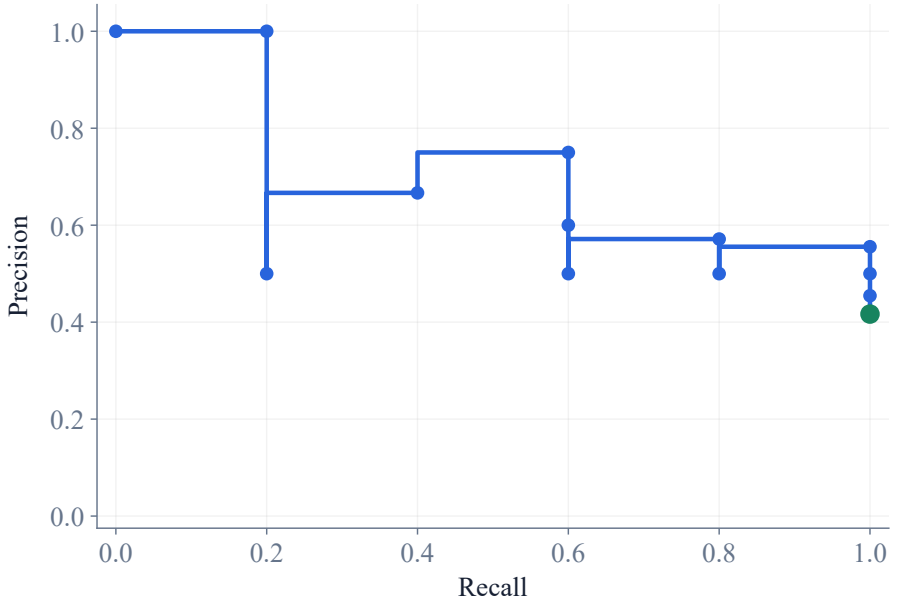
$$Precision$$

$$t \longmapsto (Recall(t), Precision(t))$$

Две стороны одного отбора: охват класса 1 и чистота очереди.

Строим PR по тем же порогам

	Оценка вероятности · по убыванию		
1	**0.95**	▲	1
2	**0.88**	■	1
3	**0.82**	▲	1
4	**0.75**	▲	1
5	**0.68**	■	1
6	**0.61**	■	1
7	**0.55**	▲	1
8	**0.48**	■	1
9	**0.35**	▲	1
10	**0.30**	■	1
11	**0.18**	■	1
12	**0.08**	■	1



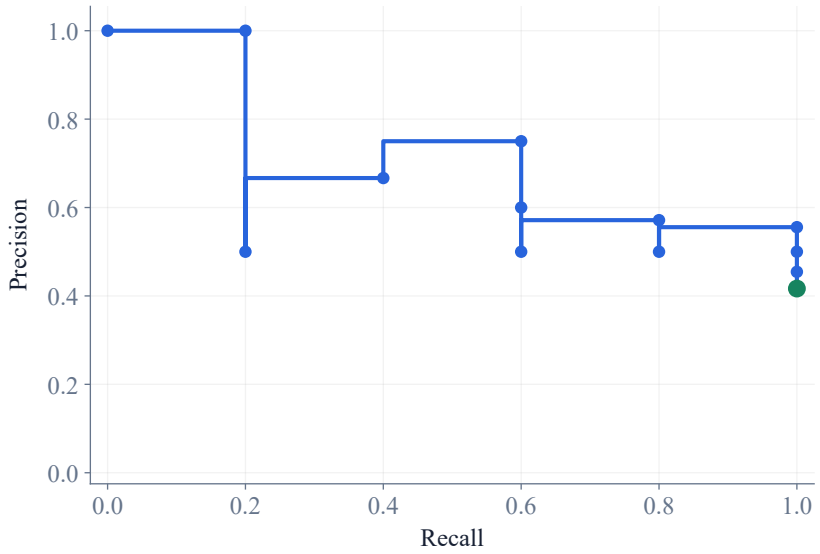
$$(Recall, Precision) = \left(\frac{5}{5}, \frac{5}{12}\right)$$

Вошёл отрицательный: Recall прежний, Precision уменьшился.

Точки — отдельные пороговые состояния. Ступени — выбранный способ изображения между ними.

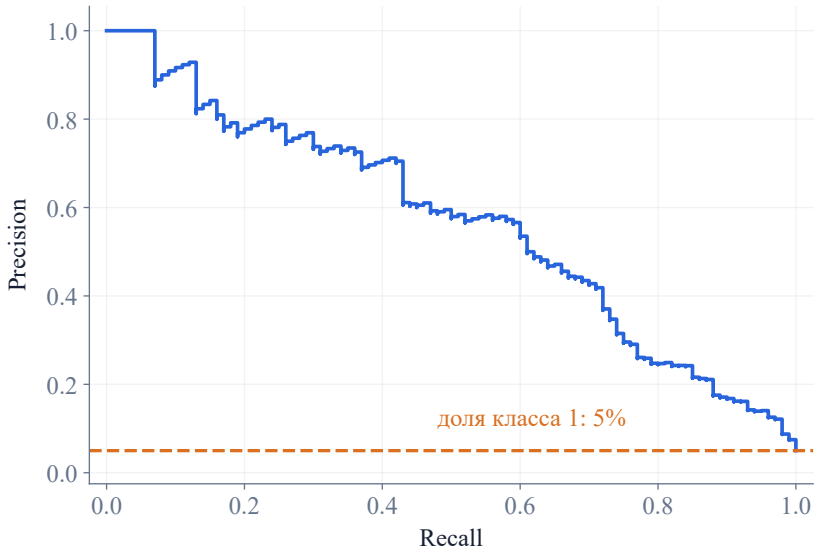
PR-кривая и её базовый уровень

НАШИ 12 ОБЪЕКТОВ



$$\pi = \frac{5}{12} \approx 0.417$$

ДРУГОЙ НАБОР: РЕДКИЙ КЛАСС



$$\pi = 0.05$$

При случайном ранжировании ожидаемая Precision ≈ π.
Конкретная PR-кривая может колебаться вокруг этого уровня.

Average Precision: среднее на позициях положительных

№1	№2	№3	№4	№5	№6	№7	№8	№9	№10	№11	№12
0.95	**0.88**	**0.82**	**0.75**	**0.68**	**0.61**	**0.55**	**0.48**	**0.35**	**0.30**	**0.18**	**0.08**
▲	■	▲	▲	■	■	▲	■	▲	■	■	■

Положительные объекты стоят на позициях 1, 3, 4, 7 и 9.

$$AP = \frac{1}{5}\left(1 + \frac{2}{3} + \frac{3}{4} + \frac{4}{7} + \frac{5}{9}\right) \approx 0.709$$

При встрече очередного положительного берём Precision
от начала списка до этой позиции включительно.

При разных score это обычное среднее пяти значений. AP не равна автоматически трапецеидальной площади PR.

Почему в общей формуле появляется прирост Recall

Каждый найденный положительный увеличивает Recall на:

$$\Delta Recall = \frac{1}{N_+} = \frac{1}{5}$$

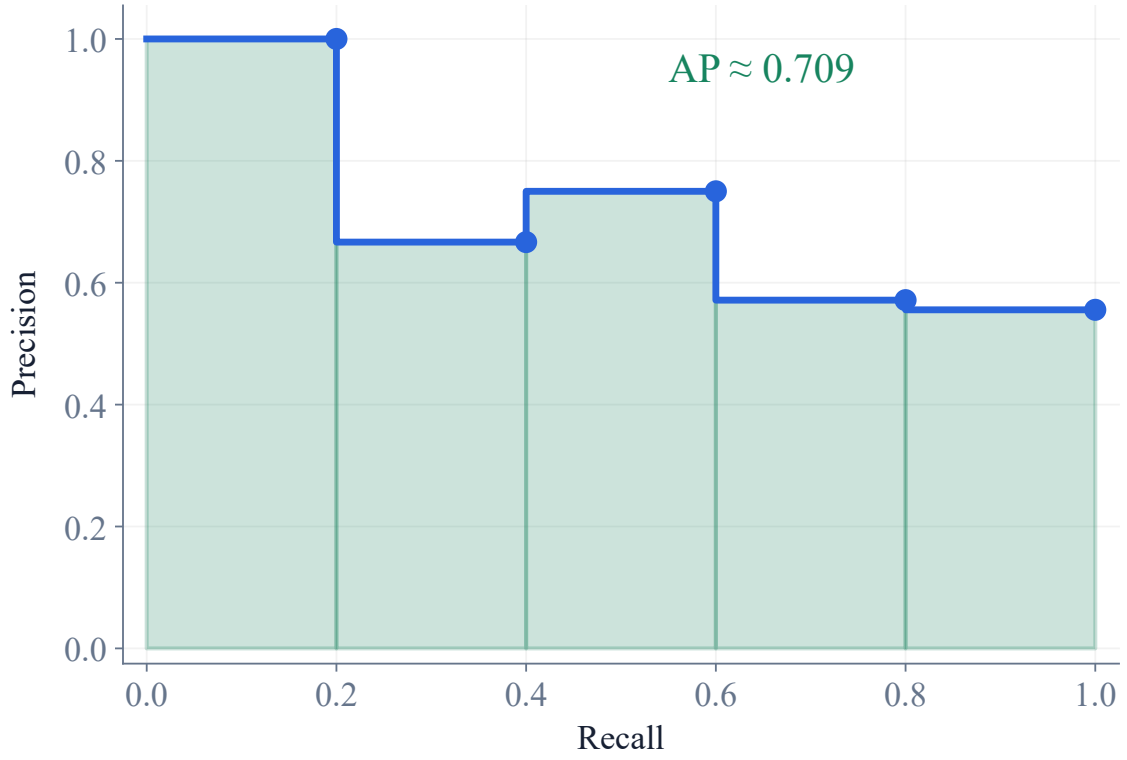
$$AP = \frac{1}{5} \cdot 1 + \frac{1}{5} \cdot \frac{2}{3} + \frac{1}{5} \cdot \frac{3}{4} + \frac{1}{5} \cdot \frac{4}{7} + \frac{1}{5} \cdot \frac{5}{9}$$

$$\boxed{AP = \sum_k \Delta Recall_k \cdot Precision_k}$$

Если Recall не изменился, вес шага равен нулю.

При равных score используем группы и фактический прирост Recall.

AP как площадь под ступенчатой PR-кривой



$$\text{ширина} = \Delta Recall_k$$

$$\text{высота} = Precision_k$$

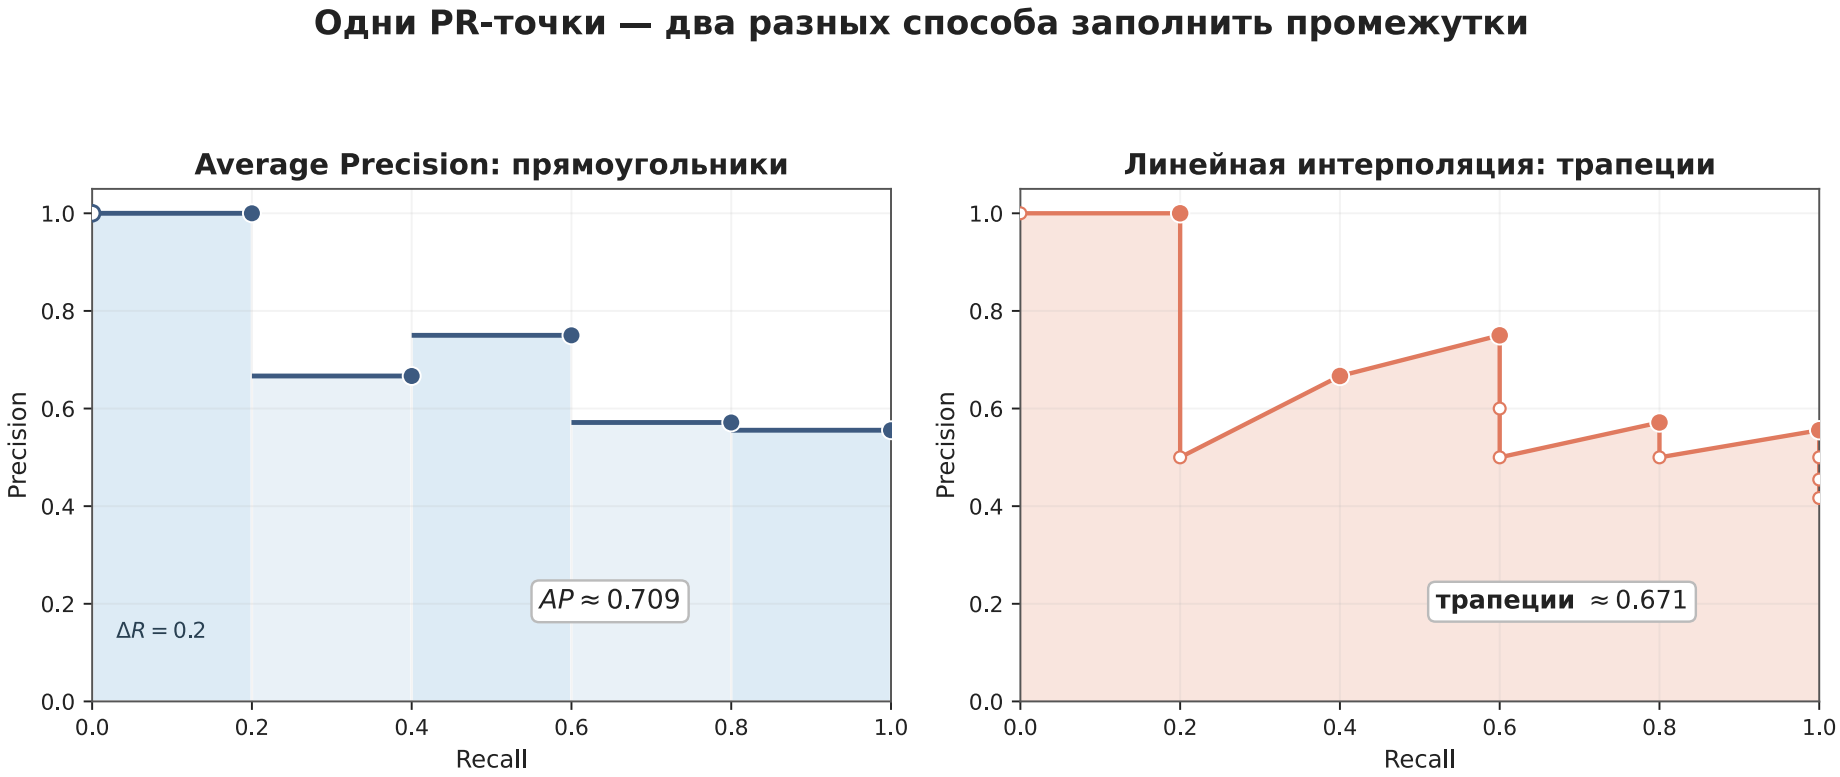
Площадь прямоугольника:

$$\Delta Recall_k \cdot Precision_k$$

Пять прямоугольников дают AP ≈ 0.709.

Сумма площадей пяти прямоугольников — та же AP.

AP и площадь с линейной интерполяцией — не одно и то же



AP — площадь ступенчатой конструкции;
трапеции соответствуют другой интерполяции между теми же точками.

Те же точки и разные интерполяции дают разные площади.

Выбираем оценку ранжирования под задачу

Инструмент	На какой вопрос отвечает?
ROC / ROC-AUC	Как разделяются положительные и отрицательные?
PR / AP	Насколько чиста выбранная группа при росте Recall?
Верхние k объектов	Сколько событий найдём в доступной очереди?

Хорошая глобальная метрика не гарантирует лучшую очередь
из первых 50 или 100 кандидатов.

Один порядок — две вероятностные шкалы

Порядок групп одинаковый, вероятностные шкалы разные.

Наблюдаемая частота события	Модель A	Модель B
0.10	0.10	0.0122
0.30	0.30	0.1552
0.50	0.50	0.5000
0.70	0.70	0.8448
0.90	0.90	0.9878

Модель A согласуется с наблюдаемыми частотами; модель B даёт более крайние значения. ROC-AUC и AP одинаковы: ранжирование не изменилось.

От группы прогнозов к точке на диаграмме

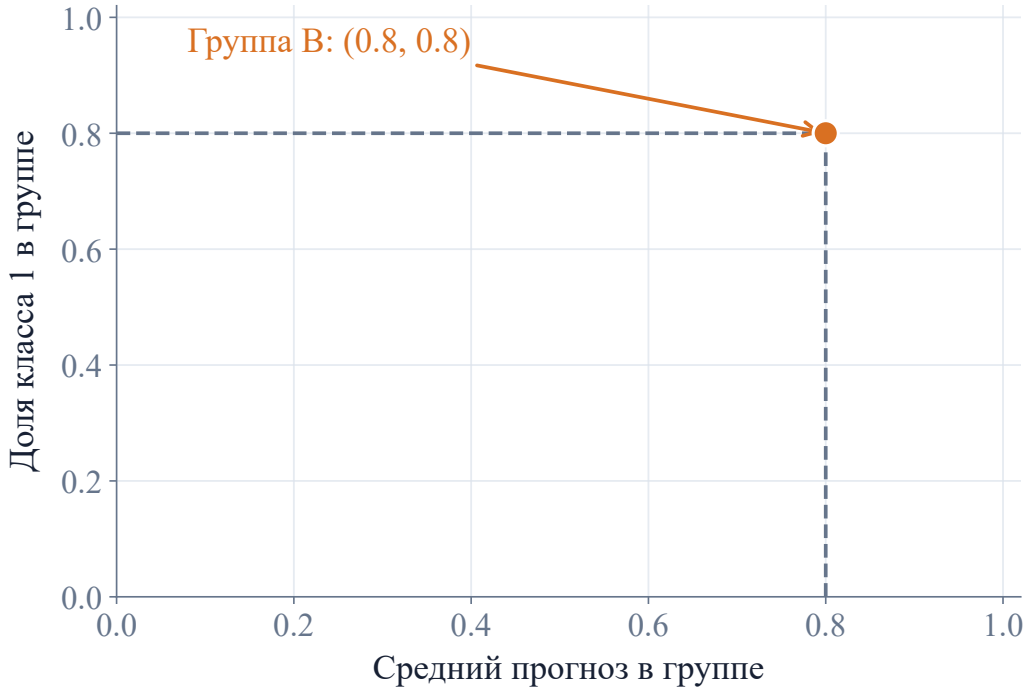
Отдельная иллюстративная группа:

10 объектов с прогнозами около 0.8.

1	1	1	1	1
1	1	1	0	0

$$\bar{p}_B \approx 0.8$$

$$\bar{y}_B = \frac{8}{10} = 0.8$$



Средний прогноз и доля событий задают координаты одной точки.

8 из 10 иллюстрирует механику. Надёжность вывода зависит от числа объектов и группировки.

От групп данных к reliability diagram

Для группы B_k:

$$\bar{p}_k = \frac{1}{|B_k|} \sum_{i \in B_k} \hat{p}_i$$

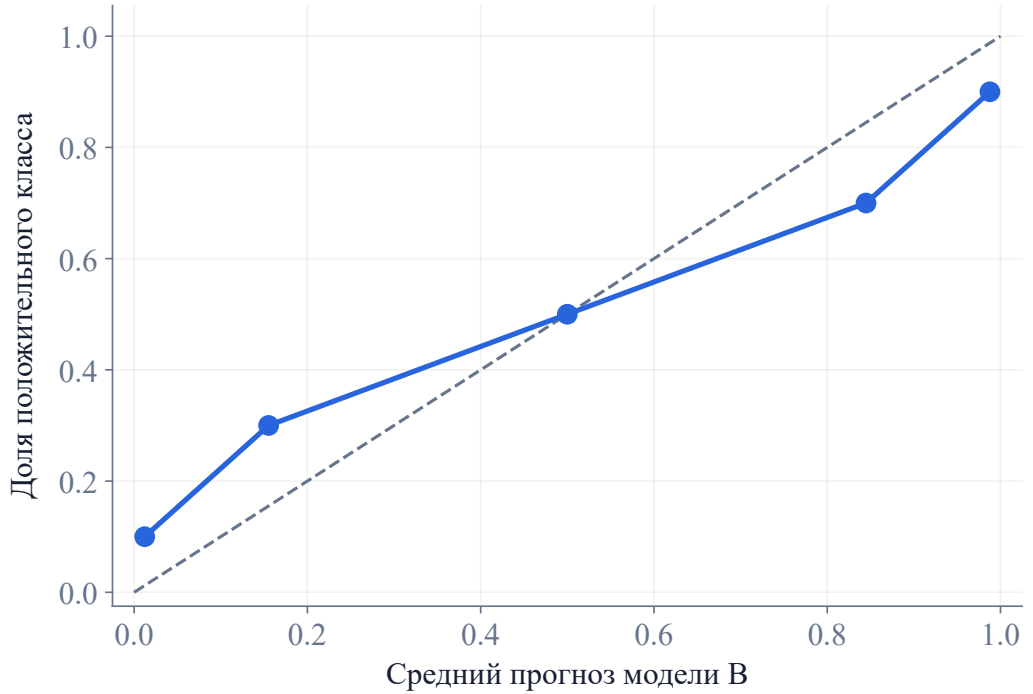
Средний прогноз модели B в группе.

$$\bar{y}_k = \frac{1}{|B_k|} \sum_{i \in B_k} y_i$$

Наблюдаемая доля положительных исходов.

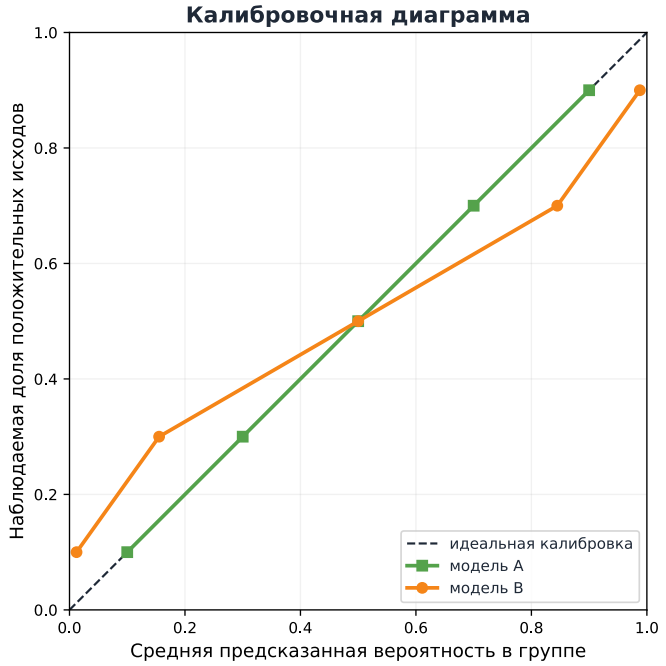
$$(\bar{p}_k, \bar{y}_k)$$

$$(\bar{p}_1, \bar{y}_1) = (0.0122, 0.10)$$



3. Наносим все пять пар:
получаем калибровочную диаграмму.

Как читать калибровочную диаграмму



Диагональ: средний прогноз совпадает с частотой.

Ниже диагонали: вероятность завышена.

Выше диагонали: вероятность занижена.

Маленькие группы дают шумную оценку; вид диаграммы зависит от группировки.

Хорошая калибровка: различает ли модель объекты?

Отдельный пример: положительный класс составляет 10% выборки.

МОДЕЛЬ 1 · ПОСТОЯННЫЙ ПРОГНОЗ

$$\hat{p}(x) = 0.10$$

Всем объектам выдаёт 0.10.
Около 10% положительных — прогноз откалиброван.

Вероятности одинаковы:
модель не различает объекты.

МОДЕЛЬ 2 · ДВЕ ГРУППЫ

Половине объектов выдаёт 0.02;
в этой группе около 2% положительных.

Другой половине — 0.18;
там около 18% положительных.

$$\frac{1}{2} \cdot 0.02 + \frac{1}{2} \cdot 0.18 = 0.10$$

Обе модели откалиброваны, но вторая различает группы.
Сравним общее качество вероятностных прогнозов через log loss и Brier.

Log loss: один объект и вся выборка

LOSS ОДНОГО НАБЛЮДЕНИЯ

$$L(y_i, \hat{p}_i) = -y_i \log \hat{p}_i - (1 - y_i) \log(1 - \hat{p}_i)$$

СРЕДНЯЯ LOG LOSS НА ОЦЕНОЧНОЙ ВЫБОРКЕ ИЗ M ОБЪЕКТОВ

$$\text{LogLoss} = \frac{1}{m} \sum_{i=1}^{m} L(y_i, \hat{p}_i)$$

На обучении это была эмпирическая целевая функция R_n.

На отложенных прогнозах то же выражение — метрика качества.

Brier score: MSE вероятностных прогнозов

$y = 1,\ p = 0.9 \Rightarrow (1 - 0.9)^2 = 0.01$ $y = 1,\ p = 0.2 \Rightarrow (1 - 0.2)^2 = 0.64$

$$Brier = \frac{1}{m} \sum_{i=1}^{m} (y_i - \hat{p}_i)^2$$

Меньше — лучше. Сравниваем модели на одной выборке и с baseline.

Это знакомая квадратичная ошибка:
сравниваем вероятность с бинарным исходом.

Диаграмма и численная оценка дополняют друг друга

Инструмент	Что показывает
Reliability diagram	Где вероятности систематически завышены или занижены
Log loss / Brier	Общее качество вероятностных прогнозов одним числом

Одно число удобно для сравнения моделей;
диаграмма показывает структуру ошибок калибровки.

Меньшие Log loss или Brier сами по себе не доказывают лучшую калибровку.

Один прогноз — три вопроса о качестве

Бинарная задача: Y ∈ {0, 1}. Для нового объекта известны признаки x.

$$x \longrightarrow \hat{z}(x) \longrightarrow \sigma\big(\hat{z}(x)\big) = \hat{p}(x)$$

РЕШЕНИЕ ПРИ ПОРОГЕ

Матрица ошибок
Precision / Recall / F1
Ресурс и цена ошибок

РАНЖИРОВАНИЕ

ROC / ROC-AUC
PR / AP
Качество верхних k

ШКАЛА ВЕРОЯТНОСТЕЙ

Калибровочная диаграмма
Log loss / Brier
Соответствие частотам

На следующей неделе — честное сравнение моделей и задачи с несколькими классами.